

無機材料データベースのためのグラフ制約付き Text-to-SQL パイプラインの構築

Satoshi Minamoto^{a,*}

^aNational Institute for Materials Science (NIMS), 1-2-1 Sengen, Tsukuba, Ibaraki 305-0047, Japan

Abstract

第一原理計算データベースに蓄積された材料データの横断的検索は、SQL の専門知識を要求するため、材料研究者にとって障壁となっている。本研究では、自然言語の問い合わせから正規化リレーショナルデータベース上の SQL クエリを自動生成する、グラフ制約付き Text-to-SQL パイプラインを提案する。

提案パイプラインは以下の構成要素からなる：(1) TF-IDF と Cross-Encoder (ms-marco-MiniLM-L-6-v2) による few-shot 例検索、(2) GPT-5.5 によるスキーマリンクと SQL 生成 (n -best = 3 候補)、(3) 外部キー関係をグラフ化し Steiner 木近似で最小 JOIN 経路を決定する構造制約、(4) 材料ドメイン辞書による用語-SQL 条件マッピング、(5) AST 解析ベースの SQLGuard によるカラム・テーブル幻觉の検出、(6) GPT-5.5 による SQL 候補ランキング。

30 テーブル・1,470 件の材料エントリからなるデータベースに対し、著者設計の 100 件クエリ (Easy 20 / Medium 30 / Hard 30 / Very Hard 20) で 7 条件の ablation study (計 700 回評価) を実施した。全構成要素を有効にした full 条件では行一致精度 80.6% を記録した。7 条件の ablation study により各構成要素の寄与を定量化した結果、few-shot 例の除去が -12.5 ポイント (pp)、材料ドメイン辞書の除去が -6.7 pp (Very Hard 帯では -22.7 pp)、ハイブリッドリランカーの除去が -4.1 pp の精度低下をそれぞれ引き起こした。SQLGuard、 n -best 生成、Steiner 木 JOIN は各 -0.2 pp であった。

なお、全評価は LLM の非決定性を伴う単一ランであり、条件間の差異には約 1-2 pp の変動が含まれる。

Keywords: Text-to-SQL, 材料インフォマティクス, スキーマグラフ, Steiner 木, ablation study, ドメイン特化辞書, リランキング

1. はじめに

第一原理計算データベース (OQMD, Materials Project, AFLOW 等) の普及により、材料特性の計算データが大量に蓄積されている。これらのデータは正規化リレーショナルデータベース (RDB) に格納されることが多いが、SQL クエリの記述には専門知識が必要であり、材料研究者が直感的にデータにアクセスする手段は限られている。

Text-to-SQL 技術は、自然言語を SQL に変換する技術として Spider [1] や BIRD [2] 等のベンチマークを中心に発展してきた。近年、大規模言語モデル (LLM) の進歩により、DIN-SQL [3] や DAIL-SQL [4] 等の手法がベンチマーク上で高い精度を達成している。

しかし、材料科学ドメインに Text-to-SQL を適用するには以下の課題が存在する：

- ドメイン用語の多義性： $L1_2$ 、 γ' 相、B2 等の結晶構造名や物性用語は汎用 LLM の学習データに十分含まれておらず、正しい SQL 条件への変換が困難である。
- 多テーブル JOIN の複雑さ：30 テーブルの正規化スキーマでは、LLM が JOIN 経路を誤る (JOIN 幻觉) リスクが高い。
- 評価データの不在：材料データベースに対する Text-to-SQL の標準的な評価セットは存在しない。

本研究では、これらの課題に対処するため、スキーマグラフ制約付き Text-to-SQL パイプラインを提案する。提案法の独自性は以下の 3 点にある：(1) 外部キーグラフ上の Steiner 木近似による JOIN 経路の構造的決定、(2) 材料ドメイン辞書による用語-SQL 条件の直接マッピング、(3) Cross-Encoder と LLM を組み合わせたハイブリッドリランカー。

7 条件 $\times$ 100 件の ablation study により、各構成要素の寄与を定量化した結果を報告する。

2. 関連研究

2.1. Text-to-SQL

Text-to-SQL は自然言語から SQL への変換タスクである。Spider [1] は複数データベースにまたがるクロスドメインベンチマークとして広く利用されている。BIRD [2] はより現実的なデータベースと外部知識を必要とするクエリを含む。

LLM ベースの手法として、DIN-SQL [3] はスキーマリンク・分類・生成を分離するパイプライン型アプローチを提案した。DAIL-SQL [4] は few-shot 例の選択戦略に着目し、候補選択にマスク類似度を導入した。

本研究は、これらの手法が想定しないドメイン特化辞書とグラフ制約の組合せを導入する点で異なる。

2.2. 材料インフォマティクスにおける NL インターフェース

材料データベースに対する自然言語インターフェースの研究は限定的である。MatSciBERT [5] や MatBERT [6] は

*Corresponding author

Email address: minamoto.satoshi@nims.go.jp (Satoshi Minamoto)

入力: 自然言語クエリ (日本語)
↓ (1) Few-shot 例検索 (TF-IDF + Cross-Encoder)
↓ (2) スキーマランキング (GPT-5.5, sort-only)
↓ (3) SQL 生成 (GPT-5.5, $n\text{-best} = 3$)
↓ (4) Steiner 木 JOIN 制約 (NetworkX)
↓ (5) 材料ドメイン辞書
↓ (6) SQLGuard 検証 (sqlglot AST)
↓ (7) SQL 候補リランキング (GPT-5.5)
↓ (8) リペアループ (最大 3 回)
出力: SQL クエリ + 実行結果

Figure 1: 提案パイプラインの構成。括弧内は各段階で使用するモデルまたはツールを示す。

材料科学テキストの言語モデルであるが、Text-to-SQL タスクには直接適用されていない。

3. 提案手法

3.1. パイプライン概要

提案パイプラインは図 1 に示す 8 つの構成要素からなる。入力は日本語の自然言語クエリであり、出力は SQL クエリとその実行結果である。

3.2. Few-shot 例検索

入力クエリに類似する few-shot 例を 2 段階で選択する。第 1 段階で TF-IDF により候補を $2k$ 件に絞り込み、第 2 段階で Cross-Encoder (ms-marco-MiniLM-L-6-v2) により上位 k 件を選択する。Cross-Encoder はローカルで動作し、処理時間は 50 ms 未満である。

ablation study において、few-shot 例の除去は全体精度を 80.6% から 68.2% へ -12.5 pp 低下させた (表 1; EVID-20260619-1335-ablation-nofewshot)。この低下は全難易度帯で観察され、Medium 帯では -16.5 pp と最も顕著であった。

3.3. スキーマランキング

GPT-5.5 により、入力クエリに関連するテーブルをスコアリングし、関連度順にソートする。テーブルの除外は行わず (sort-only 方式)、SQL 生成時のコンテキスト優先順位のみを変更する。

3.4. SQL 生成と $n\text{-best}$ 候補

GPT-5.5 により $n\text{-best} = 3$ の SQL 候補を生成する。ablation study において、 $n\text{-best} = 1$ への変更は全体精度を 0.2 pp 低下させたのみであったが、平均レイテンシは 33.1 s から 13.0 s へ低減した (表 1; EVID-20260619-1335-ablation-nonbest)。

3.5. Steiner 木 JOIN 制約

30 テーブルの外部キー関係を NetworkX の無向グラフとして表現する。クエリに必要なテーブル集合に対し、Steiner 木近似アルゴリズムにより最小 JOIN 部分木を決定する。LLM が生成した JOIN 経路がこの部分木に含まれない場合、Steiner 木の経路で置換する。

ablation study では、Steiner 木制約の除去による精度低下は -0.2 pp にとどまった (表 1; EVID-20260619-1335-ablation-nograph)。検証できた範囲では、現在の 30 テーブル規模では大半のクエリが 5 つのコアテーブル (compound, structure, element, composition, calculated_property) で完結するため、効果が限定的であった。テーブル数が拡大した場合に寄与が顕在化すると予想される。

3.6. 材料ドメイン辞書

材料科学の専門用語を SQL 条件に直接マッピングする辞書を導入した。例として、「 γ' 相」 $\rightarrow$ `structure.prototype = 'L12'`、「バルクモジュラス」 $\rightarrow$ `calculated_property` テーブルの `property_name = 'bulk_modulus'` への変換がある。

辞書は YAML 定義ファイル (74 語)、パイプライン用語 (66 語)、材料工学語彙 (390 語新規) の 3 ソースから構成され、重複除去後 492 語となる。MeCab 形態素解析器用のカスタム辞書としてもコンパイルし、日本語テキストの前処理に利用する。カスタム辞書により、402 語の材料用語の単一トークン化率はデフォルトの 30.6% から 100.0% へ向上した (EVID-20260619-1335-mecab-dict)。

ablation study では、辞書の除去は全体で -6.7 pp の低下を引き起こし、Very Hard 帯では 38.5% から 15.8% へ -22.7 pp の低下となった (表 1; EVID-20260619-1335-ablation-nodict)。Easy・Medium 帯では低下が観察されなかったことから、辞書の効果は複合的なドメイン用語を含むクエリに集中している。

3.7. SQLGuard

sqlglot による AST 解析に基づき、生成 SQL の安全性と整合性を検証する。検証項目はカラム存在確認、テーブル存在確認、JOIN 条件の整合性等 14 項目からなる。

ablation study では、SQLGuard の除去による精度低下は -0.2 pp であった (表 1; EVID-20260619-1335-ablation-noguard)。この結果について、リランカーが先に不正な SQL 候補を低スコアにするため、SQLGuard が拒否すべき SQL が選択されにくい状況が生じていると考えられる。

3.8. ハイブリッドリランカー

SQL 候補のリランキングには GPT-5.5 を使用する。few-shot 例の選択には Cross-Encoder (ローカル、50 ms 未満)、SQL 候補とスキーマのスコアリングには GPT-5.5 (API) を使用するハイブリッド構成を採用した。

ablation study では、リランカーの除去は -4.1 pp の低下を引き起こし、Medium 帯で -6.7 pp、Hard 帯で -6.2 pp の低下が観察された (表 1; EVID-20260619-1335-ablation-noreranker)。

別途実施した 90 件の A/B 評価では、リランカーありが 77.2%、なしが 69.4% で $+7.7$ pp の差が観察された (EVID-20260619-1335-reranker-eval)。ただし、この A/B 評価は ablation study とは異なるランであり、直接的な比較には注意を要する。

Table 1: Ablation study 結果 (100 件 $\times$ 7 条件 = 700 評価)。 Δ は full 条件からの精度変化 (pp)。全数値は `paper_data.json` から取得 (EVID-20260619-1335-ablation-json)。LLM の非決定性により、条件間の差異には約 1–2 pp の変動が含まれる。

条件	全体	Easy	Med	Hard	VH	Δ
full	80.6	100.0	96.1	80.4	38.5	—
no_fewshot	68.2	95.0	79.6	66.8	26.2	−12.5
no_dict	73.9	100.0	96.1	73.1	15.8	−6.7
no_reranker	76.6	100.0	89.5	74.1	37.4	−4.1
no_guard	80.4	100.0	96.1	80.4	37.4	−0.2
no_nbest	80.4	100.0	96.1	80.4	37.2	−0.2
no_graph	80.5	100.0	96.1	80.4	37.7	−0.2

3.9. 日本語 Cross-Encoder の比較

Few-shot 例選択の Cross-Encoder について、英語モデル (ms-marco-MiniLM-L-6-v2) と日本語モデル (hotchpotch/japanese-reranker-cross-encoder-xsmall-v1) を Very Hard 20 件で比較した。結果は ms-marco 32.4% に対し japanese-xsmall 28.1% であり、−4.3 pp の差で ms-marco が優位であった (EVID-20260619-1335-jp-reranker)。Few-shot 例に SQL コード (英語) が含まれるため、英語に対するスコアリング能力が ms-marco の優位性に寄与していると考えられる。

4. 評価

4.1. データベース

L1₂ 型金属間化合物を中心とする無機材料データベースを使用した。スキーマは 30 テーブルからなり、material_entry テーブルに 1,470 件、composition テーブルに 2,940 件、calculated_property テーブルに 4,410 件のレコードを含む (EVID-20260619-1335-db-schema)。

4.2. 評価クエリ

著者が設計した 100 件のクエリを使用した。難易度分布は Easy 20 件、Medium 30 件、Hard 30 件、Very Hard 20 件である (EVID-20260619-1335-dataset-author)。各クエリには gold SQL、期待される実行結果、必要テーブル、JOIN 経路が付与されている。

4.3. 評価指標

行一致精度 (row-level recall) を主指標とする。生成 SQL の実行結果と gold SQL の実行結果を比較し、行レベルでの一致率を算出する。

4.4. Ablation study

7 つの条件で ablation study を実施した (表 1)。各条件では 1 つの構成要素を無効化し、100 件全てのクエリで精度を測定した。合計 700 回の評価を実施した。

Table 2: 上位 3 コンポーネントの難易度別 Δ (pp)。数値は `paper_data.json` から取得。

条件	Easy	Med	Hard	VH
no_fewshot	−5.0	−16.5	−13.5	−12.3
no_dict	0.0	0.0	−7.3	−22.7
no_reranker	0.0	−6.7	−6.2	−1.1

5. 考察

5.1. Few-shot 例の寄与

Few-shot 例の除去は全構成要素の中で最も大きな精度低下 (−12.5 pp) を引き起こした (表 1)。この低下は全難易度帯で観察され、Easy 帯でも −5.0 pp の低下が確認された (表 2)。

LLM は few-shot 例から SQL 生成のパターン (テーブル名、JOIN 順序、カラム名の使い方) を in-context learning により獲得しており、few-shot 例なしではスキーマ情報のみから SQL を推論する必要が生じる。Medium 帯の −16.5 pp が最も顕著であったことから、中程度の複雑さのクエリにおける few-shot 例への依存度が高い。

5.2. 材料ドメイン辞書の寄与

辞書の除去は全体で −6.7 pp の低下を引き起こしたが、その効果は難易度帯により異なった (表 2)。Easy・Medium 帯では低下が観察されず、Hard 帯で −7.3 pp、Very Hard 帯で −22.7 pp の低下が生じた。

Easy・Medium クエリは汎用的な表現で構成されるため、LLM 単体で SQL 条件を推論可能である。一方、Very Hard クエリは複数のドメイン固有用語を同時に含み、辞書なしでは LLM が正しい SQL 条件 (例: 「 γ 」相 $\rightarrow$ `structure.prototype = 'L12'`) を生成できない場合がある。

5.3. リランカーの寄与

リランカーの除去は −4.1 pp の低下を引き起こした。効果は Medium (−6.7 pp) および Hard (−6.2 pp) 帯で観察され、Very Hard 帯では −1.1 pp にとどまった (表 2)。

Very Hard 帯では 3 候補全てが不正確な場合が多く、リランカーの「最良候補選択」効果が限定される。一方、Medium・Hard 帯では少なくとも 1 候補が正確であることが多く、リランカーがその候補を正しく選択する効果が発揮される。

5.4. SQLGuard・n-best・Steiner 木の寄与

これら 3 構成要素はいずれも −0.2 pp の低下にとどまった。SQLGuard については、リランカーが先に同等の選別機能を果たしているため、追加的な効果が観察されにくい状況にある。ただし、SQLGuard はセキュリティ上の安全網として機能しており、精度寄与とは独立した価値を持つ。

n-best = 1 への変更は精度をほぼ維持しつつレイテンシを 33.1 s から 13.0 s へ低減した。コスト効率を重視する場合の有力な選択肢である。

Steiner 木については、現在の 30 テーブル規模では大半のクエリが 5 つのコアテーブルで完結するため効果が限定的であった。テーブル数がさらに増加した場合 (例: OQMD 統合後) に効果が顕在化すると予想される。

5.5. 制約と今後の課題

1. 単一ランの評価：全 ablation 条件は単一ランの結果であり、LLM の非決定性による約 1–2 pp の変動が含まれる。信頼区間の算出には複数ランの評価が必要である。
2. データベース規模：現在のデータベースは 1,470 件の材料エントリを含むが、OQMD 等の大規模データベース（数十万件）へのスケーラビリティは未検証である。
3. 評価クエリの網羅性：100 件の著者設計クエリは材料研究の主要な検索パターンをカバーするように設計したが、実運用での多様なクエリパターンを網羅するものではない。

6. 結論

無機材料データベースのためのグラフ制約付き Text-to-SQL パイプラインを提案し、7 条件 × 100 件の ablation study（計 700 回評価）により各構成要素の寄与を定量化した。

全構成要素を有効にした full 条件での行一致精度は 80.6% であった（EVID-20260619-1335-ablation-full）。ablation study により、few-shot 例（−12.5 pp）、材料ドメイン辞書（−6.7 pp）、ハイブリッドリランカー（−4.1 pp）が精度に寄与する上位 3 構成要素であることが確認された。材料ドメイン辞書は Very Hard 帯で −22.7 pp の低下を引き起こし、ドメイン特化の用語マッピングが複雑クエリにおいて不可欠であることを示した。

なお、本評価は単一ランの結果であり、LLM の非決定性に起因する約 1–2 pp の変動を含む可能性がある。

データ・コード利用可能性

評価データセット、ablation 結果（JSON）、MeCab 材料辞書、および全スクリプトはリポジトリ内に含まれる。論文中の全数値は `scripts/compute_all_figures.py` により `paper/paper_data.json` へ出力され、手入力の数値は含まない。

References

- [1] T. Yu, R. Zhang, K. Yang, M. Yasunaga, D. Wang, Z. Li, J. Ma, I. Li, Q. Yao, S. Roman, Z. Zhang, D. Radev, Spider: A large-scale human-labeled dataset for complex and cross-database semantic parsing and text-to-SQL task, in: Proc. EMNLP, 2018, pp. 3911–3921.
- [2] J. Li, B. Hui, G. Qu, J. Yang, B. Li, B. Li, B. Wang, B. Qin, R. Geng, N. Huo, X. Zhou, C. Ma, G. Li, K. Chang, F. Huang, R. Cheng, Y. Li, Can LLM already serve as a database interface? A BIG bench for large-scale database grounded text-to-SQL, in: Proc. NeurIPS, 2024.
- [3] M. Pourreza, D. Rafiei, DIN-SQL: Decomposed in-context learning of text-to-SQL with self-correction, in: Proc. NeurIPS, 2024.
- [4] D. Gao, H. Wang, Y. Li, X. Sun, Y. Qian, B. Ding, J. Zhou, Text-to-SQL empowered by large language models: A benchmark evaluation, in: Proc. VLDB, 2024.
- [5] T. Gupta, M. Zaki, N. M. Anoop Krishnan, M. Mausam, MatSciBERT: A materials domain language model for text mining and information extraction, npj Comput. Mater. 8 (2022) 102.
- [6] N. Walker, J. Dagdelen, K. Cruse, A. Jain, A. Ceder, Extracting structured seed-mediated gold nanorod growth procedures from scientific text with MatBERT, Digital Discovery 1 (2022) 413–427.