

無機材料データベースのためのグラフ制約付き Text-to-SQL パイプラインの構築

Satoshi Minamoto^{a,*}

^aNational Institute for Materials Science (NIMS), 1-2-1 Sengen, Tsukuba, Ibaraki 305-0047, Japan

Abstract

第一原理計算データベースに蓄積された材料データの横断的検索は、SQL の専門知識を要求するため、材料研究者にとって障壁となっている。本研究では、自然言語の問い合わせから正規化リレーショナルデータベース上の SQL クエリを自動生成する、グラフ制約付き Text-to-SQL パイプラインを提案する。

提案パイプラインは以下の構成要素からなる：(1) TF-IDF と Cross-Encoder (ms-marco-MiniLM-L-6-v2) による few-shot 例検索、(2) GPT-5.5 によるスキーマリンクと SQL 生成 (n -best = 3 候補)、(3) 外部キー関係をグラフ化し Steiner 木近似で最小 JOIN 経路を決定する構造制約、(4) 492 語の材料ドメイン辞書 (MeCab カスタム辞書を含む) による用語-SQL 条件マッピング、(5) AST 解析ベースの SQLGuard によるカラム・テーブル幻覚の検出、(6) GPT-5.5 による SQL 候補リランキング。

L1₂ 型金属間化合物を中心とする 30 テーブル・1,470 件の材料データベースに対し、100 件の評価クエリ (Easy 20 / Medium 30 / Hard 30 / Very Hard 20) で 7 条件の ablation study (計 700 回評価) を実施した。全構成要素を有効にした full 条件では行一致精度 80.6% を達成した。Ablation study により、few-shot 例の除去が -12.5 ポイント (pp)、材料ドメイン辞書の除去が -6.7 pp (Very Hard 帯では -22.7 pp)、ハイブリッドリランカーの除去が -4.1 pp の精度低下を引き起こした。SQLGuard、 n -best 生成、Steiner 木 JOIN は各 -0.2 pp であった。全評価は LLM の非決定性を伴う単一ランであり、条件間の差異には約 1-2 pp の変動が含まれる。

Keywords: Text-to-SQL, 材料インフォマティクス, スキーマグラフ, Steiner 木, ablation study, ドメイン特化辞書, リランキング, L1₂ 型金属間化合物

1. 緒言

1.1. 材料データベースの検索障壁

第一原理計算データベース (OQMD [1, 2], Materials Project [3], AFLOW [4], NOMAD [5] 等) の普及により、材料特性の計算データが大量に蓄積されている。これらのデータは正規化リレーショナルデータベース (RDB) に格納されることが多いが、SQL クエリの記述には専門知識が必要であり、材料研究者が直感的にデータにアクセスする手段は限られている。

1.2. Text-to-SQL 技術の動向

Text-to-SQL 技術は、自然言語を SQL に変換する技術として Spider [6] や BIRD [7] 等のベンチマークを中心に発展してきた。近年、大規模言語モデル (LLM) の進歩により、DIN-SQL [8] はスキーマリンク・分類・生成を分離するパイプライン型アプローチを提案し、DAIL-SQL [9] は few-shot 例の選択戦略に着目した。RAT-SQL [10] は関係認識符号化、RESDSQL [11] はスキーマリンク分離を導入した。SchemaGraphSQL [12] は FK グラフ上のパスファインディングを用いる点で本研究と近い。

1.3. 材料インフォマティクスにおける NL インターフェース

材料データベースに対する自然言語インターフェースの研究は限定的である。MatSciBERT [13] や MatBERT [14] は材料科学テキストの言語モデルであるが、Text-to-SQL タスクには直接適用されていない。MKNA [15] や OptiMat [16] は API ベースのアクセスを提供するが、正規化 RDB 上での SQL 生成と JOIN 制御は行わない。SuperCon [17] や PoLyInfo [18] は RDF/SPARQL ベースのオントロジーアプローチであり、セマンティック推論に優れるが、既存の RDB インフラへの適用にはデータ変換が必要である。

1.4. 本研究の目的と独自性

本研究では、材料データベースへの Text-to-SQL 適用における以下の 3 つの課題に対処する：

1. ドメイン用語の多義性：L1₂、 γ' 相、B2 等の結晶構造名や物性用語は汎用 LLM の学習データに十分含まれておらず、正しい SQL 条件への変換が困難である。
2. 多テーブル JOIN の複雑さ：30 テーブルの正規化スキーマでは、LLM が JOIN 経路を誤る (JOIN 幻覚) リスクが高い。
3. 評価データの不在：材料データベースに対する Text-to-SQL の標準的な評価セットは存在しない。

提案法の独自性は以下の 3 点にある：(1) 外部キーグラフ上の Steiner 木近似による JOIN 経路の構造的決定、(2) 492 語の材料ドメイン辞書による用語-SQL 条件の直接マッピング、(3) Cross-Encoder と LLM を組み合わせたハイブリッ

*Corresponding author

Email address: minamoto.satoshi@nims.go.jp (Satoshi Minamoto)

ドリランカー。7条件×100件の ablation study により、各構成要素の寄与を定量化した結果を報告する。

2. 提案手法

2.1. パイプライン概要

提案パイプラインは図 1 に示す構成要素からなる。入力 は日本語の自然言語クエリであり、出力は SQL クエリとその実行結果である。

2.2. Few-shot 例検索

入力クエリに類似する few-shot 例を 2 段階で選択する。第 1 段階で TF-IDF [19] により候補を $2k$ 件に絞り込み、第 2 段階で Cross-Encoder (ms-marco-MiniLM-L-6-v2) により上位 k 件を選択する。Cross-Encoder はローカルで動作し、処理時間は 50 ms 未満である。

ablation study において、few-shot 例の除去は全体精度を 80.6% から 68.2% へ -12.5 pp 低下させた (表 4; EVID-20260619-1335-ablation-nofewshot)。この低下は全難易度帯で観察され、Medium 帯では -16.5 pp であった (表 5)。LLM は few-shot 例から SQL 生成のパターン (テーブル名、JOIN 順序、カラム名の使い方) を in-context learning [20] により獲得しており、few-shot 例なしではスキーマ情報のみから SQL を推論する必要が生じる。

2.3. スキーマリンキング

GPT-5.5 により、入力クエリに関連するテーブルをスコアリングし、関連度順にソートする (sort-only 方式)。テーブルの除外は行わず、SQL 生成時のコンテキスト優先順位のみを変更する。

2.4. SQL 生成と n -best 候補

GPT-5.5 により n -best = 3 の SQL 候補を生成する。ablation study において、 n -best = 1 への変更は全体精度を 0.2 pp 低下させたのみであったが、平均レイテンシは 33.1 s から 13.0 s へ低減した (表 4; EVID-20260619-1335-ablation-nonbest)。

2.5. Steiner 木 JOIN 制約

30 テーブルの外部キー (FK) 関係を NetworkX [21] の無向グラフとして表現する。FK 関係は実行時に PostgreSQL メタデータからイントロスペクションにより自動取得される。クエリに必要なテーブル集合に対し、Algorithm 1 に示す Steiner 木近似により最小 JOIN 部分木を決定する。

$|V| = n$ ノード、 $|R| = k$ 必要テーブルに対し、アルゴリズムは $O(k^2)$ 回の BFS を行う。30 テーブル規模 ($n = 30$, $k \leq 5$) でもミリ秒オーダーで完了する。

ablation study では、Steiner 木制約の除去による精度低下は -0.2 pp にとどまった (表 4; EVID-20260619-1335-ablation-nograph)。検証できた範囲では、現在の 30 テーブル規模では大半のクエリが 5 つのコアテーブル (material_entry, structure, element, composition, calculated_property) で完結するため、効果が限定的であった。テーブル数が拡大した場合に寄与が顕在化すると予想される。

JOIN 経路からの SQL FROM/JOIN 句生成例：

Algorithm 1 最小被覆 JOIN 部分グラフ (Steiner 木近似)。

Require: FK 関係グラフ $G = (V, E)$ 、必要テーブル集合 R

Ensure: JOIN 経路リスト P

```

1:  $P \leftarrow \emptyset$ ; Union-Find  $U$  を初期化
2: for all  $(s, t) \in \binom{R}{2}$  do
3:   if Find( $s$ ) = Find( $t$ ) then
4:     continue
5:   end if
6:    $p \leftarrow \text{ShortestPath}(G, s, t)$   $\triangleright$  FK グラフ上の BFS
7:   if  $p \neq \emptyset$  then
8:      $P \leftarrow P \cup \{p\}$ 
9:     for all 隣接ノード対  $(u, v) \in p$  do
10:      Union( $u, v$ )
11:     end for
12:   end if
13: end for
14: return  $P$ 

```

Table 1: MeCab 材料辞書によるトークン化率の変化。402 語の材料用語に対する単一トークン化率を示す (EVID-20260619-1335-mecab-dict)。

指標	デフォルト	カスタム辞書
単一トークン化率	30.6% (123/402)	100.0% (402/402)
改善語数	—	279
悪化語数	—	0

Listing 1: FK 経路からの JOIN 句生成

```

# path: [material_entry, structure]
# FK: structure.entry_id -> material_entry.entry_id
# output:
#   FROM material_entry m
#   JOIN structure s ON s.entry_id = m.entry_id

```

2.6. 材料ドメイン辞書

材料科学の専門用語を SQL 条件に直接マッピングする辞書を導入した。例として、「 γ' 相」→ structure.prototype = 'L12'、「バルクモジュラス」→ calculated_property テーブルの property_name = 'bulk_modulus' への変換がある。

辞書は 3 ソースから構成される：

1. YAML 定義ファイル (material_terms.yaml) : 74 語
 2. パイプライン用語 (DB/OQMD 固有語) : 66 語
 3. 材料工学語彙 (ユーザー提供リスト) : 390 語 (新規) 重複除去後 492 語となる。MeCab 形態素解析器用のカスタム辞書としてもコンパイルし、日本語テキストの前処理に利用する (EVID-20260619-1335-mecab-dict)。
- カスタム辞書により、402 語の材料用語の単一トークン化率はデフォルトの 30.6% から 100.0% へ向上した (表 1)。改善語数 279 語、悪化語数 0 語。代表的な改善例：「生成エンタルピー」(Default 2 トークン → Custom 1 トークン)、「ニッケル基超合金」(7 トークン → 1 トークン)。

ablation study では、辞書の除去は全体で -6.7 pp の低下を引き起こし、Very Hard 帯では 38.5% から 15.8%




Figure 1: 提案パイプラインの概要。自然言語クエリから few-shot 例検索 (Step 1) を経て、GPT-5.5 によるスキーマリンクング (Step 2) と SQL 生成 (Step 3) を行い、Steiner 木近似 (Step 4) が 30 テーブルから必要最小限のサブグラフを抽出する。材料辞書 (Step 5) がドメイン用語を SQL 条件にマッピングし、SQLGuard (Step 6) で安全性を検証した後、リランカー (Step 7) が最良候補を選択する。

へ -22.7 pp の低下となった (表 4; EVID-20260619-1335-ablation-nodict)。Easy・Medium 帯では低下が観察されなかったことから、辞書の効果は複合的なドメイン用語を含むクエリに集中している。

2.7. SQLGuard

sqlglot [22] による AST 解析に基づき、生成 SQL の安全性と整合性を検証する。検証項目はカラム存在確認、テーブル存在確認、FK 整合性 JOIN 検証、複文検出、SQL インジェクション検出等 14 項目からなる。

ablation study では、SQLGuard の除去による精度低下は -0.2 pp であった (表 4; EVID-20260619-1335-ablation-noguard)。リランカーが先に不正な SQL 候補を低スコアにするため、SQLGuard が拒否すべき SQL が選択されにくい状況が生じている。ただし、SQLGuard はセキュリティ上の安全網として機能しており、精度寄与とは独立した価値を持つ。

2.8. ハイブリッドリランカー

SQL 候補のリランキングには GPT-5.5 を使用する。few-shot 例の選択には Cross-Encoder (ローカル、50 ms 未満)、SQL 候補とスキーマのスコアリングには GPT-5.5 (API) を使用するハイブリッド構成を採用した。

ablation study では、リランカーの除去は -4.1 pp の低下を引き起こし、Medium 帯で -6.7 pp、Hard 帯で -6.2 pp の低下が観察された (表 4; EVID-20260619-1335-ablation-noreranker)。

別途実施した 90 件の A/B 評価では、リランカーありが 77.2%、なしが 69.4% で $+7.7$ pp の差が観察された (EVID-20260619-1335-reranker-eval)。ただし、この A/B 評価は ablation study とは異なるランであり、直接的な比較には注意を要する。

2.8.1. 日本語 Cross-Encoder の比較

Few-shot 例選択の Cross-Encoder について、英語モデル (ms-marco-MiniLM-L-6-v2) と日本語モデル (hotchpotch/japanese-reranker-cross-encoder-xsmall-v1) を Very Hard 20 件で比較した。結果は ms-marco 32.4% に対し japanese-xsmall 28.1% であり、 -4.3 pp の差で ms-marco が優位であった (EVID-20260619-1335-jp-reranker)。Few-shot 例に SQL コード (英語) が含まれるため、英語に対するスコアリング能力が ms-marco の優位性に寄与していると考えられる。

2.9. リペアループ

SQL 実行エラーまたは結果の妥当性問題が検出された場合、エラーメッセージを LLM (GPT-5.5) にフィードバックし、最大 3 回のリペアを試行する。

Table 2: 検証データベースの構成 (EVID-20260619-1335-db-schema)。

項目	件数
テーブル数	30
material_entry	1,470
composition	2,940
calculated_property	4,410
プロトタイプ種類	5 (L12, B2, NaCl, NiAs, BiF3)

Table 3: 評価クエリ設計 (全 100 件)。

難易度	件数	テーブル数	代表的内容
Easy	20	1-2	単一条件検索
Medium	30	3	構造+組成+安定性横断
Hard	30	4	複合条件・集約
Very Hard	20	5-6	材料設計クエリ

3. データベースと評価設計

3.1. 検証データベース

L12 型金属間化合物を中心とする無機材料データベースを使用した。スキーマは 30 テーブルからなり (図 2)、material_entry を中心に組成・構造・安定性・計算特性・電子構造・機械特性・表面特性等のテーブルが FK 関係で接続される。主要な統計を表 2 に示す。

3.2. 評価クエリ

著者が設計した 100 件のクエリを使用した (表 3)。各クエリには gold SQL、期待される実行結果 (JSON)、必要テーブル、JOIN 経路が付与されている (EVID-20260619-1335-dataset-author)。

3.3. 評価指標

行一致精度 (row-level recall) を主指標とする。生成 SQL の実行結果と gold SQL の実行結果を共通カラムで射影した上で行レベルの一致率を算出する：

$$\text{accuracy}(q) = \frac{|R_{\text{gen}}^C \cap R_{\text{gold}}^C|}{|R_{\text{gold}}^C|} \quad (1)$$

ここで $C = \text{cols}(R_{\text{gen}}) \cap \text{cols}(R_{\text{gold}})$ は共通カラム集合、 R^C は列集合 C への射影である。本指標は再現率ベースであり、生成 SQL が gold より多くの行を返してもペナルティがない。評価時には gold SQL と生成 SQL の両方に LIMIT 10,000 を統一的に適用する。




Figure 2: 検証データベースの 30 テーブル ER 図。中央の `material_entry` を軸に、組成・構造・安定性等のコアテーブルが直接 FK で接続される。計算特性・電子構造等は直接 FK と `calculation` 経由の 2 経路を持つ。矢印は FK 参照方向を示す。

Table 4: Ablation study 結果 (100 件 $\times$ 7 条件 = 700 評価)。 Δ は full 条件からの精度変化 (pp)。全数値は `paper_data.json` から取得。LLM の非決定性により、条件間の差異には約 1–2 pp の変動が含まれる。

条件	全体	Easy	Med	Hard	VH	Δ
full	80.6	100.0	96.1	80.4	38.5	—
no_fewshot	68.2	95.0	79.6	66.8	26.2	−12.5
no_dict	73.9	100.0	96.1	73.1	15.8	−6.7
no_reranker	76.6	100.0	89.5	74.1	37.4	−4.1
no_guard	80.4	100.0	96.1	80.4	37.4	−0.2
no_nbest	80.4	100.0	96.1	80.4	37.2	−0.2
no_graph	80.5	100.0	96.1	80.4	37.7	−0.2

Table 5: 上位 3 コンポーネントの難易度別 Δ (pp)。数値は `paper_data.json` から取得。

条件	Easy	Med	Hard	VH
no_fewshot	−5.0	−16.5	−13.5	−12.3
no_dict	0.0	0.0	−7.3	−22.7
no_reranker	0.0	−6.7	−6.2	−1.1

4. Ablation Study

7 つの条件で ablation study を実施した (表 4)。各条件では 1 つの構成要素を無効化し、100 件全てのクエリで精度を測定した。合計 700 回の評価を実施した (EVID-20260619-1335-ablation-json)。

5. 考察

5.1. Few-shot 例の寄与

Few-shot 例の除去は全構成要素の中で最も大きな精度低下 (−12.5 pp) を引き起こした (表 4)。この低下は全難易度帯で観察され、Easy 帯でも −5.0 pp の低下が確認された (表 5)。Medium 帯の −16.5 pp が最も大きく、中程度の複雑さのクエリにおける few-shot 例への依存度が高い。Few-shot 例なしではレイテンシも 33.1 s から 64.1 s へ増加した (表 6)。これは LLM が試行錯誤的に SQL を生成するためと考えられる。

5.2. 材料ドメイン辞書の寄与

辞書の除去は全体で −6.7 pp の低下を引き起こしたが、その効果は難易度帯により異なった (表 5)。Easy $\cdot$ Medium 帯では低下が観察されず、Hard 帯で −7.3 pp、Very Hard 帯で −22.7 pp の低下が生じた。

Easy $\cdot$ Medium クエリは汎用的な表現で構成されるため、LLM 単体で SQL 条件を推論可能である。一方、Very Hard クエリは複数のドメイン固有用語を同時に含み、辞書なしでは LLM が正しい SQL 条件 (例: 「 γ' 相」 $\rightarrow$ `structure.prototype = 'L12'`) を生成できない場合がある。

5.3. リランカーの寄与

リランカーの除去は −4.1 pp の低下を引き起こした。効果は Medium (−6.7 pp) および Hard (−6.2 pp) 帯で観察され、Very Hard 帯では −1.1 pp にとどまった (表 5)。

Table 6: 各条件の平均レイテンシ (秒/クエリ)。 n -best = 1 への変更はレイテンシを 60% 低減するが精度は −0.2 pp。

条件	レイテンシ (s)
full	33.1
no_fewshot	64.1
no_dict	56.5
no_reranker	25.7
no_guard	39.4
no_nbest	13.0
no_graph	34.2

Very Hard 帯では 3 候補全てが不正確な場合が多く、リランカーの「最良候補選択」効果が限定される。一方、Medium $\cdot$ Hard 帯では少なくとも 1 候補が正確であることが多く、リランカーがその候補を正しく選択する効果が発揮される。

5.4. SQLGuard $\cdot$ n -best $\cdot$ Steiner 木の寄与

これら 3 構成要素はいずれも −0.2 pp の低下にとどまった。SQLGuard については、リランカーが先に同等の選別機能を果たしているため、追加的な効果が観察されにくい状況にある。セキュリティ上の安全網としての価値は独立に存在する。

n -best = 1 への変更は精度をほぼ維持しつつレイテンシを 33.1 s から 13.0 s へ低減した (表 6)。コスト効率を重視する場合の有力な選択肢である。

Steiner 木については、現在の 30 テーブル規模では大半のクエリが 5 つのコアテーブルで完結するため効果が限定的であった。FK イントロスペクションに基づくアーキテクチャであるため、テーブル数が増加した場合 (例: OQMD 統合後) や別の正規化 RDB (Materials Project [3], AFLOW [4]) への適用時に効果が顕在化すると予想される。

5.5. 関連システムとの比較

表 7 に関連システムとの比較を示す。本手法は「正規化 RDB + 材料特化 + FK グラフ走査」の組合せで、既存アプローチがカバーしない領域を埋める。

5.6. 制約と今後の課題

1. 単一ランの評価: 全 ablation 条件は単一ランの結果であり、LLM の非決定性による約 1–2 pp の変動が含まれる。信頼区間の算出には複数ランの評価が必要である。
2. データベース規模: 現在のデータベースは 1,470 件の材料エントリを含むが、OQMD 等の大規模データベース (数十万件) へのスケーラビリティは未検証である。
3. 評価クエリの網羅性: 100 件の著者設計クエリは材料研究の主要な検索パターンをカバーするよう設計したが、実運用での多様なクエリパターンを網羅するものではない。
4. gold SQL の検証: gold SQL $\cdot$ 期待結果は著者 1 名が作成し、第三者による独立検証は行っていない。
5. 用語辞書のカバレッジ: 492 語の辞書は $L1_2$ 探索に特化しており、Heusler 型や Perovskite 型等の拡張には手動登録が必要である。

Table 7: 関連する材料 NLP / T2SQL / オントロジーシステムとの比較。

種別	名称	スキーマ 認識	正規化 RDB	材料 特化	NL→ クエリ	主な差異
<i>T2SQL</i> ベンチマーク						
データセット	Spider [6]	あり	あり	なし	SQL	汎用ベンチマーク
データセット	BIRD [7]	あり	あり	なし	SQL	大規模実データ
<i>T2SQL</i> 手法						
手法	DAIL-SQL [9]	あり	あり	なし	SQL	スケルトン選択
手法	RAT-SQL [10]	あり	あり	なし	SQL	関係認識符号化
手法	RESDSQL [11]	あり	あり	なし	SQL	スキーマリンク分離
手法	SchemaGraphSQL [12]	あり	あり	なし	SQL	パスファインディング
材料情報学						
手法	MKNA [15]	なし	なし	あり	API	エージェント
手法	OptiMat [16]	なし	なし	あり	API	オンデマンド DFT
オントロジー						
手法	SuperCon [17]	あり	なし	あり	SPARQL	RDF オントロジー
手法	PoLyInfo [18]	あり	なし	あり	SPARQL	BFO 準拠
手法	本手法	あり	あり	あり	SQL	FK 走査 + 材料辞書

6. ベースラインの公平性：リペアループ、Few-Shot RAG、SQLGuard 等は提案手法のみに適用されており、各要素の寄与は ablation study で分離済みだが、他手法（DIN-SQL、DAIL-SQL 等）との同一 DB 上の比較は未実施である。

5.7. 今後の展望

1. 大規模データ検証：OQMD 単元素データの統合により 1 万件規模での Steiner 木探索と SQL 生成精度の検証を行う。
2. 生成エンタルピー計算対応：Text-to-SQL パイプラインで計算指示を受け取れるインターフェースの実装。
3. **AI4S** エージェント統合：T2SQL 手法を MCP プロトコルや function calling 経由で自律材料探索エージェントのツールとして組み込む。
4. **CALPHAD** 連携：Schema Graph 走査で RDB から候補を絞り込んだ後、CALPHAD の自由エネルギー計算により温度依存相安定性を判定する二段階フロー。
5. 用語辞書の体系的拡張：スキーマメタデータからの半自動生成に移行し、新テーブル追加時の辞書保守コストを削減する。
6. 評価指標の多軸化：SELECT 列適合率、JOIN 経路一致率、Top-k accuracy 等を分離評価し、エラーの原因特定を容易にする。

6. 結論

無機材料データベースのためのグラフ制約付き Text-to-SQL パイプラインを提案し、7 条件 × 100 件の ablation study (計 700 回評価) により各構成要素の寄与を定量化した。

全構成要素を有効にした full 条件での行一致精度は 80.6% であった (EVID-20260619-1335-ablation-full)。Ablation study により、few-shot 例 (−12.5 pp)、材料ドメイン辞書 (−6.7 pp)、ハイブリッドリランカー (−4.1 pp) が精度に寄与する上位 3 構成要素であることが確認された。材料ドメ

イン辞書は Very Hard 帯で −22.7 pp の低下を引き起こし、ドメイン特化の用語マッピングが複雑クエリにおいて不可欠であることを示した。

FK イントロスペクションに基づく Steiner 木アーキテクチャは、任意の正規化材料 RDB (OQMD、Materials Project、AFLOW 等) への自動適応が可能であり、Materials Integration (MInt) システム [23] や provenance 管理システム pinax [24] への適用が期待される。

本評価は単一ランの結果であり、LLM の非決定性に起因する約 1–2 pp の変動を含む可能性がある。

謝辞

L1₂ 型金属間化合物の DFT 計算データは Open Quantum Materials Database (OQMD) の値を参考に構築した合成検証データである。キュリー温度・Σ5 粒界エネルギー・合成法・文献参照等の属性は OQMD に存在せず、検証用に生成したものである。OQMD の開発・維持管理にあたる Northwestern 大学 Wolverton グループに感謝する。本研究は NIMS の支援を受けた。

データ・コード利用可能性

評価データセット (100 件の gold SQL・期待結果)、ablation 結果 (7 条件 × 100 件の JSON)、MeCab 材料辞書 (492 語、コンパイル済み.dic)、日本語 reranker 比較結果、および全スクリプトはリポジトリ内に含まれる。論文中の全数値は scripts/compute_all_figures.py により paper/paper_data.json へ出力され、手入力の数値は含まない。ユニットテスト 134 件が全 PASS を達成した。

Author Contributions

Satoshi Minamoto : 研究構想、手法設計、ソフトウェア実装、データベース構築、実験実施、論文執筆。

References

- [1] J.E. Saal, S. Kirklin, M. Aykol, B. Meredig, C. Wolverton, Materials design and discovery with high-throughput density functional theory: The Open Quantum Materials Database (OQMD), *JOM* 65 (2013) 1501–1509.
- [2] S. Kirklin, J.E. Saal, B. Meredig, A. Thompson, J.W. Doak, M. Aykol, S. Rühl, C. Wolverton, The Open Quantum Materials Database (OQMD): Assessing the accuracy of DFT formation energies, *npj Comput. Mater.* 1 (2015) 15010.
- [3] A. Jain, S.P. Ong, G. Hautier, W. Chen, W.D. Richards, S. Dacek, S. Cholia, D. Gunter, D. Skinner, G. Ceder, K.A. Persson, Commentary: The Materials Project: A materials genome approach to accelerating materials innovation, *APL Mater.* 1 (2013) 011002.
- [4] S. Curtarolo, W. Setyawan, G.L.W. Hart, M. Jahnatek, R.V. Chepulskii, R.H. Taylor, S. Wang, J. Xue, K. Yang, O. Levy, M.J. Mehl, H.T. Stokes, D.O. Demchenko, D. Morgan, AFLOW: An automatic framework for high-throughput materials discovery, *Comput. Mater. Sci.* 58 (2012) 218–226.
- [5] C. Draxl, M. Scheffler, NOMAD: The FAIR concept for big data-driven materials science, *MRS Bull.* 43 (2018) 676–682.
- [6] T. Yu, R. Zhang, K. Yang, M. Yasunaga, D. Wang, Z. Li, J. Ma, I. Li, Q. Yao, S. Roman, Z. Zhang, D. Radev, Spider: A large-scale human-labeled dataset for complex and cross-database semantic parsing and text-to-SQL task, in: *Proc. EMNLP*, 2018, pp. 3911–3921.
- [7] J. Li, B. Hui, G. Qu, J. Yang, B. Li, B. Li, B. Wang, B. Qin, R. Geng, N. Huo, X. Zhou, C. Ma, G. Li, K. Chang, F. Huang, R. Cheng, Y. Li, Can LLM already serve as a database interface? A BIG bench for large-scale database grounded text-to-SQL, in: *Proc. NeurIPS*, 2024.
- [8] M. Pourreza, D. Rafiei, DIN-SQL: Decomposed in-context learning of text-to-SQL with self-correction, in: *Proc. NeurIPS*, 2024.
- [9] D. Gao, H. Wang, Y. Li, X. Sun, Y. Qian, B. Ding, J. Zhou, Text-to-SQL empowered by large language models: A benchmark evaluation, in: *Proc. VLDB*, 2024.
- [10] B. Wang, R. Shin, X. Liu, O. Polozov, M. Richardson, RAT-SQL: Relation-aware schema encoding and linking for text-to-SQL parsers, in: *Proc. ACL*, 2020, pp. 7567–7578.
- [11] H. Li, J. Zhang, C. Li, H. Chen, RESDSQL: Decoupling schema linking and skeleton parsing for text-to-SQL, in: *Proc. AAAI*, 2023.
- [12] F. Safdarian, S. Kacupaj, SchemaGraphSQL: Schema-graph-based text-to-SQL with path finding, in: *Proc. NAACL*, 2026.
- [13] T. Gupta, M. Zaki, N.M.A. Krishnan, M. Mausam, MatSciBERT: A materials domain language model for text mining and information extraction, *npj Comput. Mater.* 8 (2022) 102.
- [14] N. Walker, J. Dagdelen, K. Cruse, A. Jain, A. Ceder, Extracting structured seed-mediated gold nanorod growth procedures from scientific text with MatBERT, *Digital Discovery* 1 (2022) 413–427.
- [15] Y. Zhuang et al., MKNA: Materials knowledge navigation agent, *Nat. Comput. Sci.* (2026).
- [16] Y. Hu et al., OptiMat: On-demand DFT-driven materials optimization, *npj Comput. Mater.* (2026).
- [17] M. Ishii et al., SuperCon: Linked data platform for superconducting materials, *J. Phys.: Condens. Matter* (2023).
- [18] M. Ishii et al., PoLyInfo: BFO-compliant polymer ontology, *J. Chem. Inf. Model.* (2024).
- [19] G. Salton, C. Buckley, Term-weighting approaches in automatic text retrieval, *Inf. Process. Manag.* 24 (1988) 513–523.
- [20] T. Brown et al., Language models are few-shot learners, in: *Proc. NeurIPS*, 2020.
- [21] A.A. Hagberg, D.A. Schult, P.J. Swart, Exploring network structure, dynamics, and function using NetworkX, in: *Proc. SciPy*, 2008.
- [22] T. Palantir, sqlglot: Python SQL parser and transpiler, 2023. <https://github.com/tobymao/sqlglot>
- [23] S. Minamoto, Materials integration system for process-structure-property-performance chains, *Sci. Technol. Adv. Mater.* (2020).
- [24] S. Minamoto, pinax: Provenance-tracking analysis workflow management system, (2026).