

無機材料データベースのためのグラフ制約付き Text-to-SQL パイプラインの構築

Satoshi Minamoto^{a,*}

^aNational Institute for Materials Science (NIMS), 1-2-1 Sengen, Tsukuba, Ibaraki 305-0047, Japan

Abstract

第一原理計算データベースに蓄積された材料データの横断的検索は、SQL の専門知識を要求するため、材料研究者にとって障壁となっている。本研究では、自然言語の問い合わせから正規化リレーショナルデータベース上の SQL クエリを自動生成する、グラフ制約付き Text-to-SQL パイプラインを提案する。

提案パイプラインは以下の構成要素からなる：(1) TF-IDF と Cross-Encoder (ms-marco-MiniLM-L-6-v2) による few-shot 例検索、(2) GPT-5.5 によるスキーマリンクと SQL 生成 (n -best = 3 候補)、(3) 外部キー関係をグラフ化し Steiner 木近似で最小 JOIN 経路を決定する構造制約、(4) 492 語の材料ドメイン辞書 (MeCab カスタム辞書を含む) による用語-SQL 条件マッピング、(5) AST 解析ベースの SQLGuard によるカラム・テーブル幻覚の検出、(6) GPT-5.5 による SQL 候補リランキング。

L1₂ 型金属間化合物を中心とする 30 テーブル・1,470 件の材料データベースに対し、100 件の評価クエリ (Easy 20 / Medium 30 / Hard 30 / Very Hard 20) で 7 条件の ablation study (計 700 回評価) を実施した。全構成要素を有効にした full 条件では行一致精度 80.6% を達成した。Ablation study により、few-shot 例の除去が -12.5 ポイント (pp)、材料ドメイン辞書の除去が -6.7 pp (Very Hard 帯では -22.7 pp)、ハイブリッドリランカーの除去が -4.1 pp の精度低下を引き起こした。SQLGuard、 n -best 生成、Steiner 木 JOIN は各 -0.2 pp であった。さらに、OQMD 由来の 89 元素基底状態データを統合し、生成エンタルピーの多段計算 (3 テーブル JOIN + CTE) に自然言語から対応可能であることを示した。この実装を通じ、RDB スキーマの正規化度とテーブル構造が Text-to-SQL 精度の上流要因となること、およびビュー定義やスキーマ設計の見直しが精度向上の有効な方策となりうることを論じた。全評価は LLM の非決定性を伴う単一ランであり、条件間の差異には約 1-2 pp の変動が含まれる。

Keywords: Text-to-SQL, 材料インフォマティクス, スキーマグラフ, Steiner 木, ablation study, ドメイン特化辞書, リランキング, L1₂ 型金属間化合物

1. 緒言

1.1. 材料データベースの検索障壁

第一原理計算データベース (OQMD [1, 2], Materials Project [3], AFLOW [4], NOMAD [5] 等) の普及により、材料特性の計算データが大量に蓄積されている。これらのデータは正規化リレーショナルデータベース (RDB) に格納されることが多いが、SQL クエリの記述には専門知識が必要であり、材料研究者が直感的にデータにアクセスする手段は限られている。

1.2. Text-to-SQL 技術の動向

Text-to-SQL 技術は、自然言語を SQL に変換する技術として Spider [6] や BIRD [7] 等のベンチマークを中心に発展してきた。近年、大規模言語モデル (LLM) の進歩により、DIN-SQL [8] はスキーマリンク・分類・生成を分離するパイプライン型アプローチを提案し、DAIL-SQL [9] は few-shot 例の選択戦略に着目した。RAT-SQL [10] は関係認識符号化、RESDSQL [11] はスキーマリンク分離を導入した。SchemaGraphSQL [12] は FK グラフ上のパスファインディングを用いる点で本研究と近い。

1.3. 材料インフォマティクスにおける NL インターフェース

材料データベースに対する自然言語インターフェースの研究は限定的である。MatSciBERT [13] や MatBERT [14] は材料科学テキストの言語モデルであるが、Text-to-SQL タスクには直接適用されていない。MKNA [15] や OptiMat [16] は API ベースのアクセスを提供するが、正規化 RDB 上での SQL 生成と JOIN 制御は行わない。SuperCon [17] や PoLyInfo [18] は RDF/SPARQL ベースのオントロジーアプローチであり、セマンティック推論に優れるが、既存の RDB インフラへの適用にはデータ変換が必要である。

1.4. 本研究の目的と独自性

本研究では、材料データベースへの Text-to-SQL 適用における以下の 3 つの課題に対処する：

- ドメイン用語の多義性：L1₂、 γ' 相、B2 等の結晶構造名や物性用語は汎用 LLM の学習データに十分含まれておらず、正しい SQL 条件への変換が困難である。
- 多テーブル JOIN の複雑さ：30 テーブルの正規化スキーマでは、LLM が JOIN 経路を誤る (JOIN 幻覚) リスクが高い。
- 評価データの不在：材料データベースに対する Text-to-SQL の標準的な評価セットは存在しない。

*Corresponding author

Email address: minamoto.satoshi@nims.go.jp (Satoshi Minamoto)

提案法の独自性は以下の3点にある：(1) 外部キーグラフ上の Steiner 木近似による JOIN 経路の構造的決定、(2) 492 語の材料ドメイン辞書による用語-SQL 条件の直接マッピング、(3) Cross-Encoder と LLM を組み合わせたハイブリッドランカー。7 条件 × 100 件の ablation study により、各構成要素の寄与を定量化した結果を報告する。

2. 提案手法

2.1. パイプライン概要

提案パイプラインは図 1 に示す構成要素からなる。入力日本語の自然言語クエリであり、出力は SQL クエリとその実行結果である。

2.2. Few-shot 例検索

入力クエリに類似する few-shot 例を 2 段階で選択する。第 1 段階で TF-IDF [19] により候補を $2k$ 件に絞り込み、第 2 段階で Cross-Encoder (ms-marco-MiniLM-L-6-v2) により上位 k 件を選択する。Cross-Encoder はローカルで動作し、処理時間は 50 ms 未満である。

ablation study において、few-shot 例の除去は全体精度を 80.6% から 68.2% へ -12.5 pp 低下させた (表 4; EVID-20260619-1335-ablation-nofewshot)。この低下は全難易度帯で観察され、Medium 帯では -16.5 pp であった (表 5)。LLM は few-shot 例から SQL 生成のパターン (テーブル名、JOIN 順序、カラム名の使い方) を in-context learning [20] により獲得しており、few-shot 例なしではスキーマ情報のみから SQL を推論する必要が生じる。

2.3. スキーマリンキング

GPT-5.5 により、入力クエリに関連するテーブルをスコアリングし、関連度順にソートする (sort-only 方式)。テーブルの除外は行わず、SQL 生成時のコンテキスト優先順位のみを変更する。

2.4. SQL 生成と n -best 候補

GPT-5.5 により n -best = 3 の SQL 候補を生成する。ablation study において、 n -best = 1 への変更は全体精度を 0.2 pp 低下させたのみであったが、平均レイテンシは 33.1 s から 13.0 s へ低減した (表 4; EVID-20260619-1335-ablation-nonbest)。

2.5. Steiner 木 JOIN 制約

30 テーブルの外部キー (FK) 関係を NetworkX [21] の無向グラフとして表現する。FK 関係は実行時に PostgreSQL メタデータからイントロスペクションにより自動取得される。クエリに必要なテーブル集合に対し、Algorithm 1 に示す Steiner 木近似により最小 JOIN 部分木を決定する。

$|V| = n$ ノード、 $|R| = k$ 必要テーブルに対し、アルゴリズムは $O(k^2)$ 回の BFS を行う。30 テーブル規模 ($n = 30$, $k \leq 5$) でもミリ秒オーダーで完了する。

ablation study では、Steiner 木制約の除去による精度低下は -0.2 pp にとどまった (表 4; EVID-20260619-1335-ablation-nograph)。検証できた範囲では、現在の 30 テーブル規模では大半のクエリが 5 つのコアテーブル

Algorithm 1 最小被覆 JOIN 部分グラフ (Steiner 木近似)。

Require: FK 関係グラフ $G = (V, E)$ 、必要テーブル集合 R

Ensure: JOIN 経路リスト P

```

1:  $P \leftarrow \emptyset$ ; Union-Find  $U$  を初期化
2: for all  $(s, t) \in \binom{R}{2}$  do
3:   if Find( $s$ ) = Find( $t$ ) then
4:     continue
5:   end if
6:    $p \leftarrow \text{ShortestPath}(G, s, t)$   $\triangleright$  FK グラフ上の BFS
7:   if  $p \neq \emptyset$  then
8:      $P \leftarrow P \cup \{p\}$ 
9:     for all 隣接ノード対  $(u, v) \in p$  do
10:      Union( $u, v$ )
11:     end for
12:   end if
13: end for
14: return  $P$ 
```

(material_entry, structure, element, composition, calculated_property) で完結するため、効果が限定的であった。テーブル数が拡大した場合に寄与が顕在化すると予想される。

JOIN 経路からの SQL FROM/JOIN 句生成例：

Listing 1: FK 経路からの JOIN 句生成

```

# path: [material_entry, structure]
# FK: structure.entry_id -> material_entry.entry_id
# output:
# FROM material_entry m
# JOIN structure s ON s.entry_id = m.entry_id
```

2.6. 材料ドメイン辞書

材料科学の専門用語を SQL 条件に直接マッピングする辞書を導入した。例として、「 γ' 相」 $\rightarrow$ structure.prototype = 'L12'、 γ' 「バルクモジュラス」 $\rightarrow$ calculated_property テーブルの property_name = 'bulk_modulus' への変換がある。

辞書は 3 ソースから構成される：

1. YAML 定義ファイル (material_terms.yaml) : 74 語
2. パイプライン用語 (DB/OQMD 固有語) : 66 語
3. 材料工学語彙 (ユーザー提供リスト) : 390 語 (新規) 重複除去後 492 語となる。MeCab 形態素解析器用のカスタム辞書としてもコンパイルし、日本語テキストの前処理に利用する (EVID-20260619-1335-mecab-dict)。

カスタム辞書により、402 語の材料用語の単一トークン化率はデフォルトの 30.6% から 100.0% へ向上した (表 1)。改善語数 279 語、悪化語数 0 語。代表的な改善例：「生成エンタルピー」(Default 2 トークン $\rightarrow$ Custom 1 トークン)、「ニッケル基超合金」(7 トークン $\rightarrow$ 1 トークン)。

ablation study では、辞書の除去は全体で -6.7 pp の低下を引き起こし、Very Hard 帯では 38.5% から 15.8% へ -22.7 pp の低下となった (表 4; EVID-20260619-1335-ablation-nodict)。Easy・Medium 帯では低下が観察されなかったことから、辞書の効果は複合的なドメイン用語を含むクエリに集中している。




Figure 1: 提案パイプラインの概要。自然言語クエリから few-shot 例検索 (Step 1) を経て、GPT-5.5 によるスキーマリンク (Step 2) と SQL 生成 (Step 3) を行い、Steiner 木近似 (Step 4) が 30 テーブルから必要最小限のサブグラフを抽出する。材料辞書 (Step 5) がドメイン用語を SQL 条件にマッピングし、SQLGuard (Step 6) で安全性を検証した後、リランカー (Step 7) が最良候補を選択する。

Table 1: MeCab 材料辞書によるトークン化率の変化。402 語の材料用語に対する単一トークン化率を示す (EVID-20260619-1335-mecab-dict)。

指標	デフォルト	カスタム辞書
単一トークン化率	30.6% (123/402)	100.0% (402/402)
改善語数	—	279
悪化語数	—	0

2.7. SQLGuard

sqlglot [22] による AST 解析に基づき、生成 SQL の安全性と整合性を検証する。検証項目はカラム存在確認、テーブル存在確認、FK 整合性 JOIN 検証、複文検出、SQL インジェクション検出等 14 項目からなる。

ablation study では、SQLGuard の除去による精度低下は -0.2 pp であった (表 4; EVID-20260619-1335-ablation-noguard)。リランカーが先に不正な SQL 候補を低スコアにするため、SQLGuard が拒否すべき SQL が選択されにくい状況が生じている。ただし、SQLGuard はセキュリティ上の安全網として機能しており、精度寄与とは独立した価値を持つ。

2.8. ハイブリッドリランカー

SQL 候補のリランキングには GPT-5.5 を使用する。few-shot 例の選択には Cross-Encoder (ローカル、50 ms 未満)、SQL 候補とスキーマのスコアリングには GPT-5.5 (API) を使用するハイブリッド構成を採用した。

ablation study では、リランカーの除去は -4.1 pp の低下を引き起こし、Medium 帯で -6.7 pp、Hard 帯で -6.2 pp の低下が観察された (表 4; EVID-20260619-1335-ablation-noreranker)。

別途実施した 90 件の A/B 評価では、リランカーありが 77.2%、なしが 69.4% で $+7.7$ pp の差が観察された (EVID-20260619-1335-reranker-eval)。ただし、この A/B 評価は ablation study とは異なるランであり、直接的な比較には注意を要する。

2.8.1. 日本語 Cross-Encoder の比較

Few-shot 例選択の Cross-Encoder について、英語モデル (ms-marco-MiniLM-L-6-v2) と日本語モデル (hotchpotch/japanese-reranker-cross-encoder-xsmall-v1) を Very Hard 20 件で比較した。結果は ms-marco 32.4% に対し japanese-xsmall 28.1% であり、 -4.4 pp の差で ms-marco が優位であった (EVID-20260619-1335-jp-reranker)。Few-shot 例に SQL コード (英語) が含まれるため、英語に対するスコアリング能力が ms-marco の優位性に寄与していると考えられる。

Table 2: 検証データベースの構成 (EVID-20260619-1335-db-schema)。

項目	件数
テーブル数	30
material_entry	1,470
composition	2,940
calculated_property	4,410
プロトタイプ種類	5 (L12, B2, NaCl, NiAs, BiF3)

Table 3: 評価クエリ設計 (全 100 件)。

難易度	件数	テーブル数	代表的内容
Easy	20	1-2	単一条件検索
Medium	30	3	構造+組成+安定性横断
Hard	30	4	複合条件・集約
Very Hard	20	5-6	材料設計クエリ

2.9. リペアループ

SQL 実行エラーまたは結果の妥当性問題が検出された場合、エラーメッセージを LLM (GPT-5.5) にフィードバックし、最大 3 回のリペアを試行する。

3. データベースと評価設計

3.1. 検証データベース

L12 型金属間化合物を中心とする無機材料データベースを使用した。スキーマは 30 テーブルからなり (図 2)、material_entry を中心に組成・構造・安定性・計算特性・電子構造・機械特性・表面特性等のテーブルが FK 関係で接続される。主要な統計を表 2 に示す。

3.2. 評価クエリ

著者が設計した 100 件のクエリを使用した (表 3)。各クエリには gold SQL、期待される実行結果 (JSON)、必要テーブル、JOIN 経路が付与されている (EVID-20260619-1335-dataset-author)。

3.3. 評価指標

行一致精度 (row-level recall) を主指標とする。生成 SQL の実行結果と gold SQL の実行結果を共通カラムで射影した上で行レベルの一致率を算出する：

$$\text{accuracy}(q) = \frac{|R_{\text{gen}}^C \cap R_{\text{gold}}^C|}{|R_{\text{gold}}^C|} \quad (1)$$

ここで $C = \text{cols}(R_{\text{gen}}) \cap \text{cols}(R_{\text{gold}})$ は共通カラム集合、 R^C は列集合 C への射影である。本指標は再現率ベースであ




Figure 2: 検証データベースの 30 テーブル ER 図。中央の `material_entry` を軸に、組成・構造・安定性等のコアテーブルが直接 FK で接続される。計算特性・電子構造等は直接 FK と `calculation` 経由の 2 経路を持つ。矢印は FK 参照方向を示す。

Table 4: Ablation study 結果 (100 件 $\times$ 7 条件 = 700 評価)。 Δ は full 条件からの精度変化 (pp)。全数値は `paper_data.json` から取得。LLM の非決定性により、条件間の差異には約 1–2 pp の変動が含まれる。

条件	全体	Easy	Med	Hard	VH	Δ
full	80.6	100.0	96.1	80.4	38.5	—
no_fewshot	68.2	95.0	79.6	66.8	26.2	−12.5
no_dict	73.9	100.0	96.1	73.1	15.8	−6.7
no_reranker	76.6	100.0	89.5	74.1	37.4	−4.1
no_guard	80.4	100.0	96.1	80.4	37.4	−0.2
no_nbest	80.4	100.0	96.1	80.4	37.2	−0.2
no_graph	80.5	100.0	96.1	80.4	37.7	−0.2

Table 5: 上位 3 コンポーネントの難易度別 Δ (pp)。数値は `paper_data.json` から取得。

条件	Easy	Med	Hard	VH
no_fewshot	−5.0	−16.5	−13.5	−12.3
no_dict	0.0	0.0	−7.3	−22.7
no_reranker	0.0	−6.7	−6.2	−1.1

り、生成 SQL が gold より多くの行を返してもペナルティがない。評価時には gold SQL と生成 SQL の両方に LIMIT 10,000 を統一的に適用する。

4. Ablation Study

7 つの条件で ablation study を実施した (表 4)。各条件では 1 つの構成要素を無効化し、100 件全てのクエリで精度を測定した。合計 700 回の評価を実施した (EVID-20260619-1335-ablation-json)。

5. 考察

5.1. Few-shot 例の寄与

Few-shot 例の除去は全構成要素の中で最も大きな精度低下 (−12.5 pp) を引き起こした (表 4)。この低下は全難易度帯で観察され、Easy 帯でも −5.0 pp の低下が確認された (表 5)。Medium 帯の −16.5 pp が最も大きく、中程度の複雑さのクエリにおける few-shot 例への依存度が高い。Few-shot 例なしではレイテンシも 33.1 s から 64.1 s へ増加した (表 6)。これは LLM が試行錯誤的に SQL を生成するためと考えられる。

5.2. 材料ドメイン辞書の寄与

辞書の除去は全体で −6.7 pp の低下を引き起こしたが、その効果は難易度帯により異なった (表 5)。Easy $\cdot$ Medium 帯では低下が観察されず、Hard 帯で −7.3 pp、Very Hard 帯で −22.7 pp の低下が生じた。

Easy $\cdot$ Medium クエリは汎用的な表現で構成されるため、LLM 単体で SQL 条件を推論可能である。一方、Very Hard クエリは複数のドメイン固有用語を同時に含み、辞書なしでは LLM が正しい SQL 条件 (例: 「 γ' 相」 $\rightarrow$ `structure.prototype = 'L12'`) を生成できない場合がある。

Table 6: 各条件の平均レイテンシ (秒/クエリ)。 n -best = 1 への変更はレイテンシを 60% 低減するが精度は −0.2 pp。

条件	レイテンシ (s)
full	33.1
no_fewshot	64.1
no_dict	56.5
no_reranker	25.7
no_guard	39.4
no_nbest	13.0
no_graph	34.2

5.3. リランカーの寄与

リランカーの除去は −4.1 pp の低下を引き起こした。効果は Medium (−6.7 pp) および Hard (−6.2 pp) 帯で観察され、Very Hard 帯では −1.1 pp にとどまった (表 5)。

Very Hard 帯では 3 候補全てが不正確な場合が多く、リランカーの「最良候補選択」効果が限定される。一方、Medium $\cdot$ Hard 帯では少なくとも 1 候補が正確であることが多く、リランカーがその候補を正しく選択する効果が発揮される。

5.4. SQLGuard $\cdot$ n -best $\cdot$ Steiner 木の寄与

これら 3 構成要素はいずれも −0.2 pp の低下にとどまった。

SQLGuard については、リランカーが先に同等の選別機能を果たしているため、追加的な効果が観察されにくい状況にある。セキュリティ上の安全網としての価値は独立に存在する。

n -best = 1 への変更は精度をほぼ維持しつつレイテンシを 33.1 s から 13.0 s へ低減した (表 6)。コスト効率を重視する場合の有力な選択肢である。

Steiner 木については、現在の 30 テーブル規模では大半のクエリが 5 つのコアテーブルで完結するため効果が限定的であった。FK イントロスペクションに基づくアーキテクチャであるため、テーブル数が増加した場合 (例: OQMD 統合後) や別の正規化 RDB (Materials Project [3], AFLOW [4]) への適用時に効果が顕在化すると予想される。

5.5. 関連システムとの比較

表 7 に関連システムとの比較を示す。本手法は「正規化 RDB + 材料特化 + FK グラフ走査」の組合せで、既存アプローチがカバーしない領域を埋める。

5.6. LLM-only およびスキーマ提示のみとの定量比較

ablation study の結果を手法レベルの比較として再構成する。各 ablation 条件は、構成要素を除去した簡略手法に対応する (表 8)。

LLM-only はスキーマ情報を与えない構成であり、S3 節 (Supplementary Materials) に示すようにテーブル名 $\cdot$ カラム名の幻覚が発生し実行可能な SQL が生成されない。Full Schema 提示 (no_fewshot 条件に相当) はスキーマ定義をプロンプトに含めるが few-shot 例 $\cdot$ 辞書 $\cdot$ reranker を持たず、68.2% にとどまる。構成要素を段階的に追加するにつれ精度は単調に向上し、全構成要素を含む提案手法で 80.6% に達した。

なお、上記は各 ablation 条件の単一除去結果を段階的追加として再解釈したものであり、条件間の交互作用は分離

Table 7: 関連する材料 NLP / T2SQL / オントロジーシステムとの比較。

種別	名称	スキーマ 認識	正規化 RDB	材料 特化	NL→ クエリ	主な差異
<i>T2SQL</i> ベンチマーク						
データセット	Spider [6]	あり	あり	なし	SQL	汎用ベンチマーク
データセット	BIRD [7]	あり	あり	なし	SQL	大規模実データ
<i>T2SQL</i> 手法						
手法	DAIL-SQL [9]	あり	あり	なし	SQL	スケルトン選択
手法	RAT-SQL [10]	あり	あり	なし	SQL	関係認識符号化
手法	RESDSQL [11]	あり	あり	なし	SQL	スキーマリンク分離
手法	SchemaGraphSQL [12]	あり	あり	なし	SQL	パスファインディング
材料情報学						
手法	MKNA [15]	なし	なし	あり	API	エージェント
手法	OptiMat [16]	なし	なし	あり	API	オンデマンド DFT
オントロジー						
手法	SuperCon [17]	あり	なし	あり	SPARQL	RDF オントロジー
手法	PoLyInfo [18]	あり	なし	あり	SPARQL	BFO 準拠
手法	本手法	あり	あり	あり	SQL	FK 走査 + 材料辞書

Table 8: 手法レベルの定量比較。ablation 条件を手法構成として再解釈。全数値は ablation study (100 クエリ、単一ラン) の結果 (EVID-20260619-1335-ablation-json)。

手法構成	Overall	Easy	VH
LLM-only (スキーマ情報なし)	テーブル幻覚により実行不可 (S3 節参照)		
Full Schema 提示 (= no_fewshot: スキーマ+LLM、 few-shot 例なし)	68.2%	95.0	26.2
+ Few-shot RAG (= no_dict: +few-shot、辞書なし)	73.9%	100	15.8
+ 材料辞書 (= no_reranker: +辞書、 reranker なし)	76.6%	100	37.4
提案手法 (全構成要素)	80.6%	100	38.5

されていない。異なる手法 (DIN-SQL、DAIL-SQL 等) との同一 DB 上の直接比較は未実施である (制約 6 項参照)。

5.7. 多段計算クエリへの対応

本パイプラインの重要な拡張として、自然言語による多段計算指示への対応を実現した。代表例として「Ni₃Al の生成エンタルピーを純物質基準で計算して」というクエリを考える。このクエリに正しく応答するためには、以下の多段的なデータ抽出と計算が必要である：

1. 化合物 Ni₃Al の形成エネルギー E_f を `phase_stability` テーブルから取得する、
2. 構成元素 Ni, Al の組成比 x_i を `composition` テーブルから取得する、
3. 各元素の基底状態エネルギー $E_{\text{ref}}(i)$ を `pure_element_reference` テーブル (OQMD 由来、89 元素) から取得する、
4. 加重基準エネルギー $\sum_i x_i E_{\text{ref}}(i)$ を計算する、

5. 補正された生成エンタルピー $\Delta H_f = E_f - \sum_i x_i E_{\text{ref}}(i)$ を出力する。

この処理は単一テーブルの検索ではなく、3 テーブルの JOIN、サブクエリによる集約計算、および算術演算を含む CTE (Common Table Expression) として SQL に変換される必要がある。本パイプラインでは、`formation_enthalpy` テーブルと対応する few-shot 例の追加により、LLM がビュー経由の単純クエリと CTE 経由の明示的計算の両方のパターンを生成できるようにした。

従来の Text-to-SQL ベンチマーク (Spider [6]、BIRD [7] 等) では SELECT-WHERE-JOIN-GROUP BY の組合せが主であり、科学計算に不可欠な多段的データ統合と導出量の算出を要するクエリは評価対象に含まれていない。材料データベースにおいては、生成エンタルピー、体積サイズファクタ、格子ミスマッチ等の導出量が研究上重要であり、自然言語から直接これらの計算を指示できることは材料インフォマティクスにおける NL インターフェースの実用性を大きく向上させる。

5.8. RDB スキーマ設計と Text-to-SQL コスト

本研究を通じて得られた重要な知見として、RDB のテーブル構造そのものが Text-to-SQL 精度の上流要因であるという点が挙げられる。

正規化の度合いが高いスキーマでは、単一の問い合わせに対して複数テーブルの JOIN が必要となり、LLM が生成すべき SQL 文の複雑度が増大する。本データベースの生成エンタルピー計算 (?? 節) では、`phase_stability`、`composition`、`pure_element_reference` の 3 テーブル JOIN に加え、CTE による集約演算が必要であった。few-shot 例なしの条件では精度が -12.5 pp に低下することから (EVID-20260619-1335-ablation-nofewshot)、テーブル間の結合パターンが複雑なほど LLM 単体での正確な SQL 生成は困難であることが確認された。

この知見から、T2SQL 対応を前提としたスキーマ設計の方策として以下が考えられる：

1. ビューによる複雑度の隠蔽：頻出する多段 JOIN パターンをビューまたはマテリアライズドビューとして定義し、LLM には SELECT 一発で問い合わせ可能なインターフェースを提供する。本研究の `formation_enthalpy` ビューがこれに該当する。
2. クエリ頻度に基づく非正規化：高頻度で同時参照されるテーブル群（例： `composition` と `element` ）を結合済みテーブルとして提供することで、JOIN 数を削減する。
3. 自己説明的なカラム命名：カラム名にテーブルの文脈を埋め込む（例： `energy` → `formation_energy_per_atom` ）ことで、LLM がスキーマ情報のみから適切なカラムを選択できる確率を高める。
4. FK 制約の明示的定義：Steiner 木アルゴリズムは FK 関係に基づいて最小 JOIN 経路を決定するため、FK 制約が欠落しているスキーマでは自動 JOIN 解決が機能しない。T2SQL 対応を前提とする場合、FK 制約の網羅的な定義が必要である。

すなわち、Text-to-SQL システムの精度向上にはパイプライン側の改良のみならず、データベーススキーマの設計段階において NL インターフェースとの親和性を考慮することが有効である。この観点は、無機材料データベースに限らず、複雑なドメイン固有 RDB に Text-to-SQL を適用する際の一般的な設計指針となりうる。

5.9. 制約と今後の課題

1. 単一ランの評価：全 ablation 条件は単一ランの結果であり、LLM の非決定性による約 1-2 pp の変動が含まれる。信頼区間の算出には複数ランの評価が必要である。
2. データベース規模：現在のデータベースは 1,470 件の材料エントリを含むが、OQMD 等の大規模データベース（数十万件）へのスケーラビリティは未検証である。
3. 評価クエリの網羅性：100 件の著者設計クエリは材料研究の主要な検索パターンをカバーするよう設計したが、実運用での多様なクエリパターンを網羅するものではない。
4. **gold SQL** の検証：gold SQL ・期待結果は著者 1 名が作成し、第三者による独立検証は行っていない。
5. 用語辞書のカバレッジ：492 語の辞書は L1₂ 探索に特化しており、Heusler 型や Perovskite 型等の拡張には手動登録が必要である。
6. ベースラインの公平性：リペアループ、Few-Shot RAG、SQLGuard 等は提案手法のみに適用されており、各要素の寄与は ablation study で分離済みだが、他手法（DIN-SQL、DAIL-SQL 等）との同一 DB 上の比較は未実施である。

5.10. 今後の展望

1. 大規模データ検証：OQMD 単元素データの統合により 1 万件規模での Steiner 木探索と SQL 生成精度の検証を行う。
2. 多段計算クエリの評価：生成エンタルピー計算対応（5.7 節）を評価クエリセットに追加し、CTE ・ビュー経由の多段計算精度を定量評価する。
3. **AI4S** エージェント統合：T2SQL 手法を MCP プロトコルや function calling 経由で自律材料探索エージェントのツールとして組み込む。

4. **CALPHAD** 連携：Schema Graph 走査で RDB から候補を絞り込んだ後、CALPHAD の自由エネルギー計算により温度依存相安定性を判定する二段階フロー。
5. 用語辞書の体系的拡張：スキーマメタデータからの半自動生成に移行し、新テーブル追加時の辞書保守コストを削減する。
6. 評価指標の多軸化：SELECT 列適合率、JOIN 経路一致率、Top-k accuracy 等を分離評価し、エラーの原因特定を容易にする。

6. 結論

無機材料データベースのためのグラフ制約付き Text-to-SQL パイプラインを提案し、7 条件 × 100 件の ablation study（計 700 回評価）により各構成要素の寄与を定量化した。

全構成要素を有効にした full 条件での行一致精度は 80.6% であった（EVID-20260619-1335-ablation-full）。Ablation study により、few-shot 例（-12.5 pp）、材料ドメイン辞書（-6.7 pp）、ハイブリッドリランカー（-4.1 pp）が精度に寄与する上位 3 構成要素であることが確認された。材料ドメイン辞書は Very Hard 帯で -22.7 pp の低下を引き起こし、ドメイン特化の用語マッピングが複雑クエリにおいて不可欠であることを示した。

FK イントロスペクションに基づく Steiner 木アーキテクチャは、任意の正規化材料 RDB（OQMD、Materials Project、AFLOW 等）への自動適応が可能であり、Materials Integration（MInt）システム [23] や provenance 管理システム pinax [24] への適用が期待される。

さらに、OQMD 由来の 89 元素基底状態データの統合と `formation_enthalpy` ビューの導入により、「Ni₃Al の生成エンタルピーを純物質基準で計算して」のような多段計算を伴うクエリに自然言語から対応可能であることを示した。3 テーブル JOIN と CTE による加重基準エネルギー計算を含むこの種のクエリは従来の Text-to-SQL ベンチマークの範囲外であり、材料データベース固有の要求に応える機能拡張である。この実装を通じて、RDB スキーマの正規化度とテーブル構造が Text-to-SQL 精度の上流要因となることが明らかとなった（5.8 節）。ビュー定義による複雑度の隠蔽、クエリ頻度に基づく非正規化、自己説明的なカラム命名、FK 制約の網羅的定義といったスキーマ設計の方策は、パイプライン側の改良と並行して Text-to-SQL 精度を向上させる有効な手段である。

本評価は単一ランの結果であり、LLM の非決定性に起因する約 1-2 pp の変動を含む可能性がある。

謝辞

L1₂ 型金属間化合物の DFT 計算データは Open Quantum Materials Database（OQMD）の値を参考に構築した合成検証データである。キュリー温度・Σ5 粒界エネルギー・合成法・文献参照等の属性は OQMD に存在せず、検証用に生成したものである。OQMD の開発・維持管理にあたる Northwestern 大学 Wolverton グループに感謝する。本研究は NIMS の支援を受けた。

データ・コード利用可能性

評価データセット (100 件の gold SQL・期待結果)、ablation 結果 (7 条件 × 100 件の JSON)、MeCab 材料辞書 (492 語、コンパイル済み.dic)、日本語 reranker 比較結果、および全スクリプトはリポジトリ内に含まれる。論文中の全数値は `scripts/compute_all_figures.py` により `paper/paper_data.json` へ出力され、手入力の数値は含まない。ユニットテスト 134 件が全 PASS を達成した。

Author Contributions

Satoshi Minamoto: 研究構想、手法設計、ソフトウェア実装、データベース構築、実験実施、論文執筆。

References

- [1] J.E. Saal, S. Kirklin, M. Aykol, B. Meredig, C. Wolverton, Materials design and discovery with high-throughput density functional theory: The Open Quantum Materials Database (OQMD), *JOM* 65 (2013) 1501–1509.
- [2] S. Kirklin, J.E. Saal, B. Meredig, A. Thompson, J.W. Doak, M. Aykol, S. Rühl, C. Wolverton, The Open Quantum Materials Database (OQMD): Assessing the accuracy of DFT formation energies, *npj Comput. Mater.* 1 (2015) 15010.
- [3] A. Jain, S.P. Ong, G. Hautier, W. Chen, W.D. Richards, S. Dacek, S. Cholia, D. Gunter, D. Skinner, G. Ceder, K.A. Persson, Commentary: The Materials Project: A materials genome approach to accelerating materials innovation, *APL Mater.* 1 (2013) 011002.
- [4] S. Curtarolo, W. Setyawan, G.L.W. Hart, M. Jahnatek, R.V. Chepulskii, R.H. Taylor, S. Wang, J. Xue, K. Yang, O. Levy, M.J. Mehl, H.T. Stokes, D.O. Demchenko, D. Morgan, AFLOW: An automatic framework for high-throughput materials discovery, *Comput. Mater. Sci.* 58 (2012) 218–226.
- [5] C. Draxl, M. Scheffler, NOMAD: The FAIR concept for big data-driven materials science, *MRS Bull.* 43 (2018) 676–682.
- [6] T. Yu, R. Zhang, K. Yang, M. Yasunaga, D. Wang, Z. Li, J. Ma, I. Li, Q. Yao, S. Roman, Z. Zhang, D. Radev, Spider: A large-scale human-labeled dataset for complex and cross-database semantic parsing and text-to-SQL task, in: *Proc. EMNLP*, 2018, pp. 3911–3921.
- [7] J. Li, B. Hui, G. Qu, J. Yang, B. Li, B. Li, B. Wang, B. Qin, R. Geng, N. Huo, X. Zhou, C. Ma, G. Li, K. Chang, F. Huang, R. Cheng, Y. Li, Can LLM already serve as a database interface? A Big bench for large-scale database grounded text-to-SQL, in: *Proc. NeurIPS*, 2024.
- [8] M. Pourreza, D. Rafiei, DIN-SQL: Decomposed in-context learning of text-to-SQL with self-correction, in: *Proc. NeurIPS*, 2024.
- [9] D. Gao, H. Wang, Y. Li, X. Sun, Y. Qian, B. Ding, J. Zhou, Text-to-SQL empowered by large language models: A benchmark evaluation, in: *Proc. VLDB*, 2024.
- [10] B. Wang, R. Shin, X. Liu, O. Polozov, M. Richardson, RAT-SQL: Relation-aware schema encoding and linking for text-to-SQL parsers, in: *Proc. ACL*, 2020, pp. 7567–7578.
- [11] H. Li, J. Zhang, C. Li, H. Chen, RESDSQL: Decoupling schema linking and skeleton parsing for text-to-SQL, in: *Proc. AAAI*, 2023.
- [12] F. Safdarian, S. Kacupaj, SchemaGraphSQL: Schema-graph-based text-to-SQL with path finding, in: *Proc. NAACL*, 2026.
- [13] T. Gupta, M. Zaki, N.M.A. Krishnan, M. Mausam, MatSciBERT: A materials domain language model for text mining and information extraction, *npj Comput. Mater.* 8 (2022) 102.
- [14] N. Walker, J. Dagdelen, K. Cruse, A. Jain, A. Ceder, Extracting structured seed-mediated gold nanorod growth procedures from scientific text with MatBERT, *Digital Discovery* 1 (2022) 413–427.
- [15] Y. Zhuang et al., MKNA: Materials knowledge navigation agent, *Nat. Comput. Sci.* (2026).
- [16] Y. Hu et al., OptiMat: On-demand DFT-driven materials optimization, *npj Comput. Mater.* (2026).
- [17] M. Ishii et al., SuperCon: Linked data platform for superconducting materials, *J. Phys.: Condens. Matter* (2023).
- [18] M. Ishii et al., PoLyInfo: BFO-compliant polymer ontology, *J. Chem. Inf. Model.* (2024).
- [19] G. Salton, C. Buckley, Term-weighting approaches in automatic text retrieval, *Inf. Process. Manag.* 24 (1988) 513–523.
- [20] T. Brown et al., Language models are few-shot learners, in: *Proc. NeurIPS*, 2020.
- [21] A.A. Hagberg, D.A. Schult, P.J. Swart, Exploring network structure, dynamics, and function using NetworkX, in: *Proc. SciPy*, 2008.
- [22] T. Mao, sqlglot: Python SQL parser and transpiler, 2023. <https://github.com/tobymao/sqlglot>
- [23] S. Minamoto, Materials integration system for process-structure-property-performance chains, *Sci. Technol. Adv. Mater.* (2020).
- [24] S. Minamoto, pinax: Provenance-tracking analysis workflow management system, (2026).

Supplementary Materials

Schema-Graph-Constrained Natural Language Interface for Intermetallic Compound Exploration

金属間化合物探索のための Schema Graph 制約型 自然言語データベースインターフェース

Satoshi Minamoto

National Institute for Materials Science (NIMS),
1-2-1 Sengen, Tsukuba, Ibaraki 305-0047, Japan

minamoto.satoshi@nims.go.jp

本補足資料では、本論文で提案した Schema Graph 制約型 Text-to-SQL システムの検証・評価に関する詳細情報を提供する。S1 節ではユニットテストの全カテゴリと検証焦点を示し、S2 節で回帰テストケース 39 件の一覧を掲載する。S3 節では代表的なクエリに対する生成 SQL 例を比較し、本手法の JOIN パス制約の効果を具体的に示す。S4 節では SQL インジェクション攻撃を含む安全性テスト結果を報告する。S5 節では LLM モード (GPT-5.5) の設定パラメータとプロンプト構成を記載する。S6 節では評価クエリ 100 件の詳細結果 (クエリ文、精度、レイテンシ) を一覧する。S7 節では ablation study 7 条件間で結果が異なるクエリの比較を示す。全数値は `paper_data.json` から取得 (EVID-20260619-1335-ablation-json)。

S1. ユニットテストカテゴリ詳細

開発安全性テストとして 6 カテゴリ 39 件の回帰テスト、SQL 検証テスト 6 件、Coverage Score・パーサーテスト 15 件、Intent Classifier テスト 20 件の計 80 件を構築した (表 S1)。これらに加え、エイリアス解決テスト、スーパーセット検出テスト等を含む全 134 件のユニットテストが全 PASS を達成した。

Table S1: ユニットテストカテゴリ (全 134 件、全 PASS)。

カテゴリ	ID	<i>n</i>	検証焦点
正常系	A01-A15	15	L1 ₂ 元素・プロトタイプ・安定性・ソート・複合条件
該当なし	B01-B05	5	希ガス元素、非存在組合せ → 0 行期待
曖昧な入力	C01-C10	10	空入力、無関係テキスト、単語のみ
矛盾条件	D01-D02	2	「安定かつ準安定」等
SQL インジェクション	E01-E05	5	DROP, DELETE, INSERT、ピギーバック攻撃
安全性検査	F01-F02	2	直接 SQL 入力 (SELECT, UPDATE)
SQL 検証	—	6	カラム/テーブルホワイトリスト、JOIN 検証
Coverage・パーサー	—	15	数値条件、化学式、Coverage Score
Intent Classifier	—	20	VASP/DFT ワークフロー検出、分類
エイリアス解決	—	15	ORDER BY/HAVING 参照、カラムエイリアス
スーパーセット検出	—	10	過剰取得判定、行比率閾値
その他	—	29	Schema Graph 走査、辞書マッピング、エンティティ抽出

S2. 回帰テストケース一覧

表 S2 に回帰テスト 39 件 (正常系・該当なし・曖昧・矛盾・SQL インジェクション・安全性) のクエリと結果を示す。

S3. 生成 SQL 例

代表的なクエリに対する生成 SQL 例を、3 段階の手法構成 (LLM-only、Full Schema 提示、本手法) で比較する。本文の表 8 の定量比較を補完し、各構成の出力 SQL の質的差異を具体的に示す。

Table S2: 回帰テストケース一覧（全 39 件、全 PASS）。

ID	カテゴリ	自然言語クエリ	結果
A01	正常系	Fe を含む L1 ₂ 化合物を出して	PASS
A02	正常系	安定な L1 ₂ 化合物を形成エネルギー順に出して	PASS
A03	正常系	Ni と Al の両方を含む化合物を出して	PASS
A04	正常系	L1 ₂ 化合物の全リストを出して	PASS
A05	正常系	準安定な L1 ₂ 化合物を出して	PASS
A06	正常系	Co を含む安定な L1 ₂ 化合物を出して	PASS
A07	正常系	Fe と Al を含む L1 ₂ 化合物を出して	PASS
A08	正常系	γ' 化合物を出して	PASS
A09	正常系	ニッケルを含む L1 ₂ 型化合物を出して	PASS
A10	正常系	L1 ₂ 化合物の全データを出して	PASS
A11	正常系	Ti を含む L1 ₂ 化合物を格子定数順（降順）に出して	PASS
A12	正常系	安定な L1 ₂ で格子定数 3.5Å 以上のものを出して	PASS
A13	正常系	Cu ₃ Au 型化合物を出して	PASS
A14	正常系	鉄を含む L1 ₂ 化合物を出して	PASS
A15	正常系	安定な L1 ₂ 化合物で Ni を含むものを出して	PASS
B01	該当なし	Xe を含む L1 ₂ 化合物を出して	PASS
B02	該当なし	U と Pu を含む L1 ₂ 化合物を出して	PASS
B03	該当なし	Rn と Og を含む L1 ₂ 化合物を出して	PASS
B04	該当なし	Sc と Ir を含む安定な L1 ₂ 化合物を出して	PASS
B05	該当なし	Pt と Ga を含む安定な L1 ₂ 化合物を出して	PASS
C01	曖昧	安定な化合物を出して	PASS
C02	曖昧	L12	PASS
C03	曖昧	安定なものを出して	PASS
C04	曖昧	（空入力）	PASS
C05	曖昧	今日の天気を教えて	PASS
C06	曖昧	Fe	PASS
C07	曖昧	格子定数	PASS
C08	曖昧	形成エネルギーが低い安定な L1 ₂ 化合物	PASS
C09	曖昧	NiAl L12	PASS
C10	曖昧	Ni の L12	PASS
D01	矛盾	安定かつ準安定な L1 ₂ 化合物	PASS
D02	矛盾	Ni なしの Ni L1 ₂ 化合物	PASS
E01	拒否	DROP TABLE material_entry;	PASS
E02	拒否	SELECT *; DELETE FROM composition;	PASS
E03	拒否	L1 ₂ 化合物; DROP TABLE structure;	PASS
E04	拒否	SELECT * FROM secret_passwords	PASS
E05	拒否	INSERT INTO material_entry VALUES (...)	PASS
F01	安全性	SELECT entry_id FROM material_entry	PASS
F02	安全性	UPDATE material_entry SET formula='X'	PASS

S3.1. 「Niを含む安定な $L1_2$ 化合物を出して」

LLM-only (スキーマ情報なし): .「

```
1 SELECT formula, stability
2 FROM materials
3 WHERE element = 'Ni'
4     AND structure_type = 'L12'
5     AND stability = 'stable';
6 -- テーブル幻覚: materials, stability等は存在しない
7 -- 実行不可 (ERROR: relation "materials" does not exist)
```

Full Schema 提示 (スキーマ定義をプロンプトに含めるが few-shot 例なし): .「

```
1 SELECT m.formula, ps.is_stable
2 FROM material_entry m
3     JOIN composition c ON c.entry_id = m.entry_id
4     JOIN structure s ON s.entry_id = m.entry_id
5     JOIN phase_stability ps ON ps.entry_id = m.entry_id
6 WHERE c.element = 'Ni'
7     AND s.strukturbericht = 'L12'
8     AND ps.is_stable = true;
9 -- 実行可能だが不完全:
10 -- (1) prototype条件なし (L12がstrukturberichtに
11 --   ない場合を見落とし)
12 -- (2) DISTINCT/LIMITなし
13 -- (3) 格子定数等の材料的に有用な列を選択していない
```

本手法 (Schema Graph 制約 + Few-shot + 辞書): .「

```
1 SELECT DISTINCT m.entry_id, m.formula,
2     s.prototype, s.lattice_a, s.space_group
3 FROM material_entry m
4     JOIN composition c ON c.entry_id = m.entry_id
5     JOIN structure s ON s.entry_id = m.entry_id
6     JOIN phase_stability ps ON ps.entry_id = m.entry_id
7 WHERE (s.prototype = 'L12'
8     OR s.strukturbericht = 'L12')
9     AND c.element = 'Ni'
10    AND ps.energy_above_hull <= 0.001
11 LIMIT 10000;
12 -- Schema Graph走査で必要な3 JOINのみ
13 -- テーブル幻覚なし、DISTINCT, LIMIT付き
```

S3.2. 「NiとAlの両方を含む $L1_2$ 化合物を出して」

LLM-only (スキーマ情報なし): .「

```
1 SELECT * FROM compounds
2 WHERE elements LIKE '%Ni%' AND elements LIKE '%Al%'
3     AND crystal_structure = 'L12';
4 -- テーブル幻覚: compounds, elements列は存在しない
```

Full Schema 提示 (few-shot 例なし): .「

```
1 SELECT m.entry_id, m.formula
2 FROM material_entry m
3     JOIN composition c ON c.entry_id = m.entry_id
4     JOIN structure s ON s.entry_id = m.entry_id
5 WHERE c.element = 'Ni' AND c.element = 'Al'
6     AND s.prototype = 'L12';
7 -- 致命的: 単一行が両条件を同時に満たすことは
8 -- 不可能 -> 常に0行
```

本手法 (EXISTS 副問い合わせ): .「

```
1 SELECT DISTINCT m.entry_id, m.formula
2 FROM material_entry m
3     JOIN structure s ON s.entry_id = m.entry_id
4 WHERE (s.prototype = 'L12'
5     OR s.strukturbericht = 'L12')
6 AND EXISTS (
7     SELECT 1 FROM composition
8     WHERE entry_id = m.entry_id AND element = 'Ni')
9 AND EXISTS (
10    SELECT 1 FROM composition
11    WHERE entry_id = m.entry_id AND element = 'Al')
12 LIMIT 10000;
13 -- EXISTS副問い合わせで正確な多元素AND
```

Table S3: SQL インジェクション・安全性テスト結果（全件安全処理）。

ID	入力	処理
E01	DROP TABLE material_entry;	禁止キーワード：DROP
E02	SELECT *; DELETE FROM composition;	複数文 + DELETE
E03	L1 ₂ 化合物; DROP TABLE structure;	複数文 + DROP
E04	SELECT * FROM secret_passwords	非許可テーブル
E05	INSERT INTO material_entry ...	禁止キーワード：INSERT
F01	SELECT entry_id FROM material_entry	LIMIT 自動付加（安全化）
F02	UPDATE material_entry SET ...	禁止キーワード：UPDATE

S4. SQL インジェクション・安全性テスト結果

7 件の敵対的入力（E01–E05、F01–F02）はすべて SQLGuard により安全に処理された（表 S3）。破壊的・注入的入力は遮断され、LIMIT なしの直接 SELECT は LIMIT 自動付加により安全化された。

S5. LLM モード設定

LLM モードでは OpenAI API を介して GPT-5.5 を使用した。表 S4 にモデルパラメータを示す。

Table S4: LLM モード設定パラメータ（EVID-20260619-1335-model-gpt55）。

パラメータ	値
モデル名	GPT-5.5（OpenAI）
API アクセス日	2026 年 5–6 月
Temperature	未指定（GPT-5 系は temperature パラメータ未サポート）
Max tokens	4,096（全手法共通）
Top- <i>p</i>	1.0
リクエストタイムアウト	30 秒
リトライ回数	最大 3 回（指数バックオフ）
n-best 候補数	3
Cross-Encoder	ms-marco-MiniLM-L-6-v2
リペアループ上限	3 回

構造化プロンプトは以下の 4 要素から構成される：

1. システムメッセージ：タスク説明 + スキーマ YAML（テーブル名、カラム名、型、FK 関係）
2. **Few-Shot** 事例：TF-IDF + Cross-Encoder で選択された Top-*k* 類似 NL-SQL ペア
3. ユーザーメッセージ：自然言語クエリ
4. 制約：「SELECT 文のみ生成」「LIMIT 10000 を含める」「スキーマに記載されたテーブルのみ使用」

GPT-5 系 API では temperature パラメータはサポートされておらず、本実装でも送信していない。そのため、LLM の内部状態により同一入力でも出力が変動する可能性がある。本論文の全 ablation 結果は単一ランであり、信頼区間の算出は行っていない。

S6. 評価クエリ 100 件の詳細結果

表 S5 に評価クエリ 100 件（著者設計、E=20/M=30/H=30/VH=20）の各クエリの質問文、実行精度（行一致 recall）、レイテンシ、正誤判定（精度 ≥ 0.8 で ✓）を示す。全数値は ablation full 条件の結果（EVID-20260619-1335-ablation-json）である。

Table S5: 評価クエリ 100 件の詳細結果（full 条件）。

ID	クエリ	精度	秒	正誤
Easy（20 件）				
q_easy_001	L1 ₂ 構造を持つ化合物を一覧にして。	1.00	29.7	✓

次ページに続く

ID	クエリ	精度	秒	正誤
q_easy_002	Ni を含む L1 ₂ 型金属間化合物を抽出して。	1.00	44.3	✓
q_easy_003	A ₃ B 型組成を持つ化合物を表示して。	1.00	31.5	✓
q_easy_004	L12 型化合物の格子定数を一覧にして。	1.00	13.1	✓
q_easy_005	Co を含む化合物を表示して。	1.00	17.2	✓
q_easy_006	cubic 構造の化合物を一覧にして。	1.00	12.6	✓
q_easy_007	L1 ₂ 型化合物のリストを出して。	1.00	20.9	✓
q_easy_008	Al を含む化合物を抽出して。	1.00	16.3	✓
q_easy_009	空間群番号 221 の化合物を表示して。	1.00	13.1	✓
q_easy_010	Ti を含む L1 ₂ 型化合物を一覧にして。	1.00	23.7	✓
q_easy_011	全化合物の formula 一覧を出して。	1.00	12.3	✓
q_easy_012	L12 型化合物の数を教えて。	1.00	19.9	✓
q_easy_013	Pt を含む化合物を表示して。	1.00	14.7	✓
q_easy_014	Ni と Al の両方を含む化合物を抽出して。	1.00	17.9	✓
q_easy_015	Ga を含む L1 ₂ 型化合物を表示して。	1.00	37.5	✓
q_easy_016	Fe を含む化合物を一覧にして。	1.00	20.1	✓
q_easy_017	A サイトの元素を一覧にして。	1.00	10.7	✓
q_easy_018	化合物の元素系を表示して。	1.00	13.7	✓
q_easy_019	L1 ₂ 型で cubic 構造の化合物を出して。	1.00	18.4	✓
q_easy_020	W を含む L1 ₂ 型化合物を表示して。	1.00	34.4	✓
Medium (30 件)				
q_medium_001	Ni を含む安定な L1 ₂ 型化合物を抽出して。	1.00	26.4	✓
q_medium_002	形成エネルギーが負の L1 ₂ 型化合物を元素組み合わせごとに整理して。	1.00	29.0	✓
q_medium_003	Al を含む安定な L1 ₂ 型金属間化合物を抽出して。	1.00	43.3	✓
q_medium_004	Ni ₃ Al に近い格子定数を持つ L1 ₂ 化合物を探して。	1.00	34.9	✓
q_medium_005	安定な L1 ₂ 型化合物を形成エネルギーが低い順に出して。	1.00	33.9	✓
q_medium_006	準安定な L1 ₂ 型化合物を抽出して。	0.84	34.3	✓
q_medium_007	L1 ₂ 型化合物の形成エネルギー分布を教えて。	1.00	24.8	✓
q_medium_008	Co 含有 L1 ₂ 型化合物を安定性の高い順に表示して。	1.00	25.6	✓
q_medium_009	格子定数が 3.5Å 以上の L1 ₂ 化合物を出して。	1.00	14.3	✓
q_medium_010	Ni または Co を含む L1 ₂ 型化合物を一覧にして。	1.00	34.7	✓
q_medium_011	形成エネルギーが -0.4 以下の L1 ₂ 型化合物を出して。	1.00	20.5	✓
q_medium_012	energy above hull が 0.01 以下の L1 ₂ 型化合物を表示して。	1.00	31.0	✓
q_medium_013	Ti 含有 L1 ₂ 型化合物の格子定数と形成エネルギーを表示して。	1.00	18.0	✓
q_medium_014	L1 ₂ 化合物の格子定数を小さい順にソートして。	1.00	16.5	✓
q_medium_015	化学系 Al-Ni に属する L1 ₂ 化合物を抽出して。	1.00	20.9	✓
q_medium_016	安定で格子定数が 3.6Å 未満の L1 ₂ 化合物を出して。	1.00	24.2	✓
q_medium_017	Nb を含む L1 ₂ 型化合物の安定性情報を出して。	1.00	30.8	✓
q_medium_018	Sc を含む L1 ₂ 型化合物を格子定数と共に表示して。	1.00	26.6	✓
q_medium_019	L1 ₂ 型化合物のうち is_stable が true のものを出して。	1.00	30.1	✓
q_medium_020	Ni-Al 系以外の L1 ₂ 型化合物を一覧にして。	1.00	19.6	✓
q_medium_021	A サイト元素ごとの L1 ₂ 型化合物数を集計して。	1.00	24.4	✓
q_medium_022	形成エネルギーが最も低い L1 ₂ 型化合物 TOP5 を出して。	1.00	25.9	✓
q_medium_023	格子定数が 4.0Å 以上の L1 ₂ 化合物を出して。	1.00	16.3	✓
q_medium_024	Pd を含む L1 ₂ 型化合物を形成エネルギー順に出して。	1.00	43.6	✓
q_medium_025	Cu 含有の L1 ₂ 型化合物を安定性で分類して。	1.00	33.7	✓
q_medium_026	B サイト元素ごとの平均形成エネルギーを出して。	0.00	29.2	—
q_medium_027	格子体積が 12Å ³ /atom 以下の L1 ₂ 化合物を出して。	1.00	19.8	✓
q_medium_028	Ir 含有 L1 ₂ 型化合物の一覧を出して。	1.00	23.7	✓
q_medium_029	2 元素系の L1 ₂ 型化合物を chemical_system で分類して。	1.00	21.9	✓
q_medium_030	安定な L1 ₂ 型化合物のうち格子定数が大きい順に並べて。	1.00	28.8	✓

次ページに続く

ID	クエリ	精度	秒	正誤
Hard (30 件)				
q_hard_001	Ni 基超合金の γ' 相候補として有望な安定/準安定 L1 ₂ 化合物。	0.06	70.6	—
q_hard_002	A サイト × B サイト組み合わせと形成エネルギーの関係。	1.00	36.0	✓
q_hard_003	格子定数が Ni ₃ Al に近く形成エネルギーが低い候補。	1.00	40.7	✓
q_hard_004	安定 L1 ₂ のバルクモジュラスを高い順に表示。	1.00	29.5	✓
q_hard_005	Ni/Co を含む安定 L1 ₂ を形成エネルギー順に。	1.00	45.9	✓
q_hard_006	A サイト元素別の平均格子定数を集計。	1.00	23.5	✓
q_hard_007	$E_f \leq -0.3$ かつ $a = 3.5\text{--}3.7\text{\AA}$ の L1 ₂ 化合物。	1.00	25.7	✓
q_hard_008	バルクモジュラス 180GPa 以上の L1 ₂ 化合物。	1.00	26.8	✓
q_hard_009	Co 基 L1 ₂ で Ni ₃ Al に近い格子定数、安定性順。	1.00	50.6	✓
q_hard_010	B サイト Al/Ti の L1 ₂ を形成エネルギー順に。	1.00	25.4	✓
q_hard_011	L1 ₂ 化合物のせん断弾性率を表示。	1.00	23.0	✓
q_hard_012	安定で E_f 最低の L1 ₂ トップ 10。	0.50	29.4	—
q_hard_013	Ni 含有 L1 ₂ のバルクモジュラスと E_f の関係。	1.00	38.5	✓
q_hard_014	A サイト元素グループ別平均 E_f 。	0.00	34.8	—
q_hard_015	$a \approx 3.55\text{\AA}$ でバルクモジュラスの高い L1 ₂ 。	0.51	36.3	—
q_hard_016	格子定数と E_f の相関データ。	1.00	18.9	✓
q_hard_017	Co ₃ Ti と Ni ₃ Al の格子定数差を計算。	1.00	31.0	✓
q_hard_018	Al 系 L1 ₂ の安定/不安定の件数。	0.00	35.6	—
q_hard_019	準安定 L1 ₂ を energy above hull 順にランキング。	0.84	31.0	✓
q_hard_020	B サイト元素ごとの安定 L1 ₂ 数を集計。	0.20	21.8	—
q_hard_021	DFT 計算で得られた物性一覧。	1.00	36.6	✓
q_hard_022	PBE 汎関数計算のバルクモジュラス。	1.00	25.3	✓
q_hard_023	Ni ₃ Al との格子ミスマッチを小さい順に。	1.00	19.0	✓
q_hard_024	Fe 含有 L1 ₂ の安定性と弾性特性を同時表示。	0.00	31.2	—
q_hard_025	安定 L1 ₂ でバルクモジュラス 160GPa 以上。	1.00	36.9	✓
q_hard_026	安定性 × 格子定数で Ni ₃ Al に近い候補。	1.00	30.0	✓
q_hard_027	A サイト=Ni/Co、B サイト=Al/Ti の L1 ₂ 。	1.00	34.8	✓
q_hard_028	体積あたり原子数と格子定数の関係。	1.00	23.2	✓
q_hard_029	$E_{hull} = 0$ かつ $E_f \leq -0.4$ の L1 ₂ 。	1.00	30.7	✓
q_hard_030	遷移金属含有の安定 L1 ₂ 。	1.00	58.2	✓
Very Hard (20 件)				
q_vhard_001	相安定性 × 格子ミスマッチ × 弾性の多基準評価。	0.19	57.6	—
q_vhard_002	Ni ₃ Al 代替/ γ' 候補の多基準探索。	0.04	57.9	—
q_vhard_003	γ' 候補の重み付きスコアでランキング。	0.00	53.3	—
q_vhard_004	Ni/Co 含有 × 安定 × 高 B のトップ 10。	1.00	32.2	✓
q_vhard_005	元素組み合わせ × 安定性を A/B サイト別に集計。	1.00	62.9	✓
q_vhard_006	Ni ₃ Al に近い格子 × 高 B × 安定の総合評価。	0.19	50.6	—
q_vhard_007	析出強化 L1 ₂ の多基準 (ミスマッチ × G × 安定性)。	1.00	52.8	✓
q_vhard_008	Co 基 γ' 候補の Ni ₃ Al 比較付き探索。	0.11	43.2	—
q_vhard_009	B/G 比で ductile/brittle を分類。	0.00	43.0	—
q_vhard_010	E_f vs E_{hull} の安定性マップデータ。	1.00	51.9	✓
q_vhard_011	高温安定性の観点で E_f 上位候補。	0.09	38.6	—
q_vhard_012	Ni-Al 系以外の γ' 代替候補。	0.18	35.2	—
q_vhard_013	B vs a の散布図データ出力。	1.00	20.7	✓
q_vhard_014	3d vs 4d/5d 遷移金属 A サイトの比較。	0.88	56.4	✓
q_vhard_015	Ni ₃ Al より安定で B が高い候補。	0.02	137.7	—
q_vhard_016	Co-Al-W 系 L1 ₂ 候補の安定性 × 弾性。	0.00	53.0	—
q_vhard_017	安定性 × 格子整合 × 弾性の複合スコア。	1.00	55.2	✓
q_vhard_018	γ' 候補の多変量 (B , E_f , Δa) ランキング。	0.00	58.1	—
q_vhard_019	安定化合物の元素パターンから材料設計仮説を導出。	0.00	62.7	—

次ページに続く

ID	クエリ	精度	秒	正誤
q_vhard_020	Ni-Al-Co-Ti 四元系 L1 ₂ 候補探索。	0.00	53.7	—

S7. Ablation 条件間の精度差異クエリ

表 S6 に、7 条件間で精度が異なる 30 件のクエリを示す。太字は full 条件から 0.05 以上低下した値を表す。-FS = no_fewshot、-Dict = no_dict、-RR = no_reranker、-GD = no_guard、-NB = no_nbest、-GR = no_graph。

Table S6: Ablation 条件間で精度が異なるクエリ (30 件/100 件)。太字は full 条件から > 0.05 の低下。

ID	D	Full	-FS	-Dict	-RR	-GD	-NB	-GR
q_easy_007	E	1.00	0.00	1.00	1.00	1.00	1.00	1.00
q_hard_001	H	0.06	0.00	0.00	0.06	0.06	0.06	0.06
q_hard_002	H	1.00	1.00	0.00	1.00	1.00	1.00	1.00
q_hard_003	H	1.00	0.00	1.00	0.01	1.00	1.00	1.00
q_hard_004	H	1.00	0.00	1.00	1.00	1.00	1.00	1.00
q_hard_006	H	1.00	1.00	0.00	1.00	1.00	1.00	1.00
q_hard_010	H	1.00	0.00	1.00	1.00	1.00	1.00	1.00
q_hard_011	H	1.00	0.00	1.00	1.00	1.00	1.00	1.00
q_hard_012	H	0.50	0.50	0.38	0.50	0.50	0.50	0.50
q_hard_024	H	0.00	0.00	0.00	0.11	0.00	0.00	0.00
q_hard_026	H	1.00	1.00	1.00	0.01	1.00	1.00	1.00
q_medium_001	M	1.00	0.00	1.00	1.00	1.00	1.00	1.00
q_medium_004	M	1.00	1.00	1.00	0.00	1.00	1.00	1.00
q_medium_012	M	1.00	0.00	1.00	1.00	1.00	1.00	1.00
q_medium_013	M	1.00	0.00	1.00	1.00	1.00	1.00	1.00
q_medium_014	M	1.00	0.00	1.00	1.00	1.00	1.00	1.00
q_medium_020	M	1.00	1.00	1.00	0.00	1.00	1.00	1.00
q_medium_021	M	1.00	0.00	1.00	1.00	1.00	1.00	1.00
q_medium_026	M	0.00	0.05	0.00	0.00	0.00	0.00	0.00
q_vhard_001	V	0.19	0.00	0.00	0.19	0.00	0.00	0.00
q_vhard_002	V	0.04	0.17	0.19	0.03	0.02	0.00	0.02
q_vhard_004	V	1.00	1.00	0.00	1.00	1.00	1.00	1.00
q_vhard_005	V	1.00	1.00	0.00	1.00	1.00	1.00	1.00
q_vhard_006	V	0.19	0.19	0.00	0.19	0.19	0.19	0.19
q_vhard_007	V	1.00	0.00	0.00	1.00	1.00	1.00	1.00
q_vhard_008	V	0.11	0.11	0.00	0.11	0.11	0.11	0.11
q_vhard_012	V	0.18	0.18	0.00	0.18	0.18	0.18	0.18
q_vhard_013	V	1.00	0.00	1.00	1.00	1.00	1.00	1.00
q_vhard_015	V	0.02	0.02	0.00	0.21	0.02	0.00	0.07
q_vhard_017	V	1.00	0.60	0.00	0.60	1.00	1.00	1.00

表 S6 から、以下の傾向が読み取れる：

- no_fewshot (-FS) では Easy-Hard 帯のクエリが広範に 0 化し、few-shot 例の汎用的な寄与を示す。
- no_dict (-Dict) では Very Hard 帯で集中的に 0 化し、ドメイン辞書が VH 帯に不可欠であることを裏付ける。
- no_reranker (-RR) では q_hard_003, q_hard_026, q_medium_004, q_medium_020 で完全失敗し、候補選別の効果を示す。
- no_guard, no_nbest, no_graph は差異クエリ数が限定的であり、本文で報告した -0.2pp と整合する。
- q_vhard_001 は full 条件と -RR 条件で 0.19 であるが、他の 5 条件では 0。これは few-shot + dict の複合効果を示唆する（リランカーの除去は精度に影響しなかった）。