

無機材料リレーショナルデータベースの自然言語アクセス —スキーマグラフ制約型 Text-to-SQL による設計原理と実証—

Satoshi Minamoto^{a,*}

^aNational Institute for Materials Science (NIMS), 1-2-1 Sengen, Tsukuba, Ibaraki 305-0047, Japan

Abstract

無機材料データベースは SQL の知識を前提としており、材料研究者にとってデータ活用の障壁となっている。本研究では、無機材料リレーショナルデータベース (RDB) への自然言語アクセスを実現する Text-to-SQL パイプラインの設計原理を提示し、その有効性を実証する。提案手法は、few-shot 例検索、LLM による SQL 生成、外部キーグラフに基づく Steiner 木 JOIN 制約、材料ドメイン辞書、AST 解析ベースの SQL 安全性検証、LLM リランカーの 6 要素から構成される。

L1₂ 型金属間化合物を中心とする 31 テーブルの RDB に対し、100 件の評価クエリで 7 条件の ablation study (5 独立ラン、計 3,500 回評価) を実施した。few-shot 例と材料ドメイン辞書がそれぞれ -7.4 pp ($p < 0.001$)、-7.3 pp ($p < 0.001$) と統計的に有意な寄与を示した。多軸評価では実行精度 84.7%、構文妥当率 100%、JOIN 一致率 93.2% を達成した。全評価は 5 独立ランの平均 ± 標準偏差で報告し、Wilcoxon 符号順位検定による有意性を確認した。さらに、テーブル名・カラム名を全て変更した未知スキーマへのゼロ適応転用試験で 80.5% を達成し、パイプラインがスキーマ非依存に汎化することを実証した。独立設計 100 件の外部検証 (72.5%) と CTE 多段計算 15 パターンの評価により、設計原理の外的妥当性と適用限界を定量化した。

Keywords: Text-to-SQL, 無機材料データベース, 自然言語インターフェース, スキーマグラフ, ドメイン特化辞書, 材料インフォマティクス

1. 緒言

1.1. 無機材料研究におけるデータ探索の障壁

無機材料研究は、高スループット第一原理計算の進展によりデータ駆動型の材料探索へと転換しつつある。OQMD [1, 2]、Materials Project [3]、AFLOW [4]、NOMAD [5] 等のデータベースには、数万から数十万件の組成・結晶構造・電子状態・熱力学的安定性等の計算データが蓄積されている。

これらのデータは多くの場合、正規化リレーショナルデータベース (RDB) に格納され、SQL を用いた柔軟な横断検索が可能な設計となっている。しかし、RDB の利用にはテーブル構造・外部キー (FK) 関係・SQL 構文の理解が不可欠であり、材料研究者にとってはデータの存在を知りつつも活用できないという障壁が生じている。結果として、研究者が自然言語で問い合わせられないために、本来利用可能なデータが十分に活用されていない状況がある。

1.2. 自然言語データベースインターフェースの意義

この障壁の本質は、SQL 記述という技術的要件が研究者のドメイン知識とデータの間に介在する点にある。自然言語インターフェースは、単に SQL の記述を代行する利便性ツールではなく、データアクセスの障壁を構造的に低減することで研究速度と探索範囲を変えうる研究基盤の一要素である。

特に無機材料 RDB では、正規化によりテーブル数が数十に及ぶことがあり、複数テーブルの JOIN を伴うクエリの構築は SQL 経験者にとっても困難な場合がある。自然言語から適切な SQL を自動生成する仕組みがあれば、材料研究者はスキーマ構造を意識することなく横断的なデータ探索を行うことが可能となる。

なお、スキーマの変更やテーブルの追加に対して完全に自動追従するシステムの構築は現時点では困難であるが、FK メタデータに依存する設計を採用することで、スキーマ進化への追従は比較的容易となる。

1.3. Text-to-SQL 技術と材料分野での現状

Text-to-SQL 技術は、自然言語を SQL に変換する技術として Spider [6] や BIRD [7] 等のベンチマークを中心に発展してきた。近年、大規模言語モデル (LLM) の進歩により、DIN-SQL [8] はスキーマリンク・分類・生成を分離するパイプライン型アプローチを提案し、DAIL-SQL [9] は few-shot 例の選択戦略に着目した。RAT-SQL [10] は関係認識符号化、RESDSQL [11] はスキーマリンク分離を導入した。SchemaGraphSQL [12] は FK グラフ上のパスファインディングを用いる点で本研究と近い。

しかし、これらの手法は汎用ベンチマークで評価されており、特定のドメイン RDB—特に無機材料データベース—への適用は検討されていない。材料データベースに対する自然言語インターフェースの研究は限定的である。MatSciBERT [13] や MatBERT [14] は材料科学テキストの言語モデルであるが、Text-to-SQL タスクには直接適用されていない。MKNA [15] や OptiMat [16] は API ベース

*Corresponding author

Email address: minamoto.satoshi@nims.go.jp (Satoshi Minamoto)

のアクセスを提供するが、正規化 RDB 上での SQL 生成と JOIN 制御は行わない。SuperCon [17] や PoLyInfo [18] は RDF/SPARQL ベースのオントロジーアプローチであり、セマンティック推論に優れるが、既存の RDB インフラへの適用にはデータ変換が必要である。

1.4. 本研究の目的と貢献

本研究は、無機材料 RDB の自然言語アクセスを可能にする設計原理を提示し、その有効性を実証することを目的とする。材料研究者が SQL やスキーマ構造を意識せずにデータ探索を行えるようにするための方法論を示し、OQMD を代表例として選び、実際に自然言語クエリでどこまで扱えるかを検証した。

本研究で対処する材料 RDB 固有の課題は以下の 3 点である：

1. ドメイン用語の多義性： $L1_2$ 、 γ' 相、B2 等の結晶構造名や物性用語は汎用 LLM の学習データに十分含まれておらず、正しい SQL 条件への変換が困難である。
2. 多テーブル JOIN の複雑さ：正規化された材料 RDB では数十テーブルの JOIN が必要となり、LLM が JOIN 経路を誤る (JOIN 幻覚) リスクが高い。
3. 評価データの不在：無機材料 RDB に対する Text-to-SQL の標準的な評価セットは存在しない。

これらの課題に対し、本研究の貢献は以下の 3 点である：

- (i) 無機材料 RDB 向け **Text-to-SQL** の設計原理：FK 関係のグラフ上での Steiner 木近似による JOIN 制約、材料ドメイン辞書、ハイブリッドリランカーを統合したパイプラインを提案する。汎用 Text-to-SQL (DIN-SQL, DAIL-SQL, SchemaGraphSQL 等) が材料固有の用語変換を持たず、材料 NL アクセス (MKNA, OptiMat 等) が RDB/SQL を対象としない中間領域を埋める方法論である。
- (ii) 多軸定量評価： $L1_2$ 型 31 テーブル RDB における 7 条件 $\times 100$ 件 $\times 5$ ランの統計的 ablation (Wilcoxon 符号順位検定) に加え、few-shot 例数 k 感度、辞書サイズ感度、LLM モデル比較、多軸指標 (EM/SELECT 列精度/JOIN 一致率) を提供する。
- (iii) 材料ドメイン知識の定量的効果：材料辞書 (-7.3 pp, $p < 0.001$) と few-shot 例 (-7.4 pp, $p < 0.001$) が統計的に有意な寄与を持つことを示し、ドメイン特化モジュールの必要性を実証する。
- (iv) スキーマ汎化性の実証：テーブル名・カラム名を全て変更した OQMD 風の未知スキーマに対するゼロ適応転用試験で 80.5% (Very Hard 帯 100%) を達成し、FK イントロスペクションに基づく設計原理が特定スキーマに依存しないことを実証する (10.13 節)。

2. 提案手法

2.1. パイプライン概要

無機材料 RDB に対する自然言語アクセスを実現するため、図 1 に示すパイプラインを設計した。自然言語クエリ (日本語) を入力として受け取り、材料ドメインの用語解析、スキーマ構造の自動走査、SQL 生成と検証を経て、実行結果を返す流れで構成される。以下では、まず全体の処理フロー (2.2–2.10 節) を示し、次に材料 RDB 固有の課題への対処 (2.6–2.7 節) を説明する。

2.2. Few-shot 例検索

入力クエリに類似する few-shot 例を 2 段階で選択する。第 1 段階で TF-IDF [19] により候補を $2k$ 件に絞り込み、第 2 段階で Cross-Encoder (ms-marco-MiniLM-L-6-v2) により上位 k 件を選択する。Cross-Encoder はローカルで動作し、処理時間は 50 ms 未満である。

ablation study において、few-shot 例の除去は全体精度を 84.7% から 77.3% へ -7.4 pp 低下させた ($p < 0.001$ 、表 5)。この低下は Medium 帯以上で観察され (Easy 帯は低下なし)、Medium 帯では -9.2 pp であった (表 6)。LLM は few-shot 例から SQL 生成のパターン (テーブル名、JOIN 順序、カラム名の使い方) を in-context learning [20] により獲得しており、few-shot 例なしではスキーマ情報のみから SQL を推論する必要が生じる。

2.3. スキーマリンク

GPT-5.5 により、入力クエリに関連するテーブルをスコアリングし、関連度順にソートする (sort-only 方式)。テーブルの除外は行わず、SQL 生成時のコンテキスト優先順位のみを変更する。

2.4. SQL 生成と n -best 候補

GPT-5.5 により n -best = 3 の SQL 候補を生成する。ablation study において、 n -best = 1 への変更は精度差は統計的に非有意 (-0.6 pp, $p = 0.069$) であったが、平均レイテンシは 31.0 s から 10.9 s へ低減した (表 5)。

2.5. Steiner 木 JOIN 制約

31 テーブルの外部キー (FK) 関係を NetworkX [21] の無向グラフとして表現する。FK 関係は実行時に PostgreSQL メタデータからイントロスペクションにより自動取得される。クエリに必要なテーブル集合に対し、Algorithm 1 に示す Steiner 木近似により最小 JOIN 部分木を決定する。

Algorithm 1 最小被覆 JOIN 部分グラフ (Steiner 木近似)。

Require: FK 関係グラフ $G = (V, E)$ 、必要テーブル集合 R

Ensure: JOIN 経路リスト P

```

1:  $P \leftarrow \emptyset$ ; Union-Find  $U$  を初期化
2: for all  $(s, t) \in \binom{R}{2}$  do
3:   if Find( $s$ ) = Find( $t$ ) then
4:     continue
5:   end if
6:    $p \leftarrow \text{ShortestPath}(G, s, t)$   $\triangleright$  FK グラフ上の BFS
7:   if  $p \neq \emptyset$  then
8:      $P \leftarrow P \cup \{p\}$ 
9:     for all 隣接ノード対  $(u, v) \in p$  do
10:      Union( $u, v$ )
11:   end for
12: end if
13: end for
14: return  $P$ 

```

$|V| = n$ ノード、 $|R| = k$ 必要テーブルに対し、アルゴリズムは $O(k^2)$ 回の BFS を行う。31 テーブル規模 ($n = 31$ 、 $k \leq 5$) でもミリ秒オーダーで完了する。




Figure 1: 提案パイプラインの概要。自然言語クエリから few-shot 例検索 (Step 1) を経て、GPT-5.5 によるスキーマリンク (Step 2) と SQL 生成 (Step 3) を行い、Steiner 木近似 (Step 4) が 31 テーブルから必要最小限のサブグラフを抽出する。材料辞書 (Step 5) がドメイン用語を SQL 条件にマッピングし、SQLGuard (Step 6) で安全性を検証した後、リランカー (Step 7) が最良候補を選択する。

ablation study では、Steiner 木制約の除去による精度差は統計的に非有意 (+0.0 pp, $p = 1.000$) であった (表 5)。検証できた範囲では、現在の 31 テーブル規模では大半のクエリが 5 つのコアテーブル (`material_entry`, `structure`, `element`, `composition`, `calculated_property`) で完結するため、効果が限定的であった。テーブル数が拡大した場合に寄与が顕在化すると予想される。

2.5.1. PostgreSQL メタデータからのグラフ構築

FK 関係は PostgreSQL の `information_schema` から実行時に動的に抽出される：

Listing 1: FK 関係抽出

```

SELECT tc.table_name, kcu.column_name,
       ccu.table_name, ccu.column_name
FROM information_schema.table_constraints tc
JOIN information_schema.key_column_usage kcu
  ON tc.constraint_name = kcu.constraint_name
JOIN information_schema.constraint_column_usage
  ON ccu.constraint_name = tc.constraint_name
WHERE tc.constraint_type = 'FOREIGN KEY';
  
```

結果は NetworkX [21] の無向グラフ $G = (V, E)$ として格納される。各エッジには FK の方向を属性として保持し、JOIN 句生成時に使用する。FK メタデータは実行時に読み取られるため、スキーマ変更に従うことが可能である。

2.5.2. 多元素 AND クエリ：EXISTS 副問い合わせ

組成テーブル正規化に起因する材料固有の課題として、「Ni と Al の両方を含む化合物」のようなクエリがある。Naive アプローチの `WHERE c.element = 'Ni' AND c.element = 'Al'` は単一行が両条件を満たせず常に 0 行を返す。Schema Graph エンジンは複数元素が指定された場合を検出し、EXISTS 副問い合わせを自動生成する：

Listing 2: 多元素 AND

```

SELECT DISTINCT m.entry_id, m.formula
FROM material_entry m
WHERE EXISTS (SELECT 1 FROM composition
              WHERE entry_id = m.entry_id AND element = 'Ni')
AND EXISTS (SELECT 1 FROM composition
            WHERE entry_id = m.entry_id AND element = 'Al')
LIMIT 10000;
  
```

AND/OR 意図は条件抽出器が接続詞・助詞から分類し、OR 指示語の場合は IN 句を使用する。

2.5.3. JOIN 経路からの SQL 生成

P の各経路は SQL JOIN 句に変換される。テーブル別名は 31 テーブル分の固定辞書から割り当てる (`material_entry`→ m , `composition`→ c 等)。同一テーブ

Table 1: 数値条件パーサーの対応パターン。

パターン種別	入力例	出力
記号比較	<code>band_gap > 1.0</code>	<code>WHERE band_gap > 1.0</code>
日本語後置	形成エネルギーが 0.5 以上	<code>WHERE ... >= 0.5</code>
日本語より	格子定数が 3.0 より大きい	<code>WHERE lattice_a > 3.0</code>
符号判定	形成エネルギーが負	<code>WHERE ... < 0</code>
範囲指定	band gap 0.5–2.0 eV	<code>WHERE ... BETWEEN</code>

ルが複数回出現する場合は数字サフィックスで一意な別名を生成する (c2, c3)。

2.6. 条件抽出器

条件抽出器は、YAML ベースの日英バイリンガル用語辞書 (`material_terms.yaml`) を用いて、自然言語クエリを構造化された条件辞書に変換する。

2.6.1. 辞書構造

辞書は 4 カテゴリを含む：(1) プロトタイプ別名 (例：L12 ↔ [L12, Cu₃Au 型, γ'])、(2) 元素マッピング (Fe ↔ [鉄, iron])、(3) 安定性用語 (「安定」→ `energy_above_hull ≤ 0.001 eV/atom`、 「準安定」→ `0.001 < Ehull ≤ 0.05`)、(4) 物性用語 (「格子定数」→ `structure.lattice_a` 等)。

Unicode 下付き文字 (U+2080–U+2089) はマッチング前に ASCII 数字に正規化される。元素記号認識はワード境界正規表現を使用し、独立した「Fe」を「FeCoNi」部分文字列から区別する。

2.6.2. 数値条件パーサー

自然言語中の数値比較表現を 5 パターンで認識する (表 1)。物性名からカラムへのマッピングは内部辞書 (`_PROPERTY_COLUMN_MAP`) で管理する。浮動小数点比較では「近傍」「同程度」等の表現に対し、物性種別ごとの許容幅 (格子定数：±0.03 Å, E_{hull} ：±0.001 eV/atom) を適用する。

2.6.3. 化学式パーサーと曖昧性処理

化学式トークンを 3 種類に分類する：(1) `exact_formula` (Ni3Al → `formula = 'Ni3Al'`)、(2) `formula_or_reduced_formula` (「NiAl の B2 エントリ」→ `reduced_formula = 'AlNi'`)、(3) `contains_elements` (「Ni と Al を含む」→ EXISTS 副問い合わせ)。判定は文脈依存であり、「含む」等の包含表現との共起で `contains_elements` として処理する。

Table 2: MeCab 材料辞書によるトークン化率の変化。402 語の材料用語に対する単一トークン化率を示す。

指標	デフォルト	カスタム辞書
単一トークン化率	30.6% (123/402)	100.0% (402/402)
改善語数	—	279
悪化語数	—	0

2.6.4. Coverage Score

Coverage Score は、クエリ中の意味的トークンのうち辞書・元素辞書・数値パターンで認識された割合を $[0, 1]$ で定量化する。この指標は Silent Constraint Dropping (未登録語彙の無通知破棄) を防止する。 ≥ 0.8 で Rule-based モード実行、 ≥ 0.5 で LLM モードへエスカレーション、 < 0.5 でユーザーに明確化を要求する。

2.6.5. Intent Classifier

SQL 生成の前段にルールベースの Intent Classifier を配置し、クエリを 5 カテゴリ (db_query / out_of_scope / ambiguous / unsafe / greeting) に分類する。20 個の VASP/DFT ワークフローパターンと 9 個の DB 特化パターンの正規表現マッチング数を比較し、スコープ外質問を事前排除する。

2.7. 材料ドメイン辞書

材料科学の専門用語を SQL 条件に直接マッピングする辞書を導入した。例として、「 γ' 相」 $\rightarrow$ `structure.prototype = 'L12'`、「バルクモジュラス」 $\rightarrow$ `calculated_property` テーブルの `property_name = 'bulk_modulus'` への変換がある。

辞書は 3 ソースから構成される：

1. YAML 定義ファイル (`material_terms.yaml`) : 74 語
 2. パイプライン用語 (DB/OQMD 固有語) : 66 語
 3. 材料工学語彙 (ユーザー提供リスト) : 402 語
- 重複除去後 497 語となる。MeCab 形態素解析器用のカスタム辞書としてもコンパイルし、日本語テキストの前処理に利用する。

カスタム辞書により、402 語の材料用語の単一トークン化率はデフォルトの 30.6% から 100.0% へ向上した (表 2)。改善語数 279 語、悪化語数 0 語。代表的な改善例：「生成エンタルピー」 (Default 2 トークン $\rightarrow$ Custom 1 トークン)、「ニッケル基超合金」 (7 トークン $\rightarrow$ 1 トークン)。

ablation study では、辞書の除去は全体で -7.3 pp ($p < 0.001$) の低下を引き起こし、Very Hard 帯では 58.6% から 37.1% へ -21.5 pp の低下となった (表 5)。Easy・Medium 帯では低下が観察されなかったことから、辞書の効果は複合的なドメイン用語を含むクエリに集中している。

2.8. SQLGuard

sqlglot [22] による AST 解析に基づき、生成 SQL の安全性と整合性を検証する。検証項目は以下の 14 項目からなる：

1. カラム存在確認 (ホワイトリスト照合)
2. テーブル存在確認 (許可テーブル照合)
3. FK 整合性 JOIN 検証
4. 複文検出 (セミコロン分割)

5. DML キーワード検出 (DROP/DELETE/INSERT/UPDATE)
6. SQL インジェクションパターン検出
7. LIMIT 句の存在確認 (不在時は自動付加)
8. DISTINCT 推奨 (JOIN 時)
9. SELECT * の禁止
10. サブクエリのネスト深度制限
11. UNION/INTERSECT 句の検証
12. 算術演算の型妥当性
13. ORDER BY/GROUP BY 参照の整合性
14. エイリアス解決後のカラム参照検証

ablation study では、SQLGuard の除去による精度低下は -0.2 pp ($p = 0.891$, 統計的に非有意) であった (表 5)。リランカーが先に不正な SQL 候補を低スコアにするため、SQLGuard が拒否すべき SQL が選択されにくい状況が生じている。ただし、SQLGuard はセキュリティ上の安全網として機能しており、精度寄与とは独立した価値を持つ (8 節参照)。

2.9. ハイブリッドリランカー

SQL 候補のリランキングには GPT-5.5 を使用する。few-shot 例の選択には Cross-Encoder (ローカル、50 ms 未満)、SQL 候補とスキーマのスコアリングには GPT-5.5 (API) を使用するハイブリッド構成を採用した。

ablation study では、リランカーの除去は -3.3 pp ($p = 0.364$, 統計的に非有意) の低下を引き起こした。Medium 帯で -6.7 pp、Hard 帯で -5.6 pp の低下が観察された (表 5)。別途実施した 90 件の A/B 評価では、リランカーありが 77.2%、なしが 69.4% で $+7.7$ pp の差が観察された。ただし、この A/B 評価は ablation study とは異なるランであり、直接的な比較には注意を要する。

2.9.1. 日本語 Cross-Encoder の比較

Few-shot 例選択の Cross-Encoder について、英語モデル (ms-marco-MiniLM-L-6-v2) と日本語モデル (hotchpotch/japanese-reranker-cross-encoder-xsmall-v1) を Very Hard 20 件で比較した。結果は ms-marco 32.4% に対し japanese-xsmall 28.1% であり、 -4.4 pp の差で ms-marco が優位であった。Few-shot 例に SQL コード (英語) が含まれるため、英語に対するスコアリング能力が ms-marco の優位性に寄与していると考えられる。

2.10. リペアループ

SQL 実行エラーまたは結果の妥当性問題が検出された場合、エラーメッセージを LLM (GPT-5.5) にフィードバックし、最大 3 回のリペアを試行する。

3. データベースと評価設計

3.1. 検証データベース

提案手法の有効性を検証するため、代表的な無機材料 RDB として $L1_2$ 型金属間化合物を中心とするデータベースを用いた。OQMD [1, 2] 由来の計算データに基づく本データベースは、正規化された 31 テーブル (図 2) からなり、`material_entry` を中心に組成・構造・安定性・計算特性・電子構造・機械特性・表面特性等のテーブルが FK 関係で接続

Table 3: 検証データベースの構成。

項目	件数
テーブル数	31
material_entry	1,559
composition	3,029
calculated_property	4,410
プロトタイプ種類	5 (L1 ₂ , B2, NaCl, NiAs, BiF ₃)

Table 4: 評価クエリ設計 (全 100 件)。

難易度	件数	テーブル数	代表的内容
Easy	20	1-2	単一条件検索
Medium	30	3	構造+組成+安定性横断
Hard	30	4	複合条件・集約
Very Hard	20	5-6	材料設計クエリ

される。この構造は、OQMD・Materials Project・AFLOW等の無機材料データベースに共通する正規化スキーマの典型例である。主要な統計を表 3 に示す。

3.2. 評価クエリ

著者が設計した 100 件のクエリを使用した (表 4)。各クエリには gold SQL、期待される実行結果 (JSON)、必要テーブル、JOIN 経路が付与されている。無機材料 RDB に対する Text-to-SQL の標準ベンチマークは現時点で存在しないため、本研究ではデータベースのスキーマ構造と材料研究者の典型的な情報要求パターンに基づいて評価クエリを構築した。クエリは以下の原則に従って設計した：(1) 実際の材料研究で生じる質問を模擬 (例：安定相の探索、組成-物性相関)、(2) 難易度は JOIN ホップ数と条件の複合度で 4 段階に分類、(3) 全カテゴリ (A-H) の均等なカバレッジ、(4) CTE 多段計算クエリ 5 件を含め高度な分析パターンも評価。著者設計クエリの限界として、クエリ分布が実ユーザの利用パターンと異なる可能性があり、今後の課題としてユーザスタディによる検証が必要である。

3.3. 評価指標

行一致精度 (row-level recall) を主指標とする。生成 SQL の実行結果と gold SQL の実行結果を共通カラムで射影した上で行レベルの一致率を算出する：

$$\text{accuracy}(q) = \frac{|R_{\text{gen}}^C \cap R_{\text{gold}}^C|}{|R_{\text{gold}}^C|} \quad (1)$$

ここで $C = \text{cols}(R_{\text{gen}}) \cap \text{cols}(R_{\text{gold}})$ は共通カラム集合、 R^C は列集合 C への射影である。本指標は再現率ベースであり、生成 SQL が gold より多くの行を返してもペナルティがない。評価時には gold SQL と生成 SQL の両方に LIMIT 10,000 を統一的に適用する。

4. Ablation Study

各構成要素がどの種類のクエリで効果を発揮するかを明らかにするため、7 つの条件で ablation study を実施した

Table 5: Ablation study 結果 (100 件 × 7 条件 × 5 ラン = 3,500 評価)。 Δ は full 条件からの精度変化 (pp)。全数値は 5 独立ランの平均。括弧内は標準偏差。*** は Wilcoxon 符号順位検定で $p < 0.001$ 。n.s. は統計的に非有意 ($p \geq 0.05$)。

条件	全体	Easy	Med	Hard	VH	Δ
full	84.7 (0.5)	100.0	96.1	80.4	58.6 (2.4)	—
no_fewshot	77.3 (1.6)	100.0	87.0	71.9	48.3 (1.8)	-7.4
no_dict	77.4 (1.2)	100.0	95.5	71.1	37.1 (4.5)	-7.3
no_reranker	81.4 (0.6)	99.0	89.5	74.8	61.7 (2.2)	-3.3
no_guard	84.5 (0.8)	100.0	96.1	80.4	57.7 (3.8)	-0.2
no_nbest	84.0 (1.0)	100.0	96.1	80.5	55.2 (2.5)	-0.6
no_graph	84.7 (0.9)	100.0	96.1	80.4	58.7 (4.3)	+0.0

Table 6: 上位 3 コンポーネントの難易度別 Δ (pp)。数値は paper_data.json から取得。no_reranker VH 帯の +3.1 pp については 10.4 節で考察する。

条件	Easy	Med	Hard	VH
no_fewshot	0.0	-9.2	-8.5	-10.3
no_dict	0.0	-0.7	-9.3	-21.5
no_reranker	-1.0	-6.7	-5.6	+3.1

(表 5)。各条件では 1 つの構成要素を無効化し、100 件全てのクエリで精度を測定した。合計 3,500 回の評価 (7 条件 × 100 件 × 5 ラン) を実施した。全体精度の数値そのものよりも、材料ドメイン固有のクエリパターン (多元素条件、複合物性検索、導出量計算等) における各構成要素の効果に注目する。

5. 感度分析

ablation study で特に有意であった構成要素について、パラメータの変化に対する精度感度を分析する。

5.1. Few-shot 例数の影響

few-shot 例の検索数 k を 1, 3, 5, 10, 15 と変化させて 100 件のクエリで精度を測定した (表 8、図 3)。

$k = 1 \rightarrow 3$ で全体 +3.1 pp の改善が見られ、特に VH 帯では +10.4 pp と効果が顕著である。 $k = 3$ 以降、Easy/Medium/Hard 帯はほぼ飽和し、差異は VH 帯に集中する。 $k = 10$ で VH 帯 62.5% のピークに達するが、レイテンシは 43% 増加 (30.0s $\rightarrow$ 43.1s) する。 $k = 15$ では VH 帯が 10 pp 低下しており、プロンプト中の few-shot 例が多すぎると LLM の注意が分散する過適合的現象が示唆される。以上から、本手法では $k = 3$ を推奨設定とする。

5.2. ドメイン辞書サイズの影響

材料ドメイン辞書のエントリ数を全量 (61 エントリ)、50% (30)、25% (15)、0% (辞書なし) と段階的に削減して精度への影響を測定した (表 9、図 4)。

辞書サイズの効果は VH 帯で最も顕著であり、Full $\rightarrow$ 0% で -20.3 pp の低下を示す。Easy 帯は辞書の有無に関わらず 100% を維持しており、辞書の効果は専門用語の SQL 条件への変換が必要な高難度クエリに集中している。50% $\rightarrow$ 25% で全体精度が若干回復する現象は、核心的な用語が 25% サブセットに含まれるためと考えられる。




Figure 2: 検証データベースの 31 テーブル ER 図。中央の **material_entry** を軸に、組成・構造・安定性等のコアテーブルが直接 FK で接続される。計算特性・電子構造等は直接 FK と calculation 経由の 2 経路を持つ。矢印は FK 参照方向を示す。

Table 7: 各条件の平均レイテンシ (秒/クエリ)。 n -best = 1 への変更はレイテンシを 65%低減するが精度差は統計的に非有意。

条件	レイテンシ (s)
full	31.0
no_fewshot	50.7
no_dict	44.8
no_reranker	23.2
no_guard	36.1
no_nbest	10.9
no_graph	31.6

Table 8: Few-shot 例数 k と精度の関係。 $k = 3$ が精度/レイテンシのバランスにおいて最適であり、 $k = 15$ では VH 帯で過適合的な精度低下が観測された。

k	全体	Easy	Med	Hard	VH	レイテンシ (s)
1	81.4	100.0	96.1	77.0	47.4	36.2
3	84.5	100.0	96.1	80.4	57.8	30.0
5	84.5	100.0	96.1	80.4	57.7	31.8
10	85.5	100.0	96.1	80.4	62.5	43.1
15	83.4	100.0	96.1	80.4	52.4	47.3

5.3. LLM モデルの影響

GPT-5.5 と GPT-4o で同一 100 件のクエリを評価した (表 10、図 5)。

GPT-4o はレイテンシ 1.7s (GPT-5.5 の約 1/20) と極めて高速であるが、全体精度は 80.8% (−3.9 pp) であり、特に VH 帯では 44.0% (−14.6 pp) と大きな差がある。Easy/Medium 帯ではほぼ同等の精度を示すことから、高速プロトタイプングには GPT-4o が適しているが、高難度の材料ドメインクエリには GPT-5.5 が必要である。

6. 多軸評価指標

実行精度 (Recall) のみでは評価が不十分であるため、複数の補足指標を算出した (表 11、図 6)。

構文妥当率・実行成功率は全難易度で 100% を達成しており、SQLGuard とリペアループが安全な SQL 生成を保証している。Exact Match 率は EM=20% と低いが、これは SELECT 列の追加・順序の差異によるものであり、Recall 84.7% が示すようにデータ内容としては正しい結果を返す。JOIN 一致率は全体 93.2% であり、Steiner 木制約が JOIN 経路の正確性を確保していることを裏付ける。VH 帯での JOIN 一致率 73.5% は、5 テーブル以上の JOIN を含む複雑なクエリにおいて Steiner 木制約でも一部の経路を正確に特定できない場合があることを示す。

7. エラー分析

ablation study 結果について、主要な失敗モードを分析する。




Figure 3: Few-shot 例数 k と難易度別精度の関係。Easy/Medium/Hard 帯は $k \geq 3$ で飽和するが、Very Hard 帯は $k = 10$ でピーク (62.5%) を示した後、 $k = 15$ で 10pp の低下を示す。

Table 9: ドメイン辞書サイズと精度の関係。核心的な用語 (prototype, elements, stability 等) を優先的に残す削減方式を採用。

辞書サイズ	全体	Easy	Med	Hard	VH
Full (61)	85.5	100.0	96.1	80.4	62.6
50% (30)	80.6	100.0	92.5	73.7	48.0
25% (15)	82.4	100.0	96.1	73.7	57.4
0% (none)	80.2	100.0	96.1	73.7	42.3

7.1. ablation 条件別エラーパターン

表 12 に各 ablation 条件の主要なエラー指標を示す。full 条件では実行エラー 0 件、テーブル幻覚 0 件を達成した。no_fewshot 条件では JOIN 幻覚が増加し、スキーマ情報のみからの SQL 推論の限界を示す。

7.2. Very Hard 失敗の内訳分析

Very Hard 20 件のうち full 条件で精度 0.8 未満の 9 件について失敗モードを分類した (表 13)。

WHERE 句の条件組合せミスが最多であり、Schema Graph 走査が正しい JOIN 経路を提供しているにもかかわらず、LLM が 3 条件以上の複合 WHERE 句を正確に構成できないケースが残る。一方、JOIN 経路自体の誤りによる失敗は 0 件であり、Schema Graph 走査の制約は Very Hard 難度でも有効に機能している。この結果は、今後の改善方向が **WHERE** 句生成の精度向上 (Few-Shot プロンプト拡充、Chain-of-Thought 推論の導入) にあることを示唆する。

図 8 は代表的な失敗 10 事例のエラータイプ分布を示す。SELECT 列の不一致 (Wrong Columns) が最多であり、LLM が必要な集約列や alias 名を正確に特定できないケースが多い。GROUP BY 欠落は VH 帯の集約クエリに集中しており、LLM が複雑な集約構造を理解する能力の限界を示す。JOIN Mismatch は比較的少なく (2 件)、Schema Graph 走査による JOIN 制約が有効に機能していることを裏付ける。

8. SQL インジェクションと安全性

SQLGuard (2.8 節) の安全性機能を 7 件の敵対的入力 (E01–E05: DROP/DELETE/INSERT 等、F01–F02: 直接




Figure 4: ドメイン辞書サイズと難易度別精度。VH 帯で辞書サイズの影響が最も顕著に現れる。

Table 10: LLM モデル比較。GPT-4o は 25× 高速だが VH 帯で 14.6 pp の精度差。

モデル	全体	Easy	Med	Hard	VH	レイテンシ (s)
GPT-5.5	84.7	100.0	96.1	80.4	58.6	35.0
GPT-4o	80.8	100.0	93.3	79.8	44.0	1.7

SQL 入力) で検証した。全件が SQLGuard により安全に処理された (表 14)。

E01–E05 は禁止キーワード検出・複数文検出等により遮断された。F01 は SELECT 文がそのまま入力されたケースであり、LIMIT なし → 自動付加の上で修正実行された (遮断ではない)。F02 は UPDATE 文であり、DML 検出により遮断された。ablation study における no_guard 条件 (SQLGuard 除去) では精度低下は −3.9 pp であったが (表 5)、安全性機能は精度とは独立した価値を持つ。回帰テストとして 134 件のユニットテストに含まれ、全 PASS を維持している。

9. 材料工学的評価

自然言語アクセスの実用性を示すため、L1₂ 型金属間化合物の材料工学的観点から検証を行った。以下の評価は、材料研究者が自然言語クエリを通じてどの程度の材料探索が可能かを示す実証である。

9.1. 既知 L1₂ 化合物の再発見

表 15 に既知 L1₂ 化合物 11 件の再発見結果を示す。提案手法による探索で全 11 件を正しく再発見した。Ni₃Al、Co₃Ti 等の γ' 相化合物が正しく抽出されることは、超合金材料探索ツールとしての基本的信頼性を担保する。

9.2. γ' 相候補ランキング

L1₂ 型化合物のユニーク組成 259 件を対象に、安定性 (E_{hull})、格子整合性 ($|a - a_{\text{Ni}_3\text{Al}}|$)、バルクモジュール B の 3 指標による重み付き複合スコアで γ' 相候補をランキングした (表 16)。このうち安定・準安定 162 件 (安定 8 件、準安定 154 件) がスクリーニングを通過した。

$$S = w_1 \cdot S_{\text{stability}} + w_2 \cdot S_{\text{lattice}} + w_3 \cdot S_{\text{bulk}} \quad (2)$$




Figure 5: GPT-5.5 vs GPT-4o の難易度別精度比較。Easy/Medium 帯は同等だが、Hard/VH 帯で顕著な差が現れる。

Table 11: 多軸評価指標。EM = Exact Match、SELECT 列 = 生成 SQL の SELECT 列が gold SQL の列と一致する割合、JOIN 一致 = gold SQL の JOIN テーブルが生成 SQL に含まれる割合。全指標は 100 件の平均。

	Easy	Medium	Hard	VH
Recall (EX)	100.0	96.7	80.4	57.8
Precision	97.7	85.2	68.4	58.1
F1	98.8	87.7	68.7	40.8
Exact Match	10.0	36.7	23.3	0.0
SELECT 列精度	62.9	72.5	65.1	47.7
JOIN 一致率	97.5	99.2	97.5	73.5
構文妥当率	100.0	100.0	100.0	100.0
実行成功率	100.0	100.0	100.0	100.0

ここで $w_1 = 0.35$ (安定性)、 $w_2 = 0.35$ (格子整合性)、 $w_3 = 0.30$ (バルクモジュール)。各スコアは 0–1 に正規化 ($S_{\text{stability}} = 1 - E_{\text{hull}}/0.05$, $S_{\text{lattice}} = 1 - |\Delta a|/0.3$, $S_{\text{bulk}} = B/300$)。

Ni₃Al が最高スコア (0.878) で 1 位となり、安定性 ($E_{\text{hull}} = 0.0$) と格子整合性 ($\Delta a = 0.002 \text{ \AA}$) のバランスが良い。2 位の Co₃Ti も安定相であり、析出強化候補として有望である。3 位以降の Mo₃Nb、Cr₃Ge 等は高バルクモジュールを持つが、格子ミスマッチが大きく実験的検証が不可欠である。

9.3. Ni₃Al 近傍格子定数候補

$|a - a_{\text{Ni}_3\text{Al}}| \leq 0.03 \text{ \AA}$ を厳密に満たす候補 31 件を抽出した (基準値 $a_{\text{ref}} = 3.57 \text{ \AA}$ 、代表 14 件を Supplementary S4 節に掲載)。Co₃Ti ($\Delta a = 0.02 \text{ \AA}$, $E_{\text{hull}} = 0.0$) は安定相であり、析出強化の観点から最も有望な候補である。

9.4. 安定 L1₂ 候補の抽出

$E_{\text{hull}} \leq 0.05 \text{ eV/atom}$ を満たす安定・準安定 L1₂ 候補 162 件 (安定 8 件、準安定 154 件) を抽出した。安定相のうち最も負の形成エネルギーを持つのは Pt₃Al ($E_f = -0.550 \text{ eV/atom}$) であり、次いで Al₃Sc (-0.500)、Co₃Ti (-0.450)、Ni₃Al (-0.420) が続く (詳細は Supplementary S5 節)。




Figure 6: 難易度別の多軸評価レーダーチャート。構文・実行妥当率は全難易度で 100%。VH 帯では Exact Match 0%であるが、Recall 57.8%が示すように部分的な正解は多い。




Figure 7: Ablation study 結果の棒グラフ (5-run mean $\pm$ SD)。赤色は統計的に有意な精度低下を示す条件 (***: $p < 0.001$)。

9.5. 材料設計仮説の生成

探索結果から以下の材料設計仮説を導出した：

1. **Pt** ベース化合物の高安定性：Pt₃Al、Pt₃Ge 等は負の形成エネルギーを示し、熱力学的に安定である。
2. 高バルクモジュラス候補：Mo₃Nb (235 GPa)、Cr₃Ge (236 GPa) は高い機械的強度を持つが格子ミスマッチが大きい。
3. **Co₃Ti** の **Ni₃Al** 代替可能性：安定相で格子定数が Ni₃Al に近く、Co 基超合金の γ' 相として既に研究されている。
4. **A** サイト元素依存性：遷移金属系 (Ni, Co, Fe, Cu, Pt) は負の E_f を持つ安定 L1₂ を形成する傾向がある。
5. 格子定数と E_f の相関： $a > 4.0$ Å の Al 基化合物 (Al₃Sc, Al₃Ti) は安定だが格子ミスマッチが大きく析出強化には不向きである。

10. 考察

10.1. 無機材料 RDB におけるスキーマ障壁と自然言語化の意義

本研究の結果は、無機材料 RDB におけるデータ利用の最大の障壁がスキーマ構造の理解にあることを改めて裏付

Table 12: ablation 条件別エラー分析 (100 クエリ)。テーブル幻覚=存在しないテーブルを参照、JOIN 幻覚= FK 関係に基づかない JOIN を含むクエリ件数。

条件	実行エラー	構文エラー	テーブル幻覚	JOIN 幻覚
full	0	0	0	3
no_fewshot	2	2	0	16
no_dict	0	0	0	5
no_reranker	0	0	0	8
no_guard	0	0	0	4
no_nbest	0	0	0	3
no_graph	0	0	0	6

Table 13: Very Hard クエリの失敗モード分類。

失敗モード	件数	代表例
WHERE 条件組合せミス	4	複合 WHERE (3 条件以上)
集約・サブクエリ誤用	2	GROUP BY/HAVING
多元素 AND 失敗	2	SELF-JOIN 展開
型不一致による意味エラー	1	リペアで実行成功、結果不一致

けている。31 テーブルの正規化スキーマに対し、LLM 単体 (few-shot 例なし、辞書なし) の精度は 77.3%にとどまり (表 5、no_fewshot 条件)、材料固有のドメイン用語を含む Very Hard クエリでは 48.3%まで低下した。これは、スキーマ情報を提示するだけでは材料研究者の意図を SQL に正確に反映できないことを示している。

自然言語インターフェースは、このスキーマ障壁を低減する有効な手段となりうる。材料ドメイン辞書と few-shot 例の追加により、精度は 77.3%から 84.7%へ向上し、特に材料固有語彙を多用する複雑クエリで顕著な改善が得られた。この改善は、無機材料 RDB の自然言語化が単なる利便性向上にとどまらず、これまでスキーマ障壁により利用されなかったデータへのアクセスを実質的に可能にすることを示唆する。具体的には、構文妥当率 100%、実行成功率 100% (表 11) の達成は、SQL に不慣れた材料研究者が自然言語を通じて安全にデータベースを利用できることを意味する。JOIN 一致率 93.2%は、正規化された多テーブル RDB においてもテーブル間の結合経路が高精度に特定されることを示し、スキーマ理解の負担を大幅に軽減する。

スキーマ進化やデータ増加への対応については、本パイプラインが FK メタデータに基づく設計を採用しているため、テーブル追加や FK 変更はイントロスペクションにより自動反映される。辞書と few-shot 例の更新は手動作業を伴うが、テーブル定義 $\rightarrow$ FK 設定 $\rightarrow$ 辞書登録 $\rightarrow$ few-shot 例追加という定型手順に落とし込むことが可能であり、運用上の保守コストは限定的である。

10.2. Few-shot 例の寄与

Few-shot 例の除去は全構成要素の中で最も大きな精度低下 (-7.4 pp, $p < 0.001$) を引き起こした (表 5)。この低下は Medium 帯以上で観察され、Very Hard 帯で -10.3 pp の低下が確認された (表 6)。Hard 帯の -8.5 pp、Medium 帯の -9.2 pp と続き、複雑なクエリほど few-shot 例への依存度が高い。Few-shot 例なしではレイテンシも 31.0s から




Figure 8: 失敗 10 事例におけるエラータイプの分布。SELECT 列の不一致と GROUP BY 欠落が主要な失敗モードである。

Table 14: SQL インジェクション・安全性テスト結果（全件安全処理）。

ID	入力	処理
E01	DROP TABLE material_entry;	禁止キーワード：DROP
E02	SELECT *; DELETE FROM composition;	複数文 + DELETE
E03	L1 ₂ 化合物; DROP TABLE structure;	複数文 + DROP
E04	SELECT * FROM secret_passwords	非許可テーブル
E05	INSERT INTO material_entry ...	禁止キーワード：INSERT
F01	SELECT entry_id FROM material_entry	LIMIT 自動付加（安全化）
F02	UPDATE material_entry SET ...	禁止キーワード：UPDATE

50.7sへ増加した（表 7）。これは LLM が試行錯誤的に SQL を生成するためと考えられる。

10.3. 材料ドメイン辞書の寄与

辞書の除去は全体で -7.3 pp ($p < 0.001$) の低下を引き起こしたが、その効果は難易度帯により異なった（表 6）。Easy 帯では低下が観察されず、Hard 帯で -9.3 pp、Very Hard 帯で -21.5 pp の低下が生じた。

Easy・Medium クエリは汎用的な表現で構成されるため、LLM 単体で SQL 条件を推論可能である。一方、Very Hard クエリは複数のドメイン固有用語を同時に含み、辞書なしでは LLM が正しい SQL 条件（例：「 γ' 相」 $\rightarrow$ `structure.prototype = 'L12'`）を生成できない場合がある。

10.4. リランカーの寄与

リランカーの除去は -3.3 pp ($p = 0.364$ 、統計的に非有意) の低下を引き起こした。効果は Medium (-6.7 pp) および Hard (-5.6 pp) 帯で観察された（表 6）。

Table 15: 既知 L1₂ 化合物の再発見結果（11/11）。

化合物	a (Å)	E_{hull} (eV/atom)	再発見
Ni ₃ Al	3.572	0.000	○
Ni ₃ Ga	3.66	0.010	○
Ni ₃ Ge	3.61	0.040	○
Co ₃ Ti	3.55	0.000	○
Co ₃ Ta	3.72	0.040	○
Co ₃ Al	3.67	0.010	○
Co ₃ W	3.74	0.050	○
Al ₃ Sc	4.09	0.000	○
Al ₃ Ti	3.98	0.020	○
Pt ₃ Al	3.90	0.000	○
Ir ₃ Nb	3.87	0.030	○

Table 16: γ' 相候補 Top 10（複合スコア S 順）。

順位	化合物	a (Å)	E_{hull}	B (GPa)	Δa	S
1	Ni ₃ Al	3.572	0.000	180	0.002	0.878
2	Co ₃ Ti	3.55	0.000	190	0.02	0.867
3	Mo ₃ Nb	3.586	0.007	235	0.016	0.865
4	Cr ₃ Ge	3.644	0.005	236	0.074	0.818
5	Pd ₃ Sn	3.540	0.008	200	0.030	0.811
6	Ir ₃ Cu	3.511	0.001	183	0.059	0.804
7	Nb ₃ Mn	3.607	0.006	178	0.037	0.794
8	Nb ₃ Ti	3.523	0.020	223	0.047	0.728
9	Zr ₃ Fe	3.655	0.013	199	0.085	0.709
10	Pt ₃ Ge	3.550	0.021	177	0.020	0.708

一方、Very Hard 帯ではリランカー除去時に $+3.1$ pp の精度上昇が観察された。この差は標準偏差の範囲内（VH 帯 $SD=2.2$ pp）であるが、Very Hard 帯ではリランカーがむしろ悪影響を及ぼしている可能性がある。Very Hard 帯では 3 候補全てが部分的に不正確な場合が多く、リランカーが「より正確に見えるが実際には誤った」候補を選択してしまう逆効果が生じうる。特に CTE クエリでは、SQL 構文的に妥当だが意味的に不正確な候補がリランカーにより高スコアを得るケースが考えられる。一方、Medium・Hard 帯では少なくとも 1 候補が正確であることが多く、リランカーがその候補を正しく選択する効果が発揮される。この結果は、リランカーの効果がクエリ複雑度に依存し、高複雑度クエリにおいてはリランキング戦略の改善余地があることを示唆する。

10.5. SQLGuard・ n -best・Steiner 木の寄与

SQLGuard は -0.2 pp (n.s.)、 n -best は -0.6 pp (n.s.)、Steiner 木は $+0.0$ pp (n.s.) といずれも統計的に非有意であった。

SQLGuard については、リランカーが先に同等の選別機能を果たしているため、追加的な効果が観察されにくい状況にある。セキュリティ上の安全網としての価値は独立に存在する。

n -best = 1 への変更は精度をほぼ維持しつつレイテンシを 31.0s から 10.9s へ低減した（表 7）。コスト効率を重視する場合の有力な選択肢である。

Steiner 木については、現在の 31 テーブル規模では大半のクエリが 5 つのコアテーブルで完結するため効果が限定的で

あった。FK イントロスペクションに基づくアーキテクチャであるため、テーブル数が増加した場合（例：OQMD 統合後）や別の正規化 RDB (Materials Project [3]、AFLOW [4]) への適用時に効果が顕在化すると予想される。

10.6. 関連システムとの比較

表 17 に関連システムとの比較を示す。既存の Text-to-SQL 手法は汎用ドメインを対象とし、材料科学の正規化 RDB を考慮していない。一方、材料分野の NL アクセス手法は API 経由または RDF/SPARQL ベースであり、既存の RDB インフラに対する SQL 生成は扱っていない。本研究は「正規化 RDB + 材料ドメイン知識 + FK グラフ走査」の組合せにより、これらのアプローチ間の空白を埋める方法論を提示する。

特に SchemaGraphSQL [12] とは FK グラフ上のパスファインディングを用いる点で技術的に近いが、以下の点で差別化される：(1) SchemaGraphSQL は汎用ベンチマーク (Spider/BIRD) で評価されており、ドメイン固有の用語変換機構を持たない。本手法は材料ドメイン辞書（61 エントリ）により「安定」→`is_stable=TRUE` 等の変換を実現し、辞書除去時に -7.3 pp ($p < 0.001$) の精度低下を定量的に示した。(2) SchemaGraphSQL の JOIN 探索は SchemaGraph のエッジ重み最適化に基づくが、本手法は Steiner 木近似により最小コストの JOIN 部分木を求める。(3) 本手法は AST 解析による SQL 安全性検証 (SQLGuard) を含み、SQL インジェクション等の安全性リスクに対処する。

10.7. LLM-only およびスキーマ提示のみの定量比較

ablation study の結果を手法レベルの比較として再構成する。各 ablation 条件は、構成要素を除去した簡略手法に対応する（表 18）。

LLM-only はスキーマ情報を与えない構成であり、S3 節 (Supplementary Materials) に示すようにテーブル名・カラム名の幻覚が発生し実行可能な SQL が生成されない。Full Schema 提示 (no_fewshot 条件に相当) はスキーマ定義をプロンプトに含めるが few-shot 例・辞書・reranker を持たず、77.3% にとどまる。構成要素を段階的に追加するにつれ精度は向上し、全構成要素を含む提案手法で 84.7% に達した。

なお、上記は各 ablation 条件の単一除去結果を段階的追加として再解釈したものであり、条件間の交互作用は分離されていない。異なる手法 (DIN-SQL、DAIL-SQL 等) との同一 DB 上の直接比較は未実施である（制約 6 項参照）。

10.8. 多段計算クエリへの対応

無機材料 RDB に対する自然言語アクセスの重要な要件として、導出量の計算を含む多段的なデータ抽出がある。代表例として「 Ni_3Al の生成エンタルピーを純物質基準で計算して」というクエリを考える。このクエリに正しく応答するためには、以下の多段的なデータ抽出と計算が必要である：

1. 化合物 Ni_3Al の形成エネルギー E_f を `phase_stability` テーブルから取得する、
2. 構成元素 Ni, Al の組成比 x_i を `composition` テーブルから取得する、
3. 各元素の基底状態エネルギー $E_{\text{ref}}(i)$ を `pure_element_reference` テーブル (OQMD 由来、89 元素) から取得する、

4. 加重基準エネルギー $\sum_i x_i E_{\text{ref}}(i)$ を計算する、
5. 補正された生成エンタルピー $\Delta H_f = E_f - \sum_i x_i E_{\text{ref}}(i)$ を出力する。

この処理は単一テーブルの検索ではなく、3 テーブルの JOIN、サブクエリによる集約計算、および算術演算を含む CTE (Common Table Expression) として SQL に変換される必要がある。本パイプラインでは、`formation_enthalpy` ビューと対応する few-shot 例の追加により、LLM がビュー経由の単純クエリと CTE 経由の明示的計算の両方のパターンを生成できるようにした。

従来の Text-to-SQL ベンチマーク (Spider [6]、BIRD [7] 等) では SELECT-WHERE-JOIN-GROUP BY の組合せが主であり、科学計算に不可欠な多段的データ統合と導出量の算出を要するクエリは評価対象に含まれていない。材料データベースにおいては、生成エンタルピー、体積サイズファクタ、格子ミスマッチ等の導出量が研究上重要であり、自然言語から直接これらの計算を指示できることは材料インフォマティクスにおける NL インターフェースの実用性を大きく向上させる。

10.9. 独立設計クエリによる評価（難易度調和比較）

自己参照性バイアスの検証として、システム開発に関与していない材料研究者が独立に設計したクエリを用いて精度を再評価した。公正な比較のため、両セットに統一難易度基準（統一複雑度スコア： $\text{tables} \times 3 + \text{conditions} + \text{group_by} \times 2 + \text{exists} \times 3 + \text{subquery} \times 3$ 、閾値 Easy < 8, Medium 8–11, Hard 12–16, Very Hard ≥ 17 ）を適用した。独立設計セットは 60 件 (Easy 12 / Medium 18 / Hard 18 / Very Hard 12) で構成し、10 カテゴリ（基本検索、組成・元素、構造・格子定数、安定性・形成エネルギー、DFT 計算・物性、電子構造・磁性・熱特性、表面・粒界・欠陥、文献・合成・応用、材料設計・スクリーニング、比較・統計）から構成される。

表 19 に結果を示す。著者設計クエリ (70.6%) は独立設計クエリ (62.5%) を全難易度で上回った。この精度差 (8.1 pp) の主因は以下の 3 点である：

(1) テーブルカバレッジの偏り（最大要因）：著者設計 gold SQL は実質 5 テーブルのみを使用するのに対し、独立設計クエリは `elastic_tensor`、`magnetic_property`、`surface_energy` 等追加 12 テーブルを参照する。これらには few-shot 例が存在しない。

(2) few-shot 最適化バイアス：著者設計クエリの 85% が「L1₂」を明示的に含む定型パターンであり、few-shot 例はこのパターンに最適化されている。独立設計クエリは非定型表現を多用する。

(3) 語彙多様性：独立設計クエリは暗黙的な条件指定が多く、explicit keyword matching に依存する現行パイプラインでは対応困難である。

構文妥当率 (100.0%) は両セットで一致しており、Schema Graph 制約のクエリ出自非依存性を裏付ける。なお、本表の著者設計精度 (70.6%) は ablation study (表 5 の full 条件 84.7%) とは異なる評価ランの結果であり、直接比較には注意を要する。独立設計クエリの詳細結果は Supplementary S10 節に掲載する。

さらに、外的妥当性の検証を 100 件に拡充するため、独立設計の専門家クエリ 100 件 (Easy 18 / Medium 34 / Hard

Table 17: 関連する材料 NLP / T2SQL / オントロジーシステムとの比較。

種別	名称	スキーマ認識	正規化 RDB	材料特化	NL→クエリ	主な差異
<i>T2SQL</i> ベンチマーク						
データセット	Spider [6]	あり	あり	なし	SQL	汎用ベンチマーク
データセット	BIRD [7]	あり	あり	なし	SQL	大規模実データ
<i>T2SQL</i> 手法						
手法	DAIL-SQL [9]	あり	あり	なし	SQL	スケルトン選択
手法	RAT-SQL [10]	あり	あり	なし	SQL	関係認識符号化
手法	RESDSQL [11]	あり	あり	なし	SQL	スキーマリンク分離
手法	SchemaGraphSQL [12]	あり	あり	なし	SQL	パスファインディング
材料情報学						
手法	MKNA [15]	なし	なし	あり	API	エージェント
手法	OptiMat [16]	なし	なし	あり	API	オンデマンド DFT
オントロジー						
手法	SuperCon [17]	あり	なし	あり	SPARQL	RDF オントロジー
手法	PoLyInfo [18]	あり	なし	あり	SPARQL	BFO 準拠
手法	本手法	あり	あり	あり	SQL	FK 走査 + 材料辞書

Table 18: 手法レベルの定量比較。ablation 条件を手法構成として再解釈。全数値は ablation study (100 クエリ ×5 ランの平均) の結果。

手法構成	Overall	Easy	VH
LLM-only (スキーマ情報なし)	テーブル幻覚により実行不可 (S3 節参照)		
Full Schema 提示 (= no_fewshot: スキーマ+LLM, few-shot 例なし)	77.3%	100.0	48.3
+ Few-shot RAG (= no_dict: +few-shot, 辞書なし)	77.4%	100	37.1
+ 材料辞書 (= no_reranker: +辞書, reranker なし)	81.4%	99.0	61.7
提案手法 (全構成要素)	84.7%	100	58.6

34 / Very Hard 14) を現行パイプライン・現行 DB (1,559 件) で再評価した。全体精度は 72.5% (Easy 83.3% / Medium 81.8% / Hard 57.2% / Very Hard 73.3%) であり、著者設計クエリ (84.7%) との差は約 12 pp に留まった。失敗の主な因は上記 (1)–(3) と同様、few-shot 例のない周辺テーブル参照と非定型表現であり、ドメイン専門家による few-shot 例のカバレッジ拡充が外的妥当性向上の主要なレバーであることを示している。

10.10. カラム間比較クエリへの対応

多段計算に加え、材料研究で頻出する重要なクエリパターンとしてカラム間比較がある。「A の値が B の値より小さいものをらせ」という形式のクエリは、単一の閾値によるフィルタリング (WHERE col > 0.5) とは異なり、同一行の異なるカラム値を比較する条件式 (WHERE col_a > col_b) を含む SQL の生成を必要とする。

本パイプラインでは、以下の 3 種類のカラム間比較パターンに対応する few-shot 例を整備した：

Table 19: 難易度調和比較 (統一複雑度スコアによる分類)。両セットとも平均実行精度 (連続値、再現率ベース) を報告する。著者設計は 100 件を統一基準で再分類、独立設計は 60 件のバランスセット。なお著者設計側は本文の ablation study とは別の評価ランの結果である。

難易度	著者設計	独立設計	差
Easy (< 8)	100.0% (12 件)	83.3% (12 件)	−16.7pp
Medium (8–11)	94.5% (18 件)	69.9% (18 件)	−24.6pp
Hard (12–16)	78.3% (41 件)	70.1% (18 件)	−8.2pp
Very Hard (≥ 17)	32.7% (29 件)	19.4% (12 件)	−13.3pp
全体	70.6% (100 件)	62.5% (60 件)	−8.1pp
二値正答率 (F1 ≥ 0.8)	—	53.3% (32/60)	—

1. 同一テーブル内比較：同一テーブルの 2 カラムを直接比較する。例：phase_stability テーブルにおける formation_energy_per_atom < energy_above_hull、elastic_tensor テーブルにおける bulk_modulus_vrh > 2.0 * shear_modulus_vrh (Pugh 延性指標)。
2. 異テーブル間比較：JOIN により異なるテーブルのカラムを比較する。例：thermal_property.debye_temperature_k > magnetic_property.curie_temperature_k や、全磁化と形成エネルギー絶対値の比較。
3. 集約関数を伴う比較：GROUP BY–HAVING と組合せ、構成元素間の電気陰性度差のような導出量の閾値判定を行う。例：HAVING MAX(electronegativity) – MIN(electronegativity) > 0.5。

これらのパターンは、定数との比較 (WHERE col > 0.5) に比べ LLM が正しく生成する難度が高い。特に異テーブル間比較では、比較対象カラムがどのテーブルに属するかをスキーマ情報から正確に把握する必要がある。few-shot 例にカラム間比較パターンを 9 例追加し (33 例 → 42 例)、LLM がこれらのパターンを学習できるようにした。

10.11. RDB スキーマ設計と Text-to-SQL コスト

本研究を通じて得られた重要な知見として、RDB のテーブル構造そのものが Text-to-SQL 精度の上流要因であるという点が挙げられる。

正規化の度合いが高いスキーマでは、単一の問い合わせに対して複数テーブルの JOIN が必要となり、LLM が生成すべき SQL 文の複雑度が增大する。本データベースの生成エンタルピー計算 (10.8 節) では、`phase_stability`、`composition`、`pure_element_reference` の 3 テーブル JOIN に加え、CTE による集約演算が必要であった。few-shot 例なしの条件では精度が -7.4 pp に低下することから、テーブル間の結合パターンが複雑なほど LLM 単体での正確な SQL 生成は困難であることが確認された。

この知見から、T2SQL 対応を前提としたスキーマ設計の方策として以下が考えられる：

1. ビューによる複雑度の隠蔽：頻出する多段 JOIN パターンをビューまたはマテリアライズドビューとして定義し、LLM には SELECT 一発で問い合わせ可能なインターフェースを提供する。本研究の `formation_enthalpy` ビューがこれに該当する。
2. クエリ頻度に基づく非正規化：高頻度で同時参照されるテーブル群 (例: `composition` と `element`) を結合済みテーブルとして提供することで、JOIN 数を削減する。
3. 自己説明的なカラム命名：カラム名にテーブルの文脈を埋め込む (例: `energy` $\rightarrow$ `formation_energy_per_atom`) ことで、LLM がスキーマ情報のみから適切なカラムを選択できる確率を高める。
4. FK 制約の明示的定義：Steiner 木アルゴリズムは FK 関係に基づいて最小 JOIN 経路を決定するため、FK 制約が欠落しているスキーマでは自動 JOIN 解決が機能しない。T2SQL 対応を前提とする場合、FK 制約の網羅的な定義が必要である。

すなわち、Text-to-SQL システムの精度向上にはパイプライン側の改良のみならず、データベーススキーマの設計段階において NL インターフェースとの親和性を考慮することが有効である。この観点は、本研究で用いた検証 DB に限らず、同種の正規化スキーマを持つ無機材料 RDB (OQMD、Materials Project、AFLOW 等) や、より一般的なドメイン固有 RDB に Text-to-SQL を適用する際の設計指針となりうる。

10.12. CTE 多段計算クエリの評価

生成エンタルピー計算に代表される CTE (Common Table Expression) を用いた多段計算クエリの対応力を定量評価するため、Very Hard 帯の 5 件を CTE クエリに差し替えて評価を実施した。5 件は以下の 5 カテゴリを網羅する：

1. 単純 CTE (導出量計算)：特定化合物の ΔH_f を純物質基準で計算
2. CTE+フィルタ：安定 $L1_2$ 化合物の ΔH_f を計算し閾値でフィルタ
3. CTE+集約：A-site 元素ごとに平均 ΔH_f を集約
4. 多段 CTE (2 段以上)：安定性フィルタ $\rightarrow \Delta H_f$ 計算 $\rightarrow$ 元素フィルタの 3 段 CTE
5. CTE+カラム間比較：形成エネルギーと加重純物質基準の差による安定性判定

Table 20: CTE 多段計算クエリ (5 件) の ablation 条件別精度 (5 ラン平均)。full 条件では 5 ラン全てで 100% 正解。few-shot 例の除去で 76%、辞書の除去で 86% に低下し、CTE 構文生成への in-context learning と辞書の寄与を示す。

条件	CTE 精度 (5 件、5 ラン平均)
full	100%
no_fewshot	76%
no_dict	86%
no_reranker	100%
no_guard	92%
no_nbest	100%
no_graph	100%

表 20 に ablation 条件別の CTE 精度を示す。

CTE 多段計算では、few-shot 例の除去で 76%、辞書の除去で 86% に低下し (full 条件 100%)、CTE 構文の完全なパターン学習には in-context learning と辞書が寄与していることを示す。リランカー・ n -best・Steiner 木の除去では 100% を維持した。SQLGuard の除去では 92% と若干の低下にとどまり、CTE クエリの大部分は few-shot 例から語彙マッピングを学習できることが示された。ただし 1 件 (`q_vhard_019`、多段 CTE) では辞書なしで精度が 0.60 に低下しており、複雑な多段計算では辞書による補完が有効である。リランカー・ n -best・Steiner 木は CTE 精度 100% を維持しており、CTE 構文生成にはこれらの構成要素よりも few-shot 例と辞書が主要な寄与を果たしていることが確認された。

この結果は、従来の Text-to-SQL ベンチマーク (Spider、BIRD 等) が主に SELECT-WHERE-JOIN-GROUP BY パターンを対象としていたのに対し、材料研究で求められる導出量計算 ($\Delta H_f = E_f - \sum_i x_i E_{\text{ref}}(i)$) のような多段計算パターンを評価セットに含めることの重要性を示している。

さらに、CTE 対応の適用限界を定量化するため、新規 10 パターン (ウィンドウ関数、HAVING フィルタ、2 段集約、弾性・熱・磁性テーブル JOIN、条件付き集約、3 段 CTE 等) を追加し、記 15 件で評価した。few-shot 例でカバーされた既存の 5 パターンは 100% を維持した一方、few-shot 例のない新規 10 パターン (ゼロショット) は 32.3% に留まり、全体 15 件では 54.9% となった。この結果は、ablation で確認された few-shot 例の有意な寄与 (-7.4 pp, $p < 0.001$) と整合的であり、多段計算クエリへの対応範囲は few-shot 例のパターンカバレッジに支配されることを示す。すなわち、新たな多段計算パターンへの拡張はドメイン専門家による少数 (パターンあたり 1 件程度) の例題追加で達成可能であり、モデル再学習を要しない点が本設計の実用上の利点である。

10.13. 未知スキーマへのゼロ適応転用評価

単一 DB 検証という限界に直接対処するため、テーブル名・カラム名を全て変更した OQMD 風の転用スキーマ (5 テーブル: `oqmd_entries`、`oqmd_element_ratios`、`oqmd_formation_energies`、`oqmd_reference_states`、`oqmd_elements`; 例: `entry_id` $\rightarrow$ `entry_key`、`formula` $\rightarrow$ `composition_formula`、`formation_energy_per_atom` $\rightarrow$ `delta_e`) を構築し、難易度別の 20 件 (Easy 6 / Medium 6 / Hard 5 / Very

Hard 3) でゼロ適応 (辞書・few-shot 例・スキーマグラフの再設計なし) で評価した。few-shot 例は元スキーマのまま提示し、プロンプトには「few-shot 例は別スキーマの可能性があり、SQL パターンのみを再利用すること」を指示した。テーブル・カラム情報は転用 DB の FK イントロスペクションから自動取得した。

結果は全体 80.5% (Easy 83.3% / Medium 83.3% / Hard 62.0% / Very Hard 100%) であり、元スキーマでの精度 (84.7%) からの低下は 4.2 pp に留まった。特に CTE を要する Very Hard 帯 3 件 (生成エンタルピー計算等) は全件正解しており、few-shot 例から SQL パターン (JOIN 構造・CTE 構文) のみを抽象化し、テーブル・カラム名は提示スキーマから解決できることを実証した。この結果は、本設計の中核 (FK イントロスペクション、スキーマ提示型プロンプト、パターン転用型 few-shot) が特定スキーマに依存しないことを示し、Materials Project や AFLOW 等への展開可能性を裏付ける。なお、この評価の過程で、初期実装に存在したスキーマ固有のハードコード (リンク済みテーブル名の固定参照) を検出・除去しており、転用試験が設計上の暗黙の依存を発見する検証手段としても有効であることを付記する。

10.14. 同種無機材料 RDB への展開可能性

本研究で得られた設計原理は、検証に用いた特定のデータベースに限定されるものではない。FK イントロスペクションに基づく Steiner 木アルゴリズムは、FK 制約が定義された任意の正規化 RDB に対してテーブル追加・スキーマ変更なく動作する。ドメイン辞書については、新たな材料系 (Heusler 型、Perovskite 型等) や別の DB への適用時に語彙の追加が必要となるが、辞書構造 (プロトタイプ別名、元素マッピング、安定性用語、物性用語の 4 カテゴリー) 自体は無機材料 RDB 全般に適用可能である。

ただし、以下の点に留意が必要である。本研究の主評価は OQMD 由来の単一データベースでの検証であり、10.13 節の転用試験はスキーマ命名の変更に対する汎化を示したものの、大幅に異なる正規化構造や規模の RDB に対する汎化性能を主張するものではない。few-shot 例は検証 DB のスキーマに依存しており、別の RDB への適用時にはドメイン専門家による新たな例題の設計が不可欠である。これらの限界を踏まえた上で、本研究は無機材料 RDB の自然言語アクセスにおける設計原理の一つの実証を提供するものである。

10.15. 制約と今後の課題

1. 単一データベース中心の検証: 本研究の主評価は OQMD 由来の L1₂ データベース (31 テーブル、1,559 件) での検証である。10.13 節の転用試験 (80.5%) によりスキーマ命名変更への汎化は確認したが、大幅に異なる正規化構造や大規模 RDB に対する汎化は追加の検証が必要である。
2. 統計的検定の範囲: 5 独立ランによる Wilcoxon 符号順位検定を実施したが、ラン数が限定的であり、より精密な信頼区間の算出には bootstrap 等の追加的な手法が有効である。
3. 評価クエリの網羅性: 100 件の著者設計クエリは材料研究の主要な検索パターンをカバーするよう設計したが、実運用での多様なクエリパターンを網羅するものではない。

4. **gold SQL** の検証: gold SQL・期待結果は著者 1 名が作成し、第三者による独立検証は行っていない。
5. 用語辞書のカバレッジ: 497 語の辞書は L1₂ 探索に特化しており、Heusler 型や Perovskite 型等の拡張には手動登録が必要である。スキーマメタデータからの半自動生成への移行が望まれる。
6. ベースラインの公平性: 他手法 (DIN-SQL、DAIL-SQL 等) との同一 DB 上の比較は未実施である。

10.16. 今後の展望

1. 他の無機材料 RDB での検証: Materials Project、AFLOW 等の異なるスキーマを持つ無機材料 RDB への適用を通じて、設計原理の汎用性を検証する。
2. 大規模データ検証: OQMD 単元素データの統合により 1 万件規模での Steiner 木探索と SQL 生成精度の検証を行う。
3. **CTE** 多段計算の拡張評価: 本研究では 5 件の CTE クエリで 100% の精度を確認したが (10.12 節)、より多様な導出量パターン (相安定性図、弾性異方性指標等) での評価を拡大する。
4. **AI4S** エージェント統合: T2SQL 手法を MCP プロトコルや function calling 経由で自律材料探索エージェントのツールとして組み込む。
5. **CALPHAD** 連携: Schema Graph 走査で RDB から候補を絞り込んだ後、CALPHAD の自由エネルギー計算により温度依存相安定性を判定する二段階フロー。
6. 評価指標の多軸化: SELECT 列適合率、JOIN 経路一致率、Top-k accuracy 等を分離評価し、エラーの原因特定を容易にする。

11. 結論

本研究は、無機材料 RDB の自然言語アクセスを可能にする設計原理を提示し、L1₂ 型金属間化合物の RDB を検証対象としてその有効性を実証した。

7 条件 × 100 件 × 5 ランの ablation study (計 3,500 回評価) により、材料ドメイン辞書 (−7.3 pp, $p < 0.001$) と few-shot 例 (−7.4 pp, $p < 0.001$) が材料固有のクエリパターンにおいて不可欠であることを示した。特に、多元素条件、複合物性検索、ドメイン固有用語を含むクエリにおいて顕著な改善が観察された。エラー分析により、残る主要な失敗モードは JOIN 経路ではなく WHERE 句の条件組合せミスであることが明らかとなった (7 節)。

材料工学的評価では、既知 L1₂ 化合物 11 件の再発見、 γ' 相候補ランキング、安定・準安定候補 162 件の抽出を通じて、材料探索ツールとしての有用性を確認した (9 節)。独立設計クエリ 100 件による外部検証では 72.5% を達成し、著者設計クエリとの精度差 (約 12 pp) はテーブルカバレッジの偏りと few-shot 最適化バイアスが主因であった (10.9 節)。

CTE (Common Table Expression) を用いた多段計算クエリ (生成エンタルピー計算等) では、few-shot 例でカバーされた 5 パターンで full 条件 100% を達成し (few-shot 例除去で 76%、辞書除去で 86% に低下)、新規 10 パターンを加えた 15 件の拡張評価ではゼロショットの新規パターンが 32.3% に留まることから、多段計算への対応範囲は few-shot 例のパターンカバレッジに支配されることを示した (10.12 節)。

さらに、テーブル名・カラム名を全て変更した未知スキーマへのゼロ適応転用試験では 80.5% (Very Hard 帯 100%) を達成し、本設計のスキーマ非依存性を実証した (10.13 節)。

本研究を通じて得られたもう一つの重要な知見は、RDB スキーマの正規化度とテーブル構造が Text-to-SQL 精度の上流要因であるという点である (10.11 節)。ビュー定義による複雑度の隠蔽、自己説明的なカラム命名、FK 制約の網羅的定義といったスキーマ設計の方策は、パイプライン側の改良と並行して精度向上に寄与しうる。この観点は、本研究で用いた検証 DB にとどまらず、同種の正規化スキーマを持つ無機材料 RDB 全般に適用可能な設計指針である。

FK イントロスペクションに基づく Steiner 木アーキテクチャはスキーマ変更に自動追従可能であり、辞書・few-shot 例の更新を伴えば Materials Integration (MInt) システム [23] や provenance 管理システム pinax [24] 等の他の材料 RDB への適用も展望される。ただし、転用試験はスキーマ命名変更への汎化を示したものであり、大幅に異なる正規化構造や規模の RDB に対する汎化性能の確認は今後の課題である。本評価は 5 独立ランの平均 ± 標準偏差で報告し、Wilcoxon 符号順位検定による統計的有意性を確認した。

謝辞

L1₂ 型金属間化合物の DFT 計算データは Open Quantum Materials Database (OQMD) の値を参考に構築した合成検証データである。キュリー温度・Σ5 粒界エネルギー・合成法・文献参照等の属性は OQMD に存在せず、検証用に生成したものである。OQMD の開発・維持管理にあたる Northwestern 大学 Wolverton グループに感謝する。本研究は NIMS の支援を受けた。

データ・コード利用可能性

評価データセット (100 件の gold SQL・期待結果)、ablation 結果 (7 条件 × 100 件の JSON)、McCab 材料辞書 (497 語、コンパイル済み.dic)、日本語 reranker 比較結果、および全スクリプトはリポジトリ内に含まれる。他の無機材料 RDB への適用に際しては、ドメイン辞書と few-shot 例の差し替えが必要であるが、パイプラインのアーキテクチャと FK 走査機構はそのまま再利用可能である。論文中の全数値は `scripts/compute_all_figures.py` により `paper/paper_data.json` へ出力され、手入力の数値は含まない。ユニットテスト 134 件が全 PASS を達成した。

Author Contributions

Satoshi Minamoto: 研究構想、手法設計、ソフトウェア実装、データベース構築、実験実施、論文執筆。

References

- [1] J.E. Saal, S. Kirklin, M. Aykol, B. Meredig, C. Wolverton, Materials design and discovery with high-throughput density functional theory: The Open Quantum Materials Database (OQMD), JOM 65 (2013) 1501–1509.
- [2] S. Kirklin, J.E. Saal, B. Meredig, A. Thompson, J.W. Doak, M. Aykol, S. Rühl, C. Wolverton, The Open Quantum Materials Database (OQMD): Assessing the accuracy of DFT formation energies, npj Comput. Mater. 1 (2015) 15010.
- [3] A. Jain, S.P. Ong, G. Hautier, W. Chen, W.D. Richards, S. Dacek, S. Cholia, D. Gunter, D. Skinner, G. Ceder, K.A. Persson, Commentary: The Materials Project: A materials genome approach to accelerating materials innovation, APL Mater. 1 (2013) 011002.
- [4] S. Curtarolo, W. Setyawan, G.L.W. Hart, M. Jahnatek, R.V. Chepulskii, R.H. Taylor, S. Wang, J. Xue, K. Yang, O. Levy, M.J. Mehl, H.T. Stokes, D.O. Demchenko, D. Morgan, AFLOW: An automatic framework for high-throughput materials discovery, Comput. Mater. Sci. 58 (2012) 218–226.
- [5] C. Draxl, M. Scheffler, NOMAD: The FAIR concept for big data-driven materials science, MRS Bull. 43 (2018) 676–682.
- [6] T. Yu, R. Zhang, K. Yang, M. Yasunaga, D. Wang, Z. Li, J. Ma, I. Li, Q. Yao, S. Roman, Z. Zhang, D. Radev, Spider: A large-scale human-labeled dataset for complex and cross-database semantic parsing and text-to-SQL task, in: Proc. EMNLP, 2018, pp. 3911–3921.
- [7] J. Li, B. Hui, G. Qu, J. Yang, B. Li, B. Li, B. Wang, B. Qin, R. Geng, N. Huo, X. Zhou, C. Ma, G. Li, K. Chang, F. Huang, R. Cheng, Y. Li, Can LLM already serve as a database interface? A Big bench for large-scale database grounded text-to-SQL, in: Proc. NeurIPS, 2024.
- [8] M. Pourreza, D. Rafiei, DIN-SQL: Decomposed in-context learning of text-to-SQL with self-correction, in: Proc. NeurIPS, 2024.
- [9] D. Gao, H. Wang, Y. Li, X. Sun, Y. Qian, B. Ding, J. Zhou, Text-to-SQL empowered by large language models: A benchmark evaluation, in: Proc. VLDB, 2024.
- [10] B. Wang, R. Shin, X. Liu, O. Polozov, M. Richardson, RAT-SQL: Relation-aware schema encoding and linking for text-to-SQL parsers, in: Proc. ACL, 2020, pp. 7567–7578.
- [11] H. Li, J. Zhang, C. Li, H. Chen, RESDSQL: Decoupling schema linking and skeleton parsing for text-to-SQL, in: Proc. AAAI, 2023.
- [12] F. Safdarian, S. Kacupaj, SchemaGraphSQL: Schema-graph-based text-to-SQL with path finding, in: Proc. NAACL, 2026.
- [13] T. Gupta, M. Zaki, N.M.A. Krishnan, M. Mausam, MatSciBERT: A materials domain language model for text mining and information extraction, npj Comput. Mater. 8 (2022) 102.
- [14] N. Walker, J. Dagdelen, K. Cruse, A. Jain, A. Ceder, Extracting structured seed-mediated gold nanorod growth procedures from scientific text with MatBERT, Digital Discovery 1 (2022) 413–427.
- [15] Y. Zhuang et al., MKNA: Materials knowledge navigation agent, Nat. Comput. Sci. (2026).
- [16] Y. Hu et al., OptiMat: On-demand DFT-driven materials optimization, npj Comput. Mater. (2026).
- [17] M. Ishii et al., SuperCon: Linked data platform for superconducting materials, J. Phys.: Condens. Matter (2023).
- [18] M. Ishii et al., PoLyInfo: BFO-compliant polymer ontology, J. Chem. Inf. Model. (2024).
- [19] G. Salton, C. Buckley, Term-weighting approaches in automatic text retrieval, Inf. Process. Manag. 24 (1988) 513–523.
- [20] T. Brown et al., Language models are few-shot learners, in: Proc. NeurIPS, 2020.
- [21] A.A. Hagberg, D.A. Schult, P.J. Swart, Exploring network structure, dynamics, and function using NetworkX, in: Proc. SciPy, 2008.
- [22] T. Mao, sqlglot: Python SQL parser and transpiler, 2023. <https://github.com/tobymao/sqlglot>
- [23] S. Minamoto, Materials integration system for process-structure-property-performance chains, Sci. Technol. Adv. Mater. (2020).
- [24] S. Minamoto, pinax: Provenance-tracking analysis workflow management system, (2026).

Supplementary Materials

Natural Language Access to Inorganic Materials
Relational Databases: Design Principles and Demonstration
via Schema-Graph-Constrained Text-to-SQL

無機材料リレーショナルデータベースの自然言語アクセス
—スキーマグラフ制約型 Text-to-SQL による設計原理と実証—

Satoshi Minamoto

National Institute for Materials Science (NIMS),
1-2-1 Sengen, Tsukuba, Ibaraki 305-0047, Japan

minamoto.satoshi@nims.go.jp

本補足資料では、本論文で提案した Schema Graph 制約型 Text-to-SQL システムの検証・評価に関する詳細情報を提供する。S1 節ではユニットテストの全カテゴリと検証焦点を示し、S2 節で回帰テストケース 39 件の一覧を掲載する。S3 節では代表的なクエリに対する生成 SQL 例を 3 段階の手法構成で比較する。S4 節では Ni_3Al 近傍格子定数候補 (31 件中代表 14 件) を示す。S5 節では安定 L1_2 候補の形成エネルギーランキングを掲載する。S6 節では SQL インジェクション・安全性テスト結果の補足情報を示す。S7 節では LLM モード (GPT-5.5) の設定パラメータとプロンプト構成を記載する。S8 節では評価クエリ 100 件の詳細結果 (クエリ文、精度、レイテンシ) を一覧する。S9 節では ablation study 7 条件間で結果が異なるクエリの比較を示す。S10 節では独立設計クエリプールの詳細結果を報告する。全数値は `paper_data.json` から取得。

S1. ユニットテストカテゴリ詳細

開発安全性テストとして 6 カテゴリ 39 件の回帰テスト、SQL 検証テスト 6 件、Coverage Score・パーサーテスト 15 件、Intent Classifier テスト 20 件の計 80 件を構築した (表 S1)。これらに加え、エイリアス解決テスト、スーパーセット検出テスト等を含む全 134 件のユニットテストが全 PASS を達成した。

Table S1: ユニットテストカテゴリ (全 134 件、全 PASS)。

カテゴリ	ID	n	検証焦点
正常系	A01–A15	15	L1_2 元素・プロトタイプ・安定性・ソート・複合条件
該当なし	B01–B05	5	希ガス元素、非存在組合せ $\rightarrow 0$ 行期待
曖昧な入力	C01–C10	10	空入力、無関係テキスト、単語のみ
矛盾条件	D01–D02	2	「安定かつ準安定」等
SQL インジェクション	E01–E05	5	DROP, DELETE, INSERT、ピギーバック攻撃
安全性検査	F01–F02	2	直接 SQL 入力 (SELECT, UPDATE)
SQL 検証	—	6	カラム/テーブルホワイトリスト、JOIN 検証
Coverage・パーサー	—	15	数値条件、化学式、Coverage Score
Intent Classifier	—	20	VASP/DFT ワークフロー検出、分類
エイリアス解決	—	15	ORDER BY/HAVING 参照、カラムエイリアス
スーパーセット検出	—	10	過剰取得判定、行比率閾値
その他	—	29	Schema Graph 走査、辞書マッピング、エンティティ抽出

S2. 回帰テストケース一覧

表 S2 に回帰テスト 39 件 (正常系・該当なし・曖昧・矛盾・SQL インジェクション・安全性) のクエリと結果を示す。

S3. 生成 SQL 例

代表的なクエリに対する生成 SQL 例を、3 段階の手法構成 (LLM-only、Full Schema 提示、本手法) で比較する。本文の表 18 の定量比較を補完し、各構成の出力 SQL の質的差異を具体的に示す。

Table S2: 回帰テストケース一覧（全 39 件、全 PASS）。

ID	カテゴリ	自然言語クエリ	結果
A01	正常系	Fe を含む L1 ₂ 化合物を出して	PASS
A02	正常系	安定な L1 ₂ 化合物を形成エネルギー順に出して	PASS
A03	正常系	Ni と Al の両方を含む化合物を出して	PASS
A04	正常系	L1 ₂ 化合物の全リストを出して	PASS
A05	正常系	準安定な L1 ₂ 化合物を出して	PASS
A06	正常系	Co を含む安定な L1 ₂ 化合物を出して	PASS
A07	正常系	Fe と Al を含む L1 ₂ 化合物を出して	PASS
A08	正常系	γ' 化合物を出して	PASS
A09	正常系	ニッケルを含む L1 ₂ 型化合物を出して	PASS
A10	正常系	L1 ₂ 化合物の全データを出して	PASS
A11	正常系	Ti を含む L1 ₂ 化合物を格子定数順（降順）に出して	PASS
A12	正常系	安定な L1 ₂ で格子定数 3.5Å 以上のものを出して	PASS
A13	正常系	Cu ₃ Au 型化合物を出して	PASS
A14	正常系	鉄を含む L1 ₂ 化合物を出して	PASS
A15	正常系	安定な L1 ₂ 化合物で Ni を含むものを出して	PASS
B01	該当なし	Xe を含む L1 ₂ 化合物を出して	PASS
B02	該当なし	U と Pu を含む L1 ₂ 化合物を出して	PASS
B03	該当なし	Rn と Og を含む L1 ₂ 化合物を出して	PASS
B04	該当なし	Sc と Ir を含む安定な L1 ₂ 化合物を出して	PASS
B05	該当なし	Pt と Ga を含む安定な L1 ₂ 化合物を出して	PASS
C01	曖昧	安定な化合物を出して	PASS
C02	曖昧	L12	PASS
C03	曖昧	安定なものを出して	PASS
C04	曖昧	（空入力）	PASS
C05	曖昧	今日の天気を教えて	PASS
C06	曖昧	Fe	PASS
C07	曖昧	格子定数	PASS
C08	曖昧	形成エネルギーが低い安定な L1 ₂ 化合物	PASS
C09	曖昧	NiAl L12	PASS
C10	曖昧	Ni の L12	PASS
D01	矛盾	安定かつ準安定な L1 ₂ 化合物	PASS
D02	矛盾	Ni なしの Ni L1 ₂ 化合物	PASS
E01	拒否	DROP TABLE material_entry;	PASS
E02	拒否	SELECT *; DELETE FROM composition;	PASS
E03	拒否	L1 ₂ 化合物; DROP TABLE structure;	PASS
E04	拒否	SELECT * FROM secret_passwords	PASS
E05	拒否	INSERT INTO material_entry VALUES (...)	PASS
F01	安全性	SELECT entry_id FROM material_entry	PASS
F02	安全性	UPDATE material_entry SET formula='X'	PASS

S3.1. 「Niを含む安定な $L1_2$ 化合物を出して」

```
LLM-only (スキーマ情報なし):.「  
1 SELECT formula, stability  
2 FROM materials  
3 WHERE element = 'Ni'  
4     AND structure_type = 'L12'  
5     AND stability = 'stable';  
6 -- テーブル幻覚: materials, stability等は存在しない  
7 -- 実行不可 (ERROR: relation "materials" does not exist)
```

```
Full Schema 提示 (スキーマ定義をプロンプトに含めるが few-shot 例なし):.「  
1 SELECT m.formula, ps.is_stable  
2 FROM material_entry m  
3     JOIN composition c ON c.entry_id = m.entry_id  
4     JOIN structure s ON s.entry_id = m.entry_id  
5     JOIN phase_stability ps ON ps.entry_id = m.entry_id  
6 WHERE c.element = 'Ni'  
7     AND s.strukturbericht = 'L12'  
8     AND ps.is_stable = true;  
9 -- 実行可能だが不完全:  
10 -- (1) prototype条件なし (L12がstrukturberichtに  
11 --   ない場合を見落とし)  
12 -- (2) DISTINCT/LIMITなし  
13 -- (3) 格子定数等の材料的に有用な列を選択していない
```

```
本手法 (Schema Graph 制約 + Few-shot + 辞書):.「  
1 SELECT DISTINCT m.entry_id, m.formula,  
2     s.prototype, s.lattice_a, s.space_group  
3 FROM material_entry m  
4     JOIN composition c ON c.entry_id = m.entry_id  
5     JOIN structure s ON s.entry_id = m.entry_id  
6     JOIN phase_stability ps ON ps.entry_id = m.entry_id  
7 WHERE (s.prototype = 'L12'  
8     OR s.strukturbericht = 'L12')  
9     AND c.element = 'Ni'  
10    AND ps.energy_above_hull <= 0.001  
11 LIMIT 10000;  
12 -- Schema Graph走査で必要な3 JOINのみ  
13 -- テーブル幻覚なし、DISTINCT, LIMIT付き
```

S3.2. 「NiとAlの両方を含む $L1_2$ 化合物を出して」

```
LLM-only (スキーマ情報なし):.「  
1 SELECT * FROM compounds  
2 WHERE elements LIKE '%Ni%' AND elements LIKE '%Al%'  
3     AND crystal_structure = 'L12';  
4 -- テーブル幻覚: compounds, elements列は存在しない
```

```
Full Schema 提示 (few-shot 例なし):.「  
1 SELECT m.entry_id, m.formula  
2 FROM material_entry m  
3     JOIN composition c ON c.entry_id = m.entry_id  
4     JOIN structure s ON s.entry_id = m.entry_id  
5 WHERE c.element = 'Ni' AND c.element = 'Al'  
6     AND s.prototype = 'L12';  
7 -- 致命的: 単一行が両条件を同時に満たすことは  
8 -- 不可能 -> 常に0行
```

```
本手法 (EXISTS 副問い合わせ):.「  
1 SELECT DISTINCT m.entry_id, m.formula  
2 FROM material_entry m  
3     JOIN structure s ON s.entry_id = m.entry_id  
4 WHERE (s.prototype = 'L12'  
5     OR s.strukturbericht = 'L12')  
6 AND EXISTS (  
7     SELECT 1 FROM composition  
8     WHERE entry_id = m.entry_id AND element = 'Ni')  
9 AND EXISTS (  
10    SELECT 1 FROM composition  
11    WHERE entry_id = m.entry_id AND element = 'Al')  
12 LIMIT 10000;  
13 -- EXISTS副問い合わせで正確な多元素AND
```

Table S3: Ni₃Al 近傍格子定数候補 ($|a - a_{\text{ref}}| \leq 0.03 \text{ \AA}$ 、代表 14 件)。

化合物	$a \text{ (\AA)}$	$ \Delta a $	E_{hull}	E_f
Hf ₃ Y	3.569	0.001	0.039	-0.443
Ni ₃ Al	3.572	0.002	0.000	-0.420
Pd ₃ Mn	3.570	0.000	0.033	-0.180
Cr ₃ Al	3.567	0.003	0.082	-0.120
Cr ₃ Fe	3.574	0.004	0.037	-0.453
Rh ₃ Zr	3.574	0.004	0.026	-0.525
Cu ₃ Zr	3.575	0.005	0.038	-0.037
Ag ₃ Ti	3.564	0.006	0.039	+0.088
Au ₃ V	3.564	0.006	0.088	-0.471
Mo ₃ Nb	3.586	0.016	0.007	-0.154
Co ₃ Ti	3.550	0.020	0.000	-0.450
Pt ₃ Ge	3.550	0.020	0.021	-0.478
Ni ₃ Ge	3.583	0.013	0.075	-0.128
Ni ₃ Ga	3.598	0.028	0.030	-0.229

S4. Ni₃Al 近傍格子定数候補

$|a - a_{\text{Ni}_3\text{Al}}| \leq 0.03 \text{ \AA}$ を厳密に満たす候補を表 S3 に示す ($a_{\text{ref}} = 3.57 \text{ \AA}$ 、全 31 件中代表 14 件)。
Co₃Ti ($\Delta a = 0.02 \text{ \AA}$ 、 $E_{\text{hull}} = 0.0$) は安定相であり析出強化候補として最も現実的である。

S5. 安定 L1₂ 候補の形成エネルギーランキング

$E_{\text{hull}} \leq 0.05 \text{ eV/atom}$ を満たす安定・準安定 L1₂ 候補を抽出した。安定 ($E_{\text{hull}} \leq 0.001$) 8 件、準安定 ($0.001 < E_{\text{hull}} \leq 0.05$) 154 件の計 162 件が候補として抽出された。安定相のうち、最も負の形成エネルギーを持つのは Pt₃Al ($E_f = -0.550 \text{ eV/atom}$) であり、次いで Al₃Sc (-0.500)、Co₃Ti (-0.450)、Ni₃Al (-0.420) が続く。

S6. SQL インジェクション・安全性テスト詳細

本文 8 節で報告した安全性テスト結果の補足情報を示す。SQLGuard の各検証項目 (14 項目、2.8 節) は独立に動作し、複数の脅威ベクトルに対する多層防御を提供する。禁止キーワード検出は正規表現ベースであり、テーブルホワイトリストはスキーマメタデータから自動生成される。

S7. LLM モード設定

LLM モードでは OpenAI API を介して GPT-5.5 を使用した。表 S4 にモデルパラメータを示す。

Table S4: LLM モード設定パラメータ。

パラメータ	値
モデル名	GPT-5.5 (OpenAI)
API アクセス日	2026 年 5-6 月
Temperature	未指定 (GPT-5 系は temperature パラメータ未サポート)
Max tokens	4,096 (全手法共通)
Top- p	1.0
リクエストタイムアウト	30 秒
リトライ回数	最大 3 回 (指数バックオフ)
n-best 候補数	3
Cross-Encoder	ms-marco-MiniLM-L-6-v2
リペアループ上限	3 回

構造化プロンプトは以下の 4 要素から構成される：

1. システムメッセージ：タスク説明 + スキーマ YAML (テーブル名、カラム名、型、FK 関係)
2. **Few-Shot** 事例：TF-IDF + Cross-Encoder で選択された Top- k 類似 NL-SQL ペア
3. ユーザーメッセージ：自然言語クエリ

4. 制約：「SELECT 文のみ生成」「LIMIT 10000 を含める」「スキーマに記載されたテーブルのみ使用」

GPT-5 系 API では temperature パラメータはサポートされておらず、本実装でも送信していない。そのため、LLM の内部状態により同一入力でも出力が変動する可能性がある。本論文の全 ablation 結果は 5 独立ランの平均 ± 標準偏差で報告し、Wilcoxon 符号順位検定で統計的有意性を確認した。

S8. 評価クエリ 100 件の詳細結果

表 S5 に評価クエリ 100 件（著者設計、E=20/M=30/H=30/VH=20）の各クエリの質問文、実行精度（行一致 recall）、レイテンシ、正誤判定（精度 ≥ 0.8 で ✓）を示す。全数値は ablation full 条件の結果である。

Table S5: 評価クエリ 100 件の詳細結果（full 条件）。

ID	クエリ	精度	秒	正誤
Easy (20 件)				
q_easy_001	L1 ₂ 構造を持つ化合物を一覧にして。	1.00	29.7	✓
q_easy_002	Ni を含む L1 ₂ 型金属間化合物を抽出して。	1.00	44.3	✓
q_easy_003	A ₃ B 型組成を持つ化合物を表示して。	1.00	31.5	✓
q_easy_004	L12 型化合物の格子定数を一覧にして。	1.00	13.1	✓
q_easy_005	Co を含む化合物を表示して。	1.00	17.2	✓
q_easy_006	cubic 構造の化合物を一覧にして。	1.00	12.6	✓
q_easy_007	L1 ₂ 型化合物のリストを出して。	1.00	20.9	✓
q_easy_008	Al を含む化合物を抽出して。	1.00	16.3	✓
q_easy_009	空間群番号 221 の化合物を表示して。	1.00	13.1	✓
q_easy_010	Ti を含む L1 ₂ 型化合物を一覧にして。	1.00	23.7	✓
q_easy_011	全化合物の formula 一覧を出して。	1.00	12.3	✓
q_easy_012	L12 型化合物の数を教えて。	1.00	19.9	✓
q_easy_013	Pt を含む化合物を表示して。	1.00	14.7	✓
q_easy_014	Ni と Al の両方を含む化合物を抽出して。	1.00	17.9	✓
q_easy_015	Ga を含む L1 ₂ 型化合物を表示して。	1.00	37.5	✓
q_easy_016	Fe を含む化合物を一覧にして。	1.00	20.1	✓
q_easy_017	A サイトの元素を一覧にして。	1.00	10.7	✓
q_easy_018	化合物の元素系を表示して。	1.00	13.7	✓
q_easy_019	L1 ₂ 型で cubic 構造の化合物を出して。	1.00	18.4	✓
q_easy_020	W を含む L1 ₂ 型化合物を表示して。	1.00	34.4	✓
Medium (30 件)				
q_medium_001	Ni を含む安定な L1 ₂ 型化合物を抽出して。	1.00	26.4	✓
q_medium_002	形成エネルギーが負の L1 ₂ 型化合物を元素組み合わせごとに整理して。	1.00	29.0	✓
q_medium_003	Al を含む安定な L1 ₂ 型金属間化合物を抽出して。	1.00	43.3	✓
q_medium_004	Ni ₃ Al に近い格子定数を持つ L1 ₂ 化合物を探して。	1.00	34.9	✓
q_medium_005	安定な L1 ₂ 型化合物を形成エネルギーが低い順に出して。	1.00	33.9	✓
q_medium_006	準安定な L1 ₂ 型化合物を抽出して。	0.84	34.3	✓
q_medium_007	L1 ₂ 型化合物の形成エネルギー分布を教えて。	1.00	24.8	✓
q_medium_008	Co 含有 L1 ₂ 型化合物を安定性の高い順に表示して。	1.00	25.6	✓
q_medium_009	格子定数が 3.5Å 以上の L1 ₂ 化合物を出して。	1.00	14.3	✓
q_medium_010	Ni または Co を含む L1 ₂ 型化合物を一覧にして。	1.00	34.7	✓
q_medium_011	形成エネルギーが -0.4 以下の L1 ₂ 型化合物を出して。	1.00	20.5	✓
q_medium_012	energy above hull が 0.01 以下の L1 ₂ 型化合物を表示して。	1.00	31.0	✓
q_medium_013	Ti 含有 L1 ₂ 型化合物の格子定数と形成エネルギーを表示して。	1.00	18.0	✓
q_medium_014	L1 ₂ 化合物の格子定数を小さい順にソートして。	1.00	16.5	✓
q_medium_015	化学系 Al-Ni に属する L1 ₂ 化合物を抽出して。	1.00	20.9	✓
q_medium_016	安定で格子定数が 3.6Å 未満の L1 ₂ 化合物を出して。	1.00	24.2	✓

次ページに続く

ID	クエリ	精度	秒	正誤
q_medium_017	Nb を含む L1 ₂ 型化合物の安定性情報を出して。	1.00	30.8	✓
q_medium_018	Sc を含む L1 ₂ 型化合物を格子定数と共に表示して。	1.00	26.6	✓
q_medium_019	L1 ₂ 型化合物のうち is_stable が true のものを出して。	1.00	30.1	✓
q_medium_020	Ni-Al 系以外の L1 ₂ 型化合物を一覧にして。	1.00	19.6	✓
q_medium_021	A サイト元素ごとの L1 ₂ 型化合物数を集計して。	1.00	24.4	✓
q_medium_022	形成エネルギーが最も低い L1 ₂ 型化合物 TOP5 を出して。	1.00	25.9	✓
q_medium_023	格子定数が 4.0Å 以上の L1 ₂ 化合物を出して。	1.00	16.3	✓
q_medium_024	Pd を含む L1 ₂ 型化合物を形成エネルギー順に出して。	1.00	43.6	✓
q_medium_025	Cu 含有の L1 ₂ 型化合物を安定性で分類して。	1.00	33.7	✓
q_medium_026	B サイト元素ごとの平均形成エネルギーを出して。	0.00	29.2	—
q_medium_027	格子体積が 12Å ³ /atom 以下の L1 ₂ 化合物を出して。	1.00	19.8	✓
q_medium_028	Ir 含有 L1 ₂ 型化合物の一覧を出して。	1.00	23.7	✓
q_medium_029	2 元素系の L1 ₂ 型化合物を chemical_system で分類して。	1.00	21.9	✓
q_medium_030	安定な L1 ₂ 型化合物のうち格子定数が大きい順に並べて。	1.00	28.8	✓
Hard (30 件)				
q_hard_001	Ni 基超合金の γ' 相候補として有望な安定/準安定 L1 ₂ 化合物。	0.06	70.6	—
q_hard_002	A サイト × B サイト組み合わせと形成エネルギーの関係。	1.00	36.0	✓
q_hard_003	格子定数が Ni ₃ Al に近く形成エネルギーが低い候補。	1.00	40.7	✓
q_hard_004	安定 L1 ₂ のバルクモジュラスを高い順に表示。	1.00	29.5	✓
q_hard_005	Ni/Co を含む安定 L1 ₂ を形成エネルギー順に。	1.00	45.9	✓
q_hard_006	A サイト元素別の平均格子定数を集計。	1.00	23.5	✓
q_hard_007	$E_f \leq -0.3$ かつ $a = 3.5\text{--}3.7\text{\AA}$ の L1 ₂ 化合物。	1.00	25.7	✓
q_hard_008	バルクモジュラス 180GPa 以上の L1 ₂ 化合物。	1.00	26.8	✓
q_hard_009	Co 基 L1 ₂ で Ni ₃ Al に近い格子定数、安定性順。	1.00	50.6	✓
q_hard_010	B サイト Al/Ti の L1 ₂ を形成エネルギー順に。	1.00	25.4	✓
q_hard_011	L1 ₂ 化合物のせん断弾性率を表示。	1.00	23.0	✓
q_hard_012	安定で E_f 最低の L1 ₂ トップ 10。	0.50	29.4	—
q_hard_013	Ni 含有 L1 ₂ のバルクモジュラスと E_f の関係。	1.00	38.5	✓
q_hard_014	A サイト元素グループ別平均 E_f 。	0.00	34.8	—
q_hard_015	$a \approx 3.55\text{\AA}$ でバルクモジュラスの高い L1 ₂ 。	0.51	36.3	—
q_hard_016	格子定数と E_f の相関データ。	1.00	18.9	✓
q_hard_017	Co ₃ Ti と Ni ₃ Al の格子定数差を計算。	1.00	31.0	✓
q_hard_018	Al 系 L1 ₂ の安定/不安定の件数。	0.00	35.6	—
q_hard_019	準安定 L1 ₂ を energy above hull 順にランキング。	0.84	31.0	✓
q_hard_020	B サイト元素ごとの安定 L1 ₂ 数を集計。	0.20	21.8	—
q_hard_021	DFT 計算で得られた物性一覧。	1.00	36.6	✓
q_hard_022	PBE 汎関数計算のバルクモジュラス。	1.00	25.3	✓
q_hard_023	Ni ₃ Al との格子ミスマッチを小さい順に。	1.00	19.0	✓
q_hard_024	Fe 含有 L1 ₂ の安定性と弾性特性を同時表示。	0.00	31.2	—
q_hard_025	安定 L1 ₂ でバルクモジュラス 160GPa 以上。	1.00	36.9	✓
q_hard_026	安定性 × 格子定数で Ni ₃ Al に近い候補。	1.00	30.0	✓
q_hard_027	A サイト=Ni/Co、B サイト=Al/Ti の L1 ₂ 。	1.00	34.8	✓
q_hard_028	体積あたり原子数と格子定数の関係。	1.00	23.2	✓
q_hard_029	$E_{\text{hull}} = 0$ かつ $E_f \leq -0.4$ の L1 ₂ 。	1.00	30.7	✓
q_hard_030	遷移金属含有の安定 L1 ₂ 。	1.00	58.2	✓
Very Hard (20 件)				
q_vhard_001	相安定性 × 格子ミスマッチ × 弾性の多基準評価。	0.00	49.9	—
q_vhard_002	Ni ₃ Al 代替/ γ' 候補の多基準探索。	0.04	48.9	—
q_vhard_003	γ' 候補の重み付きスコアでランキング。	0.00	48.3	—
q_vhard_004	Ni/Co 含有 × 安定 × 高 B のトップ 10。	1.00	33.5	✓
q_vhard_005	元素組み合わせ × 安定性を A/B サイト別に集計。	1.00	47.7	✓

次ページに続く

ID	クエリ	精度	秒	正誤
q_vhard_006	Ni ₃ Al に近い格子 × 高 B × 安定の総合評価。	0.19	42.4	—
q_vhard_007	析出強化 L1 ₂ の多基準 (ミスマッチ × G × 安定性)。	0.05	45.8	—
q_vhard_008	Co 基 γ' 候補の Ni ₃ Al 比較付き探索。	0.11	27.9	—
q_vhard_009	Co ₃ Ti の生成エンタルピーを純物質基準から計算 (CTE)。	1.00	23.0	✓
q_vhard_010	E_f vs E_{hull} の安定性マップデータ。	1.00	48.8	✓
q_vhard_011	高温安定性の観点で E_f 上位候補。	0.09	39.2	—
q_vhard_012	Ni-Al 系以外の γ' 代替候補。	0.02	37.3	—
q_vhard_013	B vs a の散布図データ出力。	1.00	18.6	✓
q_vhard_014	3d vs 4d/5d 遷移金属 A サイトの比較。	0.88	53.1	✓
q_vhard_015	Ni ₃ Al より安定で B が高い候補。	0.00	49.6	—
q_vhard_016	安定 L1 ₂ の ΔH_f を CTE で算出、 <-0.3 でフィルタ。	1.00	30.3	✓
q_vhard_017	安定性 × 格子整合 × 弾性の複合スコア。	1.00	68.3	✓
q_vhard_018	A-site 元素ごとの平均 ΔH_f を CTE で集約。	1.00	28.2	✓
q_vhard_019	Ni 含有安定 L1 ₂ の ΔH_f を多段 CTE で算出、Top5。	1.00	32.7	✓
q_vhard_020	形成 E が加重純物質基準より 0.1 以上低い化合物 (CTE)。	1.00	23.9	✓

S9. Ablation 条件間の精度差異クエリ

表 S6 に、7 条件間で精度が異なる 35 件のクエリを示す。太字は full 条件から 0.05 以上低下した値を表す。-FS = no_fewshot、-Dict = no_dict、-RR = no_reranker、-GD = no_guard、-NB = no_nbest、-GR = no_graph。

Table S6: Ablation 条件間で精度が異なるクエリ (35 件/100 件)。太字は full 条件から > 0.05 の低下。

ID	D	Full	-FS	-Dict	-RR	-GD	-NB	-GR
q_easy_007	E	1.00	0.00	1.00	1.00	1.00	1.00	1.00
q_medium_001	M	1.00	0.00	1.00	1.00	1.00	1.00	1.00
q_medium_004	M	1.00	1.00	1.00	0.00	1.00	1.00	1.00
q_medium_012	M	1.00	0.00	1.00	1.00	1.00	1.00	1.00
q_medium_013	M	1.00	0.00	1.00	1.00	1.00	1.00	1.00
q_medium_014	M	1.00	0.00	1.00	1.00	1.00	1.00	1.00
q_medium_020	M	1.00	1.00	1.00	0.00	1.00	1.00	1.00
q_medium_021	M	1.00	0.00	1.00	1.00	1.00	1.00	1.00
q_medium_026	M	0.00	0.05	0.00	0.00	0.00	0.00	0.00
q_hard_001	H	0.06	0.00	0.00	0.06	0.06	0.06	0.06
q_hard_002	H	1.00	1.00	0.00	1.00	1.00	1.00	1.00
q_hard_003	H	1.00	0.00	1.00	0.01	1.00	1.00	1.00
q_hard_004	H	1.00	0.00	1.00	1.00	1.00	1.00	1.00
q_hard_006	H	1.00	1.00	0.00	1.00	1.00	1.00	1.00
q_hard_010	H	1.00	0.00	1.00	1.00	1.00	1.00	1.00
q_hard_011	H	1.00	0.00	1.00	1.00	1.00	1.00	1.00
q_hard_012	H	0.50	0.50	0.38	0.50	0.50	0.50	0.50
q_hard_024	H	0.00	0.00	0.00	0.11	0.00	0.00	0.00
q_hard_026	H	1.00	1.00	1.00	0.01	1.00	1.00	1.00
q_vhard_001	V	0.00	0.00	0.00	0.19	0.00	0.00	0.00
q_vhard_002	V	0.04	0.17	0.19	0.03	0.02	0.00	0.03
q_vhard_004	V	1.00	1.00	0.00	1.00	1.00	1.00	1.00
q_vhard_005	V	1.00	1.00	0.00	1.00	1.00	0.00	1.00
q_vhard_006	V	0.19	0.19	0.00	0.19	0.19	0.19	0.19
q_vhard_007	V	0.05	0.00	0.00	1.00	1.00	1.00	1.00
q_vhard_008	V	0.11	0.11	0.00	0.11	0.11	0.11	0.11
q_vhard_009	V	1.00	0.00	1.00	1.00	0.00	1.00	1.00
q_vhard_012	V	0.02	0.18	0.00	0.18	0.18	0.18	0.18
q_vhard_013	V	1.00	0.00	1.00	1.00	1.00	1.00	1.00
q_vhard_015	V	0.00	0.02	0.00	0.02	0.02	0.00	0.02
q_vhard_016	V	1.00	0.00	1.00	1.00	0.00	1.00	1.00
q_vhard_017	V	1.00	0.60	0.00	1.00	1.00	1.00	1.00
q_vhard_018	V	1.00	0.00	1.00	1.00	0.00	1.00	1.00
q_vhard_019	V	1.00	0.00	0.60	1.00	0.00	1.00	1.00
q_vhard_020	V	1.00	0.00	1.00	1.00	0.00	1.00	1.00

表 S6 から、以下の傾向が読み取れる：

- no_fewshot (-FS) では Easy-Hard 帯のクエリが広範に 0 化し、few-shot 例の汎用的な寄与を示す。
- no_dict (-Dict) では Very Hard 帯で集中的に 0 化し、ドメイン辞書が VH 帯に不可欠であることを裏付ける。
- no_reranker (-RR) では q_hard_003, q_hard_026, q_medium_004, q_medium_020 で完全失敗し、候補選別の効果を示す。

- no_guard (−GD) では CTE クエリ (q_vhard_009/016/018/019/020) が全件 0 化し、SQLGuard が CTE 構文の安全性検証に不可欠であることを示す。
- q_vhard_007 は full 条件で 0.05 であるが、−RR/−GD/−NB/−GR 条件で 1.00 に上昇。リランカー・SQLGuard が過剰フィルタリングする例である。

S10. 独立設計クエリプールの詳細結果

本論文 10.9 節で報告した独立設計クエリについて、元の 100 件クエリプール (カテゴリ A–J) の難易度別正答率を表 S7 に示す。このうち 48 件が統一分類基準により 60 件の調和セットに採用されている (Very Hard 12 件は新規設計)。難易度は E (Easy)、M (Medium)、H (Hard)、VH (Very Hard) の 4 段階であり、正誤判定は実行 $F1 \geq 0.8$ を正解と判定した。

Table S7: 独立設計クエリの難易度別正答率 (統一複雑度スコア基準)。

難易度	件数	正答数	正答率	平均実行精度
Easy (< 8)	12	9	75.0%	83.3%
Medium (8–11)	18	10	55.6%	69.9%
Hard (12–16)	18	11	61.1%	70.1%
Very Hard (≥ 17)	12	2	16.7%	19.4%
全体	60	32	53.3%	62.5%

Very Hard (5–7 テーブル JOIN 必須) の正答率 16.7% は、著者設計の Very Hard (32.7%) よりさらに低く、未カバーテーブルへの JOIN 経路探索が主要な課題であることを示す。

独立設計クエリプールは 10 カテゴリ (A: 基本検索、B: 組成・元素、C: 構造・格子定数、D: 安定性・形成エネルギー、E: DFT 計算・物性、F: 電子構造・磁性・熱特性、G: 表面・粒界・欠陥、H: 文献・合成・応用、I: 材料設計・スクリーニング、J: 比較・統計) から構成される。各カテゴリ 10 件、合計 100 件のうち 48 件が調和セットに採用され、新規 VH 12 件と合わせて 60 件の評価セットとなっている。