

Schema-Graph-Constrained Natural Language Interface for Intermetallic Compound Exploration: 金属間化合物探索のための Schema Graph 制約型自然言語データベースインターフェース

Satoshi Minamoto^{a,*}

^aNational Institute for Materials Science (NIMS), 1-2-1 Sengen, Tsukuba, Ibaraki 305-0047, Japan

Abstract

第一原理計算データベースに蓄積された材料データの横断的探索には SQL の専門知識が求められ、材料研究者にとって大きな障壁となっている。本研究では、自然言語による問い合わせから正規化リレーショナルデータベース上の SQL クエリを自動生成する Schema Graph 制約型 Text-to-SQL 手法を提案する。提案手法は、外部キー関係をグラフとして表現し Steiner 木近似による最小 JOIN 経路の同定、ドメイン特化型条件抽出器による材料用語の正規化、多層 SQL ガードによるテーブル・カラム幻覚の防止、およびスキーマ制約付き大規模言語モデル (LLM) 生成を統合したパイプラインである。L1₂ 型金属間化合物を中心とする 30 テーブル・1,470 件の検証データベースに対し、100 件の評価クエリ (最大 6 テーブル参照) で 5 手法を比較した結果、提案手法は平均実行精度 70.2%、構文妥当率 99%、テーブル幻覚率 0% を達成し、全スキーマ提示手法 (26.6%) に対して +43.6 ポイントの改善を示した。独立した材料研究者が設計した 100 件の追加クエリでは実行精度 79.3% を記録し、構文妥当率 100% を維持した。材料工学的評価では、既知 L1₂ 化合物 11 件の全件再発見および γ' 相候補のランキング出力を達成した。本手法は外部キー関係の実行時イントロスペクションに基づくため、任意の正規化材料データベースへの適用が可能である。

Keywords: Text-to-SQL, L1₂ 型金属間化合物, スキーマグラフ, Steiner 木近似, γ' 相, 材料データベース, 自然言語処理, マテリアルズ・インフォマティクス

1. 緒言

1.1. AI for Science と材料インフォマティクスにおけるデータアクセス障壁

材料データベースにおける自然言語インターフェースの本質的課題は、SQL 文の構文生成そのものではなく、正規化された異種材料データを、外部キー関係と材料ドメイン意味論に従って正しく結合することである。本論文では、L1₂ 型金属間化合物 (γ' 相候補) の探索を対象として、Schema Graph 走査 (FK 関係のグラフ表現と Steiner 木近似) に基づく制約型手法を提案し、1,470 エントリ (5 プロトタイプ)・100 クエリの評価で Proposed 手法がテーブル幻覚率 0%、実行精度 70.2% を達成したことを報告する。

AI for Science (AI4S)—科学的発見を加速するための人工知能の体系的応用—は、材料研究を変革しつつある [1, 2]。AI4S は、AI エージェントが自律的に仮説を生成し、大規模データベースから関連データを検索し、実験やシミュレーションを設計し、結果を解釈する統合的ワークフローを構想している。このビジョンにおいて、構造化された材料データへの自然言語アクセスは単なる利便性ではなく前提条件である：AI エージェント (またはそれを指揮する研究者)

が正規化リレーショナルデータベースを効率的にクエリできなければ、AI4S パイプライン全体がデータ検索段階でボトルネックとなる。

ハイスループット第一原理計算の急速な発展により、複数の大規模材料データベースが構築されている：Open Quantum Materials Database (OQMD, 約 100 万件) [3, 4]、Materials Project (15 万件超) [5]、AFLOW (350 万件超) [6]、NOMAD [7]。これらのデータベースは計算材料探索、候補相のスクリーニング [8, 9]、実験観測の検証に不可欠である。一方、材料データの構造化・知識化の取り組みとして、Ishii らはレガシー超伝導データベース SuperCon のオントロジー構築と RDF 化 [10] や、高分子データベース PoLyInfo の機械可読化 [11] を実現しており、スキーマの意味的構造化が材料データ活用の前提条件であることを示している。

しかし、正規化リレーショナルスキーマ (外部キーで接続された複数テーブル) に格納されたデータへのアクセスには SQL 知識が必要である。材料工学において本質的に重要なのは、大量データの収集よりも少量の異種データを正確に組み合わせることである：組成・結晶構造・熱力学的安定性・計算条件・物性値はそれぞれ独立したテーブルに正規化されており、これらを外部キー (FK) に沿って正しく JOIN することで初めて意味のある材料情報が得られる。例えば、「Fe を含む安定な B2 化合物の格子定数」を検索するには、元素・プロトタイプ・熱力学的安定性に対する WHERE 条件を持つ 4 テーブル JOIN が必要となる—データベース技

*Corresponding author

Email address: minamoto.satoshi@nims.go.jp (Satoshi Minamoto)

術者にとっては容易だが、材料研究者にとっては非自明な操作である。不正確な JOIN (不要なテーブル結合や結合条件の欠落) は誤ったデータの組み合わせを返し、材料探索やスクリーニングの判断を誤導する深刻なリスクとなる。

多くの材料データベースが提供する REST API や GraphQL エンドポイントはこの障壁を部分的に緩和するが、RDB 全般に共通する根本的制約が残る：(a) 事前定義されたフィルタ構文への依存 (アドホックな複合条件や集約が困難)、(b) スキーマ更新時の API 非互換リスク、(c) 機関内データベースや独自拡張スキーマには API が存在しない場合が多いこと。T2SQL アプローチは、スキーマ構造を実行時に解析するため、API の有無に関わらず任意の正規化 RDB に対して原理的に適用可能である (用語辞書の整備と大規模スキーマでの性能検証は別途必要)。

AI4S の文脈において、このデータアクセス障壁は特に深刻である：材料スクリーニングや物性予測を行う自律 AI エージェントは、複雑な複合条件データベースクエリをプログラマ的に発行する必要がある。正しい SQL を確実に生成する自然言語インターフェースは、人間の研究者と AI エージェントの双方がデータベース工学の専門知識なしに材料データベースと対話することを可能にし、AI4S ワークフローの重要なボトルネックを除去する。

1.2. Text-to-SQL の技術動向

Text-to-SQL (T2SQL) 研究は大規模ベンチマークにより急速に進展している：Spider [12] (10,181 問、200 データベース、138 ドメイン)、BIRD [13] (12,751 問、95 データベース、33.4 GB)。最近の LLM ベース手法は高い精度を達成している：DAIL-SQL [14] はスケルトンベースの few-shot 事例選択により Spider 上で実行精度 86.6% を報告し、DIN-SQL [15] は分解型文脈内学習により 85.3% を達成し、XiYan-SQL [16] はマルチジェネレータアンサンブルによりさらなる精度向上を報告している。Hong et al. [17] はスキーマリンクの支配的役割を指摘する包括的サーベイを提供し、Maamari et al. [18] は高度な LLM により明示的スキーマリンクが不要になる可能性を論じているが、これは議論が続いている。

スキーマ構造をグラフとして明示的に利用する手法も発展している。RAT-SQL [19] は Relation-Aware Schema Encoding によりテーブル間関係を事前学習し、ShadowGNN [20] はグラフ射影ニューラルネットワークでスキーマグラフを符号化する。RESDSL [21] はスキーマリンクとスケルトン解析を分離し、Bridge [22] はテキストと表形式データの橋渡しを行う。最近では、SchemaGraphSQL [23] がパースファインディングアルゴリズムによる大規模 DB スキーマリンクを提案し、GraST-SQL [24] は機能依存グラフによるスキーマフィルタリングのスケールリングに取り組んでいる。McMillan [25] は構造化コンテキストエンジニアリングがマルチファイルエージェントシステムにおけるスキーマ精度に与える影響を評価している。

しかし、既存の **T2SQL** ベンチマークはすべて汎用ドメイン (e コマース、医療、教育) を対象としており、材料科学データベース固有の課題に取り組んだ先行研究は存在しない：ドメイン固有の用語 (Strukturbericht 記号、プロトタイプ名)、バイリンガルクエリ (日英元素名)、組成テーブル正規化 (化合物ごとに元素 1 行)、熱力学的安定性フィルタ ($E_{\text{hull}} \leq 0.001$ eV/atom) などの課題である。

1.3. 材料インフォマティクスにおける NLP

材料科学における NLP 応用は拡大している：MatSci-NLP [26] は材料テキストの 7 つの NLP タスクをベンチマークし、LLAMAT [27] は LLaMA の継続事前学習により情報抽出を改善し、Materials Knowledge Navigation Agent (MKNA) [28] は自然言語の意図をデータベース検索・構造生成アクションに変換し、OptiMat Alloys [29] は LLM 駆動型対話式合金探索ツールを提供している。Materials Project は MCP ベースの LLM 統合の提供を開始している [30]。

これらの研究は情報抽出やエージェントベースのデータベース対話を扱っているが、正規化リレーショナルデータベース上のスキーマ認識型 **SQL** 生成—特に外部キーグラフ走査による自動 JOIN 経路探索—を対象としたものはない。このギャップが本手法の焦点である。

1.4. オントロジー・知識グラフアプローチとの関連

材料データへの構造化アクセスには、オントロジー・知識グラフ (KG) に基づくアプローチも有力な系譜を形成している。Ishii らは超伝導材料データベース SuperCon を RDF オントロジーとして再構築し、SPARQL エンドポイントを通じた意味検索を実現した [10]。同グループは PoLyInfo の高分子データについても同様の機械可読化を行い、BFO 上位オントロジーとの整合により分野横断的なデータ連携を可能にしている [11]。欧州では Elementary Multiperspective Material Ontology (EMMO) が材料モデリングの標準オントロジーとして整備され、OWL 推論に基づく意味の一貫性の保証を提供している [31]。

汎用ドメインでは、Sequeda & Allemang [32] が企業 SQL データベースを知識グラフに変換し、Text-to-SPARQL が Text-to-SQL に比べ正解率を 16% から 54% に向上させることを示した。さらにオントロジーの意味制約を用いたクエリ検証 (OBQC) により 72% まで改善している [33]。

本手法はこれらオントロジーアプローチと構造制約によるクエリ品質保証という目的を共有する。オントロジーの OWL プロパティにおける domain/range 制約は、RDB における FK 関係のテーブル間制約と機能的に対応し、OBQC による SPARQL クエリ検証は、本手法の SQLGuard (カラムホワイトリスト・FK 整合 JOIN 検証) と同等の役割を果たす。ただし、両アプローチの適用文脈は異なる。オントロジーアプローチは RDF トリプルストアへのデータ変換を前提とし、OWL 推論による意味的推移律 (例：「NiAl は L1₂ 型」→「NiAl は金属間化合物」) や異種データベース間の相互運用性において優れた表現力を持つ。一方、OQMD [3]・Materials Project [5]・AFLOW [6] 等の大規模材料データベースは既にリレーショナルスキーマで運用されており、本手法はこれらの既存 **RDB** インフラをそのまま活用する設計を採用している。FK 関係のグラフ走査 (Steiner 木近似) は、オントロジーの推論に依存せずに JOIN パスの正確性を保証する軽量な代替手段を提供する。

両アプローチは排他的ではなく相補的である。将来的には、オントロジーが定義する意味的制約を Schema Graph の走査ヒューリスティックに統合することで、FK 関係だけでなくドメイン知識に基づく JOIN パス選択が可能になると考えられる。

1.5. 目的と新規性

本研究の貢献は以下の5点である：

1. **L1₂ 型化合物探索に特化した Schema Graph 制約型 T2SQL 手法**：日英バイリンガル材料用語辞書と FK 関係グラフ走査を組み合わせ、L1₂/γ'/Cu₃Au 型等の同義表現正規化を含む正規化材料データベース上の自動 JOIN 経路計算を実現する。Schema Graph 制約によりテーブル幻覚率 **0%**を達成し、LLM-only 手法の幻覚を解消するとともに、不要 JOIN の排除により実行精度 **70.2%**を達成する。
2. **5 手法ベースライン比較による定量評価**：LLM-only、Full Schema、Rule-based、FK-list、Proposed の5手法を100クエリ（Easy/Medium/Hard/Very Hard、参照テーブル数基準）で比較し、スキーマ情報の提示方法が SQL 品質に与える影響を体系的に評価する。
3. **多層 SQL ガードによる安全性保証**：キーワードブラックリスト、テーブル/カラムホワイトリスト、JOIN 検証、自動 LIMIT 注入を統合し、不正 SQL の実行を防止する。
4. **材料工学的評価**：既知 L1₂ 化合物 11 件の全件再発見（11/11）、γ' 相候補ランキング、Ni₃Al 近傍格子定数候補抽出、材料設計仮説の自動生成を達成する。
5. **マルチテーブルクエリ評価**：3 テーブル以上の JOIN を要する 73 件のマルチテーブルクエリに対し、Proposed 手法の実行精度と各ベースラインの比較を報告する。
本手法の全体アーキテクチャを図 1（概要）および図 2（詳細構成）に示す。

2. 材料 Text-to-SQL の設計要件

汎用 Text-to-SQL システムを材料データベースに直接適用した場合、以下の材料固有の要件が満たされず、重大な精度低下を招く。

1. **正規化組成テーブルの正確な JOIN**：多元素化合物の各元素が独立行として格納されるため、「Ni と Al を両方含む」検索には SELF-JOIN または INTERSECT が必要となる。汎用 LLM はこのパターンを頻繁に誤る。
2. **材料用語の曖昧性解消**：「NiAl」が特定化合物（B2-NiAl）か含有元素条件かは文脈依存であり、「安定」が $E_{\text{hull}} \leq 0.001$ eV/atom か $\Delta G_f < 0$ かはスキーマ依存である。ドメイン辞書なしではカラムマッピングが不定となる。
3. **プロトタイプ・空間群の語彙正規化**：L1₂、AuCu₃ 型、Cu₃Au 型は同一プロトタイプを指すが、表記が多様であり、日英バイリンガルでの同義語展開が必要。
4. **FK に沿った最小 JOIN パスの計算**：30 テーブル規模のスキーマでは候補 JOIN パスが爆発し、不要テーブルの結合が LLM 精度を低下させる。Steiner 木近似による最小サブグラフ抽出が不可欠。
5. **数値条件の単位・閾値解釈**：「バンドギャップが大きい」→ > 1.0 eV か > 2.0 eV か、「安定な」→ $E_{\text{hull}} \leq 0.001$ か ≤ 0.1 かは材料ドメイン知識に基づく判断が必要。
6. **スコープ外質問の拒否**：VASP 計算パラメータの最適化や DFT ワークフローに関する質問は SQL-answerable ではなく、無理に SQL を生成すると無意味な結果を返す。
7. **安全実行の保証**：SELECT 以外の SQL（INSERT/UPDATE/DELETE）の排除、無制限結果セットの防止（自動 LIMIT 注入）、テーブル・カラムホワイトリストによるインジェクション防止。

これらの要件は、汎用 Text-to-SQL ベンチマーク（Spider、WikiSQL 等）では評価対象に含まれない材料データベース固有の課題である。本手法は上記 7 要件すべてに対応する統合フレームワークとして設計された。

3. 手法

本節では各技術要素を詳述する。システム全体のパイプラインアーキテクチャを図 2 に示す。

3.1. 材料データのためのデータベーススキーマ設計

3.1.1. OQMD データの正規化スキーマ設計

OQMD は組成・構造・熱力学的安定性を体系的に格納しており、材料データベースに典型的なスキーマ複雑性（多対多関係、正規化された組成テーブル、構造パラメータの分離）を備えた好例である。API から取得したフラットな JSON レコードをリレーショナルスキーマに正規化する（表 1）。設計は Boyce-Codd 正規形（BCNF）に従い、以下の材料ドメイン固有の考慮に基づく。

組成テーブルの分離。単一の化合物が複数の元素を含む場合がある（例：Fe₃Al → Fe と Al）。各元素を composition テーブルの個別行として格納することで、文字列解析なしに柔軟な元素ベースクエリ（AND, OR, NOT）を可能にする [34]。ただし、この正規化は重要な複雑性を導入する：「Ni と Al の両方を含む化合物」のクエリは単純な WHERE element = 'Ni' AND element = 'Al' では不可能である（単一行が両条件を同時に満たすことはないため 0 行が返る）。代わりに EXISTS 副問い合わせが必要となる（3.3.4 節参照）。なお、この設計により化学式の表記順序（例：Ni₃Al と AlNi₃ は同一化合物だがデータベースによって表記慣例が異なる）に依存しない検索が実現される。元素と原子分率を個別行で格納するため、式全体の文字列比較ではなく元素単位のクエリで同一化合物を一意に特定できる。

構造/相安定性/計算の分離。結晶構造情報（プロトタイプ、格子定数）、熱力学的安定性（hull 上エネルギー）、計算メタデータ（DFT 汎関数）を別テーブルに格納し、独立した更新・拡張を可能にする。

計算物性の Entity-Attribute-Value (EAV) パターン。calculated_property テーブルは EAV パターン（property_name, value, unit）を使用し、スキーマ変更なしに任意の計算物性（体積弾性率、せん断弾性率等）を収容する。EAV 設計ではカラムホワイトリストに加え、property_name の許可値リスト（bulk_modulus、shear_modulus 等）を管理し、LLM が存在しない物性名を生成した場合に検出する。

ER 設計の汎用性に関する注記。OQMD は内部的に Django ORM + PostgreSQL で運用されているが、公開 API はフラット JSON を返却する。本研究ではこのフラットデータに対し、NetworkX グラフおよび YAML スキーマとして走査しやすい ER 図を新規に設計した。この設計判断により、本手法の適用可能性は以下の二つのシナリオに一般化される：(1) 既存 RDB のスキーマ情報（FK 制約）をそのまま抽出して走査する場合、(2) フラットデータから目的に応じた




Figure 1: Step 3 パイプラインの概要。自然言語クエリから条件抽出（Step 2）を経て、Steiner 木近似（Step 3）が 30 テーブルから必要最小限のサブグラフを抽出する。抽出されたテーブル・カラム・JOIN 条件を YAML で LLM に注入し（Step 4）、8 層 SQLGuard（Step 5）を経て安全な SQL を実行する。LLM の視界が必要テーブルに限定されるため、不要 JOIN とテーブル幻覚が原理的に排除される。




Figure 2: システムアーキテクチャの全体構成。実線矢印は主要データフロー、破線矢印（橙色）はデータ参照・フィードバックループを示す。Coverage Score に基づき Rule-based（高カバレッジ）または LLM（低カバレッジ）経路に分岐し、いずれも Schema Graph（30 テーブル FK 走査）による JOIN パス制約と SQLGuard 8 層検証を経て安全な SQL が生成・実行される。実行エラーまたは空結果が検出された場合は、エラー診断情報付きで LLM にリペアを依頼するリペアループ（最大 2 回）が作動する。成功したクエリベアは Few-Shot RAG ストアに蓄積され、以降の LLM 生成に活用される。

Table 1: データベーススキーマ概要。

テーブル名	主キー	外部キー	主要カラム
material_entry	entry_id	—	formula, reduced_formula, chemical_system
composition	composition_id	entry_id	element, atomic_fraction
structure	structure_id	entry_id	prototype, strukturbericht, lattice_a, space_group
phase_stability	stability_id	entry_id	formation_energy_per_atom, energy_above_hull, band_gap
calculation	calculation_id	entry_id	method, functional
calculated_property	property_id	calculation_id	property_name, value, unit
prototype_definition	prototype_id	—	prototype_name, strukturbericht, description

ER 図を新規構築して走査する場合。いずれの場合も、FK 関係がグラフとして表現可能であれば Schema Graph 走査による JOIN パス最適化が適用可能である。

3.1.2. RAG コンテキスト注入のための XML/YAML 表現
スキーマ構造は YAML (allowed_schema.yaml) としてシリアル化され、二重の目的に供される：(a) SQL ガードのテーブル/カラムホワイトリスト (3.6 節)、(b) LLM プロンプトへの RAG コンテキストスキーマ YAML がシステムメッセージに注入され、LLM が利用可能なテーブル・カラム・型を理解する。このアプローチは汎用 T2SQL のスキーマシリアル化技術 [14] と類似するが、材料データベースのドメイン固有カラム意味論（例：energy_above_hull は E_{hull} を表す）に特化している。

3.2. 材料用語辞書を備えた条件抽出器

条件抽出器は、YAML ベースの日英バイリンガル用語辞書 (material_terms.yaml) を用いて、自然言語クエリを構造化された条件辞書に変換する。

3.2.1. 辞書構造

- 辞書は 4 つのカテゴリを含む：
- プロトタイプ別名：プロトタイプ名とその変種の対応。
例：B2 $\leftrightarrow$ [B2, CsCl, CsCl 型, B2 型]
L12 $\leftrightarrow$ [L1₂, L12, AuCu₃, Cu₃Au 型, γ']
 - 元素マッピング：元素記号 $\leftrightarrow$ 日英名対応。
例：Fe $\leftrightarrow$ [Fe, 鉄, iron]
 - 安定性用語：自然言語 $\rightarrow$ 数値閾値。
「安定」/ “stable” $\rightarrow$ energy_above_hull $\leq$ 0.001 eV/atom
「準安定」/ “metastable” $\rightarrow$ 0.001 < energy_above_hull $\leq$ 0.05 eV/atom
「安定または準安定」 $\rightarrow$ energy_above_hull $\leq$ 0.05 eV/atom
SQL 条件では浮動小数点精度を考慮し、等号比較 (= 0) ではなく範囲条件 (<= 0.001) を使用する。
なお、DB カラム phase_stability.is_stable はデータ投入時に概ね $E_{\text{hull}} \leq 0.01$ eV/atom で付与されたブール値であり、上記の辞書定義 (≤ 0.001) とは閾値が異なる。Gold SQL では文脈に応じて両方を使い分けている。
 - 物性用語：物性記述からテーブル・カラム参照への対応。
「格子定数」/ “lattice constant” $\rightarrow$ structure.lattice_a
「形成エネルギー」/ “formation energy” $\rightarrow$ phase_stability.formation_energy_per_atom

3.2.2. Unicode 正規化とパターンマッチング

Unicode 下付き文字 (U+2080–U+2089、すなわち _{012...9}) はマッチング前に ASCII 数字に正規化される。プロトタイプ名は投入時に ASCII 表記 (L12、B2 等) へ正規化し、自然言語側の表記揺れ (L1₂、L12、 γ' 、Cu₃Au 型) は辞書で DB 内部値 (L12) に写像する。元素記号認識はワード境界正規表現を使用し、独立した「Fe」を「FeCoNi」部分文字列から正しく区別する。

3.2.3. 出力形式

抽出器は構造化辞書を返す：

Listing 1: 条件抽出の例。

```
# 入力: "Feを含む安定なB2化合物を出して"
# 出力:
{
  "prototype": "B2",
  "contains_elements": ["Fe"],
  "stability": "stable",
  "sort_by": None,
  "sort_order": None
}
```

3.2.4. 数値条件パーサー

条件抽出器は、自然言語中の数値比較表現を構造化された WHERE 句条件に変換する正規表現ベースの数値条件パーサーを含む。対応する 5 種類のパターンを表 2 に示す。

Table 2: 数値条件パーサーの対応パターン。

パターン種別	入力例	出力
記号比較	band_gap > 1.0 eV	WHERE band_gap > 1.0
日本語後置	形成エネルギーが 0.5 以上	WHERE ... >= 0.5
日本語より	格子定数が 3.0 より大きい	WHERE lattice_a > 3.0
符号判定	形成エネルギーが負	WHERE ... < 0
範囲指定	band gap 0.5–2.0 eV	WHERE ... BETWEEN 0.5 AND 2.0

物性名から対応カラムへのマッピングは内部辞書 (_PROPERTY_COLUMN_MAP) により管理され、「格子定数」 $\rightarrow$ structure.lattice_a、「形成エネルギー」 $\rightarrow$ phase_stability.formation_energy_per_atom 等の変換を行う。単位変換 (eV, Å, GPa 等) も内蔵するが、現検証 DB では物性値を投入時に標準単位 (eV/atom, Å, GPa) へ正規化しており、変換係数は全て 1.0 である。一般化の際には、入力単位を標準単位へ変換した上で WHERE 条件を生成する機構が必要となる。

浮動小数点比較と許容誤差。DFT 計算値は浮動小数点精度の制約を受けるため、厳密等号比較 (例：lattice_a = 3.572) は避け、範囲条件 (BETWEEN 3.571 AND 3.573) を優先する。「近傍」「同程度」等の自然言語表現に対しては、物性種別ごとに定義された許容幅 (格子定数： ± 0.03 Å, E_{hull} ： ± 0.001 eV/atom) を辞書から適用する。

NULL 値の処理。物性値が未計算 (NULL) のエントリは、数値比較クエリ (例：「バルクモジュラスが高い」) の結果から自動的に除外される。SQL 生成時に暗黙的に IS NOT NULL 条件が付加され、欠損値がランキングや統計値を歪めることを防止する。

3.2.5. 化学式パーサーと曖昧性処理

化学式パーサーは、クエリ中の化学式トークン (例：Ni3Al、NiAl、Fe2CoAl) を検出し、以下の 3 種類の解釈に分類する：

- exact_formula：化学量論比が明示された場合 (例：Ni3Al $\rightarrow$ formula = 'Ni3Al')。組成テーブルの化学式カラムとの完全一致検索を生成する。

- **formula_or_reduced_formula** : 化学量論比が省略されているが、化学式単体として使用されている場合 (例: 「NiAl の B2 エントリ」 → `reduced_formula = 'AlNi'`)。 `reduced_formula` カラムとの一致検索を優先的に生成する。
- **contains_elements** : 「X を含む」「X と Y を含む化合物」等の包含表現で使用されている場合 (例: 「Ni と Al を含む」 → 元素 Ni **AND** 元素 Al)。組成テーブルに対する EXISTS 副問い合わせ (多元素 AND) を生成する。判定は文脈依存である: 化学式トークンが単独でプロトタイプ名 (B2, L1₂ 等) や「エントリ」「物性」と共起する場合は `formula_or_reduced_formula` を優先し、「含む」「both」「contains」等の包含表現と共起する場合は `contains_elements` として処理する。この文脈依存判定は、材料研究者が「NiAl」と言ったとき多くの場合 B2-NiAl という特定化合物を意味する一方、「Ni と Al を含む化合物」は包含検索を意図するというドメイン知識に基づく設計判断である。

3.2.6. Coverage Score : 未認識語彙検出

Coverage Score は、自然言語クエリに含まれる意味的トークンのうち、用語辞書・元素辞書・数値パターンで認識された割合を $[0, 1]$ で定量化する。この指標は、Silent Constraint Dropping (未登録語彙の無通知破棄) を防止するために導入された。

算出手順:

1. クエリを正規表現でトークン化し、ストップワード (助詞、接尾辞等) を除去
2. 各トークンを辞書エイリアス (プロトタイプ、元素、物性、安定性) と照合
3. 元素記号の既知/未知を判定 (辞書登録済みか否か)
4. Coverage = 認識トークン数/全意味トークン数

Coverage Score に基づき、システムは 3 段階のアクションに分岐する:

- ≥ 0.8 (かつ未知元素なし) → `execute_rule_based`: Rule-based モードで安全に実行
- ≥ 0.5 (または未知元素あり) → `fallback_to_llm`: LLM モードにエスカレーション
- < 0.5 → `clarification_required`: ユーザーに明確化を要求

この仕組みにより、「Xe を含む化合物」のようなクエリで Xe (キセノン) が辞書未登録の場合、Coverage Score が低下し、条件を無視して SQL 生成するのではなく、LLM フォールバックまたは明確化要求が発生する。

3.2.7. Intent Classifier : スコープ外質問の事前排除

評価実験において、LLM が VASP ワークフロー質問に対して SQL を生成してしまう問題が判明した (out-of-scope 正解率 0%)。この問題に対処するため、SQL 生成パイプラインの前段にルールベースの Intent Classifier を導入した。

Intent Classifier は以下の 5 カテゴリにクエリを分類する:

1. **db_query**: 材料データベースで回答可能
2. **out_of_scope**: VASP/DFT ワークフロー、計算手法、一般知識
3. **ambiguous**: 明確化が必要
4. **unsafe**: SQL インジェクション等の不正意図
5. **greeting**: 挨拶・雑談

分類アルゴリズムは、20 個の VASP/DFT ワークフローパターン (INCAR, KPOINTS, POTCAR 等のファイル名、SCF 収束、ENCUT 等のパラメータ名、フォノン計算、Wannier90、Bader 解析等) と 9 個の DB 特化パターン (化合物検索、安定性フィルタ、物性条件等) の正規表現マッチング数を比較する。VASP パターンのみが検出された場合は `out_of_scope` として拒否し、DB パターンが優勢な場合は `db_query` としてパイプラインに通過させる。

3.3. Schema Graph 走査エンジン

本手法の中核的アルゴリズム貢献である。このエンジンはデータベーススキーマをグラフとして表現し、最適な JOIN 経路を自動計算する。

3.3.1. PostgreSQL メタデータからのグラフ構築

本実装は PostgreSQL を対象とする。アーキテクチャは他の RDBMS にも移植可能だが、メタデータ取得 SQL、LIMIT 構文、型情報、権限設計は DBMS ごとの調整が必要である。

外部キー関係は PostgreSQL の `information_schema` から動的に抽出される。本研究の検証スキーマでは単一カラム FK を対象としたが、複合外部キー ((a, b) REFERENCES parent(a, b)) や複数スキーマを跨ぐ場合は `pg_catalog` による抽出への拡張が必要である:

Listing 2: FK 関係抽出クエリ。

```
SELECT tc.table_name AS source_table,
       kcu.column_name AS source_column,
       ccu.table_name AS target_table,
       ccu.column_name AS target_column
FROM   information_schema.table_constraints tc
JOIN   information_schema.key_column_usage kcu
ON     tc.constraint_name = kcu.constraint_name
JOIN   information_schema.constraint_column_usage
       ccu
ON     ccu.constraint_name = tc.constraint_name
WHERE  tc.constraint_type = 'FOREIGN KEY'
AND    tc.table_schema = 'public';
```

結果は NetworkX [35] の無向グラフ $G = (V, E)$ として格納される。ここで $V = \{\text{テーブル名}\}$ 、 $E = \{\text{FK 関係}\}$ である。経路探索には無向グラフを用いるが、各エッジには FK の方向 (参照元テーブル・カラム、参照先テーブル・カラム) を属性として保持し、JOIN 句生成時にはこの有向メタデータを用いる。FK メタデータは実行時に PostgreSQL から読み取られるため、FK 経路探索部分はスキーマ変更に追従できる。ただし、自然言語語彙とカラム意味の対応 (用語辞書)、`property_name` の許可値リスト、Few-Shot 例は別途更新を必要とする。

3.3.2. 最小被覆 JOIN 経路: Steiner 木近似

条件抽出器の出力から決定された必要テーブル集合 $R \subseteq V$ に対し、 R のすべてのテーブルを接続する G の最小部分グラフが必要となる。これはグラフにおける Steiner 木問題 [36] であり、一般グラフでは NP 困難である。ただし、本研究のスキーマは `material_entry` をハブとするスター型木構造であるため、貪欲法で厳密解が得られる。本手法のアルゴリズム的貢献は NP 困難問題の解法にあるのではなく、材料ドメイン固有の用語辞書・EXISTS パターン生成を Schema Graph 走査に統合したドメイン統合にある。100 テーブル

以上の一般正規化スキーマ（非木構造）では近似が必要となるため、必要テーブル集合を接続する最小部分グラフ問題として定式化した。本規模では厳密解を与える貪欲ヒューリスティック（アルゴリズム 1）を採用する：

Algorithm 1 最小被覆 JOIN 部分グラフ (Steiner 木近似)。

Require: FK 関係グラフ $G = (V, E)$ 、必要テーブル集合 R

Ensure: JOIN 経路リスト P

```

1:  $P \leftarrow \emptyset$ , covered  $\leftarrow \emptyset$ 
2: for all  $(s, t) \in \binom{R}{2}$  do
3:   if  $s \in \text{covered} \wedge t \in \text{covered}$  then
4:     continue ▷ 両端点は既に接続済み
5:   end if
6:    $p \leftarrow \text{ShortestPath}(G, s, t)$  ▷ FK グラフ上の BFS
7:   if  $p \neq \emptyset$  then
8:      $P \leftarrow P \cup \{p\}$ 
9:     covered  $\leftarrow$  covered  $\cup$  nodes( $p$ )
10:  end if
11: end for
12: for all  $r \in R \setminus \text{covered}$  do ▷ 孤立必要テーブルの処理
13:    $c \leftarrow$  covered の最近傍ノード
14:    $P \leftarrow P \cup \{\text{ShortestPath}(G, r, c)\}$ 
15: end for
16: return  $P$ 

```

計算量. $|V| = n$ ノード、 $|R| = k$ 必要テーブルのグラフに対し、アルゴリズムは $O(k^2)$ 回の最短路計算を行い、各計算は $O(n + |E|)$ (BFS) である。30 テーブル規模 ($n = 30$, $k \leq 5$) でもミリ秒オーダーで完了する。

木構造 FK グラフでの正確性. G が木（本スキーマでは `material_entry` がハブ）の場合、Steiner 木は一意であり、貪欲アルゴリズムはこれを厳密に求める。FK サイクルを持つスキーマ（自己参照テーブル等）では近似が不要な辺を含む可能性があるが、SQL 生成においては DISTINCT を適用すれば正確性に影響しない。

3.3.3. JOIN 経路 $\rightarrow$ SQL FROM/JOIN 句生成

P の各経路は SQL JOIN 句に変換される。FK メタデータが結合カラム名を提供する：

Listing 3: 経路からの JOIN 句生成。

```

# 経路: [material_entry, structure]
# FK: structure.entry_id -> material_entry.entry_id
# 生成:
#   FROM material_entry m
#   JOIN structure s ON s.entry_id = m.entry_id

```

テーブル別名はテーブル名の先頭文字から自動割当される（例: `material_entry` $\rightarrow$ `m`, `composition` $\rightarrow$ `c`）。`structure` と `space_group` のように先頭文字が衝突する場合は 2 文字目以降を追加して解決する (`s`, `sg`)。同一テーブルが複数回出現する場合（多元素 AND クエリ等）は出現順で `c1`, `c2` のように一意な別名を割り当て、カラム参照も別名解決後の名前空間で検証する。

3.3.4. 多元素 AND クエリ: EXISTS 副問い合わせパターン

組成テーブル正規化に起因する材料固有の重要課題が存在する。「Ni と Al の両方を含む化合物」のクエリには以下が必要：

Listing 4: EXISTS 副問い合わせによる多元素 AND クエリ。

```

1 SELECT DISTINCT m.entry_id, m.formula
2 FROM material_entry m
3 WHERE EXISTS (
4   SELECT 1 FROM composition
5   WHERE entry_id = m.entry_id AND element = 'Ni')
6 AND EXISTS (
7   SELECT 1 FROM composition
8   WHERE entry_id = m.entry_id AND element = 'Al')
9 LIMIT 10000;

```

Schema Graph エンジンは複数元素が指定された場合を検出し、直接 JOIN の代わりに EXISTS 副問い合わせを自動生成する。このパターンなし (Naive アプローチ) では、WHERE `c.element = 'Ni' AND c.element = 'Al'` は単一組成行が両条件を同時に満たすことが不可能なため常に 0 行を返す。これが Schema Graph 手法により防止される最も重要な故障モードである。

なお、EXISTS パターンの適用は AND 意図が検出された場合に限定する。「Ni または Al」[いずれかを含む] 等の OR 指示語が検出された場合は WHERE `c.element IN ('Ni', 'Al')` を生成し、EXISTS パターンは適用しない。条件抽出器 (??節) が接続詞・助詞から AND/OR 意図を分類し、適切な SQL 構造を選択する。

3.3.5. 比較: Naive vs. Schema Graph (具体例)

表 3 に「Fe を含む B2 化合物を出して」に対する差異を示す：

Table 3: SQL 生成比較: 「Fe を含む B2 化合物」に対する Naive vs. Schema Graph。

観点	Naive (Level 0)	Schema Graph (Level 1)
JOIN テーブル	常に全テーブル	必要テーブルのみ
JOIN 数	全テーブル分	最小限
DISTINCT	なし $\rightarrow$ 重複行	あり
LIMIT	なし $\rightarrow$ 無制限	あり (10,000)
安全性検証	なし	完全 (キーワード + テーブル WL)
多元素 AND	不正 (0 行)	正確 (EXISTS)

3.4. SQL 生成: Rule-based モードと LLM モード

システムは 2 つの SQL 生成モードをサポートし、LLM モードは Schema Graph 走査結果をプロンプトに注入して制約を与える。Rule-based モードは、辞書ベースで抽出した条件からハードコードされた JOIN テンプレート (JOIN `t ON t.entry_id = m.entry_id` 形式の直結パターン) で SQL を生成する。このため、間接テーブル (`measured_property` 等) への正しい JOIN は生成されない場合がある。

3.4.1. Rule-based モード (Level 1)

決定論的テンプレートベース生成器が、抽出された条件と Schema Graph JOIN 経路から SQL を構築する。外部 API は不要で、レイテンシは約 8 ms (表 11 参照)。

改訂版での拡張。前稿の Rule-based モードでは数値比較 WHERE 句の生成が不可であったが、改訂版では数値条件パーサー (3.2.4 節) および化学式パーサー (3.2.5 節) を統合し、`band_gap > 1.0`、`formation_energy < 0`、`Ni3Al` (完全一致) 等の条件を Rule-based モード内で処理可能とした。

残存する制限。以下のクエリ種別は Rule-based モードでは処理できず、Coverage Score (3.2.6 節) または Intent Classifier (3.2.7 節) により自動的に LLM フォールバック、明確化要求、またはスコープ外拒否に分岐する：

- 否定条件 (「Fe を含まない化合物」)
- 辞書未登録語彙を含む自由記述クエリ
- VASP/DFT ワークフロー質問 (Intent Classifier が検出・拒否)
- 複雑な集約 (GROUP BY + HAVING 等)

3.4.2. Few-Shot RAG を備えた LLM モード (Level 2)

Rule-based モードの辞書カバレッジが不十分な場合 (未登録元素、数値条件、複雑な表現など)、LLM ベース生成にフォールバックする。LLM (本実験では gpt-5.5、API 設定の詳細は Supplementary S7 節を参照) は以下の構造化プロンプトを受け取る：

- システムメッセージ: タスク説明 + スキーマ YAML (テーブル名、カラム名、型、FK 関係)
- Few-Shot** 事例: RAG ストアからの Top- k 類似 NL-SQL ペア (3.5 節)
- ユーザーメッセージ: 自然言語クエリ
- 制約: 「SELECT 文のみ生成」「LIMIT 10000 を含める」「スキーマに記載されたテーブルのみ使用」

生成された SQL は実行前に SQL ガード (3.6 節) で検証される。

3.5. Few-Shot RAG ストア (SQL-as-Few-Shot-Examples)

3.5.1. アーキテクチャ

Few-Shot ストアは T2SQL に特化した RAG [37] パターンを実装する。GPT-3 [38] 以降、少数事例の文脈内提示による task-agnostic な精度向上が広く知られており、本システムではドメイン特化事例の動的検索によりこれを材料 T2SQL に適用する：

- 蓄積：クエリが正常に結果を返した場合、(NL クエリ、SQL、条件、行数、ソース) タブルを JSON ストアに追加する。
- 検索：新規クエリに対し、全蓄積 NL クエリとの TF-IDF [39] コサイン類似度を計算し、上位 k 件 (デフォルト $k = 3$) を返す。
- 注入：検索された事例を「Question: ... SQL: ...」ブロックとしてフォーマットし、LLM プロンプトの先頭に配置する。

3.5.2. 材料クエリのための TF-IDF トークナイゼーション

標準 NLP トークナイザは化学式や元素記号を不正確に分割するため、材料クエリには不適切である。本トークナイザは複合正規表現パターンを使用する：

Listing 5: 材料クエリ用 TF-IDF トークナイザ。

```
# トークナイゼーションパターン (優先順):
# 1. Strukturbericht 記号: L12, B2, A15, D0_3, ...
# 2. 化学式: Ni3Al, Fe2O3, ...
# 3. 化学記号: Fe, Ni, Al, ...
# 4. 日本語文字列: [\u3040-\u9fff]+
# 5. 英単語: [a-z]+
# 6. 数字: \d+
PROTO_PAT = r'[A-Za-z]\d+[_]?[d*]' # L12, B2, A15
FORMULA_PAT = r'[A-Z][a-z]?[d*]' # Ni3, Al, Fe2
tokens = re.findall(
    PROTO_PAT + r'|' + FORMULA_PAT
    + r'|[\u3040-\u9fff]+|[a-z]+|\d+',
    query # 大文字保持で照合後、最終的に小文字化
)
tokens = [t.lower() for t in tokens]
```

IDF は $IDF(t) = \log(N/n_t)$ で計算される。ここで N は蓄積事例総数、 n_t は語 t を含む事例数である。クエリと蓄積事例の TF-IDF ベクトル間のコサイン類似度によりランキングされる。

3.5.3. 研究論文からの種事例抽出

手動キュレーションなしに Few-Shot ストアをブートストラップするため、LaTeX 原稿からの自動種事例抽出を実装した。抽出器は以下のパターンを走査する：

- B2 型パターン: `B2[-\s]type` + 化学式 $\rightarrow$ {prototype: B2, elements: 抽出}
- L1₂ 型パターン: `L1_2 / L12` + 化学式 $\rightarrow$ {prototype: L1₂, elements: 抽出}
- 100 文字以内のコンテキストキーワード: “lattice”, “stable”, “formation energy”

抽出された各化合物言及に対し、正規 NL クエリと対応 SQL が生成される。本実験では `hea_lattice_prediction.tex` から 4 件の種事例が自動抽出され、手動キュレーション 7 件と合わせて合計 11 件となった (表 4)。

Table 4: Few-Shot ストア構成 (11 事例)。

ソース	件数	比率	クエリ例
手動キュレーション	7	64%	Fe を含む B2 化合物を出して
論文抽出	4	36%	B2 FeAl の物性を出して

3.6. SQL ガード：多層安全性検証

本手法は CRUD 操作のうち参照系 (Read) のみを対象とし、生成 SQL は SELECT 文に限定される。Rule-based モード・LLM モードを問わず、生成された全 SQL はデータベース実行前に 8 層検証パイプラインを通過する。前稿の 5 層構成に対し、カラムホワイトリスト検証 (層 6)、FK 整合 JOIN 検証 (層 7)、ガード判定分類 (層 8) を追加した。

3.6.1. 基本安全性検証 (層 1-5)

1. 複数文検出：文字列リテラル除去後の SQL 本体内にセミコロンがあれば拒否 (SELECT ...; DROP TABLE ... 等のビジーバック攻撃を防止)。リテラル内のセミコロン (例：SELECT 'A;B') は誤検出ししない。
2. 禁止キーワード検出：INSERT, UPDATE, DELETE, DROP, ALTER, TRUNCATE, CREATE, GRANT, REVOKE, COPY をワード境界正規表現で走査。
3. **SELECT** 専用制約：SELECT または WITH で始まらない文を拒否。
4. テーブルホワイトリスト検証：FROM/JOIN 句の全テーブル名を抽出し、allowed_schema.yaml に存在するか検証。未宣言テーブル (例：secret_passwords) 参照クエリは拒否。
5. 自動 **LIMIT** 注入：LIMIT 句がなければ LIMIT 10000 を付加し、無制限結果セットによる過剰メモリ・計算消費を防止。

3.6.2. カラムホワイトリスト検証 (層 6)

SELECT 句、WHERE 句、ORDER BY 句で参照される全カラム名を抽出し、allowed_schema.yaml のカラム定義と照合する。スキーマに存在しないカラム (例：LLM が幻覚生成した melting_point) を参照する SQL は実行前に拒否される。これにより、LLM モードにおけるスキーマ幻覚 (hallucinated schema) を防止する。

3.6.3. FK 整合 JOIN 検証 (層 7)

FROM/JOIN 句のテーブル結合条件が、PostgreSQL メタデータから取得した FK 関係と整合するかを検証する。Schema Graph 走査 (3.3 節) が生成した JOIN 経路と実際の SQL 内の JOIN 条件を比較し、以下を検出する：

- FK 関係に基づかない不正 JOIN 条件 (例：ON a.id = b.name)
- Schema Graph 経路に含まれないテーブル間の JOIN (不要 JOIN)
- JOIN 条件の欠落 (Cartesian product リスク)

原則として FK メタデータに存在する結合のみを許可する。FK が存在しないが業務上必要な結合 (将来のマスターテーブル拡張等) は、allowed_joins.yaml に明示登録することで許可する拡張点を設けている。

3.6.4. ガード判定分類 (層 8)

8 層検証の結果に基づき、生成 SQL を以下の 4 カテゴリに分類する：

1. **SAFE**：全層パス。実行可能。
2. **MODIFIED**：自動修正適用 (LIMIT 注入等)。修正後実行可能。
3. **BLOCKED**：安全性違反により実行拒否。ユーザーに理由を通知。
4. **WARNING**：軽微な逸脱 (カラム幻覚疑い等)。実行するが警告付き。

層 1-5 の正規表現ベース検証に加え、SQLGlot [40] による AST (抽象構文木) レベルの構文検証を標準で併用する。AST パーサーにより、CTE (WITH 句) を許可する場合も各 CTE 本体が SELECT であることを検証し、INSERT/UPDATE/DELETE を含む writable CTE は拒否する。正規表現のみでは検出困

難な quoted identifier、schema-qualified name、ネストされたサブクエリ内の危険操作も AST 走査で捕捉する。本番運用では AST ベース検証を主軸とし、正規表現検証は高速な事前フィルタとして位置づける。

DB 権限による多層防御。SQLGuard は文字列・AST 検査によるベストエフォートの事前フィルタであり、安全性の最終保証は DB 権限層が担う。実行ユーザーには read-only ロールを適用し、対象スキーマに対する SELECT 権限のみを付与する。DDL/DML 権限は付与しない。これにより、SQLGuard を迂回する未知の攻撃パターン (DB 固有関数の悪用等) に対してもデータ改変・権限昇格を原理的に防止する。

3.6.5. 空結果診断

SQL が正常に実行され結果が 0 行となった場合、システムは追加の診断クエリを発行し、0 行の原因を以下の 2 カテゴリに分類してユーザーに通知する：

1. 該当データなし (**no_matching_data**)：クエリ中の元素・プロトタイプ・化学式等のエンティティはデータベースに存在するが、指定された条件の組み合わせを満たすエントリが存在しない。例：「Pt を含む安定な L1₂ でバルクモジュラス 500 GPa 以上」—Pt, L1₂ は DB 内に存在するが、条件が厳しすぎるため 0 件。
2. エンティティ未登録 (**entity_not_found**)：クエリ中で参照された元素・プロトタイプ・化学式がデータベースにそもそも登録されていない。例：「Xe を含む L1₂ 化合物」—希ガス元素 Xe は composition テーブルに DB 未登録。

診断は SQL 中の WHERE 句からリテラル値 (元素名、プロトタイプ名、化学式) を抽出し、各エンティティの存在を個別に検証する。この機構により、ユーザーは「検索条件が厳しすぎるのか」「そもそもデータが収録されていないのか」を即座に判断でき、クエリの修正方針を迅速に決定できる。

3.7. 推奨運用構成：段階的フォールバック方式

各生成モードの特性に基づき、以下の段階的フォールバック戦略を推奨する：

1. **Intent** 分類：Intent Classifier (3.2.7 節) がクエリを db_query / out_of_scope / unsafe / greeting に分類。db_query 以外は即座に拒否または適切な応答を返す。
2. 条件抽出 + **Coverage Score**：条件抽出器 (3.2 節) がクエリを解析し、Coverage Score (3.2.6 節) で辞書カバレッジを判定。
3. **Rule-based** 生成 (**Coverage** ≥ 0.8)：テンプレートベース SQL 生成 (Level 1、32-60 ms)。
4. **LLM** フォールバック (**Coverage** < 0.8)：Schema Graph 制約付き LLM 生成にエスカレーション (Level 2、2.4-6.1 秒)。
5. 明確化要求 (**Coverage** < 0.5)：ユーザーに追加情報を要求。
6. **SQL** ガード：生成モードによらず 8 層検証 (3.6 節) を常に適用。

このアプローチは、辞書がカバーするクエリを外部 API 依存なしに処理し、複雑または新規なクエリにのみ LLM 呼び出しを使用する。

3.8. 実行時リペアループ：失敗診断と自動再生成

SQL ガード検証を通過したクエリであっても、PostgreSQL 実行時にエラーとなる場合や、結果が0行（空集合）となる場合がある。本システムでは、これらの失敗を自動的に診断し、LLM による SQL 再生成を試みるリペアループを実装した。

3.8.1. 失敗モードの分類

リペアループは以下の3種の失敗モードを区別する：

1. **実行エラー**：PostgreSQL が返すランタイムエラー（存在しないカラム参照、型不一致、JOIN 条件誤り等）。エラーメッセージをそのまま LLM にフィードバックし、許可テーブル・カラム・JOIN 一覧とともに修正 SQL の生成を依頼する。
2. **空結果（0 行）**：クエリは正常に実行されたが結果が空。Coverage Score (3.2.6 節) の未認識語彙リストを診断情報として LLM に提供し、WHERE 条件の緩和（完全一致 → ILIKE、値の正規化等）や JOIN 経路の修正を促す。
3. **SQLGuard 拒否**：8 層検証で拒否された SQL。拒否理由（禁止テーブル、DML 検出等）をフィードバックして再生成する。
4. **SUPERSET 検出**：クエリは正常に実行され結果が非空だが、返却行数が過大（WHERE 条件数に対して不釣り合いに多い行を返却）な場合。条件抽出器が認識した条件数と返却行数のヒューリスティックにより WHERE 条件の欠落を推定し、条件不足の旨を LLM にフィードバックして追加 WHERE 句の生成を促す。本モードは著者設計 100 件の評価パイプラインでのみ動作し、独立設計 100 件の評価 (run_expert_evaluation.py) には未実装である点に注意する。

3.8.2. リペアプロセス

リペアは最大 2 回まで試行する（初回生成を含め最大 3 回の実行機会）。各リペア試行では以下の情報を LLM に提供する：

- 失敗した SQL 全文
- エラーメッセージまたは空結果診断
- 許可テーブル一覧（Schema Graph から導出）
- 許可カラム一覧（スキーマリンカーが特定）
- 許可 JOIN 条件一覧（FK 経路から生成）

リペアで生成された SQL は再度 SQL ガード検証を経て実行される。同一の SQL が返された場合は無限ループを回避するため即座に終了する。リペアに使用したトークン数は総トークン数に加算され、コスト評価に含まれる。

3.8.3. Coverage Score による診断精度の向上

空結果リペアでは、条件抽出器の Coverage Score (3.2.6 節) が重要な役割を果たす。Coverage Score が低い (< 0.8) 場合、未認識語彙リスト (unrecognized_terms) がリペアプロンプトに含まれ、LLM に「どの用語がスキーマにマッピングされなかったか」を明示的に伝える。これにより、LLM は条件値の綴り違い（例：'L12' vs 'L1_2' vs 'Cu3Au'）やカラム名の誤り（例：prototype vs strukturbericht）を修正できる。

4. データ準備

4.1. 検証データベースの構築

本研究では、OQMD (Open Quantum Materials Database) [3] のデータを参考に、複数プロトタイプを含む検証データベースを構築した。OQMD API から取得可能なデータはフラットな JSON レコード形式であり、そのままでは多元素 AND 検索や構造・安定性・計算条件を跨ぐ複合検索が困難である。そこで本研究では、Schema Graph 制約型 Text-to-SQL のコンセプト実証のために、組成・構造・熱力学的安定性・計算条件・物性を分離した独自の正規化 ER 図 (30 テーブル) を設計した。この独自設計により、FK 関係を通じたマルチホップ JOIN の自動算出を検証するための現実的な複雑さを備えたスキーマを実現している。なお、本研究における material_entry は単なる組成ではなく、化学式・プロトタイプ・構造を含む計算エンタリ単位を表す（同一組成でも異なるプロトタイプは別エンタリとなる）。

データベースには 5 プロトタイプ 1,470 件を格納した (表 5)。

Table 5: 検証データベースの構成（全体 1,470 件）。

プロトタイプ	件数	備考
L1 ₂ 型 (Cu ₃ Au 型)	392	既知 L1 ₂ 11 件含む
B2 型 (CsCl 型)	636	—
NaCl 型 (岩塩型)	355	—
NiAs 型 (ニッケルヒ素型)	74	—
BiF ₃ 型	13	—
合計	1,470	

L1₂ 型 (Cu₃Au 型) は A₃B 組成を持つ規則化 FCC 構造であり、Ni 基超合金の γ' 析出相として重要である。既知の L1₂ 化合物 11 件 (Ni₃Al、Ni₃Ga、Ni₃Ge、Co₃Ti、Co₃Ta、Co₃Al、Al₃Sc、Al₃Ti、Pt₃Al、Co₃W、Ir₃Nb) を含む。B2 型 (CsCl 型) は AB 組成の BCC 規則構造であり、NiAl、FeAl、CoAl 等の耐熱材料や形状記憶合金 (NiTi) を含む 636 件を格納した。NaCl 型 (岩塩型) 355 件、NiAs 型 74 件、BiF₃ 型 13 件を加え、プロトタイプ間の多様性（組成比 2:1~1:1、5 種の結晶構造）により、スキーマ設計の汎用性を検証できる構成とした。

各エンタリについて、化学式、格子定数 a 、空間群、原子当たり形成エネルギー E_f 、hull 上エネルギー E_{hull} 、バルクモジュラス B 、剪断弾性率 G を格納した。

4.2. ER 設計の根拠：フラットデータから正規化 RDB へ

OQMD のオリジナルスキーマは大規模な単一テーブル構造を基本としており、化学式・プロトタイプ・格子定数・形成エネルギー・hull 上エネルギー・弾性特性等がフラットなレコードとして格納されている。本研究では OQMD のオリジナル構造をそのまま使用せず、Schema Graph 制約型 Text-to-SQL のコンセプト実証に適した独自の正規化 ER 図 (30 テーブル) を設計した。この独自設計により、FK 関係を介したマルチホップ JOIN の自動算出という本手法の核心的機能を現実的な複雑さの中で検証できる。図 3 に 30 テーブルの全体構成と FK 関係を示す。以下に主要な設計判断を述べる。




Figure 3: 検証データベースの 30 テーブル ER 図。中央の **material_entry** を軸に、組成 (composition)・構造 (structure)・安定性 (phase_stability) 等のコアテーブルが直接 FK で接続され、計算特性・電子構造・機械特性・表面エネルギー等が 2 ホップ以上でアクセスされる。灰色矢印は FK 関係、赤矢印は自己参照 FK (application_domain の階層構造) を示す。黄色のテーブルは N:M 結合テーブルである。

設計判断 1: 組成テーブルの分離 (1:N 正規化). 最も重要な設計判断は、`composition` テーブルの分離である。化合物と構成元素の関係は 1:N (例: Ni_3Al は Ni 行と Al 行の 2 レコード) であり、これをフラットテーブルの 1 カラムに格納すると「Ni と Al を両方含む化合物」のような多元素 AND 検索が不可能になる。正規化により、`composition` テーブルの自己結合 (SELF JOIN) で任意の元素組み合わせ検索が実現される。この自己結合を含む JOIN パスの正確な算出が Schema Graph 走査 (3.3 節) の主要な貢献である。

設計判断 2: 構造・安定性・計算条件の分離. 同一化合物に対して複数の結晶構造 (多形) や異なる計算条件が存在するため、`structure` (プロトタイプ、空間群、格子定数)、`phase_stability` (形成エネルギー、 E_{hull} 、バンドギャップ)、`calculation` (DFT 計算条件) を独立テーブルとした。これにより「安定な ($E_{\text{hull}} \leq 0.001$) L1_2 構造のうち格子定数が $3.5 \text{ \AA}$ 以上」のような、構造と安定性を跨ぐ複合条件が FK 整合 JOIN で正確に検索できる。

設計判断 3: 計算と物性の親子関係. 1 つの DFT 計算から複数の物性値 (体積弾性率、剪断弾性率等) が出力されるため、`calculation` $\rightarrow$ `properties` (1:N) の親子関係とした。物性名・値・単位を行として格納する EAV (Entity-Attribute-Value) パターンにより、新しい物性を追加する際にスキーマ変更が不要である。

設計判断 4: プロトタイプ定義のマスタ化. `prototype_definition` テーブルに B2、 L1_2 、A15 等のプロトタイプ名・Strukturbericht 記号・結晶型の対応を格納し、`structure` テーブルから参照する。これにより「 L1_2 」「 Cu_3Au 型」「 AuCu_3 型」等の同義表現を一元的に管理できる。

正規化が Schema Graph 走査を必要にする。上記の正規化設計により、単純な検索でも 2–4 テーブルの JOIN が必要となる。この正規化の代償としての JOIN 複雑性こそが、FK 関係をグラフとして表現し最短 JOIN パスを自動算出する Schema Graph 走査エンジンの存在意義である。

4.3. データ投入と変換

各 L1_2 エントリを CSV から正規化スキーマに分解して投入する。例えば、 Ni_3Al (L1_2 プロトタイプ) は以下を生成する: `material_entry` に 1 行、`composition` に 2 行 (Ni: 0.75, Al: 0.25)、`structure` に 1 行 (prototype= L1_2 , lattice_a=3.572, space_group=Pm-3m)、`phase_stability` に 1 行 (formation_energy=-0.42, energy_above_hull=0.0)、`calculation` に 1 行 (method=GGA-PBE)、`calculated_property` にバルクモジュラス (180 GPa)、剪断弾性率 (78 GPa) の 2 行。プロトタイプ別の seed CSV ファイルから ingestion/load_seed_data.py により自動投入される。

Table 6: 評価クエリ設計 (全 100 件)。

難易度	件数	参照テーブル数	代表的クエリ内容
Easy	27	1–2	単一元素・プロトタイプ条件
Medium	28	3	構造+組成+安定性の横断
Hard	22	4	複数テーブル横断・複合条件
Very Hard	23	5–6	材料設計条件を含む複合クエリ

※難易度は gold SQL が参照するテーブル数 (FROM/JOIN 節に現れる異なるテーブルの数) に基づく客観的分類である。

5. 結果

5.1. 評価設計

5.1.1. 評価データセット (100 クエリ)

L1_2 型化合物探索に特化した 100 件の自然言語クエリを、4 段階の難易度に分けて設計した (表 6)。

各クエリには gold SQL、期待結果セット (JSON)、必要テーブル・カラム・JOIN 経路を紐付けた。マルチテーブルクエリ (3 テーブル以上) は 73 件を占め、うち 4 テーブル 22 件、5 テーブル以上 23 件を含む。

5.1.2. 比較手法 (5 手法)

スキーマ情報の提示方法が SQL 品質に与える影響を評価するため、以下の 5 手法を比較した (表 7)。LLM には gpt-5.5 (OpenAI, 2026 年 5 月アクセス) を使用した。gpt-5 系 API では temperature パラメータはサポートされておらず未指定である (S7 節参照)。全手法の max_completion_tokens は 4,096 に統一した (詳細は Supplementary S7 節)。

5.1.3. 評価指標

以下の指標で各手法を評価する:

- 構文妥当率 (Syntax validity): SQL パーサーを通る割合。LIMIT の影響を受けない。
- 実行成功率 (Execution validity): PostgreSQL でエラーなく実行できる割合。LIMIT の影響を受けない。
- 実行精度 (Execution accuracy): 返された結果セットと gold 結果の行レベル一致率。式 (1) に基づく再現率 (recall) が主指標である。注意: 本指標は再現率ベースであり、生成 SQL が gold より多くの行を返してもペナルティがない。precision と F1 の併記は今後の再実行で追加予定である。
- テーブル幻覚率 (Hallucinated table rate): スキーマに存在しないテーブルを 1 つ以上参照するクエリの割合。SQLGuard 適用前の生成 SQL (LLM 出力直後) に対して測定する。
- JOIN 幻覚数 (Hallucinated JOIN count): FK 関係に基づかない JOIN を含むクエリの件数。本指標は生成 SQL の sqlglot AST からエイリアス表を構築し、FK 経路の許可リストと照合する。本指標も SQLGuard 適用前の生成 SQL に対して測定する。
- マルチテーブル成功率 (Multi-table success rate): 3 テーブル以上を参照するクエリの正解割合。

5.1.4. 評価指標の改善: 共通カラム照合と LIMIT 正規化

評価指標は予備実験前に設計したが、予備実験で SELECT 列の選択自由度と LIMIT 値の実装差異という 2 つの系統的

Table 7: 比較手法の構成（全手法共通：100 クエリ）。

ID	手法名	構成
B1	LLM-only	LLM のみ。スキーマ情報なし
B2	Full Schema	LLM + 全スキーマ（テーブル・カラム一覧）をプロンプトに注入
B3	Rule-based	LLM なし。辞書ベース条件抽出 + テンプレート SQL 生成
B4	FK-list	LLM + 外部キー一覧のみをプロンプトに注入
P	Proposed	エンティティ抽出 + Schema Linking + Schema Graph 走査 + 制約付き LLM

バイアスを発見したため、評価指標を修正した。以下に各修正の技術的根拠と独立検証可能性を示す。

共通カラム照合 (*Column-aware matching*)。SQL 生成において、LLM は gold SQL と異なる SELECT 列を出力することがある。例えば gold が `entry_id, formula` の 2 列を返すのに対し、生成 SQL が `entry_id, formula, lattice_a, space_group` の 4 列を返す場合、従来のタプル完全一致では同じ行でも不一致と判定される。共通カラム照合では、gold と生成の両方に存在するカラム名のみで行マッチングを行う：

$$\text{accuracy}(q) = \frac{|R_{\text{gen}}^C \cap R_{\text{gold}}^C|}{|R_{\text{gold}}^C|} \quad (1)$$

ここで $C = \text{cols}(R_{\text{gen}}) \cap \text{cols}(R_{\text{gold}})$ は共通カラム集合、 R^C は列集合 C への射影である。この集合照合は Jaccard 係数 [41] に類似するが、分母を gold 側に限定した再現率ベースの指標である。

LIMIT 正規化。SQLGuard が自動付加する LIMIT の値が gold SQL と生成 SQL で異なる場合、行数の差異により精度が過小評価される。本研究では、評価時のみ gold SQL と生成 SQL の両方に LIMIT 10,000 を統一的に適用する。DB 規模 1,470 件に対して実質的に制限なしと同等でありかつ、暴走クエリ防止の安全弁としての役割を果たす。実運用ではユーザー指定値、管理者設定上限、またはクエリ種別（集約クエリでは LIMIT なし許可等）に応じた値を適用する。

改善効果。表 8 に評価指標改善の効果を示す。

Table 8: Proposed 手法における評価指標改善の効果。

評価条件	平均 実行精度	改善幅
従来（タプル完全一致）	4.8%	—
+A+C（共通カラム照合 + LIMIT 正規化）	70.2%	+65.4pt

共通カラム照合および LIMIT 正規化の併用により +65.4 ポイントの精度向上が得られた。いずれの修正も、gold SQL と生成 SQL のペアさえあれば第三者が独立に再現可能である。なお、ベースライン手法の実行失敗行（B1: 92 件、B2: 70 件、B4: 91 件）では LLM 生成 SQL が保存されていないため、精度 0 の結果のみ同梱 CSV に記録されている。以降の結果はすべて A+C 適用後の値を報告する。

5.1.5. 回帰テスト（80 件）

開発安全性テストとして、正常系（15 件）、該当なし（5 件）、曖昧入力（10 件）、矛盾条件（2 件）、SQL インジェクション（5 件）、安全性検査（2 件）、SQL 検証（6 件）、Coverage・パーサー（15 件）、Intent Classifier（20 件）の計 80 件を構築した。これらを含む全 123 件のユニットテストが全 PASS を達成した。テストカテゴリの詳細および全テストケース一覧は Supplementary S1–S2 節に掲載する。

5.2. 5 手法ベースライン比較

表 9 に 5 手法の比較結果を示す（gpt-5.5 使用、100 クエリ、評価指標 A+C 適用）。

主要な発見。

- LLM-only (B1)** は実行成功率 **0%**・テーブル幻覚率 **8%**：スキーマ情報なしでは LLM が存在しないテーブル名を幻覚し、生成された SQL は一切実行できない。
- Proposed (P)** はテーブル幻覚率 **0%**かつ実行精度 **70.2%**：Schema Graph 走査により LLM の視界を必要テーブルに限定し、不要 JOIN の排除とテーブル幻覚の防止を同時に達成する。リベアループにより実行失敗クエリを自動回復し、Easy（1–2 テーブル）では 81.2%、Medium（3 テーブル）では 79.1%に達する。
- Rule-based (B3)** は LLM なしで実行精度 **58.2%**：辞書カバー範囲内では LLM 呼び出しが不要だが、テンプレートの柔軟性が制約となり精度は Proposed に劣る。
- Full Schema (B2)** は不要 JOIN が多く精度 **26.6%**：全スキーマ提示では不要な JOIN が発生し、実行コストと精度の両面で劣化する。
- FK-list (B4)** は実行成功率 **8%**：FK 情報のみの提示では JOIN 経路を正しく構成できない。

5.3. 難易度別の詳細分析

表 10 に難易度別の Proposed 手法の実行成功率・実行精度を示す。

難易度別の傾向。

- Easy (27 件、1–2 テーブル)**：実行精度 81.2%。単純な元素・プロトタイプ条件では Schema Graph 制約が有効に機能する。
- Medium (28 件、3 テーブル)**：79.1%。構造・組成・安定性の横断クエリでも Steiner 木近似による JOIN 経路制約が有効に機能する。
- Hard (22 件、4 テーブル)**：74.7%。複数テーブルを横断する WHERE 句の条件組合せが複雑化する。
- Very Hard (23 件、5–6 テーブル)**：42.0%。材料設計条件（安定性・物性・構造の複合絞り込み）を含むクエリでは LLM の WHERE 句生成が主なボトルネック。

Table 9: 5 手法のベースライン比較 (100 クエリ、gpt-5.5、共通カラム照合+LIMIT 10,000)。

ID	手法	構文 妥当率	実行 成功率	平均 実行精度	テーブル 幻覚率	不要 JOIN
B1	LLM-only	100%	0%	0%	8%	—
B2	Full Schema	100%	30%	26.6%	0%	多い
B3	Rule-based	100%	95%	58.2%	0%	なし
B4	FK-list	100%	8%	7.0%	0%	—
P	Proposed	99%	99%	70.2%	0%	最小

Table 10: 難易度別の実行成功率と実行精度 (Proposed 手法)。

難易度	件数	参照テーブル数	実行成功率	実行精度
Easy	27	1-2 テーブル	100%	81.2%
Medium	28	3 テーブル	96.4%	79.1%
Hard	22	4 テーブル	100%	74.7%
Very Hard	23	5-6 テーブル	100%	42.0%

※難易度は gold SQL が参照するテーブル数に基づく客観的分類である。テーブル数別の精度分析は表 12 を参照。

5.3.1. レイテンシ比較

表 11 に手法別の平均レイテンシを示す。Rule-based (B3) は LLM API を呼び出さないため 8 ms で最速である。LLM ベース手法は API 呼び出し時間が支配的であり、Proposed 手法は平均 11,422 ms である。リペアループ発動時は追加の LLM 呼び出しによりレイテンシが増加するが、発動率は 5% (5/100 件、計 8 試行) と低く全体平均への影響は限定的である。

Table 11: 手法別レイテンシ比較 (gpt-5.5)。

ID	手法	平均 Latency (ms)	平均 Token 数
B1	LLM-only	12,098	562
B2	Full Schema	10,190	2,299
B3	Rule-based	8	0
B4	FK-list	12,605	967
P	Proposed	11,422	2,550

5.4. マルチテーブルクエリ分析

表 12 に参照テーブル数別の精度比較を示す。評価クエリ 100 件中、3 テーブル 28 件、4 テーブル 22 件、5-6 テーブル 23 件がマルチテーブルクエリに分類される。

Table 12: 参照テーブル数別の実行精度比較 (3 テーブル以上)。

参照テーブル数	件数	Proposed 精度	Full Schema 精度
3 テーブル	28	79.1%	28.6%
4 テーブル	22	74.7%	16.2%
5-6 テーブル	23	42.0%	0.0%

マルチテーブルの傾向。参照テーブル数が増えるほど精度が単調に低下する (3 テーブル 79.1% → 5-6 テーブル 42.0%)。ただし、Full Schema や LLM-only と比較すると、どのテーブ

ル数でも Proposed が大幅に優位である。特に 5 テーブル以上では Full Schema の精度が 0% となるのに対し、Proposed は 42.0% を維持しており、Schema Graph 走査による JOIN 経路制約の効果が顕著である。

5.5. エラー分析

各手法の主要な失敗モードを表 13 に示す。

Table 13: 手法別エラー分析 (100 クエリ)。実行エラー = PostgreSQL 実行時エラー件数、テーブル幻覚 = 存在しないテーブルを 1 つ以上参照するクエリ件数、JOIN 幻覚 = FK 関係に基づかない JOIN を含むクエリ件数。

ID	手法	実行 エラー	構文 エラー	テーブル 幻覚	JOIN 幻覚
B1	LLM-only	100	0	8	0
B2	Full Schema	70	0	0	0
B3	Rule-based	5	0	0	22
B4	FK-list	92	0	0	0
P	Proposed	1	1	0	6

失敗モードの分類。

B1: テーブル幻覚と全件実行失敗 LLM-only では 100 件全てが実行エラー。8 件でテーブル名を幻覚し、**materials**、**compounds** 等の汎用名を生成する。残りも存在するテーブル名を使用するがカラム構造を誤る。

B4: FK 情報だけでは不十分 FK 一覧の提示では 92 件が実行エラー。テーブル間関係は伝わるが、カラム名・型・テーブル構造が不足するため、SELECT 句や WHERE 句の生成に失敗する。

P: 高難度での **WHERE** 句複雑性 Proposed 手法の失敗は主に Very Hard/Hard 難度に集中。Schema Graph 制約が提供する JOIN 経路は正しいが、LLM が複合 WHERE 句の条件組合せを正確に生成できないケースが残る。

Very Hard 失敗の内訳分析。Very Hard 23 件のうち精度 42.0% (10 件が精度 45% 未満) の失敗内訳を以下に分類する。

WHERE 句の条件組合せミスが全失敗の 50% を占める。これらのクエリでは Schema Graph が正しい JOIN パスを提供しているにもかかわらず、LLM が 3 条件以上の複合 WHERE 句を正確に構成できない。一方、JOIN 経路自体の誤りによる失敗は 0 件であり、Schema Graph 走査の制約は Very Hard 難度でも有効に機能している。この結果は、今後の改善方向が JOIN 制約ではなく **WHERE** 句生成の精度向上 (例: Few-Shot プロンプトの拡充、Chain-of-Thought 推論の導入) にあることを示唆する。

Table 14: Very Hard クエリ (23 件) の失敗モード分類。

失敗モード	件数	代表例	順位	化合物	a (Å)	E_{hull}	B (GPa)	Δa	S
WHERE 句の条件組合せミス	5	安定性+物性+組成の 3 条件以上を同一時に正しく生成できない	2	Ni_3Al	3.572	0.000	180	0.002	0.878
集約関数・サブクエリの誤用	2	GROUP BY + HAVING 句の生成ミス、EXISTS 副問い合わせの欠落	3	Cu_3Ti	3.54	0.000	212	0.03	0.877
多元素 AND 検索の失敗	2	SELF-JOIN または INTERSECT ターンを正しく展開できない	6	Co_3Ti	3.55	0.000	190	0.02	0.867
実行エラー (型不一致等)	1	数値カラムへの文字列比較によるgreSQL エラー	8	Cu_3Ta	3.58	0.008	224	0.01	0.856
			6	Co_3Nb	3.68	0.000	224	0.11	0.796
			8	Cu_3Sc	3.60	0.012	140	0.03	0.721
合計	10		9	Ir_3Ge	3.70	0.004	200	0.13	0.720
			10	Pt_3Sc	3.48	0.016	224	0.09	0.707

Table 16: γ' 相候補 Top 10 (複合スコア S 順)。

5.6. SQL インジェクションと安全性結果

7 件の敵対的入力 (E01–E05: DROP/DELETE/INSERT 等、F01–F02: 直接 SQL 入力) はすべて SQL ガードにより処理された。E01–E05 は禁止キーワード検出・複数文検出等により遮断された。F01 は SELECT 文がそのまま入力されたケースであり、LIMIT なし→自動付加の上で修正実行 (MODIFIED) された (遮断ではない)。F02 は UPDATE 文であり、DML 検出により遮断された。詳細なテスト結果は Supplementary S4 節に掲載する。

5.7. 材料工学的評価

L_{12} 型金属間化合物の材料工学的観点からシステムの有用性を評価する。

5.7.1. 既知 L_{12} 化合物の再発見

表 15 に既知 L_{12} 化合物 11 件の再発見結果を示す。Proposed 手法による探索で全 11 件を正しく再発見した。

Table 15: 既知 L_{12} 化合物の再発見結果 (11/11)。

化合物	a (Å)	E_{hull} (eV/atom)	再発見
Ni_3Al	3.572	0.000	○
Ni_3Ga	3.66	0.010	○
Ni_3Ge	3.61	0.040	○
Co_3Ti	3.55	0.000	○
Co_3Ta	3.72	0.040	○
Co_3Al	3.67	0.010	○
Co_3W	3.74	0.050	○
Al_3Sc	4.09	0.000	○
Al_3Ti	3.98	0.020	○
Pt_3Al	3.90	0.000	○
Ir_3Nb	3.87	0.030	○

5.7.2. γ' 相候補ランキング

安定性 (E_{hull})、格子整合性 ($|a - a_{\text{Ni}_3\text{Al}}|$)、バルクモジュール B の 3 指標による重み付き複合スコアで γ' 相候補をランキングした (表 16)。

$$S = w_1 \cdot S_{\text{stability}} + w_2 \cdot S_{\text{lattice}} + w_3 \cdot S_{\text{bulk}} \quad (2)$$

ここで $w_1 = 0.35$ (安定性)、 $w_2 = 0.35$ (格子整合性)、 $w_3 = 0.30$ (バルクモジュール)。各スコアは 0–1 に正規化

($S_{\text{stability}} = 1 - E_{\text{hull}}/0.05$ 、 $S_{\text{lattice}} = 1 - |\Delta a|/0.3$ 、 $S_{\text{bulk}} = B/300$)。

Cu_3Nb は計算上、格子整合性 ($\Delta a = 0.01$ Å) と高バルクモジュール (218 GPa) を兼ね備えるが、Cu–Ni 系の相分離傾向および実験合成例の欠如から、 γ' 相候補としての実現可能性には実験的検証が不可欠である。

5.7.3. Ni_3Al 近傍格子定数候補

$|a - a_{\text{Ni}_3\text{Al}}| \leq 0.03$ Å を満たす候補 14 件を抽出した。なお、基準値はコード内で $a_{\text{ref}} = 3.57$ 、 Ni_3Al 自身の $\Delta a = |3.572 - 3.57| = 0.002$ はこの基準値との差である。 Cu_3Nb ($E_{\text{hull}} = 0.004$)、 Cu_3Ta ($E_{\text{hull}} = 0.008$) は準安定であり、 Co_3Ti ($E_{\text{hull}} = 0.0$)、 Cu_3Ti ($E_{\text{hull}} = 0.0$) は安定相として確認された。これらは Ni_3Al との格子ミスマッチが小さく、析出強化の観点から有望な候補である。候補一覧は Supplementary S5 節に掲載する。

5.7.4. 安定 L_{12} 候補の抽出

$E_{\text{hull}} \leq 0.05$ eV/atom を満たす安定・準安定 L_{12} 候補 337 件 (安定 100 件、準安定 237 件) を抽出した。拡張インポート後の DBAB では従前の 57 件から大幅に増加している。安定相のうち最も負の形成エネルギーを持つのは YPt_3 ($E_f = -0.981$ eV/atom) であり、次いで ErPd_3 (-0.914)、 PaRh_3 (-0.900)、 ScPd_3 (-0.854) が続く。詳細は Supplementary S6 節に掲載する。

5.7.5. 材料設計仮説の生成

探索結果から以下の材料設計仮説を導出した：

1. **Pt** ベース化合物の高安定性： Pt_3Al 、 Pt_3Ge 等の Pt ベース L_{12} 化合物は負の形成エネルギーを示し、熱力学的に安定である。
2. **Cu** 系 γ' 候補の計算的抽出： Cu_3Nb 、 Cu_3Ti 、 Cu_3Ta は計算上、格子整合性とバルクモジュールのバランスが良いが、Cu–Ni 系の相分離傾向から実験的検証が必要である。
3. **Co_3Ti の Ni_3Al 代替可能性**： Co_3Ti は安定相であり、格子定数が Ni_3Al に近く、Co 基超合金の γ' 相として既に研究されている。
4. **A サイト元素依存性**：遷移金属系 (Ni, Co, Fe, Cu, Pt) の A サイト元素は負の形成エネルギーを持つ安定 L_{12} を形成する傾向がある。
5. 格子定数と形成エネルギーの相関： $a > 4.0$ Å の Al 基化合物 (Al_3Sc 、 Al_3Ti) は安定だが格子ミスマッチが大きく、析出強化には不向きである。

6. 考察

6.1. Schema Graph 制約の有効性

5 手法比較の結果 (表 9) から、以下の設計原則が導出される。

スキーマ情報注入が決定的. LLM-only (B1) の実行成功率 0% と Proposed (P) の 99% の対比は、材料データベースの専門的テーブル名に対して LLM の事前知識が無力であることを示す。スキーマ情報の提示方法が性能を支配する。

Schema Graph 走査によるテーブル幻覚排除. Proposed 手法がテーブル幻覚率 0% を達成した。Schema Graph 走査が提供する関連テーブルのみのサブグラフ提示が、テーブル幻覚を原理的に排除し、同時に不要 JOIN も削減する。ここで「不要 JOIN」とは、Schema Graph が返す最小接続部分グラフ (Steiner 木) に含まれないテーブルへの JOIN と定義する。Full Schema 手法 (26.6%) との精度差 (43.6pt) は、LLM に提示するテーブルの絞り込みが精度に直結することを示す。

実行精度の構造. Proposed 手法の実行精度 70.2% は Easy 81.2%、Medium 79.1%、Hard 74.7%、Very Hard 42.0% と参照テーブル数に応じて単調に低下する。これは Schema Graph 制約が JOIN 経路の正確性を保証する一方、WHERE 句の生成品質が LLM の能力に依存することを示す。5-6 テーブルクエリでも精度 42.0% を達成しており、Schema Graph 走査と LLM の役割分担が機能している。

6.2. 材料工学的考察

6.2.1. 既知化合物の完全再発見

11 件の既知 $L1_2$ 化合物の 100% 再発見 (表 15) は、データベース構築とクエリ変換パイプラインの内部整合性を検証する。特に Ni_3Al 、 Co_3Ti 等の γ' 相化合物が正しく抽出されることは、超合金材料探索ツールとしての基本的な信頼性を担保する。

6.2.2. γ' 候補の材料工学的妥当性

γ' 相候補ランキング (表 16) で Cu_3Nb が Ni_3Al と同等の最高スコア (0.878) を得た。 Cu_3Nb は計算上、格子整合性 [42] ($\Delta a = 0.01 \text{ \AA}$)、準安定性 ($E_{\text{hull}} = 0.004 \text{ eV/atom}$)、高バルクモジュラス [43] (218 GPa) を兼ね備える。ただし、Cu-Ni 系は広い温度範囲で相分離を示すため、Ni 基超合金マトリックスとの共存性には実験的検証が必要である。

一方、 Ni_3Al 近傍格子定数候補 (Supplementary S5 節) では、 Co_3Ti ($\Delta a = 0.02 \text{ \AA}$ 、安定) が析出強化候補として最も現実的である。 Co_3Ti は Co 基超合金の γ' 相として既に研究されており、本データベースからの抽出結果は既知の材料工学的知見と整合する。

6.3. 独立設計クエリによる評価 (B1 検証)

自己参照性バイアスの検証として、システム開発に関与していない材料研究者が独立に設計した 100 件のクエリを用いて Proposed 手法の精度を再評価した。独立設計クエリは 10 カテゴリ (基本検索、組成・元素、構造・格子定数、安定性・形成エネルギー、DFT 計算・物性、電子構造・磁性・熱特性、表面・粒界・欠陥、文献・合成・応用、材料設

Table 17: 著者設計クエリと独立設計クエリの精度比較。「平均実行精度」は連続値の単純平均、「二値正答率」は閾値 ≥ 0.8 で二値化した正答率である。

指標	著者設計 (100 件)	独立設計 (100 件)
平均実行精度 (連続値)	70.2%	79.3%
二値正答率	—	77.0% (77/100)
構文妥当率	99.0%	100.0%
実行成功率	99.0%	100.0%
難易度別 (著者: 参照テーブル数基準、独立: 専門家判定)		
Easy	81.2% [†] (27 件)	66.7% (12/18) [‡]
Medium	79.1% [†] (28 件)	85.3% (29/34) [‡]
Hard	74.7% [†] (22 件)	67.6% (23/34) [‡]
Very Hard	42.0% [†] (23 件)	92.9% (13/14) [‡]

[†] 平均実行精度 (連続値) [‡] 二値正答率

計・スクリーニング、比較・統計) から構成され、30 テーブルの拡張スキーマ全体を対象とする。

表 17 に結果を示す。表中の「全体精度」は `execution_accuracy` の単純平均 (連続値) である。著者設計の難易度別値は平均実行精度、独立設計の難易度別値は二値正答率である。二値正答率で揃えると全体は $77/100=77.0\%$ となる。独立設計クエリでの平均実行精度 (連続値) は 79.3% であり、著者設計クエリの 70.2% を 9.1 ポイント上回った。ただし、以下の点に留意が必要である:

版差異: 著者設計 100 件と独立設計 100 件は、システムの異なる改良段階で実行された。独立設計側ではカラム同義語マッピング追加等の改良が反映されており、厳密な同一条件比較ではない。同一最終バージョンでの再評価が今後の課題である。

SUPERSET 検出の帰属: SUPERSET 検出リベアルーブは著者設計 100 件の評価パイプライン (`run_full_evaluation.py`) にのみ実装されており、独立設計 100 件の評価 (`run_expert_evaluation.py`) には含まれていない。したがって、独立設計側の好成績を SUPERSET 検出の効果に帰属することはできない。

構文妥当率 (100.0%) は Schema Graph 制約のクエリ出自非依存性を裏付ける。

構造的難易度と意味的難易度の乖離: 著者設計クエリの難易度は gold SQL の参照テーブル数で客観的に分類しており、精度は難易度の上昇に伴い単調に低下する (81.2% $\rightarrow$ 42.0%)。一方、独立設計クエリの難易度は専門家の主観的判定であり、Easy クエリ (66.7%) が Very Hard クエリ (92.9%) より低い精度を示す逆転が観測された。この乖離の主因は意図解釈の曖昧性である: 構造的に単純なクエリ (1-2 テーブル) でも「あるか」 (EXISTS 判定 vs 全件列举)、「何件」 (COUNT 列名の不一致) 等、自然言語の解釈に複数の合理的候補がある場合、LLM と gold SQL の意図が不一致となる。対照的に、構造的に複雑なクエリでは質問文が具体的で解釈の余地が少ない。この結果は、Text-to-SQL の難易度評価において SQL 構造の複雑さだけでなく質問文の意味的曖昧性が独立した難易度軸であることを示唆する。

クエリサンプルの提供: 独立設計者には事前にカテゴリ別のサンプルクエリ集 (`independent_query_samples.md`) を提供した。最終的に採用された 100 件はこのサンプルと高い一致率を示しており、完全に自由記述のクエリではな

い。この点は独立性の制約として認識されるべきである。

6.4. 限界と制約

6.4.1. データベース規模

1,470 エントリ・5 プロトタイプの検証データベースは、本番規模の材料 DB (OQMD: ~30 テーブル・100 万件超) より小さい。30 テーブル・100 万件規模での検証は未実施であり、今後の課題である。

6.4.2. テストケースの自己参照性

80 件の回帰テストおよび 100 件の著者設計評価クエリはシステム開発者が設計したものである。独立設計 100 件による追加評価 (6.3 節) で独立設計クエリでの精度向上 (70.2% → 79.3%) を確認したが、クエリ設計者が 1 名に限られる点は依然として制約であり、複数の材料研究者によるブラインドテストが今後の課題である。

6.4.3. 実行精度の難易度依存性

Proposed 手法の実行精度 70.2% は Easy (1-2 テーブル) では 81.2% だが Very Hard (5-6 テーブル) では 42.0% に低下する。参照テーブル数が増えるほど WHERE 句の複雑性が増すため、LLM の生成能力が精度の上限を制約する。Few-shot 例の拡充、Self-correction、プロンプト改善が今後の方向性である。

6.4.4. データバイアスと合成データの限界

1,470 エントリの検証データは OQMD の値を参考に構築した合成検証データであり、実験的に合成・検証されたデータではない。30 テーブルの大半 (キュリー温度・ $\Sigma 5$ 粒界エネルギー・合成法・文献参照等) は OQMD に存在しない属性であり、検証用に生成されたものである。したがって 5.7 節の材料工学的分析結果 (特に Cu_3Nb の γ' 候補としての評価) は Text-to-SQL システムの検証用ケーススタディであり、材料学的結論を直接導くものではない。

6.4.5. 評価指標の限界

本評価の execution accuracy は再現率 (recall) ベースであり、生成 SQL が余分な行を返してもペナルティがない。WHERE 句を全て除去して全件返却すれば精度 1.0 となる構造であり、precision/F1 の併記が必要である。修正済みの評価パイプライン (B1 修正) では precision/recall/F1 の 3 指標を出力するが、本稿の結果は再実行前の recall 単独指標に基づく。

6.4.6. ベースラインの公平性

リペアループ (リペア最大 2 回、初回生成を含め最大 3 回の実行機会) と Few-Shot RAG は Proposed のみに適用されている。表 9 の差分は Schema Graph 制約のみの効果ではなく、複数要素の合算である。予備的なアブレーション実験 (Traversal 有無、RAG 有無) は実施済みであり、結果は experiments/results/ に格納されているが、体系的なコンポーネント別分離 (リペアループ OFF 時の Proposed 精度等) は未実施であり、今後の課題である。

6.4.7. LLM の単一・単一実行

gpt-5.5 の 1 種類・1 回実行で分散・信頼区間を算出していない。オープンモデルでの追試、および DAIL-SQL/DIN-SQL 等の既存 SOTA パイプラインを同 DB に適用した比較も未実施である。

6.4.8. gold SQL の検証

gold SQL・期待結果は著者 1 名が作成し、第三者による独立検証は行っていない。

6.5. 大規模データベースにおける精度変化の想定

本評価は 1,470 エントリの検証 DB で実施したが、本番運用では 10 倍 (~15,000 件) ~100 倍 (~150,000 件) 規模が想定される。データ規模拡大が各失敗カテゴリに与える影響を以下に分析する。

6.5.1. 失敗パターンのスケール依存性分類

評価で観測された失敗パターンを、データ規模との依存性で分類する (表 18)。

Table 18: 失敗パターンのデータ規模依存性

失敗パターン	規模依存性	根拠
カラム名幻覚	なし	スキーマ構造の問題。データに非依存
JOIN 経路不足	なし	FK graph 走査は件数に非依存
集約パターン認識失敗	低	GROUP BY 構文生成はデータ量と無関係
WHERE 条件欠落 (SUPERSET)	高	返却行数がデータ量に比例して増加
LIMIT 不適切	中	大規模データでは切り捨ての影響が顕在化
生成自体の失敗	なし	LLM 生成プロセスの問題

6.5.2. 規模別の精度予測

スキーマ依存エラー (カラム幻覚・JOIN 不足)・Schema Graph によるカラム/テーブル制約はデータ件数に依存せず、10 倍・100 倍でも同一の防止効果を維持する。

WHERE 条件欠落 (SUPERSET 返却)・フィルタ条件の欠落は、データ規模に比例して影響が増大する。例: source_db='OQMD' 条件の欠落は 1,470 件では 1,470 行の全件返却だが、100 倍規模では 150,000 行を返却し、precision 低下が顕著になる。リペアループでの「結果行数が過大」検出を強化することで緩和可能。

集約クエリ (COUNT/AVG/分布)・GROUP BY+集約関数の生成自体はデータ量に非依存だが、集約結果の値がデータ量で変化するため、精度判定の閾値設定に注意が必要。本手法の execution accuracy は row-level 一致率で計算するため、集約結果が正しければ規模に関わらず精度 1.0 となる。

Table 19: データ規模別の予測精度

6.8. 今後の展望

データ規模	予測精度範囲	根拠
現状 (1,470 件)	70.2%	実測値 (標準 100 クエリ)
10 倍 (～15,000 件)	66–70%	SUPERSET 検出で一部緩和
100 倍 (～150,000 件)	62–68%	SUPERSET + LIMIT なし版、EXISTS パターンなし版、SQLGuard なし版、辞書なし版を構成し、各要素の精度寄与を定量化することで提案手法の設計根拠を明確化する。

総合予測。精度低下の主因は **WHERE** 条件欠落に限定される。Schema Graph 制約 (テーブル幻覚 0%) は規模に非依存であり、構造的正しさの保証は維持される。JOIN 幻覚は 6 件 (表 13) が残存し、完全排除は達成されていない。本手法ではリベアループに SUPERSET 検出 (WHERE 条件数と返却行数の妥当性検証) を実装しており、条件不足のクエリを自動検出・LLM フィードバックによる修正を行う。大規模データではこの検出機構がさらに重要となる。

6.6. 関連システムとの比較

表 20 に関連システムとの比較を示す。汎用 T2SQL ベンチマーク (Spider, BIRD, DAIL-SQL 等) は正規化 RDB 上での SQL 生成を評価するが、材料データベース固有の用語曖昧性や多元素組成検索には対応していない。RAT-SQL や SchemaGraphSQL は FK 関係のグラフ構造を活用する点で本手法と共通するが、材料用語辞書や化学式パーサー等のドメイン特化要素を欠く。材料特化システム (MKNA, OptiMat) は API ベースのアクセスを提供するが、正規化 RDB 上での SQL 生成と JOIN 制御は行わない。オントロジーアプローチ (SuperCon, PoLyInfo, EMMO 等) は RDF/SPARQL を前提とし、セマンティック推論に優れるが、既存の RDB インフラへの適用にはデータ変換が必要である。本手法は「正規化 RDB + 材料特化 + FK グラフ走査」の組合せで、これらの既存アプローチがカバーしない領域を埋める。

6.7. AI for Science (AI4S) における意義

本手法は AI4S パラダイムに直接的な含意を持つ。Schema Graph アーキテクチャは **FK** 経路探索部分がスキーマ非依存であり、FK 関係は実行時に PostgreSQL メタデータからイントロスペクション (3.3 節) されるため、FK 経路探索は任意の正規化 RDB (Materials Project [5], AFLOW [6], NOMAD [7]、機関内データベース) に自動適応可能である。ただし、用語辞書のドメイン適応、**property_name** の意味対応、Few-Shot 例の整備、および大規模スキーマ (100 テーブル以上) での Steiner 木探索性能はターゲット DB 毎に調整・検証が必要である。

とりわけ、Materials Integration (MInt) システム [44] における PSPP 連鎖の各モジュールが出力する RDB や、provenance 管理システム pinax [45] が蓄積する解析ワークフローデータベースは、本手法の自然な適用先として期待される。

L1₂ 探索で実証された Schema Graph 制約 → LLM SQL 生成 → 材料分析 (γ 候補ランキング、格子整合性評価) の一連のフローは、NL → データ検索 → 材料設計仮説生成のエンドツーエンドパイプラインの原型を提供する。

1. 体系的コンポーネント別アブレーション実験：予備的な Traversal/RAG アブレーションは実施済みだが、各コンポーネントの個別寄与は未分離である。Schema Graph なし版、EXISTS パターンなし版、SQLGuard なし版、辞書なし版を構成し、各要素の精度寄与を定量化することで提案手法の設計根拠を明確化する。
2. **FK** 循環スキーマでの動作検証：「木構造グラフでは厳密解」という主張を超え、意図的に FK 循環を持つスキーマ (例：プロトタイプ共有による循環) で Steiner 木近似の誤差を定量評価する。
3. 別データベースへの転用実験：「アーキテクチャ上適用可能」という主張を裏付けるため、Materials Project の public スキーマに Pipeline を適用し、用語辞書の適応コストと精度を報告する。
4. ブラインドユーザスタディの拡大：独立設計 100 件での検証 (6.3 節) を実施済みだが、設計者 1 名に限られる。複数の材料研究者からの自由文クエリ収集により自己参照性問題をさらに緩和する。
5. **AI4S** エージェント統合：T2SQL 手法を自律材料探索エージェントのツールとして組み込み (MCP プロトコルや function calling 経由)、仮説 → データ検索 → 分析のエンドツーエンドパイプラインを実現。
6. **CALPHAD** 連携：Schema Graph 走査で RDB から候補を絞り込んだ後、CALPHAD の自由エネルギー計算により温度依存相安定性を判定する二段階フローを想定する。
7. **LLM** 能力向上との組合せ：gpt-5.5 での実行精度 70.2% は、Very Hard 難易度 (42.0%) に改善余地がある。Chain-of-Thought 推論や Few-Shot プロンプトの拡充との組合せが期待される。
8. 大規模データ検証：10 万レコード・100 テーブル以上での Steiner 木近似の計算性能と SQL 生成精度の検証が残る。
9. **SQLGuard** の **AST** 検証完全化：現行の正規表現 + SQLGlot 併用を、AST ベース検証を主軸とする構成に移行し、型制約検証 (数値カラムへの文字列比較禁止等) を追加する。
10. **EAV** 物性テーブルの **VIEW** 化：頻用物性 (**bulk_modulus**, **shear_modulus** 等) をピボット VIEW として提示し、LLM の SQL 生成安定性を向上させる。
11. インデックス設計と性能評価：**composition(element, entry_id)**, **calculated_property(property_name, value)** 等の複合インデックスを追加し、大規模 DB (100 万件) での応答時間を評価する。
12. 評価指標の多軸化：現行の実行結果一致に加え、SELECT 列適合率、JOIN 経路一致率、ORDER BY 正確性 (Top-k accuracy, NDCG) を分離評価し、エラーの原因特定を容易にする。
13. 多元素検索の代替戦略比較：EXISTS 方式と GROUP BY/HAVING 方式の性能・可読性比較を実施し、DB サイズに応じた最適戦略を明確化する。
14. 集約クエリのテンプレート化：COUNT、AVG、MAX/MIN、ORDER BY...LIMIT の各パターンを intent 分類に基づき半自動生成し、Rule-based モードの適用範囲を拡大する。

Table 20: 関連する材料 NLP / T2SQL / オントロジーシステム・手法・データセットとの比較。

種別	名称	スキーマ 認識	正規化 RDB	材料 特化	NL→ クエリ	主な差異
<i>T2SQL</i> ベンチマーク						
データセット	Spider [12]	あり	あり	なし	SQL	汎用ベンチマーク (10,181 件)
データセット	BIRD [13]	あり	あり	なし	SQL	大規模実データ (12,751 件)
<i>T2SQL</i> 手法						
手法	DAIL-SQL [14]	あり	あり	なし	SQL	スケルトン選択
手法	RAT-SQL [19]	あり	あり	なし	SQL	関係認識符号化
手法	RESDSQL [21]	あり	あり	なし	SQL	スキーマリンク分離 + スケルトン分離
手法	SchemaGraphSQL [23]	あり	あり	なし	SQL	パスファインディング
材料情報学						
手法	MKNA [28]	なし	なし	あり	API	エージェント
手法	OptiMat [29]	なし	なし	あり	API	オンデマンド DFT
オントロジー・知識グラフ						
手法	SuperCon [10]	あり	なし	あり	SPARQL	RDF オントロジー
手法	PoLyInfo [11]	あり	なし	あり	SPARQL	BFO 準拠
手法	EMMO [31]	あり	なし	あり	—	上位オントロジー
手法	KG+OBQC [33]	あり	なし	なし	SPARQL	72%精度
手法	本手法	あり	あり	あり	SQL	FK 走査 + L1 ₂ 辞書

7. 結論

本研究では、Schema Graph 制約型 Text-to-SQL 手法を提案し、1,470 エントリ (5 プロトタイプ)・100 クエリの評価で検証した。主要な知見：

1. テーブル幻覚率 **0%**かつ実行精度 **70.2%**: Schema Graph 走査 (Steiner 木近似) により LLM の視界を必要テーブルに限定し、テーブル幻覚の排除と不要 JOIN の削減を同時に達成。JOIN 幻覚は 6 件残存し完全排除には至っていない。1,470 エントリ (L1₂+B2+NaCl+NiAs+BiF₃) で検証。
2. **FK** イントロスペクションによる汎用性: FK 経路探索部分は任意の正規化材料 RDB (OQMD [3]、Materials Project [5]、AFLOW [6] 等) に自動適応可能。ただし用語辞書・**property_name** 対応のドメイン適応および大規模スキーマでの性能検証が別途必要。
3. **L1₂** 化合物探索で材料工学的有用性を実証: 既知 L1₂ 11 件の全件再発見、Cu₃Nb を γ 候補として計算的に抽出 (実験的検証が必要)。
4. 評価指標の改善: 共通カラム照合と LIMIT 10,000 正規化の併用 (合計+65.4pt) により、T2SQL 評価における SELECT 列差異と LIMIT 切り詰めの影響を排除。
5. 回帰テスト **39/39 PASS**: SQL インジェクション安全処理、Intent 分類を含む安全性・頑健性テストに全件合格。
独立評価: 材料研究者が設計した 100 件のクエリ (30 テーブル対象) での平均実行精度 (連続値) は 79.3%、二値正答率は 77.0% であり、著者設計 100 件 (70.2%) を上回った。ただし両セットはシステムの異なる改良段階で実行されており、厳密な同一条件比較ではない。構文妥当率は 100.0% を達成した (表 17)。

実証の限界: 検証は 1,470 エントリに限定される。Very Hard 精度は 42.0% (著者設計、5-6 テーブル) であり、複合 WHERE 句の生成が今後の課題である。

本手法は正規化 RDB 全般に対する Schema Graph 制約型 T2SQL の汎用フレームワークを提供し、マルチデータベース対応、大規模スキーマ検証、AI4S エージェント統合、CALPHAD 連携への拡張が期待される。

謝辞

L1₂ 型金属間化合物の DFT 計算データは Open Quantum Materials Database (OQMD) の値を参考に構築した合成検証データである。L1₂ の格子定数・形成エネルギー・hull 上エネルギー等は OQMD 公開値に近い値を用いたが、キュリー温度・ $\Sigma 5$ 粒界エネルギー・合成法・文献参照等の属性は OQMD に存在せず、検証用に生成したものである。したがって 5.7 節の材料工学的分析は Text-to-SQL システムの検証を目的としたケーススタディであり、材料学的結論を直接導くものではない。OQMD の開発・維持管理にあたる Northwestern 大学 Wolverton グループに感謝する。本研究は NIMS の支援を受けた。

Data Availability

本研究で利用した検証データベース (5 プロトタイプ 1,470 エントリ) の seed データ、評価クエリ 100 件 (gold SQL・期待結果セット)、5 手の実験結果 CSV、回帰テスト 39 件、ソースコード一式 (Schema Graph 走査エンジン・SQL ガード・条件抽出器・LLM モード)、および検証手順書 (VERIFICATION_GUIDE.md) は検証資材リポジトリに収録されている。

Author Contributions

Satoshi Minamoto: 研究構想、手法設計、ソフトウェア実装、データベース構築、実験実施、論文執筆。

References

- [1] H. Wang, T. Fu, Y. Du, W. Gao, K. Huang, Z. Liu, P. Chandak, S. Liu, P. Van Katwyk, A. Deac, A. Anandkumar, K. Bergen, C. P. Gomes, S. Ho, P. Kohli, J. Lasenby, J. Leskovec, T.-Y. Liu, A. Manber, D. Misra, E. Moret, J. Pineau, B. Poole, M. Sacks, S. SenGupta, J. Sun, J. Tang, A. Trischler, M. Welling, Y. Xie, M. Zitnik, Scientific discovery in the age of artificial intelligence, *Nature* 620 (2023) 47–60. doi:10.1038/s41586-023-06221-2.
- [2] L. Himanen, M. O. J. Geurts, A. S. Foster, P. Rinke, et al., Data-driven materials science: Status, challenges, and perspectives, *Adv. Sci.* 7 (2020) 1903667. doi:10.1002/advsc.201903667.
- [3] J. E. Saal, S. Kirklin, M. Aykol, B. Meredig, C. Wolverton, Materials design and discovery with high-throughput density functional theory: The Open Quantum Materials Database (OQMD), *JOM* 65 (2013) 1501–1509. doi:10.1007/s11837-013-0755-4.
- [4] S. Kirklin, J. E. Saal, B. Meredig, A. Thompson, J. W. Doak, M. Aykol, S. Rühl, C. Wolverton, The Open Quantum Materials Database (OQMD): Assessing the accuracy of DFT formation energies, *npj Comput. Mater.* 1 (2015) 15010. doi:10.1038/npjcompumats.2015.10.
- [5] A. Jain, S. P. Ong, G. Hautier, W. Chen, W. D. Richards, S. Dacek, S. Cholia, D. Gunter, D. Skinner, G. Ceder, K. A. Persson, Commentary: The Materials Project: A materials genome approach to accelerating materials innovation, *APL Mater.* 1 (2013) 011002. doi:10.1063/1.4812323.
- [6] S. Curtarolo, W. Setyawan, G. L. W. Hart, M. Jahnatek, R. V. Chepulskii, R. H. Taylor, S. Wang, J. Xue, K. Yang, O. Levy, M. J. Mehl, H. T. Stokes, D. O. Demchenko, D. Morgan, AFLOW: An automatic framework for high-throughput materials discovery, *Comput. Mater. Sci.* 58 (2012) 218–226. doi:10.1016/j.commatsci.2012.02.005.
- [7] C. Draxl, M. Scheffler, NOMAD: The FAIR concept for big data-driven materials science, *MRS Bull.* 43 (2018) 676–682. doi:10.1557/mrs.2018.208.
- [8] O. N. Senkov, D. B. Miracle, K. J. Chaput, J.-P. Couzinie, Development and exploration of refractory high entropy alloys — A review, *J. Mater. Res.* 33 (2018) 3092–3128. doi:10.1557/jmr.2018.153.
- [9] E. P. George, D. Raabe, R. O. Ritchie, High-entropy alloys, *Nat. Rev. Mater.* 4 (2019) 515–534. doi:10.1038/s41578-019-0121-4.
- [10] M. Ishii, K. Sakamoto, Structuring superconductor data with ontology: Reproducing historical datasets as knowledge bases, *Science and Technology of Advanced Materials: Methods* 3 (1) (2023) 2223051. doi:10.1080/27660400.2023.2223051.
- [11] M. Ishii, T. Ito, K. Sakamoto, NIMS polymer database PoLy-Info (II): machine-readable standardization of polymer knowledge expression, *Science and Technology of Advanced Materials: Methods* 4 (1) (2024) 2354651. doi:10.1080/27660400.2024.2354651.
- [12] T. Yu, R. Zhang, K. Yang, M. Yasunaga, D. Wang, Z. Li, J. Ma, I. Li, Q. Yao, S. Roman, Z. Zhang, D. Radev, Spider: A large-scale human-labeled dataset for complex and cross-domain semantic parsing and text-to-SQL task, in: *Proceedings of EMNLP*, 2018, pp. 3911–3921.
- [13] J. Li, B. Hui, G. Qu, J. Yang, B. Li, B. Li, B. Wang, B. Qin, R. Geng, N. Huo, et al., Can LLM already serve as a database interface? A BIG Bench for Large-Scale Database Grounded Text-to-SQL (BIRD), *Advances in Neural Information Processing Systems* 36 (2024).
- [14] D. Gao, H. Wang, Y. Li, X. Sun, Y. Qian, B. Ding, J. Zhou, Text-to-SQL empowered by large language models: A benchmark evaluation, *arXiv preprint arXiv:2308.15363* (2023).
- [15] M. Pourreza, D. Rafiei, DIN-SQL: Decomposed in-context learning of text-to-SQL with self-correction, in: *Advances in Neural Information Processing Systems*, Vol. 36, 2024.
- [16] Y. Gao, Y. Liu, X. Li, X. Shi, Y. Zhu, Y. Wang, S. Li, W. Li, Y. Hong, Z. Luo, J. Gao, L. Mou, Y. Li, XiYan-SQL: A multi-generator ensemble framework for text-to-SQL, *arXiv preprint arXiv:2411.08599* (2024).
- [17] Z. Hong, Z. Yuan, Q. Zhang, H. Chen, J. Dong, F. Huang, X. Huang, Next-generation database interfaces: A survey of LLM-based text-to-SQL, *arXiv preprint arXiv:2406.08426* (2024).
- [18] K. Maamari, F. Abubaker, D. Jaroslawicz, A. Mhedhbi, The death of schema linking? text-to-SQL in the age of well-reasoned language models, *arXiv preprint arXiv:2408.07702* (2024).
- [19] B. Wang, R. Shin, X. Liu, O. Polozov, M. Richardson, RAT-SQL: Relation-aware schema encoding and linking for text-to-SQL parsers, in: *Proceedings of the 58th Annual Meeting of the ACL*, 2020, pp. 7567–7578.
- [20] Z. Chen, L. Chen, Y. Zhao, R. Cao, Z. Xu, S. Zhu, K. Yu, ShadowGNN: Graph projection neural network for text-to-SQL parser, in: *Proceedings of the 2021 Conference of the North American Chapter of the ACL*, 2021, pp. 5567–5577.
- [21] H. Li, J. Zhang, C. Li, H. Chen, RESDSQL: Decoupling schema linking and skeleton parsing for text-to-SQL, in: *Proceedings of the AAAI Conference on Artificial Intelligence*, Vol. 37, 2023, pp. 13067–13075. doi:10.1609/aaai.v37i11.26535.
- [22] X. V. Lin, R. Socher, C. Xiong, Bridging textual and tabular data for cross-domain text-to-SQL semantic parsing, in: *Findings of the Association for Computational Linguistics: EMNLP 2020*, 2020, pp. 4870–4888.
- [23] A. Safdarian, M. Mohammadi, E. Jahanbakhsh, M. Shahamat Naderi, H. Faili, SchemaGraphSQL: Efficient schema linking with pathfinding graph algorithms for text-to-SQL on large-scale databases, in: *Findings of the Association for Computational Linguistics: EACL 2026*, 2026, pp. 2585–2599. doi:10.18653/v1/2026.findings-eacl.134.
- [24] T. D. Hoang, T. T. Nguyen, T. T. Huynh, H. Yin, Q. V. H. Nguyen, Scaling Text2SQL via LLM-efficient schema filtering with functional dependency graph rerankers, *arXiv preprint arXiv:2512.16083* (2025).
- [25] D. McMillan, Structured context engineering for file-native agentic systems: Evaluating schema accuracy, format effectiveness, and multi-file navigation at scale, *arXiv preprint arXiv:2602.05447* (2026).
- [26] Y. Song, S. Miret, B. Liu, MatSci-NLP: Evaluating scientific language models on materials science language tasks using text-to-schema modeling, in: *Proceedings of the 61st Annual Meeting of the ACL*, 2023, pp. 3621–3639.
- [27] V. Mishra, S. Singh, M. Zaki, et al., LLAMAT: Large language models for materials science information extraction, *arXiv preprint arXiv:2411.00177* (2024).
- [28] G. Zhuang, A. B. Farimani, From natural language to materials discovery: The Materials Knowledge Navigation Agent, *arXiv preprint arXiv:2602.11123* (2026).
- [29] Y. Hu, V. Turlo, OptiMat Alloys: A FAIR end-to-end agent with living database for computational multi-principal alloy exploration, *arXiv preprint arXiv:2604.21850* (2026).
- [30] B. Debrah, *Materials Project MCP Server*, model Context Protocol integration for Materials Project database (2025). URL <https://www.pulsemcp.com/servers/benedictdebrah-materials-project>
- [31] EMMC-CSA Consortium, *Elementary multiperspective material ontology (EMMO)*, version 1.0.0, CC BY 4.0 (2020). URL <https://github.com/emmo-repo/EMMO>
- [32] J. F. Sequeda, D. Allemang, B. Jacob, A benchmark to understand the role of knowledge graphs on large language model’s accuracy for question answering on enterprise SQL databases, in: *Proceedings of the 7th Joint Workshop on Graph Data Management Experiences & Systems (GRADES) and Network Data Analytics (NDA)*, ACM, 2024. doi:10.1145/3661304.3661901.
- [33] D. Allemang, J. F. Sequeda, Increasing the LLM accuracy for question answering: Ontologies to the rescue!, *arXiv preprint arXiv:2405.11706* (2024).
- [34] P. Villars, K. Cenzual, J. Daams, R. Gladyshevskii, Crystal structures of inorganic compounds, *Landolt-Börnstein – Numer-*

- ical Data and Functional Relationships in Science and Technology (2004).
- [35] A. A. Hagberg, D. A. Schult, P. J. Swart, Exploring network structure, dynamics, and function using NetworkX, proceedings of the 7th Python in Science Conference (SciPy) (2008).
 - [36] F. K. Hwang, D. S. Richards, P. Winter, The Steiner Tree Problem, North-Holland, 1992.
 - [37] P. Lewis, E. Perez, A. Piktus, F. Petroni, V. Karpukhin, N. Goyal, H. Küttler, M. Lewis, W.-t. Yih, T. Rocktäschel, et al., Retrieval-augmented generation for knowledge-intensive NLP tasks, *Advances in Neural Information Processing Systems* 33 (2020) 9459–9474.
 - [38] T. B. Brown, B. Mann, N. Ryder, et al., Language models are few-shot learners, *Advances in Neural Information Processing Systems* 33 (2020) 1877–1901.
 - [39] G. Salton, C. Buckley, Term-weighting approaches in automatic text retrieval, *Inf. Process. Manage.* 24 (1988) 513–523. doi:[10.1016/0306-4573\(88\)90021-0](https://doi.org/10.1016/0306-4573(88)90021-0).
 - [40] T. Mao, SQLGlot: A python SQL parser, transpiler, optimizer, and engine, <https://github.com/tobymao/sqlglot> (2023).
 - [41] P. Jaccard, The distribution of the flora in the alpine zone, *New Phytologist* 11 (2) (1912) 37–50. doi:[10.1111/j.1469-8137.1912.tb05611.x](https://doi.org/10.1111/j.1469-8137.1912.tb05611.x).
 - [42] L. Vegard, Die Konstitution der Mischkristalle und die Raumfüllung der Atome, *Z. Phys.* 5 (1921) 17–26.
 - [43] H. W. King, Quantitative size-factors for metallic solid solutions, *J. Mater. Sci.* 1 (1966) 79–90.
 - [44] S. Minamoto, T. Kadohira, K. Ito, M. Watanabe, Development of the Materials Integration system for materials design and manufacturing, *Materials Transactions* 61 (11) (2020) 2067–2071. doi:[10.2320/matertrans.MT-MA2020002](https://doi.org/10.2320/matertrans.MT-MA2020002).
 - [45] S. Minamoto, T. Kadohira, J. Fujima, Y. Fujiwara, A. Endo, C. Suematsu, K. Daimaru, H. Izuno, J. Sakurai, M. Demura, pinax: a provenance management system for materials data science, *Science and Technology of Advanced Materials: Methods* 6 (1) (2026) 2629051. doi:[10.1080/27660400.2026.2629051](https://doi.org/10.1080/27660400.2026.2629051).

Supplementary Materials

Schema-Graph-Constrained Natural Language Interface for
Intermetallic Compound Exploration

金属間化合物探索のための Schema Graph 制約型
自然言語データベースインターフェース

Satoshi Minamoto

National Institute for Materials Science (NIMS),
1-2-1 Sengen, Tsukuba, Ibaraki 305-0047, Japan

minamoto.satoshi@nims.go.jp

本補足資料では、本論文で提案した Schema Graph 制約型 Text-to-SQL システムの検証・評価に関する詳細情報を提供する。S1 節では回帰テストの全カテゴリと検証焦点を示し、S2 節で全 39 件のテストケース一覧を掲載する。S3 節では代表的なクエリに対する各手法の生成 SQL 例を比較し、本手法の JOIN パス制約の効果を具体的に示す。S4 節では SQL インジェクション攻撃を含む安全性テストの詳細結果を報告する。S5 節では Ni_3Al 近傍格子定数候補の抽出結果、S6 節では安定 L_{12} 候補の形成エネルギーランキングを示す。S7 節では LLM モード (gpt-5.5) の設定パラメータとプロンプト構成を記載する。S8 節では独立設計クエリ 100 件の詳細結果 (クエリ文、難易度、実行成否、精度) を一覧する。

S1. 回帰テストカテゴリ詳細

開発安全性テストとして 6 カテゴリ 39 件の回帰テスト、SQL 検証テスト 6 件、Coverage Score・パーサーテスト 15 件、Intent Classifier テスト 20 件の計 80 件を構築した (表 S1)。これらに加え、エイリアス解決テスト、スーパーセット検出テスト等を含む全 123 件のユニットテストが全 PASS を達成した。

Table S1: 回帰テストカテゴリ (全 80 件、全 PASS)。

カテゴリ	ID	n	検証焦点
正常系	A01-A15	15	L_{12} 元素・プロトタイプ・安定性・ソート・複合条件
該当なし	B01-B05	5	希ガス元素、非存在組合せ $\rightarrow 0$ 行期待
曖昧な入力	C01-C10	10	空入力、無関係テキスト、単語のみ
矛盾条件	D01-D02	2	「安定かつ準安定」等
SQL インジェクション	E01-E05	5	DROP, DELETE, INSERT、ピギーバック攻撃
安全性検査	F01-F02	2	直接 SQL 入力 (SELECT, UPDATE)
SQL 検証	—	6	カラム/テーブルホワイトリスト、JOIN 検証
Coverage・パーサー	—	15	数値条件、化学式、Coverage Score
Intent Classifier	—	20	VASP/DFT ワークフロー検出、分類

S2. 回帰テストケース一覧

表 S2 に回帰テスト 39 件 (正常系・該当なし・曖昧・矛盾・SQL インジェクション・安全性) のクエリと結果を示す。全評価クエリ 100 件 (Easy 20、Medium 30、Hard 30、Very Hard 20) の gold SQL、期待結果セット、5 手法比較結果、プロンプトテンプレート、allowed_schema.yaml、material_terms.yaml は検証資材リポジトリに収録されている。

S3. 生成 SQL 例

代表的なクエリに対する各手法の生成 SQL 例を示す。

Table S2: 回帰テストケース一覧（全 39 件、全 PASS）。

ID	カテゴリ	自然言語クエリ	結果
A01	正常系	Fe を含む L1 ₂ 化合物を出して	PASS
A02	正常系	安定な L1 ₂ 化合物を形成エネルギー順に出して	PASS
A03	正常系	Ni と Al の両方を含む化合物を出して	PASS
A04	正常系	L1 ₂ 化合物の全リストを出して	PASS
A05	正常系	準安定な L1 ₂ 化合物を出して	PASS
A06	正常系	Co を含む安定な L1 ₂ 化合物を出して	PASS
A07	正常系	Fe と Al を含む L1 ₂ 化合物を出して	PASS
A08	正常系	γ' 化合物を出して	PASS
A09	正常系	ニッケルを含む L1 ₂ 型化合物を出して	PASS
A10	正常系	L1 ₂ 化合物の全データを出して	PASS
A11	正常系	Ti を含む L1 ₂ 化合物を格子定数順（降順）に出して	PASS
A12	正常系	安定な L1 ₂ で格子定数 3.5Å 以上のものを出して	PASS
A13	正常系	Cu ₃ Au 型化合物を出して	PASS
A14	正常系	鉄を含む L1 ₂ 化合物を出して	PASS
A15	正常系	安定な L1 ₂ 化合物で Ni を含むものを出して	PASS
B01	該当なし	Xe を含む L1 ₂ 化合物を出して	PASS
B02	該当なし	U と Pu を含む L1 ₂ 化合物を出して	PASS
B03	該当なし	Rn と Og を含む L1 ₂ 化合物を出して	PASS
B04	該当なし	Sc と Ir を含む安定な L1 ₂ 化合物を出して	PASS
B05	該当なし	Pt と Ga を含む安定な L1 ₂ 化合物を出して	PASS
C01	曖昧	安定な化合物を出して	PASS
C02	曖昧	L12	PASS
C03	曖昧	安定なものを出して	PASS
C04	曖昧	（空入力）	PASS
C05	曖昧	今日の天気を教えて	PASS
C06	曖昧	Fe	PASS
C07	曖昧	格子定数	PASS
C08	曖昧	形成エネルギーが低い安定な L1 ₂ 化合物	PASS
C09	曖昧	NiAl L12	PASS
C10	曖昧	Ni の L12	PASS
D01	矛盾	安定かつ準安定な L1 ₂ 化合物	PASS
D02	矛盾	Ni なしの Ni L1 ₂ 化合物	PASS
E01	拒否	DROP TABLE material_entry;	PASS
E02	拒否	SELECT *; DELETE FROM composition;	PASS
E03	拒否	L1 ₂ 化合物; DROP TABLE structure;	PASS
E04	拒否	SELECT * FROM secret_passwords	PASS
E05	拒否	INSERT INTO material_entry VALUES (...)	PASS
F01	安全性	SELECT entry_id FROM material_entry	PASS
F02	安全性	UPDATE material_entry SET formula='X'	PASS

S3.1. 「Niを含む安定な L12 化合物を出して」

LLM-only (B1) : .「

```
1 SELECT formula, stability
2 FROM materials
3 WHERE element = 'Ni'
4       AND structure_type = 'L12'
5       AND stability = 'stable';
6 -- テーブル幻覚: materials, stability等は
7 -- 存在しないテーブル -> 実行不可
```

Proposed 手法 (P) : .「

```
1 SELECT DISTINCT m.entry_id, m.formula,
2       s.prototype, s.lattice_a, s.space_group
3 FROM material_entry m
4       JOIN composition c
5       ON c.entry_id = m.entry_id
6       JOIN structure s
7       ON s.entry_id = m.entry_id
8       JOIN phase_stability ps
9       ON ps.entry_id = m.entry_id
10 WHERE (s.prototype = 'L12'
11        OR s.strukturbericht = 'L12')
12        AND c.element = 'Ni'
13        AND ps.energy_above_hull <= 0.001
14 LIMIT 10000;
15 -- Schema Graph 走査で必要な3 JOINのみ
16 -- テーブル幻覚0%, DISTINCT, LIMIT付き
17 -- 安定条件は浮動小数点を考慮し <= 0.001 を使用
```

S3.2. 「Ni と Al の両方を含む L12 化合物を出して」

Full Schema (B2) : .「

```
1 SELECT m.entry_id, m.formula
2 FROM material_entry m
3       JOIN composition c
4       ON c.entry_id = m.entry_id
5       JOIN structure s
6       ON s.entry_id = m.entry_id
7 WHERE c.element = 'Ni'
8       AND c.element = 'Al'
9       AND s.prototype = 'L12';
10 -- 致命的: 単一行が両条件を同時に
11 -- 満たすことは不可能 -> 常に0行
```

Proposed 手法 (P) : .「

```
1 SELECT DISTINCT m.entry_id, m.formula
2 FROM material_entry m
3       JOIN structure s
4       ON s.entry_id = m.entry_id
5 WHERE (s.prototype = 'L12'
6        OR s.strukturbericht = 'L12')
7 AND EXISTS (
8       SELECT 1 FROM composition
9       WHERE entry_id = m.entry_id
10             AND element = 'Ni')
11 AND EXISTS (
12       SELECT 1 FROM composition
13       WHERE entry_id = m.entry_id
14             AND element = 'Al')
15 LIMIT 10000;
16 -- EXISTS 副問い合わせで正確な多元素 AND
17 -- -> Ni3Al (1行) を正しく返却
```

S4. SQL インジェクション・安全性テスト結果

7 件の敵対的入力 (E01–E05, F01–F02) はすべて SQL ガードにより安全に処理された (表 S3)。破壊的・注入的入力
は遮断され、LIMIT なしの直接 SELECT は LIMIT 自動付加により安全化された。

Table S3: SQL インジェクション・安全性テスト結果（全件安全処理）。

ID	入力	処理
E01	DROP TABLE material_entry;	禁止キーワード：DROP
E02	SELECT *; DELETE FROM composition;	複数文 + DELETE
E03	L1 ₂ 化合物; DROP TABLE structure;	複数文 + DROP
E04	SELECT * FROM secret_passwords	非許可テーブル
E05	INSERT INTO material_entry ...	禁止キーワード：INSERT
F01	SELECT entry_id FROM material_entry	LIMIT 自動付加（安全化）
F02	UPDATE material_entry SET ...	禁止キーワード：UPDATE

S5. Ni₃Al 近傍格子定数候補

$|a - a_{\text{Ni}_3\text{Al}}| \leq 0.03 \text{ \AA}$ を満たす候補を表 S4 に示す。

Table S4: Ni₃Al 近傍格子定数候補 ($|a - a_{\text{ref}}| \leq 0.03 \text{ \AA}$, $a_{\text{ref}} = 3.57 \text{ \AA}$, 14 件)。

化合物	$a \text{ (\AA)}$	$ \Delta a $	E_{hull}	E_f
Ni ₃ Al	3.572	0.002	0.000	-0.420
Ni ₃ Zn	3.560	0.010	0.032	-0.340
Pt ₃ Sn	3.560	0.010	0.032	-0.490
Cu ₃ Nb	3.560	0.010	0.004	-0.315
Ni ₃ V	3.580	0.010	0.036	-0.345
Cu ₃ Ta	3.580	0.010	0.008	-0.320
Pt ₃ Zn	3.580	0.010	0.036	-0.495
Co ₃ Ti	3.550	0.020	0.000	-0.450
Cu ₃ Ti	3.540	0.030	0.000	-0.310
Ni ₃ Sn	3.540	0.030	0.028	-0.335
Pt ₃ Si	3.540	0.030	0.028	-0.485
Pt ₃ V	3.600	0.030	0.040	-0.300
Cu ₃ Sc	3.600	0.030	0.012	-0.325
Ni ₃ Zr	3.600	0.030	0.040	-0.350

格子整合性に優れた候補の中で、Cu₃Nb ($E_{\text{hull}} = 0.004$) と Cu₃Ta ($E_{\text{hull}} = 0.008$) は準安定であり、Co₃Ti ($E_{\text{hull}} = 0.0$) と Cu₃Ti ($E_{\text{hull}} = 0.0$) は安定相として確認された。これらは Ni₃Al との格子ミスマッチが小さく、析出強化の観点から有望な候補であるが、実験的合成と検証が必要である。

S6. 安定 L1₂ 候補の抽出

$E_{\text{hull}} \leq 0.05 \text{ eV/atom}$ を満たす安定・準安定 L1₂ 候補を抽出した。安定 ($E_{\text{hull}} \leq 0.001$) 100 件、準安定 ($0.001 < E_{\text{hull}} \leq 0.05$) 237 件の計 337 件が候補として抽出された。安定相のうち、最も負の形成エネルギーを持つのは YPt₃ ($E_f = -0.981 \text{ eV/atom}$) であり、次いで ErPd₃ (-0.914)、PaRh₃ (-0.900)、ScPd₃ (-0.854) が続く。

S7. LLM モード設定

LLM モード (Level 2) では OpenAI API を介して gpt-5.5 を使用した。表 S5 にモデルパラメータを示す。

構造化プロンプトは以下の 4 要素から構成される：

1. システムメッセージ：タスク説明 + スキーマ YAML（テーブル名、カラム名、型、FK 関係）
2. **Few-Shot** 事例：RAG ストアからの Top- k 類似 NL-SQL ペア
3. ユーザーメッセージ：自然言語クエリ
4. 制約：「SELECT 文のみ生成」「LIMIT 10000 を含める」「スキーマに記載されたテーブルのみ使用」

プロンプトテンプレート (llm/prompt_templates/sql_generation_prompt.md) および allowed_schema.yaml は検証資料リポジトリに収録されている。gpt-5 系 API では temperature パラメータはサポートされておらず、本実装でも送信していない。そのため、LLM の内部状態により同一入力でも出力が変動する可能性がある。本研究の結果は 2026 年 5 月時点の gpt-5.5 による単一実行に基づく。信頼区間の算出は行っていない。

Table S5: LLM モード設定パラメータ。

パラメータ	値
モデル名	gpt-5.5 (OpenAI)
API アクセス日	2026 年 5 月
Temperature	未指定 (gpt-5 系は temperature パラメータ未サポート)
Max tokens	4,096 (全手法共通)
Top- <i>p</i>	1.0
リクエストタイムアウト	30 秒
リトライ回数	最大 3 回 (指数バックオフ)

S8. 独立設計クエリ 100 件の詳細結果

本論文 6.3 節で報告した独立設計クエリ 100 件について、各クエリの質問文、難易度、実行成否、実行精度、正誤判定の詳細を表 S6 に示す。難易度は E (Easy)、M (Medium)、H (Hard)、VH (Very Hard) の 4 段階であり、正誤判定は実行精度 ≥ 0.8 を正解 (✓) と判定した。

Table S6: 独立設計クエリ 100 件の詳細結果。

No.	クエリ (抜粋)	難易度	実行	精度	正誤
A. 基本検索					
1	データベースに登録されている化合物の総数を教えて。	E	✓	1.00	✓
2	BCC_B2 構造を持つ化合物を全て表示して。	E	✓	1.00	✓
3	3 元素以上で構成される化合物はあるか？	E	✓	0.00	—
4	化学式に Fe が含まれる化合物を一覧にして。	E	✓	1.00	✓
5	NaCl 型構造の化合物は何件あるか。	E	✓	0.00	—
6	Ni3Al のエントリを表示して。	E	✓	1.00	✓
7	空間群 Pm-3m の化合物を一覧にして。	E	✓	0.88	✓
8	OQMD のエントリ数を教えて。	E	✓	0.00	—
9	化学系に Ti を含む化合物の formula を表示して。	E	✓	1.00	✓
10	BiF3 型構造の化合物を全て出して。	E	✓	1.00	✓
B. 組成・元素					
11	Pt を 25%以上含む L12 型化合物を表示して。	M	✓	1.00	✓
12	Rh と Al の両方を含む化合物を教えて。	M	✓	1.00	✓
13	希土類元素を含む L12 型化合物はあるか。	H	✓	1.00	✓
14	遷移金属のみで構成される L12 型化合物を抽出して。	H	✓	0.69	—
15	Cu の原子分率が 0.75 である L12 型化合物を出して。	M	✓	1.00	✓
16	4d 遷移金属を B サイトに持つ L12 型化合物を表示して。	H	✓	1.00	✓
17	データベース中に登場する元素を全て一覧にして。	E	✓	1.00	✓
18	Mn を含む化合物はどのプロトタイプに多いか。	M	✓	0.00	—
19	原子番号が 40 以上の元素を含む L12 型化合物を教えて。	H	✓	1.00	✓
20	V と Al の両方を含む安定な化合物を出して。	M	✓	1.00	✓
C. 構造・格子定数					
21	格子定数 <i>a</i> が 3.50–3.60 Å の範囲にある L12 型化合物をリストして。	M	✓	1.00	✓
22	B2 構造で cubic 以外の結晶系を持つものはあるか。	M	✓	1.00	✓
23	体積が最小の L12 化合物はどれか。	M	✓	1.00	✓
24	格子定数 <i>a</i> と <i>c</i> が異なる化合物を表示して。	M	✓	1.00	✓
25	Strukturbericht 記号が L12 の化合物を prototype と共に表示して。	E	✓	1.00	✓
26	空間群番号 225 の化合物は何件か。	E	✓	0.00	—
27	NiAs 型でヘキサゴナルの結晶系、格子定数 <i>c</i> が最大のもの。	M	✓	1.00	✓
28	格子定数 <i>a</i> が 4.0 Å 以上の B2 化合物を表示して。	M	✓	1.00	✓
29	L12 型化合物の格子定数 <i>a</i> の平均値と標準偏差を教えて。	M	✓	0.00	—

次ページに続く

No.	クエリ (抜粋)	難度	実行	精度	正誤
30	全プロトタイプについて、それぞれの登録件数を教えて。	E	✓	0.60	—
D. 安定性・形成エネルギー					
31	convex_hull を構成する L12 化合物を全て出して。	M	✓	1.00	✓
32	形成エネルギーが正の化合物はあるか。	M	✓	1.00	✓
33	B2 構造で安定かつ形成エネルギーが負のものを表示して。	M	✓	1.00	✓
34	準安定 ($E_{\text{hull}} > 0$ かつ < 0.1 eV/atom) な L12 化合物。	M	✓	1.00	✓
35	NaCl 型構造で不安定な化合物の割合を教えて。	H	✓	0.00	—
36	バンドギャップが 0 より大きい L12 型化合物はあるか。	M	✓	1.00	✓
37	安定な L12 化合物のうち、バンドギャップが 0 のもの。	M	✓	0.62	—
38	Ni-Al 系の化合物の convex_hull 距離を全て表示して。	M	✓	1.00	✓
39	形成エネルギーが -0.5 eV/atom 以下の極めて安定な化合物。	M	✓	0.30	—
40	プロトタイプ別の平均 energy_above_hull を比較して。	M	✓	0.00	—
E. DFT 計算・物性					
41	GGA-PBE 以外の汎関数で計算されたエントリはあるか。	E	✓	0.00	—
42	バルクモジュラスが 200GPa 以上の L12 化合物を出して。	H	✓	1.00	✓
43	せん断弾性率が最も高い L12 化合物 TOP3 を教えて。	H	✓	1.00	✓
44	ヤング率が記録されている化合物を全て表示して。	M	✓	1.00	✓
45	ポアソン比が 0.3 以上の化合物をリストして。	M	✓	1.00	✓
46	B/G 比が 2 以上の L12 化合物。	VH	✓	1.00	✓
47	DFT 計算で弾性的に不安定とされた化合物はあるか。	M	✓	1.00	✓
48	格子定数に c/a が大きいものを探してほしい。	M	✓	1.00	✓
49	Ni ₃ Al のバルクモジュラスと形成エネルギーを教えて。	H	✓	1.00	✓
50	磁気モーメントが 0 でない L12 化合物を全て出して。	H	✓	1.00	✓
F. 電子構造・磁性・熱特性					
51	フェルミ面での DOS が最も高い L12 化合物は。	H	✓	1.00	✓
52	直接バンドギャップを持つ化合物はあるか。	M	✓	1.00	✓
53	スピン偏極計算がされている化合物を表示して。	M	✓	1.00	✓
54	強磁性の L12 化合物を出して。	H	✓	1.00	✓
55	キュリー温度が最も高い化合物はどれか。	M	✓	1.00	✓
56	デバイ温度が 500K 以上の化合物を教えて。	M	✓	1.00	✓
57	熱伝導率が記録されている L12 化合物を表示して。	H	✓	1.00	✓
58	グリュナイゼン定数が 2 以上の化合物はあるか。	M	✓	1.00	✓
59	磁気異方性エネルギーが最も大きい L12 化合物を出して。	H	✓	1.00	✓
60	金属的かつ強磁性の L12 化合物を探して。	VH	✓	1.00	✓
G. 表面・粒界・欠陥					
61	(111) 面の表面エネルギーが最も低い L12 化合物を教えて。	H	✓	1.00	✓
62	仕事関数が 5 eV 以上の L12 化合物を出して。	H	✓	1.00	✓
63	表面再構成が起こる化合物はあるか。	M	✓	1.00	✓
64	$\Sigma 5$ 粒界エネルギーが記録されている化合物を表示して。	M	✓	1.00	✓
65	空孔形成エネルギーが最も低い L12 化合物は。	H	✓	1.00	✓
66	アンチサイト欠陥の情報がある L12 化合物を教えて。	H	✓	1.00	✓
67	ドーパント元素として B が使われている化合物はあるか。	H	✓	1.00	✓
68	格子間原子欠陥の情報がある化合物を表示して。	M	✓	1.00	✓
69	(100) 面と (110) 面の表面エネルギーを両方持つ化合物。	VH	✓	1.00	✓
70	Vegard 則からの乖離が大きい L12、B2 化合物の情報。	VH	✓	1.00	✓
H. 文献・合成・応用					
71	実験で合成されたことのある L12 化合物はどれか。	H	✓	1.00	✓
72	アーク溶解法で合成された L12 化合物を表示して。	H	✓	1.00	✓
73	1000K 以上の温度で合成された L12 化合物を出して。	H	✓	0.93	✓

次ページに続く

No.	クエリ（抜粋）	難度	実行	精度	正誤
74	文献参照が3件以上ある L12 化合物を教えて。	VH	✓	1.00	✓
75	高温超合金の応用領域に分類されている化合物を表示して。	H	✓	1.00	✓
76	2020 年以降の文献で報告された L12 化合物を出して。	VH	✓	1.00	✓
77	実験値と計算値の両方がある化合物を表示して。	H	✓	0.36	—
78	ボールミリングで合成された化合物はあるか。	H	✓	0.87	✓
79	耐熱材料として分類されている化合物を表示して。	H	✓	0.00	—
80	DOI が記録されている文献の一覧を出して。	E	✓	1.00	✓
I. 材料設計・スクリーニング					
81	Ni3Al と格子定数が 0.05Å 以内で安定でバルクモジュラス 150GPa 以上。	VH	✓	1.00	✓
82	γ' 相候補として有望な L12 化合物を形成エネルギー順にランキング。	H	✓	0.93	✓
83	Co を含む安定な L12 でバルクモジュラス 180GPa 以上かつデバイ温度高。	VH	✓	1.00	✓
84	格子定数 3.56Å±0.03Å でせん断弾性率 70GPa 以上の安定な L12。	VH	✓	1.00	✓
85	強磁性かつ弾性的に安定な L12 化合物を全て表示して。	VH	✓	0.14	—
86	実験合成実績ありかつ DFT で安定な L12 化合物を出して。	VH	✓	1.00	✓
87	Ni3Al よりバルクモジュラスが高くハル距離が 0.01 以下の化合物。	VH	✓	1.00	✓
88	元素数 2 の安定な化合物をプロトタイプ別に集計して。	H	✓	0.00	—
89	L12 でポアソン比が低く (<0.25) 延性が低いと予想される化合物。	H	✓	1.00	✓
90	表面エネルギーが低い (<1.5 J/m ²) かつ安定な L12 化合物。	VH	✓	1.00	✓
J. 比較・統計					
91	L12 と B2 で、安定な化合物の割合を比較して。	H	✓	0.00	—
92	プロトタイプ別の平均バルクモジュラスを教えて。	H	✓	0.00	—
93	A サイト元素ごとの L12 化合物数を集計して。	H	✓	0.00	—
94	格子定数と形成エネルギーに相関はあるか。全 L12 化合物データ。	M	✓	1.00	✓
95	安定/不安定 L12 で平均バルクモジュラスに差はあるか。	VH	✓	1.00	✓
96	化学系ごとのエントリ数 TOP10 を教えて。	E	✓	1.00	✓
97	DFT 計算手法ごとのエントリ数を出して。	E	✓	1.00	✓
98	L12 型化合物のバンドギャップの分布。0 とそうでないものを分けて。	H	✓	0.00	—
99	格子定数 a の分布を 0.1Å 刻みでヒストグラム的に表示するデータ。	H	✓	0.00	—
100	全プロトタイプについて安定/不安定/準安定の件数内訳。	H	✓	0.00	—

カテゴリ別の正答率を表 S7 に示す。

Table S7: 独立設計クエリのカテゴリ別正答率。

カテゴリ	内容	正答数/件数	正答率
A	基本検索	7/10	70.0%
B	組成・元素	8/10	80.0%
C	構造・格子定数	7/10	70.0%
D	安定性・形成エネルギー	6/10	60.0%
E	DFT 計算・物性	9/10	90.0%
F	電子構造・磁性・熱特性	10/10	100.0%
G	表面・粒界・欠陥	10/10	100.0%
H	文献・合成・応用	8/10	80.0%
I	材料設計・スクリーニング	8/10	80.0%
J	比較・統計	4/10	40.0%
全体		77/100	77.0%

カテゴリ F（電子構造・磁性・熱特性）および G（表面・粒界・欠陥）が 100%を達成した。SUPERSET 検出リペアルーブの導入により、カテゴリ I（材料設計・スクリーニング）が前回の 30%から 80%へ大幅に改善した。条件不足のクエリが自動検出・修正された効果大きい。カテゴリ J（比較・統計）の 40%は依然として課題であり、プロトタイプ横断的な集約や GROUP BY 複合条件の処理が改善の余地を示す。