

Schema-Graph-Constrained Natural Language Interface for L₁₂ Intermetallic Compound Exploration:

L₁₂ 型金属間化合物探索のための Schema Graph 制約型自然言語データベースインターフェース

Satoshi Minamoto^{a,*}

^aNational Institute for Materials Science (NIMS), 1-2-1 Sengen, Tsukuba, Ibaraki 305-0047, Japan

Abstract

L₁₂ 型金属間化合物 (Cu₃Au 型、Ni₃Al 基 γ' 相候補を含む) は次世代耐熱超合金の析出強化相として重要であるが、第一原理計算データベースに蓄積された構造・組成・相安定性・物性データを横断的に探索するには SQL 知識が不可欠である。本研究では、**Schema Graph 制約型 Text-to-SQL (T2SQL)** 手法を提案する。

本手法は以下の技術要素から構成される: (1) 日英バイリンガル材料用語辞書を備えたドメイン特化型条件抽出器 (L₁₂/ γ' /Cu₃Au 型等の同義表現正規化、数値条件パーサー・化学式パーサーを含む)、(2) 外部キー (FK) 関係を NetworkX グラフとして表現し、Steiner 木近似により最小 JOIN 経路を計算する **Schema Graph** 走査エンジン、(3) キーワードブラックリスト、テーブル/カラムホワイトリスト、JOIN 検証、自動 LIMIT 注入を行う多層 **SQL** ガード (8 層検証)、(4) 抽出条件からテーブル・カラムを推定する **Schema Linker**、および (5) JOIN 制約付きプロンプトによる **LLM** 制約付き **SQL** 生成。

検証データベースとして、5 プロトタイプ 1,471 件 (L₁₂ 393 件、B2 636 件、NaCl 355 件、NiAs 74 件、BiF₃ 13 件、Ni₃Al、Co₃Ti、Al₃Sc 等の既知 L₁₂ 化合物 11 件を含む) を組成・構造・熱力学的安定性・計算条件・物性が外部キーで接続された正規化 RDB に格納した。100 件の評価クエリ (Easy 20 件、Medium 30 件、Hard 30 件、Very Hard 20 件、最大 4-hop JOIN) に対し、5 手法の比較実験を実施した: (i) LLM-only (スキーマ情報なし)、(ii) Full Schema (全スキーマ提示)、(iii) Rule-based (LLM なし)、(iv) FK-list (FK 情報のみ提示)、(v) **Proposed** (Schema Graph + エンティティ抽出 + Schema Linker + 制約付き LLM)。

評価指標には、SELECT 列の差異による過小評価を解消する共通カラム照合 (列名ベースの行マッチング) と、LIMIT 切り詰め影響を排除する **LIMIT 10,000** 正規化を導入した。Proposed 手法 (LLM: gpt-5.5) は構文妥当率 **100%**、実行成功率 **96%**、平均実行精度 **76.3%** を達成し、テーブル幻覚率 **0%** (LLM-only は 9%) を実現した。Medium 難易度では実行精度 89.2% に達し、2-hop 以上のマルチホップクエリでも 84.4% (2-hop)、70.1% (3-hop)、68.8% (4-hop) を記録した。Schema Graph 走査により LLM の視界を必要テーブルに限定することで不要 JOIN の排除とテーブル幻覚の防止を同時に達成した。

材料工学的評価として、既知 L₁₂ 化合物 11 件の全件再発見 (11/11)、 γ' 相候補のランキング出力 (安定性・格子整合性・バルクモジュラスの重み付き複合スコア、上位: Cu₃Nb、Ni₃Al、Cu₃Ti、Co₃Ti)、Ni₃Al 近傍格子定数候補の抽出、材料設計仮説の自動生成を達成した。

本手法は FK 関係の実行時イントロスペクションに基づくため、任意の正規化材料 RDB (OQMD、Materials Project、AFLOW 等) ヘコード変更なしで展開可能な汎用フレームワークを提供する。

Keywords: Text-to-SQL, L₁₂ 型金属間化合物, スキーマグラフ, Steiner 木近似, γ' 相, 材料データベース, 自然言語処理, マテリアルズ・インフォマティクス

1. 緒言

1.1. AI for Science と材料インフォマティクスにおけるデータアクセス障壁

材料データベースにおける自然言語インターフェースの本質的課題は、SQL 文の構文生成そのものではなく、正規

化された異種材料データを、外部キー関係と材料ドメイン意味論に従って正しく結合することである。本論文では、L₁₂ 型金属間化合物 (γ' 相候補) の探索を対象として、Schema Graph 走査 (FK 関係のグラフ表現と Steiner 木近似) に基づく制約型手法を提案し、1,471 エントリ (5 プロトタイプ)・100 クエリの評価で Proposed 手法がテーブル幻覚率 0%、実行精度 76.3% を達成したことを報告する。

AI for Science (AI4S)—科学的発見を加速するための人工知能の体系的応用—は、材料研究を変革しつつある [1, 2]。AI4S は、AI エージェントが自律的に仮説を生成し、大規模

*Corresponding author

Email address: minamoto.satoshi@nims.go.jp (Satoshi Minamoto)

データベースから関連データを検索し、実験やシミュレーションを設計し、結果を解釈する統合的ワークフローを構想している。このビジョンにおいて、構造化された材料データへの自然言語アクセスは単なる利便性ではなく前提条件である：AI エージェント（またはそれを指揮する研究者）が正規化リレーショナルデータベースを効率的にクエリできなければ、AI4S パイプライン全体がデータ検索段階でボトルネックとなる。

ハイスループット第一原理計算の急速な発展により、複数の大規模材料データベースが構築されている：Open Quantum Materials Database (OQMD、約 100 万件) [3, 4]、Materials Project (15 万件超) [5]、AFLOW (350 万件超) [6]、NOMAD [7]。これらのデータベースは計算材料探索、候補相のスクリーニング [8, 9]、実験観測の検証に不可欠である。一方、材料データの構造化・知識化の取り組みとして、Ishii らはレガシー超伝導データベース SuperCon のオントロジー構築と RDF 化 [10] や、高分子データベース PoLyInfo の機械可読化 [11] を実現しており、スキーマの意味的構造化が材料データ活用前提条件であることを示している。

しかし、正規化リレーショナルスキーマ（外部キーで接続された複数テーブル）に格納されたデータへのアクセスには SQL 知識が必要である。材料工学において本質的に重要なのは、大量データの収集よりも少量の異種データを正確に組み合わせることである：組成・結晶構造・熱力学的安定性・計算条件・物性値はそれぞれ独立したテーブルに正規化されており、これらを外部キー（FK）に沿って正しく JOIN することで初めて意味のある材料情報が得られる。例えば、「Fe を含む安定な B2 化合物の格子定数」を検索するには、元素・プロトタイプ・熱力学的安定性に対する WHERE 条件を持つ 4 テーブル JOIN が必要となる—データベース技術者にとっては容易だが、材料研究者にとっては非自明な操作である。不正確な JOIN（不要なテーブル結合や結合条件の欠落）は誤ったデータの組み合わせを返し、材料探索やスクリーニングの判断を誤導する深刻なリスクとなる。

多くの材料データベースが提供する REST API や GraphQL エンドポイントはこの障壁を部分的に緩和するが、RDB 全般に共通する根本的制約が残る：(a) 事前定義されたフィルタ構文への依存（アドホックな複合条件や集約が困難）、(b) スキーマ更新時の API 非互換リスク、(c) 機関内データベースや独自拡張スキーマには API が存在しない場合が多いこと。T2SQL アプローチは、スキーマ構造を実行時に解析するため、API の有無に関わらず任意の正規化 RDB に対して原理的に展開可能である。

AI4S の文脈において、このデータアクセス障壁は特に深刻である：材料スクリーニングや物性予測を行う自律 AI エージェントは、複雑な複合条件データベースクエリをプログラマ的に発行する必要がある。正しい SQL を確実に生成する自然言語インターフェースは、人間の研究者と AI エージェントの双方がデータベース工学の専門知識なしに材料データベースと対話することを可能にし、AI4S ワークフローの重要なボトルネックを除去する。

1.2. Text-to-SQL の技術動向

Text-to-SQL (T2SQL) 研究は大規模ベンチマークにより急速に進展している：Spider [12] (10,181 問、200 データベース、138 ドメイン)、BIRD [13] (12,751 問、95 データベース、33.4 GB)。最近の LLM ベース手法は高い精度を

達成している：DAIL-SQL [14] はスケルトンベースの few-shot 事例選択により Spider 上で実行精度 86.6%を報告し、DIN-SQL [15] は分解型文脈内学習により 85.3%を達成し、XiYan-SQL [16] はマルチジェネレータアンサンブルによりさらなる精度向上を報告している。Hong et al. [17] はスキーマリンキングの支配的役割を指摘する包括的サーベイを提供し、Maamari et al. [18] は高度な LLM により明示的スキーマリンキングが不要になる可能性を論じているが、これは議論が続いている。

スキーマ構造をグラフとして明示的に利用する手法も発展している。RAT-SQL [19] は Relation-Aware Schema Encoding によりテーブル間関係を事前学習し、ShadowGNN [20] はグラフ射影ニューラルネットワークでスキーマグラフを符号化する。RESDSQL [21] はスキーマリンキングとスケルトン解析を分離し、Bridge [22] はテキストと表形式データの橋渡しを行う。最近では、SchemaGraphSQL [23] がパスファインディングアルゴリズムによる大規模 DB スキーマリンキングを提案し、GraST-SQL [24] は機能依存グラフによるスキーマフィルタリングのスケールリングに取り組んでいる。McMillan [25] は構造化コンテキストエンジニアリングがマルチファイルエージェントシステムにおけるスキーマ精度に与える影響を評価している。

しかし、既存の **T2SQL** ベンチマークはすべて汎用ドメイン（e コマース、医療、教育）を対象としており、材料科学データベース固有の課題に取り組んだ先行研究は存在しない：ドメイン固有の用語（Strukturbericht 記号、プロトタイプ名）、バイリンガルクエリ（日英元素名）、組成テーブル正規化（化合物ごとに元素 1 行）、熱力学的安定性フィルタ（ $E_{\text{hull}} \leq 0.001$ eV/atom）などの課題である。

1.3. 材料インフォマティクスにおける NLP

材料科学における NLP 応用は拡大している：MatSciNLP [26] は材料テキストの 7 つの NLP タスクをベンチマークし、LLAMAT [27] は LLaMA の継続事前学習により情報抽出を改善し、Materials Knowledge Navigation Agent (MKNA) [28] は自然言語の意図をデータベース検索・構造生成アクションに変換し、OptiMat Alloys [29] は LLM 駆動型対話式合金探索ツールを提供している。Materials Project は MCP ベースの LLM 統合の提供を開始している [30]。

これらの研究は情報抽出やエージェントベースのデータベース対話を扱っているが、正規化リレーショナルデータベース上のスキーマ認識型 **SQL** 生成—特に外部キーグラフ走査による自動 JOIN 経路探索—を対象としたものはない。このギャップが本手法の焦点である。

1.4. オントロジー・知識グラフアプローチとの関連

材料データへの構造化アクセスには、オントロジー・知識グラフ (KG) に基づくアプローチも有力な系譜を形成している。Ishii らは超伝導材料データベース SuperCon を RDF オントロジーとして再構築し、SPARQL エンドポイントを通じた意味検索を実現した [10]。同グループは PoLyInfo の高分子データについても同様の機械可読化を行い、BFO 上位オントロジーとの整合により分野横断的なデータ連携を可能にしている [11]。欧州では Elementary Multiperspective Material Ontology (EMMO) が材料モデリングの標準オントロジーとして整備され、OWL 推論に基づく意味的一貫性の保証を提供している [31]。

汎用ドメインでは、Sequeda & Allemang [32] が企業 SQL データベースを知識グラフに変換し、Text-to-SPARQL が Text-to-SQL に比べ正解率を 16% から 54% に向上させることを示した。さらにオントロジーの意味制約を用いたクエリ検証 (OBQC) により 72% まで改善している [33]。

本手法はこれらオントロジーアプローチと構造制約によるクエリ品質保証という目的を共有する。オントロジーの OWL プロパティにおける domain/range 制約は、RDB における FK 関係のテーブル間制約と機能的に対応し、OBQC による SPARQL クエリ検証は、本手法の SQLGuard (カラムホワイトリスト・FK 整合 JOIN 検証) と同等の役割を果たす。ただし、両アプローチの適用文脈は異なる。オントロジーアプローチは RDF トリプルストアへのデータ変換を前提とし、OWL 推論による意味的推移律 (例: 「NiAl は L_{12} 型」 $\rightarrow$ 「NiAl は金属間化合物」) や異種データベース間の相互運用性において優れた表現力を持つ。一方、OQMD [3]・Materials Project [5]・AFLOW [6] 等の大規模材料データベースは既にリレーショナルスキーマで運用されており、本手法はこれらの既存 RDB インフラをそのまま活用する設計を採用している。FK 関係のグラフ走査 (Steiner 木近似) は、オントロジーの推論に依存せずに JOIN パスの正確性を保証する軽量な代替手段を提供する。

両アプローチは排他的ではなく相補的である。将来的には、オントロジーが定義する意味的制約を Schema Graph の走査ヒューリスティックに統合することで、FK 関係だけでなくドメイン知識に基づく JOIN パス選択が可能になると考えられる。

1.5. 目的と新規性

本研究の貢献は以下の 5 点である：

1. L_{12} 型化合物探索に特化した **Schema Graph 制約型 T2SQL** 手法：日英バイリンガル材料用語辞書と FK 関係グラフ走査を組み合わせ、 $L_{12}/\gamma/\text{Cu}_3\text{Au}$ 型等の同義表現正規化を含む正規化材料データベース上の自動 JOIN 経路計算を実現する。Schema Graph 制約によりテーブル幻覚率 **0%** を達成し、LLM-only 手法の幻覚を解消するとともに、不要 JOIN の排除により実行精度 **76.3%** を達成する。
2. **5 手法ベースライン比較による定量評価**：LLM-only、Full Schema、Rule-based、FK-list、Proposed の 5 手法を 100 クエリ (Easy/Medium/Hard/Very Hard、最大 4-hop) で比較し、スキーマ情報の提示方法が SQL 品質に与える影響を体系的に評価する。
3. 多層 **SQL ガード** による安全性保証：キーワードブラックリスト、テーブル/カラムホワイトリスト、JOIN 検証、自動 LIMIT 注入を統合し、不正 SQL の実行を防止する。
4. 材料工学的評価：既知 L_{12} 化合物 11 件の全件再発見 (11/11)、 γ 相候補ランキング、 Ni_3Al 近傍格子定数候補抽出、材料設計仮説の自動生成を達成する。
5. マルチホップクエリ評価：2-4 テーブル JOIN を要する 47 件のマルチホップクエリに対し、Proposed 手法の実行精度と各ベースラインの比較を報告する。

図 1 に本手法の解析フロー全体を示す。

2. 材料 Text-to-SQL の設計要件

材料データベースに対する自然言語インターフェースの本質的課題は、SQL 文の構文生成そのものではなく、正規化された異種材料データを、外部キー関係と材料ドメイン意味論に従って正しく結合することである。汎用 Text-to-SQL システムを材料データベースに直接適用した場合、以下の材料固有の要件が満たされず、重大な精度低下を招く。

1. 正規化組成テーブルの正確な **JOIN**：多元素化合物の各元素が独立行として格納されるため、「Ni と Al を両方含む」検索には SELF-JOIN または INTERSECT が必要となる。汎用 LLM はこのパターンを頻繁に誤る。
2. 材料用語の曖昧性解消：「NiAl」が特定化合物 (B2-NiAl) か含有元素条件かは文脈依存であり、「安定」が $E_{\text{hull}} \leq 0.001 \text{ eV/atom}$ か $\Delta G_f < 0$ かはスキーマ依存である。ドメイン辞書なしではカラムマッピングが不定となる。
3. プロトタイプ・空間群の語彙正規化： L_{12} 、 AuCu_3 型、 Cu_3Au 型は同一プロトタイプを指すが、表記が多様であり、日英バイリンガルでの同義語展開が必要。
4. **FK** に沿った最小 **JOIN** パスの計算：30 テーブル規模のスキーマでは候補 JOIN パスが爆発し、不要テーブルの結合が LLM 精度を低下させる。Steiner 木近似による最小サブグラフ抽出が不可欠。
5. 数値条件の単位・閾値解釈：「バンドギャップが大きい」 $\rightarrow > 1.0 \text{ eV}$ か $> 2.0 \text{ eV}$ か、「安定な」 $\rightarrow E_{\text{hull}} \leq 0.001$ か ≤ 0.1 かは材料ドメイン知識に基づく判断が必要。
6. スコープ外質問の拒否：VASP 計算パラメータの最適化や DFT ワークフローに関する質問は SQL-answerable ではなく、無理に SQL を生成すると無意味な結果を返す。
7. 安全実行の保証：SELECT 以外の SQL (INSERT/UPDATE/DELETE) の排除、無制限結果セットの防止 (自動 LIMIT 注入)、テーブル・カラムホワイトリストによるインジェクション防止。

これらの要件は、汎用 Text-to-SQL ベンチマーク (Spider、WikiSQL 等) では評価対象に含まれない材料データベース固有の課題である。本手法は上記 7 要件すべてに対応する統合フレームワークとして設計された。

3. 手法

本節では各技術要素を詳述する。システム全体のパイプラインアーキテクチャを図 3 に示す。

3.1. 材料データのためのデータベーススキーマ設計

3.1.1. OQMD データの正規化スキーマ設計

OQMD は組成・構造・熱力学的安定性を体系的に格納しており、材料データベースに典型的なスキーマ複雑性 (多対多関係、正規化された組成テーブル、構造パラメータの分離) を備えた好例である。API から取得したフラットな JSON レコードをリレーショナルスキーマに正規化する (表 1)。設計は Boyce-Codd 正規形 (BCNF) に従い、以下の材料ドメイン固有の考慮に基づく。

組成テーブルの分離。単一の化合物が複数の元素を含む場合がある (例: $\text{Fe}_3\text{Al} \rightarrow \text{Fe}$ と Al)。各元素を **composition** テーブルの個別行として格納することで、文字列解析なしに柔軟な元素ベースクエリ (AND, OR, NOT) を可能にする [34]。




Figure 1: 提案手法の解析フロー全体図。自然言語クエリは Intent Classifier でスコープ判定後、用語辞書・数値/化学式パーサーで条件抽出される。Coverage Score に基づき Rule-based（高認識率）または LLM（低認識率）経路に分岐し、いずれも Schema Graph（FK 走査）による JOIN パス制約と SQLGuard 8 層検証を経て安全な SQL が生成・実行される。破線矢印はデータ参照を示す。




Figure 2: Step 3 パイプラインの概要。自然言語クエリから条件抽出（Step 2）を経て、Steiner 木近似（Step 3）が 30 テーブルから必要最小限のサブグラフを抽出する。抽出されたテーブル・カラム・JOIN 条件を YAML で LLM に注入し（Step 4）、8 層 SQLGuard（Step 5）を経て安全な SQLFN を実行する。LLM の視界が必要テーブルに限定されるため、不要 JOIN とテーブル幻覚が原理的に排除される。

Table 1: データベーススキーマ概要。

テーブル名	主キー	外部キー	主要カラム
material_entry	entry_id	—	formula, reduced_formula, chemical_system
composition	composition_id	entry_id	element, atomic_fraction
structure	structure_id	entry_id	prototype, strukturbericht, lattice_a, space_group
phase_stability	stability_id	entry_id	formation_energy_per_atom, energy_above_hull, band_gap
calculation	calculation_id	entry_id	method, functional
calculated_property	property_id	calculation_id	property_name, value, unit
prototype_definition	prototype_id	—	prototype_name, strukturbericht, description

Fig. 1: System Architecture — Schema-Graph-Assisted Text-to-SQL Pipeline




Figure 3: Schema Graph 支援 Text-to-SQL パイプラインのシステムアーキテクチャ。実線矢印は主要データフロー、破線矢印は Few-Shot RAG フィードバックループ（成功したクエリペアが蓄積・検索される）を示す。SQL ガードはデータベース実行前の最終安全層として機能する。

ただし、この正規化は重要な複雑性を導入する：「Ni と Al の両方を含む化合物」のクエリは単純な `WHERE element = 'Ni' AND element = 'Al'` では不可能である（単一行が両条件を同時に満たすことはないため 0 行が返る）。代わりに `EXISTS` 副問い合わせが必要となる（3.3.4 節参照）。なお、この設計により化学式の表記順序（例：Ni₃Al と AlNi₃ は同一化合物だがデータベースによって表記慣例が異なる）に依存しない検索が実現される。元素と原子分率を個別行で格納するため、式全体の文字列比較ではなく元素単位のクエリで同一化合物を一意に特定できる。

構造/相安定性/計算の分離。結晶構造情報（プロトタイプ、格子定数）、熱力学的安定性（hull 上エネルギー）、計算メタデータ（DFT 汎関数）を別テーブルに格納し、独立した更新・拡張を可能にする。

計算物性の *Entity-Attribute-Value* (EAV) パターン。calculated_property テーブルは EAV パターン (property_name, value, unit) を使用し、スキーマ変更なしに任意の計算物性（体積弾性率、せん断弾性率等）を収容する。

ER 設計の汎用性に関する注記。OQMD は内部的にリレーショナルデータベース（Django ORM + PostgreSQL）で運用されているが、本研究では API から取得したフラット JSON データに対し、NetworkX グラフおよび YAML スキーマとして走査しやすい ER 図を新規に設計した。この設計判断により、本手法の適用可能性は以下の二つのシナリオに一般化される：(1) 既存 RDB のスキーマ情報（FK 制約）をそのまま抽出して走査する場合、(2) フラットデータから目的に応じた ER 図を新規構築して走査する場合。いずれの場合も、FK 関係がグラフとして表現可能であれば Schema Graph 走査による JOIN パス最適化が適用可能である。

3.1.2. RAG コンテキスト注入のための XML/YAML 表現

スキーマ構造は YAML (allowed_schema.yaml) としてシリアル化され、二重の目的に供される：(a) SQL ガードのテーブル/カラムホワイトリスト（3.6 節）、(b) LLM プロンプトへの RAG コンテキスト—スキーマ YAML がシステムメッセージに注入され、LLM が利用可能なテーブル・カラム・型を理解する。このアプローチは汎用 T2SQL のスキーマシリアル化技術 [14] と類似するが、材料データベースのドメイン固有カラム意味論（例：energy_above_hull は E_{hull} を表す）に特化している。

3.2. 材料用語辞書を備えた条件抽出器

条件抽出器は、YAML ベースの日英バイリンガル用語辞書 (material_terms.yaml) を用いて、自然言語クエリを構造化された条件辞書に変換する。

3.2.1. 辞書構造

辞書は 4 つのカテゴリを含む：

1. プロトタイプ別名：プロトタイプ名とその変種の対応。
例：B2 $\leftrightarrow$ [B2, CsCl, CsCl 型, B2 型]
L12 $\leftrightarrow$ [L1₂, L12, AuCu₃, Cu₃Au 型, γ']
2. 元素マッピング：元素記号 $\leftrightarrow$ 日英名対応。
例：Fe $\leftrightarrow$ [Fe, 鉄, iron]
3. 安定性用語：自然言語 $\rightarrow$ 数値閾値。
「安定」/ “stable” $\rightarrow$ energy_above_hull ≤ 0.001 eV/atom
「準安定」/ “metastable” $\rightarrow$ energy_above_hull ≤ 0.05 eV/atom
4. 物性用語：物性記述からテーブル・カラム参照への対応。
「格子定数」/ “lattice constant” $\rightarrow$ structure.lattice_a
「形成エネルギー」/ “formation energy” $\rightarrow$ phase_stability.formation_energy_per_atom

3.2.2. Unicode 正規化とパターンマッチング

Unicode 下付き文字 (𐀀𐀁𐀂𐀃𐀄𐀅𐀆𐀇𐀈𐀉) はマッチング前に ASCII 数字に正規化される。元素記号認識はワード境界正規表現を使用し、独立した「Fe」を「FeCoNi」部分文字列から正しく区別する。

3.2.3. 出力形式

抽出器は構造化辞書を返す：

Listing 1: 条件抽出の例。

```

1 # 入力: "Feを含む安定なB2化合物を出して"
2 # 出力:
3 {
4   "prototype": "B2",
5   "contains_elements": ["Fe"],
6   "stability": "stable",
7   "sort_by": None,
8   "sort_order": None
9 }
```

3.2.4. 数値条件パーサー

条件抽出器は、自然言語中の数値比較表現を構造化された WHERE 句条件に変換する正規表現ベースの数値条件パーサーを含む。対応する 5 種類のパターンを表 2 に示す。

Table 2: 数値条件パーサーの対応パターン。

パターン種別	入力例	出力
記号比較	band_gap > 1.0 eV	WHERE band_gap > 1.0
日本語後置	形成エネルギーが 0.5 以上	WHERE ... >= 0.5
日本語より	格子定数が 3.0 より大きい	WHERE lattice_a > 3.0
符号判定	形成エネルギーが負	WHERE ... < 0
範囲指定	band gap 0.5–2.0 eV	WHERE ... BETWEEN 0.5 AND 2.0

物性名から対応カラムへのマッピングは内部辞書 (_PROPERTY_COLUMN_MAP) により管理され、「格子

定数」→ `structure.lattice_a`、「形成エネルギー」→ `phase_stability.formation_energy_per_atom` 等の変換を行う。単位変換 (eV, Å, GPa 等) も内蔵するが、現スキーマでは OQMD の内部単位がそのまま格納されているため、変換係数は全て 1.0 である。

3.2.5. 化学式パーサーと曖昧性処理

化学式パーサーは、クエリ中の化学式トークン (例: Ni3Al, NiAl, Fe2CoAl) を検出し、以下の 3 種類の解釈に分類する:

- **exact_formula**: 化学量論比が明示された場合 (例: Ni3Al → `formula = 'Ni3Al'`)。組成テーブルの化学式カラムとの完全一致検索を生成する。
- **formula_or_reduced_formula**: 化学量論比が省略されているが、化学式単体として使用されている場合 (例: 「NiAl の B2 エントリ」→ `reduced_formula = 'AlNi'`)。reduced_formula カラムとの一致検索を優先的に生成する。

- **contains_elements**: 「X を含む」「X と Y を含む化合物」等の包含表現で使用されている場合 (例: 「Ni と Al を含む」→ 元素 Ni **AND** 元素 Al)。組成テーブルに対する EXISTS 副問い合わせ (多元素 AND) を生成する。

判定は文脈依存である: 化学式トークンが単独でプロトタイプ名 (B2, L1₂ 等) や「エントリ」「物性」と共起する場合は `formula_or_reduced_formula` を優先し、「含む」「both」「contains」等の包含表現と共起する場合は `contains_elements` として処理する。この文脈依存判定は、材料研究者が「NiAl」と言ったとき多くの場合 B2-NiAl という特定化合物を意味する一方、「Ni と Al を含む化合物」は包含検索を意図するというドメイン知識に基づく設計判断である。

3.2.6. Coverage Score: 未認識語彙検出

Coverage Score は、自然言語クエリに含まれる意味的トークンのうち、用語辞書・元素辞書・数値パターンで認識された割合を $[0, 1]$ で定量化する。この指標は、Silent Constraint Dropping (未登録語彙の無通知破棄) を防止するために導入された。

算出手順:

1. クエリを正規表現でトークン化し、ストップワード (助詞、接尾辞等) を除去
2. 各トークンを辞書エイリアス (プロトタイプ、元素、物性、安定性) と照合
3. 元素記号の既知/未知を判定 (辞書登録済みか否か)
4. Coverage = 認識トークン数 / 全意味トークン数

Coverage Score に基づき、システムは 3 段階のアクションに分岐する:

- ≥ 0.8 (かつ未知元素なし) → `execute_rule_based`: Rule-based モードで安全に実行
- ≥ 0.5 (または未知元素あり) → `fallback_to_llm`: LLM モードにエスカレーション
- < 0.5 → `clarification_required`: ユーザーに明確化を要求

この仕組みにより、「Xe を含む化合物」のようなクエリで Xe (キセノン) が辞書未登録の場合、Coverage Score が低下し、条件を無視して SQL 生成するのではなく、LLM フォールバックまたは明確化要求が発生する。

3.2.7. Intent Classifier: スコープ外質問の事前排除

評価実験において、LLM が VASP ワークフロー質問に対して SQL を生成してしまう問題が判明した (out-of-scope 正解率 0%)。この問題に対処するため、SQL 生成パイプラインの前段にルールベースの Intent Classifier を導入した。

Intent Classifier は以下の 5 カテゴリにクエリを分類する:

1. **db_query**: 材料データベースで回答可能
2. **out_of_scope**: VASP/DFT ワークフロー、計算手法、一般知識
3. **ambiguous**: 明確化が必要
4. **unsafe**: SQL インジェクション等の不正意図
5. **greeting**: 挨拶・雑談

分類アルゴリズムは、20 個の VASP/DFT ワークフローパターン (INCAR, KPOINTS, POTCAR 等のファイル名、SCF 収束、ENCUT 等のパラメータ名、フォノン計算、Wannier90、Bader 解析等) と 9 個の DB 特化パターン (化合物検索、安定性フィルタ、物性条件等) の正規表現マッチング数を比較する。VASP パターンのみが検出された場合は `out_of_scope` として拒否し、DB パターンが優勢な場合は `db_query` としてパイプラインに通過させる。

3.3. Schema Graph 走査エンジン

本手法の中核的アルゴリズム貢献である。このエンジンはデータベーススキーマをグラフとして表現し、最適な JOIN 経路を自動計算する。

3.3.1. PostgreSQL メタデータからのグラフ構築

外部キー関係は PostgreSQL の `information_schema` から動的に抽出される:

Listing 2: FK 関係抽出クエリ。

```
SELECT tc.table_name AS source_table,
       kcu.column_name AS source_column,
       ccu.table_name AS target_table,
       ccu.column_name AS target_column
FROM   information_schema.table_constraints tc
JOIN   information_schema.key_column_usage kcu
      ON tc.constraint_name = kcu.constraint_name
JOIN   information_schema.constraint_column_usage
      ON ccu.constraint_name = tc.constraint_name
WHERE  tc.constraint_type = 'FOREIGN KEY'
AND    tc.table_schema = 'public';
```

結果は NetworkX [35] の無向グラフ $G = (V, E)$ として格納される。ここで $V = \{\text{テーブル名}\}$ 、 $E = \{\text{FK 関係}\}$ である。FK メタデータは実行時に読み取られるため、コード変更なしにスキーマ変更に対応する。

3.3.2. 最小被覆 JOIN 経路: Steiner 木近似

条件抽出器の出力から決定された必要テーブル集合 $R \subseteq V$ に対し、 R のすべてのテーブルを接続する G の最小部分グラフが必要となる。これはグラフにおける Steiner 木問題 [36] であり、一般に NP 困難である。

30 テーブル規模のスキーマグラフに対し、木構造グラフでは厳密解を与える貪欲ヒューリスティック (アルゴリズム 1) を採用する:

Algorithm 1 最小被覆 JOIN 部分グラフ (Steiner 木近似)。

Require: FK 関係グラフ $G = (V, E)$ 、必要テーブル集合 R

Ensure: JOIN 経路リスト P

```
1:  $P \leftarrow \emptyset$ , covered  $\leftarrow \emptyset$ 
2: for all  $(s, t) \in \binom{R}{2}$  do
3:   if  $s \in \text{covered} \wedge t \in \text{covered}$  then
4:     continue ▷ 両端点は既に接続済み
5:   end if
6:    $p \leftarrow \text{ShortestPath}(G, s, t)$  ▷ FK グラフ上の BFS
7:   if  $p \neq \emptyset$  then
8:      $P \leftarrow P \cup \{p\}$ 
9:     covered  $\leftarrow \text{covered} \cup \text{nodes}(p)$ 
10:  end if
11: end for
12: for all  $r \in R \setminus \text{covered}$  do ▷ 孤立必要テーブルの処理
13:    $c \leftarrow \text{covered}$  の最近傍ノード
14:    $P \leftarrow P \cup \{\text{ShortestPath}(G, r, c)\}$ 
15: end for
16: return  $P$ 
```

計算量. $|V| = n$ ノード、 $|R| = k$ 必要テーブルのグラフに対し、アルゴリズムは $O(k^2)$ 回の最短路計算を行い、各計算は $O(n + |E|)$ (BFS) である。30 テーブル規模 ($n = 30$, $k \leq 5$) でもミリ秒オーダーで完了する。

木構造 FK グラフでの正確性. G が木 (本スキーマでは material_entry がハブ) の場合、Steiner 木は一意であり、貪欲アルゴリズムはこれを厳密に求める。FK サイクルを持つスキーマ (自己参照テーブル等) では近似が不要な辺を含む可能性があるが、SQL 生成においては DISTINCT を適用すれば正確性に影響しない。

3.3.3. JOIN 経路 $\rightarrow$ SQL FROM/JOIN 句生成

P の各経路は SQL JOIN 句に変換される。FK メタデータが結合カラム名を提供する：

Listing 3: 経路からの JOIN 句生成。

```
# 経路: [material_entry, structure]
# FK: structure.entry_id -> material_entry.entry_id
# 生成:
# FROM material_entry m
# JOIN structure s ON s.entry_id = m.entry_id
```

テーブル別名はテーブル名の先頭文字から自動割当される (衝突時は解決処理あり)。

3.3.4. 多元素 AND クエリ: EXISTS 副問い合わせパターン

組成テーブル正規化に起因する材料固有の重要課題が存在する。「Ni と Al の両方を含む化合物」のクエリには以下が必要：

Listing 4: EXISTS 副問い合わせによる多元素 AND クエリ。

```
1 SELECT DISTINCT m.entry_id, m.formula
2 FROM material_entry m
3 WHERE EXISTS (
4   SELECT 1 FROM composition
5   WHERE entry_id = m.entry_id AND element = 'Ni')
```

```
6 AND EXISTS (
7   SELECT 1 FROM composition
8   WHERE entry_id = m.entry_id AND element = 'Al')
9 LIMIT 10000;
```

Schema Graph エンジンでは複数元素が指定された場合を検出し、直接 JOIN の代わりに EXISTS 副問い合わせを自動生成する。このパターンなし (Naive アプローチ) では、WHERE c.element = 'Ni' AND c.element = 'Al' は単一組成行が両条件を同時に満たすことが不可能なため常に 0 行を返す。これが Schema Graph 手法により防止される最も重要な故障モードである。

3.3.5. 比較: Naive vs. Schema Graph (具体例)

表 3 に「Fe を含む B2 化合物を出して」に対する差異を示す：

Table 3: SQL 生成比較: 「Fe を含む B2 化合物」に対する Naive vs. Schema Graph。

観点	Naive (Level 0)	Schema Graph (Level 1)
JOIN テーブル	常に全テーブル	必要テーブルのみ
JOIN 数	全テーブル分	最小限
DISTINCT	なし $\rightarrow$ 重複行	あり
LIMIT	なし $\rightarrow$ 無制限	あり (10,000)
安全性検証	なし	完全 (キーワード + テーブル WL)
多元素 AND	不正 (0 行)	正確 (EXISTS)

3.4. SQL 生成: Rule-based モードと LLM モード

システムは 2 つの SQL 生成モードをサポートし、いずれも Schema Graph 制約内で動作する。

3.4.1. Rule-based モード (Level 1)

決定論的テンプレートベース生成器が、抽出された条件と Schema Graph JOIN 経路から SQL を構築する。外部 API は不要で、レイテンシは 32–60 ms (5.3.1 節)。

改訂版での拡張. 前稿の Rule-based モードでは数値比較 WHERE 句の生成が不可であったが、改訂版では数値条件パーサー (3.2.4 節) および化学式パーサー (3.2.5 節) を統合し、band_gap > 1.0、formation_energy < 0、Ni3Al (完全一致) 等の条件を Rule-based モード内で処理可能とした。

残存する制限. 以下のクエリ種別は Rule-based モードでは処理できず、Coverage Score (3.2.6 節) または Intent Classifier (3.2.7 節) により自動的に LLM フォールバック、明確化要求、またはスコープ外拒否に分岐する：

- 否定条件 (「Fe を含まない化合物」)
- 辞書未登録語彙を含む自由記述クエリ
- VASP/DFT ワークフロー質問 (Intent Classifier が検出・拒否)
- 複雑な集約 (GROUP BY + HAVING 等)

3.4.2. Few-Shot RAG を備えた LLM モード (Level 2)

Rule-based モードの辞書カバレッジが不十分な場合 (未登録元素、数値条件、複雑な表現など)、LLM ベース生成にフォールバックする。LLM (本実験では gpt-5.5、API 設定の詳細は Supplementary S7 節を参照) は以下の構造化プロンプトを受け取る:

1. システムメッセージ: タスク説明 + スキーマ YAML (テーブル名、カラム名、型、FK 関係)
2. **Few-Shot** 事例: RAG ストアからの Top- k 類似 NL-SQL ペア (3.5 節)
3. ユーザーメッセージ: 自然言語クエリ
4. 制約: 「SELECT 文のみ生成」「LIMIT 10000 を含める」「スキーマに記載されたテーブルのみ使用」

生成された SQL は実行前に SQL ガード (3.6 節) で検証される。

3.5. Few-Shot RAG ストア (SQL-as-Few-Shot-Examples)

3.5.1. アーキテクチャ

Few-Shot ストアは T2SQL に特化した RAG [37] パターンを実装する。GPT-3 [38] 以降、少数事例の文脈内提示による task-agnostic な精度向上が広く知られており、本システムではドメイン特化事例の動的検索によりこれを材料 T2SQL に適用する:

1. 蓄積: クエリが正常に結果を返した場合、(NL クエリ、SQL、条件、行数、ソース) タプルを JSON ストアに追加する。
2. 検索: 新規クエリに対し、全蓄積 NL クエリとの TF-IDF [39] コサイン類似度を計算し、上位 k 件 (デフォルト $k = 3$) を返す。
3. 注入: 検索された事例を「Question: ... SQL: ...」ブロックとしてフォーマットし、LLM プロンプトの先頭に配置する。

3.5.2. 材料クエリのための TF-IDF トークナイゼーション

標準 NLP トークナイザは化学式や元素記号を不正確に分割するため、材料クエリには不適切である。本トークナイザは複合正規表現パターンを使用する:

Listing 5: 材料クエリ用 TF-IDF トークナイザ。

```
# トークナイゼーションパターン:
# 1. 化学記号: [A-Z][a-z]? (Fe, Ni, Al, ...)
# 2. 日本語文字: [\u3040-\u9fff]+
# 3. 英単語: [a-z]+
# 4. 数字: \d+
tokens = re.findall(
    r'[A-Z][a-z]?|[\u3040-\u9fff]+|[a-z]+|\d+',
    query.lower()
)
```

IDF は $IDF(t) = \log(N/n_t)$ で計算される。ここで N は蓄積事例総数、 n_t は語 t を含む事例数である。クエリと蓄積事例の TF-IDF ベクトル間のコサイン類似度によりランキングされる。

3.5.3. 研究論文からの種事例抽出

手動キュレーションなしに Few-Shot ストアをブートストラップするため、LaTeX 原稿からの自動種事例抽出を実装した。抽出器は以下のパターンを走査する:

- B2 型パターン: B2[-\s]type + 化学式 $\rightarrow$ {prototype: B2, elements: 抽出}
- L1₂ 型パターン: L1_2 / L12 + 化学式 $\rightarrow$ {prototype: L1₂, elements: 抽出}
- 100 文字以内のコンテキストキーワード: “lattice”, “stable”, “formation energy”

抽出された各化合物言及に対し、正規 NL クエリと対応 SQL が生成される。本実験では hea_lattice_prediction.tex から 4 件の種事例が自動抽出され、手動キュレーション 7 件と合わせて合計 11 件となった (表 4)。

Table 4: Few-Shot ストア構成 (11 事例)。

ソース	件数	比率	クエリ例
手動キュレーション	7	64%	Fe を含む B2 化合物を出して
論文抽出	4	36%	B2 FeAl の物性を出して

3.6. SQL ガード: 多層安全性検証

本手法は CRUD 操作のうち参照系 (Read) のみを対象とし、生成 SQL は SELECT 文に限定される。Rule-based モード・LLM モードを問わず、生成された全 SQL はデータベース実行前に 8 層検証パイプラインを通過する。前稿の 5 層構成に対し、カラムホワイトリスト検証 (層 6)、FK 整合 JOIN 検証 (層 7)、ガード判定分類 (層 8) を追加した。

3.6.1. 基本安全性検証 (層 1-5)

1. 複数文検出: SQL 本体内にセミコロンがあれば拒否 (SELECT ...; DROP TABLE ... 等のピギーバック攻撃を防止)。
2. 禁止キーワード検出: INSERT, UPDATE, DELETE, DROP, ALTER, TRUNCATE, CREATE, GRANT, REVOKE, COPY をワード境界正規表現で走査。
3. **SELECT** 専用制約: SELECT または WITH で始まらない文を拒否。
4. テーブルホワイトリスト検証: FROM/JOIN 句の全テーブル名を抽出し、allowed_schema.yaml に存在するか検証。未宣言テーブル (例: secret_passwords) 参照クエリは拒否。
5. 自動 **LIMIT** 注入: LIMIT 句がなければ LIMIT 10000 を付加し、無制限結果セットによる過剰メモリ・計算消費を防止。

3.6.2. カラムホワイトリスト検証 (層 6)

SELECT 句、WHERE 句、ORDER BY 句で参照される全カラム名を抽出し、allowed_schema.yaml のカラム定義と照合する。スキーマに存在しないカラム (例: LLM が幻覚生成した melting_point) を参照する SQL は実行前に拒否される。これにより、LLM モードにおけるスキーマ幻覚 (hallucinated schema) を防止する。

3.6.3. FK 整合 JOIN 検証 (層 7)

FROM/JOIN 句のテーブル結合条件が、PostgreSQL メタデータから取得した FK 関係と整合するかを検証する。Schema Graph 走査 (3.3 節) が生成した JOIN 経路と実際の SQL 内の JOIN 条件を比較し、以下を検出する:

- FK 関係に基づかない不正 JOIN 条件（例：ON a.id = b.name）
- Schema Graph 経路に含まれないテーブル間の JOIN（不要 JOIN）
- JOIN 条件の欠落（Cartesian product リスク）

3.6.4. ガード判定分類（層 8）

8 層検証の結果に基づき、生成 SQL を以下の 4 カテゴリに分類する：

1. **SAFE**：全層パス。実行可能。
2. **MODIFIED**：自動修正適用（LIMIT 注入等）。修正後実行可能。
3. **BLOCKED**：安全性違反により実行拒否。ユーザーに理由を通知。
4. **WARNING**：軽微な逸脱（カラム幻覚疑い等）。実行するが警告付き。
オプションで SQLGlot [40] が AST（抽象構文木）レベルの構文検証を行う。

3.7. 推奨運用構成：カスケードモード

各生成モードの特性に基づき、以下のカスケード戦略を推奨する：

1. **Intent 分類**：Intent Classifier（3.2.7 節）がクエリを db_query / out_of_scope / unsafe / greeting に分類。db_query 以外は即座に拒否または適切な応答を返す。
2. **条件抽出 + Coverage Score**：条件抽出器（3.2 節）がクエリを解析し、Coverage Score（3.2.6 節）で辞書カバレッジを判定。
3. **Rule-based 生成（Coverage ≥ 0.8 ）**：テンプレートベース SQL 生成（Level 1、32–60 ms）。
4. **LLM フォールバック（Coverage < 0.8 ）**：Schema Graph 制約付き LLM 生成にエスカレーション（Level 2、2.4–6.1 秒）。
5. **明確化要求（Coverage < 0.5 ）**：ユーザーに追加情報を要求。
6. **SQL ガード**：生成モードによらず 8 層検証（3.6 節）を常に適用。

このアプローチは、辞書がカバーするクエリを外部 API 依存なしに処理し、複雑または新規なクエリにのみ LLM 呼び出しを使用する。

4. データ準備

4.1. 検証データベースとしての $L1_2$ 型金属間化合物

本研究では、複数プロトタイプを含む検証データベースを構築した。 $L1_2$ 型（ Cu_3Au 型、Strukturbericht 記号 $L1_2$ ）は A_3B 組成を持つ規則化 FCC 構造であり、Ni 基超合金の γ' 析出相として不可欠な構造型である。

データベースには 5 プロトタイプ 1,471 件を格納した（表 5）。

$L1_2$ エントリは A_3B 型組成（ $\text{A}=\text{Ni}, \text{Co}, \text{Cu}, \text{Fe}, \text{Pt}, \text{Pd}, \text{Ir}, \text{Rh}, \text{Al}$ 等、 $\text{B}=\text{Al}, \text{Ti}, \text{Sc}, \text{Ga}, \text{Ge}, \text{Nb}, \text{Ta}, \text{Si}, \text{Sn}, \text{Mn}, \text{Hf}, \text{V}, \text{W}$ 等）を持ち、既知の $L1_2$ 化合物 11 件を含む：

- 既知 $L1_2$ 化合物（11 件）： Ni_3Al 、 Ni_3Ga 、 Ni_3Ge 、 Co_3Ti 、 Co_3Ta 、 Co_3Al 、 Al_3Sc 、 Al_3Ti 、 Pt_3Al 、 Fe_3Pt 、 Ir_3Nb 。

Table 5: 検証データベースの構成（全体 1,471 件）。

プロトタイプ	件数	備考
$L1_2$ （ Cu_3Au 型）	393	既知 $L1_2$ 11 件含む
B2（ CsCl 型）	636	—
NaCl	355	—
NiAs	74	—
BiF_3	13	—
合計	1,471	

各エントリについて、化学式、格子定数 a 、空間群、原子当たり形成エネルギー E_f 、hull 上エネルギー E_{hull} 、バルクモジュラス B 、剪断弾性率 G を格納した。

4.2. ER 設計の根拠：フラットデータから正規化 RDB へ

$L1_2$ 型化合物の各エントリは、化学式・プロトタイプ・格子定数・形成エネルギー・hull 上エネルギー・弾性特性等を含むフラットなレコードである。このフラットデータをそのまま単一テーブルに格納することも可能だが、材料データの論理構造に基づき、以下の設計判断で正規化した。

設計判断 1：組成テーブルの分離（1:N 正規化）。最も重要な設計判断は、composition テーブルの分離である。化合物と構成元素の関係は 1:N（例： Ni_3Al は Ni 行と Al 行の 2 レコード）であり、これをフラットテーブルの 1 カラムに格納すると「Ni と Al を両方含む化合物」のような多元素 AND 検索が不可能になる。正規化により、composition テーブルの自己結合（SELF JOIN）で任意の元素組み合わせ検索が実現される。Graph Traversal アブレーション（?? 節）で示したとおり、この自己結合を含む JOIN パスの正確な算出が Schema Graph 走査の主要な貢献である。

設計判断 2：構造・安定性・計算条件の分離。同一化合物に対して複数の結晶構造（多形）や異なる計算条件が存在しうるため、structure（プロトタイプ、空間群、格子定数）、phase_stability（形成エネルギー、 E_{hull} 、バンドギャップ）、calculation（DFT 計算条件）を独立テーブルとした。これにより「安定な（ $E_{\text{hull}} \leq 0.001$ ） $L1_2$ 構造のうち格子定数が $3.5 \text{ \AA}$ 以上」のような、構造と安定性を跨ぐ複合条件が FK 整合 JOIN で正確に検索できる。

設計判断 3：計算と物性の親子関係。1 つの DFT 計算から複数の物性値（体積弾性率、剪断弾性率等）が出力されるため、calculation $\rightarrow$ properties（1:N）の親子関係とした。物性名・値・単位を行として格納する EAV（Entity-Attribute-Value）パターンにより、新しい物性を追加する際にスキーマ変更が不要である。

設計判断 4：プロトタイプ定義のマスタ化。prototype_definition テーブルに B2、 $L1_2$ 、A15 等のプロトタイプ名・Strukturbericht 記号・結晶型の対応を格納し、structure テーブルから参照する。これにより「 $L1_2$ 」「 Cu_3Au 型」「 AuCu_3 型」等の同義表現を一元的に管理できる。

正規化が *Schema Graph* 走査を必要にする。上記の正規化設計により、単純な検索でも 2-4 テーブルの JOIN が必要となる。この正規化の代償としての **JOIN** 複雑性こそが、FK 関係をグラフとして表現し最短 JOIN パスを自動算出する *Schema Graph* 走査エンジンの存在意義である。

4.3. データ投入と変換

各 $L1_2$ エントリを CSV から正規化スキーマに分解して投入する。例えば、 Ni_3Al ($L1_2$ プロトタイプ) は以下を生成する: **material_entry** に 1 行、**composition** に 2 行 (Ni: 0.75, Al: 0.25)、**structure** に 1 行 (prototype= $L1_2$, lattice_a=3.572, space_group=Pm-3m)、**phase_stability** に 1 行 (formation_energy=-0.42, energy_above_hull=0.0)、**calculation** に 1 行 (method=GGA-PBE)、**calculated_property** にバルクモジュラス (180 GPa)、剪断弾性率 (78 GPa) の 2 行。プロトタイプ別の seed CSV ファイルから ingestion/load_seed_data.py により自動投入される。

5. 結果

5.1. 評価設計

5.1.1. 評価データセット (100 クエリ)

$L1_2$ 型化合物探索に特化した 100 件の自然言語クエリを、4 段階の難易度に分けて設計した (表 6)。

Table 6: 評価クエリ設計 (全 100 件)。

難易度	件数	代表的クエリ内容
Easy	20	単一元素・プロトタイプ条件
Medium	30	構造+組成+安定性の横断
Hard	30	3-hop 以上の JOIN
Very Hard	20	材料設計条件を含む複合クエリ

各クエリには gold SQL、期待結果セット (JSON)、必要テーブル・カラム・JOIN 経路を紐付けた。マルチホップクエリ (2-hop 以上) は 84 件を占め、うち 3-hop 24 件、4-hop 23 件を含む。

5.1.2. 比較手法 (5 手法)

スキーマ情報の提示方法が SQL 品質に与える影響を評価するため、以下の 5 手法を比較した (表 7)。LLM には gpt-5.5 を使用した。

5.1.3. 評価指標

以下の指標で各手法を評価する:

- 構文妥当率 (Syntax validity): SQL パーサーを通る割合。LIMIT の影響を受けない。
- 実行成功率 (Execution validity): PostgreSQL でエラーなく実行できる割合。LIMIT の影響を受けない。
- 実行精度 (Execution accuracy): 返された結果セットが gold 結果と一致する割合。
- テーブル幻覚率 (Hallucinated table rate): 存在しないテーブルを使った割合。LIMIT の影響を受けない。
- JOIN 幻覚率 (Hallucinated JOIN rate): 許可されていない JOIN を使った割合。

- マルチホップ成功率 (Multi-hop success rate): 2-hop 以上クエリの正解割合。

5.1.4. 評価指標の改善: 共通カラム照合と LIMIT 正規化

初期実験では実行精度が低く留まったため、要因分析を行い、評価指標に以下の 2 つの改善を導入した。

改善 A: 共通カラム照合 (*Column-aware matching*)。SQL 生成において、LLM は gold SQL と異なる SELECT 列を出力することがある。例えば gold が entry_id, formula の 2 列を返すのに対し、生成 SQL が entry_id, formula, lattice_a, space_group の 4 列を返す場合、従来のテーブル完全一致では同じ行でも不一致と判定される。共通カラム照合では、gold と生成の両方に存在するカラム名のみで行マッチングを行う:

$$\text{accuracy}(q) = \frac{|R_{\text{gen}}^C \cap R_{\text{gold}}^C|}{|R_{\text{gold}}^C|} \quad (1)$$

ここで $C = \text{cols}(R_{\text{gen}}) \cap \text{cols}(R_{\text{gold}})$ は共通カラム集合、 R^C は列集合 C への射影である。この集合照合は Jaccard 係数 [41] に類似するが、分母を gold 側に限定した再現率ベースの指標である。

改善 C: LIMIT 10,000 正規化。SQLGuard が自動付加する LIMIT の値が gold SQL と生成 SQL で異なる場合、行数の差異により精度が過小評価される。本研究では、gold SQL と生成 SQL の両方に LIMIT 10,000 を統一的に適用する。DB 規模 1,471 件に対して実質的に制限なしと同等でありかつ、暴走クエリ防止の安全弁としての役割を果たす。

改善効果: 表 8 に評価指標改善の効果を示す。

改善 A により +45.3 ポイント、改善 C によりさらに +22.6 ポイントの精度向上が得られた。以降の結果はすべて A+C 適用後の値を報告する。

5.1.5. 回帰テスト (80 件)

開発安全性テストとして、正常系 (15 件)、該当なし (5 件)、曖昧入力 (10 件)、矛盾条件 (2 件)、SQL インジェクション (5 件)、安全性検査 (2 件)、SQL 検証 (6 件)、Coverage・パーサー (15 件)、Intent Classifier (20 件) の計 80 件を構築した。全 80 件が PASS を達成した。テストカテゴリの詳細および全テストケース一覧は Supplementary S1-S2 節に掲載する。

5.2. 5 手法ベースライン比較

表 9 に 5 手法の比較結果を示す (gpt-5.5 使用、100 クエリ、評価指標 A+C 適用)。

主要な発見。

- LLM-only (B1)** は実行成功率 **0%**: スキーマ情報なしでは LLM が存在しないテーブル名を幻覚し、生成された SQL は一切実行できない。
- Proposed (P)** はテーブル幻覚率 **0%**かつ実行精度 **76.3%**: *Schema Graph* 走査により LLM の視界を必要テーブルに限定し、不要 JOIN の排除とテーブル幻覚の防止を同時に達成する。Medium 難易度では 89.2%、Easy では 82.4% に達する。

Table 7: 比較手法の構成（全手法共通：100 クエリ）。

ID	手法名	構成
B1	LLM-only	LLM のみ。スキーマ情報なし
B2	Full Schema	LLM + 全スキーマ（テーブル・カラム一覧）をプロンプトに注入
B3	Rule-based	LLM なし。辞書ベース条件抽出 + テンプレート SQL 生成
B4	FK-list	LLM + 外部キー一覧のみをプロンプトに注入
P	Proposed	エンティティ抽出 + Schema Linking + Schema Graph 走査 + 制約付き LLM

Table 8: Proposed 手法における評価指標改善の効果。

評価条件	平均実行精度	改善幅
従来指標（タプル完全一致, LIMIT 100）	8.4%	—
+A（共通カラム照合）	53.7%	+45.3p
+A+C（+LIMIT 10,000 正規化）	76.3%	+22.6p

マルチホップの傾向。JOIN が深くなるほど精度が低下する傾向がある（2-hop 84.4% → 4-hop 68.8%）。ただし、Full Schema や LLM-only と比較すると、どのホップ数でも Proposed が大幅に優位である。Schema Graph が JOIN 経路の正確性を保証し、LLM が WHERE 句を生成する役割分担が機能している。

- Rule-based (B3)** は LLM なしで実行精度 **58.5%**：辞書カバー範囲内では LLM 呼び出しが不要だが、テンプレートの柔軟性が制約となり精度は Proposed に劣る。
- Full Schema (B2)** は不要 JOIN が多く精度 **21.0%**：全スキーマ提示では不要な JOIN が発生し、実行コストと精度の両面で劣化する。
- FK-list (B4)** は実行成功率 **4%**：FK 情報のみの提示では JOIN 経路を正しく構成できない。

5.5. エラー分析

各手法の主要な失敗モードを表 13 に示す。

失敗モードの分類。

B1: テーブル幻覚が支配的 LLM-only では 100 件中 100 件でテーブル名を幻覚する。materials、compounds 等の汎用名を生成し、実在の material_entry、phase_stability を推測できない。

B4: FK 情報だけでは不十分 FK 一覧の提示では 89 件が実行失敗。テーブル間関係は伝わるが、カラム名・型・テーブル構造が不足するため、SELECT 句や WHERE 句の生成に失敗する。

P: 高難度での **WHERE** 句複雑性 Proposed 手法の失敗は主に Very Hard/Hard 難度に集中。Schema Graph 制約が提供する JOIN 経路は正しいが、LLM が複合 WHERE 句の条件組合せを正確に生成できないケースが残る。

5.3. 難易度別の詳細分析

表 10 に難易度別の Proposed 手法の実行成功率・実行精度を示す。

難易度別の傾向。

- Easy (20 件)**: 実行精度 82.4%。単一テーブル参照や単純な WHERE 条件のクエリでは Schema Graph 制約が有効に機能する。
- Medium (30 件)**: 89.2% で全難易度中最高。構造・組成・安定性の横断クエリでも Steiner 木近似による JOIN 経路制約が有効に機能する。
- Hard (30 件)**: 77.1%。3-hop JOIN では WHERE 句の条件組合せが複雑化する。
- Very Hard (20 件)**: 50.0%。4-hop JOIN・複合条件では LLM の WHERE 句生成が主なボトルネック。

5.3.1. レイテンシ比較

表 11 に手法別の平均レイテンシを示す。Rule-based (B3) は LLM API を呼び出さないため 17.6 ms で最速である。LLM ベース手法は API 呼び出し時間が支配的であり、Proposed 手法は平均 2,557 ms (Rule-based の 145 倍) である。

5.4. マルチホップクエリ分析

表 12 にホップ数別の精度比較を示す。評価クエリ 100 件中、2-hop 37 件、3-hop 24 件、4-hop 23 件がマルチホップクエリに分類される。

5.6. SQL インジェクションと安全性結果

7 件の敵対的入力 (E01–E05: DROP/DELETE/INSERT 等、F01–F02: 直接 SQL 入力) はすべて SQL ガードにより遮断された。遮断理由は禁止キーワード検出、複数文検出、非許可テーブル検出、自動 LIMIT 注入の各層に分布する。詳細なテスト結果は Supplementary S4 節に掲載する。

5.7. 材料工学的評価

L1₂ 型金属間化合物の材料工学的観点からシステムの有用性を評価する。

5.7.1. 既知 L1₂ 化合物の再発見

表 14 に既知 L1₂ 化合物 11 件の再発見結果を示す。Proposed 手法による探索で全 11 件を正しく再発見した。

5.7.2. γ' 相候補ランキング

安定性 (E_{hull})、格子整合性 ($|a - a_{\text{Ni}_3\text{Al}}|$)、バルクモジュラス B の 3 指標による重み付き複合スコアで γ' 相候補をランキングした (表 15)。

$$S = w_1 \cdot S_{\text{stability}} + w_2 \cdot S_{\text{lattice}} + w_3 \cdot S_{\text{bulk}} \quad (2)$$

ここで $w_1 = w_2 = w_3 = 1/3$ 、各スコアは 0–1 に正規化。

Table 9: 5 手法のベースライン比較 (100 クエリ、gpt-5.5、共通カラム照合+LIMIT 10,000)。

ID	手法	構文 妥当率	実行 成功率	平均 実行精度	テーブル 幻覚率	不要 JOIN
B1	LLM-only	100%	0%	0%	9%	—
B2	Full Schema	100%	23%	21.0%	0%	多い
B3	Rule-based	100%	98%	58.5%	0%	なし
B4	FK-list	100%	4%	4.0%	0%	—
P	Proposed	100%	96%	76.3%	0%	最小

Table 10: 難易度別の実行成功率と実行精度 (Proposed 手法)。

難易度	件数	JOIN ホップ数	実行成功率	実行精度
Easy	20	1-hop	95%	82.4%
Medium	30	2-hop	100%	89.2%
Hard	30	3-hop	93%	77.1%
Very Hard	20	4-hop	95%	50.0%

Table 11: 手法別レイテンシ比較 (gpt-5.5)。

ID	手法	平均 Latency (ms)	平均 Token 数
B1	LLM-only	1,330	115
B2	Full Schema	2,455	587
B3	Rule-based	18	0
B4	FK-list	2,231	246
P	Proposed	2,557	955

Table 12: ホップ数別の実行精度比較 (2-hop 以上)。

ホップ数	件数	Proposed 精度	Full Schema 精度
2-hop	37	84.4%	21.6%
3-hop	24	70.1%	0%
4-hop	23	68.8%	4.3%

Table 13: 手法別エラー分析 (100 クエリ)。

ID	手法	実行 失敗	構文 エラー	テーブル 幻覚	JOIN 幻覚
B1	LLM-only	100	1	100	4
B2	Full Schema	0	0	2	25
B3	Rule-based	2	0	0	94
B4	FK-list	89	2	2	81
P	Proposed	18	0	0	97

Table 14: 既知 L1₂ 化合物の再発見結果 (11/11)。

化合物	a (Å)	E_{hull} (eV/atom)	再発見
Ni ₃ Al	3.572	0.000	○
Ni ₃ Ga	3.58	0.036	○
Ni ₃ Ge	3.56	0.032	○
Co ₃ Ti	3.55	0.000	○
Co ₃ Ta	3.64	0.012	○
Co ₃ Al	3.67	0.010	○
Al ₃ Sc	4.09	0.000	○
Al ₃ Ti	3.98	0.020	○
Pt ₃ Al	3.90	0.000	○
Fe ₃ Pt	3.74	0.020	○
Ir ₃ Nb	3.87	0.000	○

Table 15: γ' 相候補 Top 10 (複合スコア S 順)。

順位	化合物	a (Å)	E_{hull}	B (GPa)	Δa	S
1	Cu ₃ Nb	3.56	0.004	218	0.01	0.878
2	Ni ₃ Al	3.572	0.000	180	0.002	0.878
3	Cu ₃ Ti	3.54	0.000	212	0.03	0.877
4	Co ₃ Ti	3.55	0.000	190	0.02	0.867
5	Ni ₃ Ti	3.40	0.000	195	0.17	0.812
6	Pt ₃ Al	3.90	0.000	230	0.33	0.801
7	Co ₃ Nb	3.68	0.000	205	0.11	0.798
8	Cu ₃ Ta	3.58	0.008	215	0.01	0.795
9	Fe ₃ Nb	3.96	0.000	198	0.39	0.785
10	Pd ₃ Ge	3.82	0.000	170	0.25	0.765

Cu₃Nb が Ni₃Al と同等の最高スコアを得た点は注目に値する。Cu₃Nb は格子整合性 ($\Delta a = 0.01 \text{ \AA}$) と高バルクモジュラス (218 GPa) を兼ね備え、Ni 基超合金の γ' 代替候補としてさらなる実験的検証に値する。

5.7.3. Ni₃Al 近傍格子定数候補

$|a - a_{\text{Ni}_3\text{Al}}| \leq 0.03 \text{ \AA}$ を満たす候補 10 件を抽出した。Cu₃Nb ($E_{\text{hull}} = 0.004$)、Cu₃Ta ($E_{\text{hull}} = 0.008$) は準安定であり、Co₃Ti ($E_{\text{hull}} = 0.0$)、Cu₃Ti ($E_{\text{hull}} = 0.0$) は安定相として確認された。これらは Ni₃Al との格子ミスマッチが小さく、析出強化の観点から有望な候補である。候補一覧は Supplementary S5 節に掲載する。

5.7.4. 安定 L1₂ 候補の抽出

$E_{\text{hull}} \leq 0.05 \text{ eV/atom}$ を満たす安定・準安定 L1₂ 候補 57 件 (安定 12 件、準安定 45 件) を抽出した。安定相のうち最も負の形成エネルギーを持つのは Pt₃Al ($E_f = -0.55 \text{ eV/atom}$) であり、次いで Al₃Sc (-0.50)、Co₃Ti (-0.45) が続く。詳細は Supplementary S6 節に掲載する。

5.7.5. 材料設計仮説の生成

探索結果から以下の材料設計仮説を導出した：

1. **Pt** ベース化合物の高安定性：Pt₃Al、Pt₃Ge 等の Pt ベース L1₂ 化合物は最も負の形成エネルギーを示し、熱力学的に極めて安定である。
2. **Cu** 系 γ' 候補の有望性：Cu₃Nb、Cu₃Ti、Cu₃Ta は格子整合性とバルクモジュラスのバランスが良く、Ni₃Al 代替候補として検討に値する。
3. **Co₃Ti** の **Ni₃Al** 代替可能性：Co₃Ti は安定相であり、格子定数が Ni₃Al に近く、Co 基超合金の γ' 相として既に研究されている。
4. **A** サイト元素依存性：遷移金属系 (Ni, Co, Fe, Cu, Pt) の A サイト元素は負の形成エネルギーを持つ安定 L1₂ を形成する傾向がある。
5. 格子定数と形成エネルギーの相関： $a > 4.0 \text{ \AA}$ の Al 基化合物 (Al₃Sc, Al₃Ti) は安定だが格子ミスマッチが大きく、析出強化には不向きである。

6. 考察

6.1. Schema Graph 制約の有効性

5 手法比較の結果 (表 9) から、以下の設計原則が導出される。

スキーマ情報注入が決定的。LLM-only (B1) の実行成功率 0% と Proposed (P) の 96% の対比は、材料データベースの専門的テーブル名に対して LLM の事前知識が無力であることを示す。スキーマ情報の提示方法が性能を支配する。

Schema Graph 走査によるテーブル幻覚排除。Proposed 手法がテーブル幻覚率 0% を達成した。Schema Graph 走査が提供する関連テーブルのみのサブグラフ提示が、テーブル幻覚を原理的に排除し、同時に不要 JOIN も削減する。Full Schema 手法 (21.0%) との精度差 (55.3pt) は、LLM に提示するテーブルの絞り込みが精度に直結することを示す。

実行精度の構造。Proposed 手法の実行精度 76.3% は Medium 89.2%、Very Hard 50.0% と難易度に依存する。これは Schema Graph 制約が JOIN 経路の正確性を保証する一方、WHERE 句の生成品質が LLM の能力に依存することを示す。4-hop クエリでも精度 68.8% を達成しており、Schema Graph 走査と LLM の役割分担が機能している。

6.2. 材料工学的考察

6.2.1. 既知化合物の完全再発見

11 件の既知 L1₂ 化合物の 100% 再発見 (表 14) は、データベース構築とクエリ変換パイプラインの内部整合性を検証する。特に Ni₃Al、Co₃Ti 等の γ' 相化合物が正しく抽出されることは、超合金材料探索ツールとしての基本的な信頼性を担保する。

6.2.2. γ' 候補の材料工学的妥当性

γ' 相候補ランキング (表 15) で Cu₃Nb が Ni₃Al と同等の最高スコア (0.878) を得た。Cu₃Nb は格子整合性 [42] ($\Delta a = 0.01 \text{ \AA}$)、準安定性 ($E_{\text{hull}} = 0.004 \text{ eV/atom}$)、高バルクモジュラス [43] (218 GPa) を兼ね備える。既知の Ni₃Al ($B = 180 \text{ GPa}$) を上回るバルクモジュラスは、機械的性質の観点で注目に値する。

一方、Ni₃Al 近傍格子定数候補 (表 ??) では、Co₃Ti ($\Delta a = 0.02 \text{ \AA}$ 、安定) が析出強化候補として最も現実的である。Co₃Ti は Co 基超合金の γ' 相として既に研究されており、本データベースからの抽出結果は既知の材料工学的知見と整合する。

6.3. 限界と制約

6.3.1. データベース規模

1,471 エントリ・5 プロトタイプの検証データベースは、本番規模の材料 DB (OQMD: ~30 テーブル・100 万件超) より小さい。30 テーブル・100 万件規模での検証は未実施であり、今後の課題である。

6.3.2. テストケースの自己参照性

80 件の回帰テストおよび 100 件の評価クエリはシステム開発者が設計したものであり、真の精度評価には材料研究者による自由文クエリのブラインドテストが必要である。

6.3.3. 実行精度の難易度依存性

Proposed 手法の実行精度 76.3% は Medium では 89.2% だが Very Hard では 50.0% に低下する。JOIN が深くなるほど WHERE 句の複雑性が増すため、LLM の生成能力が精度の上限を制約する。Few-shot 例の拡充、Self-correction、プロンプト改善が今後の方向性である。

6.3.4. seed data バイアス

1,471 エントリの seed データは第一原理計算に基づく推定値であり、実験的に合成・検証されたデータではない。形成エネルギーや格子定数の値は第一原理計算に基づく推定値であり、材料設計仮説の検証には実験的裏付けが必要である。

Table 16: 関連する材料 NLP / T2SQL / オントロジーシステムとの比較。

システム	スキーマ認識	正規化 RDB	材料特化	NL→クエリ	主な差異
Spider [12]	あり	あり	なし	SQL	汎用ベンチマーク
BIRD [13]	あり	あり	なし	SQL	大規模実データ
DAIL-SQL [14]	あり	あり	なし	SQL	スケルトン選択
RAT-SQL [19]	あり	あり	なし	SQL	関係認識符号化
RESDSQL [21]	あり	あり	なし	SQL	リンク分離
SchemaGraphSQL [23]	あり	あり	なし	SQL	パスファインディング
MKNA [28]	なし	なし	あり	API	エージェント
OptiMat [29]	なし	なし	あり	API	オンデマンド DFT
SuperCon [10]	あり	なし	あり	SPARQL	RDF オントロジー
PoLyInfo [11]	あり	なし	あり	SPARQL	BFO 準拠
EMMO [31]	あり	なし	あり	—	上位オントロジー
KG+OBQC [33]	あり	なし	なし	SPARQL	72%精度
本手法	あり	あり	あり	SQL	FK 走査 + L1 ₂ 辞書

6.4. 関連システムとの比較

6.5. AI for Science (AI₄S) における意義

本手法は AI₄S パラダイムに直接的な含意を持つ。Schema Graph アーキテクチャはスキーマ非依存であり、FK 関係は実行時に PostgreSQL メタデータからイントロスペクション (3.3 節) されるため、任意の正規化 RDB (Materials Project [5]、AFLOW [6]、NOMAD [7]、機関内データベース) にコード変更なしで展開可能である—用語辞書のドメイン適応のみが必要である。

とりわけ、Materials Integration (MInt) システム [44] における PSPP 連鎖の各モジュールが出力する RDB や、provenance 管理システム pinax [45] が蓄積する解析ワークフローデータベースは、本手法の自然な適用先として期待される。

L1₂ 探索で実証された Schema Graph 制約 → LLM SQL 生成 → 材料分析 (γ' 候補ランキング、格子整合性評価) の一連のフローは、NL → データ検索 → 材料設計仮説生成のエンドツーエンドパイプラインの原型を提供する。

6.6. 今後の展望

- マルチデータベース拡張: Schema Graph を Materials Project [5]、AFLOW [6] スキーマに適応。動的 FK イントロスペクションはアーキテクチャ上これを既にサポートする。
- AI₄S** エージェント統合: T2SQL 手法を自律材料探索エージェントのツールとして組み込み (MCP プロトコルや function calling 経由)、仮説 → データ検索 → 分析のエンドツーエンドパイプラインを実現。
- ブラインドユーザースタディ: 材料研究者から自由文クエリを収集し、テストケースの自己参照性問題を解消する。
- CALPHAD** 連携: Schema Graph 走査で RDB から候補を絞り込んだ後、CALPHAD の自由エネルギー計算により温度依存相安定性を判定する二段階フローを想定する。
- LLM** 能力向上との組合せ: gpt-5.5 での実行精度 76.3% は、Very Hard 難易度 (50.0%) に改善余地がある。Self-correction やプロンプト改善との組合せが期待される。
- 大規模データ検証: 10 万レコード以上での Steiner 木近似の計算性能検証が残る。

7. 結論

本研究では、Schema Graph 制約型 Text-to-SQL 手法を提案し、1,471 エントリ (5 プロトタイプ)・100 クエリの評価で検証した。主要な知見:

- テーブル幻覚率 **0%**かつ実行精度 **76.3%**: Schema Graph 走査 (Steiner 木近似) により LLM の視界を必要テーブルに限定し、テーブル幻覚の排除と不要 JOIN の削減を同時に達成。1,471 エントリ (L1₂+B2+NaCl+NiAs+BiF₃) で検証。
- FK** イントロスペクションによる汎用性: 任意の正規化材料 RDB (OQMD [3]、Materials Project [5]、AFLOW [6] 等) ヘコード変更なしで展開可能。用語辞書のドメイン適応のみが必要。
- L1₂** 化合物探索で材料工学的有用性を実証: 既知 L1₂ 11 件の全件再発見、Cu₃Nb を γ' 候補として発見。
- 評価指標の改善: 共通カラム照合 (+45.3pt) と LIMIT 10,000 正規化 (+22.6pt) により、T2SQL 評価における SELECT 列差異と LIMIT 切り詰めの影響を排除。
- 回帰テスト **80/80 PASS**: SQL インジェクション遮断、Intent 分類を含む安全性・頑健性テストに全件合格。

実証の限界: 検証は 1,471 エントリに限定される。Very Hard 精度は 50.0% であり、複合 WHERE 句の生成が今後の課題である。評価クエリは著者設計であり、独立した材料研究者によるブラインドテストが真の精度評価に必要である。

本手法は正規化 RDB 全般に対する Schema Graph 制約型 T2SQL の汎用フレームワークを提供し、マルチデータベース対応、大規模スキーマ検証、AI₄S エージェント統合、CALPHAD 連携への拡張が期待される。

謝辞

L1₂ 型金属間化合物の DFT 計算データは Open Quantum Materials Database (OQMD) の値を参考に構築した。OQMD の開発・維持管理にあたる Northwestern 大学 Wolverton グループに感謝する。本研究は NIMS の支援を受けた。

Data Availability

本研究で利用した検証データベース (5 プロトタイプ 1,471 エントリ) の seed データ、評価クエリ 100 件 (gold SQL・期待結果セット)、5 手法の実験結果 CSV、回帰テスト 80 件、ソースコード一式 (Schema Graph 走査エンジン・SQL ガード・条件抽出器・LLM モード)、および検証手順書 (VERIFICATION_GUIDE.md) は検証資料リポジトリに収録されている。

Author Contributions

Satoshi Minamoto : 研究構想、手法設計、ソフトウェア実装、データベース構築、実験実施、論文執筆。

Supplementary Materials

Supplementary Materials には以下を収録する : S1 回帰テストカテゴリ詳細、S2 回帰テストケース一覧 (全 44 件)、S3 生成 SQL 例 (LLM-only/Full Schema/Proposed 比較)、S4 SQL インジェクション・安全性テスト結果、S5 Ni₃Al 近傍格子定数候補、S6 安定 L1₂ 候補の抽出、S7 LLM モード設定。

References

- [1] H. Wang, T. Fu, Y. Du, W. Gao, K. Huang, Z. Liu, P. Chandak, S. Liu, P. Van Katwyk, A. Deac, A. Anandkumar, K. Bergen, C. P. Gomes, S. Ho, P. Kohli, J. Lasenby, J. Leskovec, T.-Y. Liu, A. Manber, D. Misra, E. Moret, J. Pineau, B. Poole, M. Sacks, S. SenGupta, J. Sun, J. Tang, A. Trischler, M. Welling, Y. Xie, M. Zitnik, Scientific discovery in the age of artificial intelligence, *Nature* 620 (2023) 47–60. doi:10.1038/s41586-023-06221-2.
- [2] L. Himanen, M. O. J. Geurts, A. S. Foster, P. Rinke, et al., Data-driven materials science: Status, challenges, and perspectives, *Adv. Sci.* 7 (2020) 1903667. doi:10.1002/advsc.201903667.
- [3] J. E. Saal, S. Kirklin, M. Aykol, B. Meredig, C. Wolverton, Materials design and discovery with high-throughput density functional theory: The Open Quantum Materials Database (OQMD), *JOM* 65 (2013) 1501–1509. doi:10.1007/s11837-013-0755-4.
- [4] S. Kirklin, J. E. Saal, B. Meredig, A. Thompson, J. W. Doak, M. Aykol, S. Rühl, C. Wolverton, The Open Quantum Materials Database (OQMD): Assessing the accuracy of DFT formation energies, *npj Comput. Mater.* 1 (2015) 15010. doi:10.1038/npjcompumats.2015.10.
- [5] A. Jain, S. P. Ong, G. Hautier, W. Chen, W. D. Richards, S. Dacek, S. Cholia, D. Gunter, D. Skinner, G. Ceder, K. A. Persson, Commentary: The Materials Project: A materials genome approach to accelerating materials innovation, *APL Mater.* 1 (2013) 011002. doi:10.1063/1.4812323.
- [6] S. Curtarolo, W. Setyawan, G. L. W. Hart, M. Jahnatek, R. V. Chepulskii, R. H. Taylor, S. Wang, J. Xue, K. Yang, O. Levy, M. J. Mehl, H. T. Stokes, D. O. Demchenko, D. Morgan, AFLOW: An automatic framework for high-throughput materials discovery, *Comput. Mater. Sci.* 58 (2012) 218–226. doi:10.1016/j.commatsci.2012.02.005.
- [7] C. Draxl, M. Scheffler, NOMAD: The FAIR concept for big data-driven materials science, *MRS Bull.* 43 (2018) 676–682. doi:10.1557/mrs.2018.208.
- [8] O. N. Senkov, D. B. Miracle, K. J. Chaput, J.-P. Couzinie, Development and exploration of refractory high entropy alloys — A review, *J. Mater. Res.* 33 (2018) 3092–3128. doi:10.1557/jmr.2018.153.
- [9] E. P. George, D. Raabe, R. O. Ritchie, High-entropy alloys, *Nat. Rev. Mater.* 4 (2019) 515–534. doi:10.1038/s41578-019-0121-4.
- [10] M. Ishii, K. Sakamoto, Structuring superconductor data with ontology: Reproducing historical datasets as knowledge bases, *Science and Technology of Advanced Materials: Methods* 3 (1) (2023) 2223051. doi:10.1080/27660400.2023.2223051.
- [11] M. Ishii, T. Ito, K. Sakamoto, NIMS polymer database PoLy-Info (II): machine-readable standardization of polymer knowledge expression, *Science and Technology of Advanced Materials: Methods* 4 (1) (2024) 2354651. doi:10.1080/27660400.2024.2354651.
- [12] T. Yu, R. Zhang, K. Yang, M. Yasunaga, D. Wang, Z. Li, J. Ma, I. Li, Q. Yao, S. Roman, Z. Zhang, D. Radev, Spider: A large-scale human-labeled dataset for complex and cross-domain semantic parsing and text-to-SQL task, in: *Proceedings of EMNLP*, 2018, pp. 3911–3921.
- [13] J. Li, B. Hui, G. Qu, J. Yang, B. Li, B. Li, B. Wang, B. Qin, R. Geng, N. Huo, et al., Can LLM already serve as a database interface? A Blg Bench for Large-Scale Database Grounded Text-to-SQL (BIRD), *Advances in Neural Information Processing Systems* 36 (2024).
- [14] D. Gao, H. Wang, Y. Li, X. Sun, Y. Qian, B. Ding, J. Zhou, Text-to-SQL empowered by large language models: A benchmark evaluation, *arXiv preprint arXiv:2308.15363* (2023).
- [15] M. Pourreza, D. Rafiei, DIN-SQL: Decomposed in-context learning of text-to-SQL with self-correction, in: *Advances in Neural Information Processing Systems*, Vol. 36, 2024.
- [16] Y. Gao, Y. Liu, X. Li, X. Shi, Y. Zhu, Y. Wang, S. Li, W. Li, Y. Hong, Z. Luo, J. Gao, L. Mou, Y. Li, XiYan-SQL: A multi-generator ensemble framework for text-to-SQL, *arXiv preprint arXiv:2411.08599* (2024).
- [17] Z. Hong, Z. Yuan, Q. Zhang, H. Chen, J. Dong, F. Huang, X. Huang, Next-generation database interfaces: A survey of LLM-based text-to-SQL, *arXiv preprint arXiv:2406.08426* (2024).
- [18] K. Maamari, F. Abubaker, D. Jaroslawicz, A. Mhedhbi, The death of schema linking? text-to-SQL in the age of well-reasoned language models, *arXiv preprint arXiv:2408.07702* (2024).
- [19] B. Wang, R. Shin, X. Liu, O. Polozov, M. Richardson, RAT-SQL: Relation-aware schema encoding and linking for text-to-SQL parsers, in: *Proceedings of the 58th Annual Meeting of the ACL*, 2020, pp. 7567–7578.
- [20] Z. Chen, L. Chen, Y. Zhao, R. Cao, Z. Xu, S. Zhu, K. Yu, ShadowGNN: Graph projection neural network for text-to-SQL parser, in: *Proceedings of the 2021 Conference of the North American Chapter of the ACL*, 2021, pp. 5567–5577.
- [21] H. Li, J. Zhang, C. Li, H. Chen, RESDSQL: Decoupling schema linking and skeleton parsing for text-to-SQL, in: *Proceedings of the AAAI Conference on Artificial Intelligence*, Vol. 37, 2023, pp. 13067–13075. doi:10.1609/aaai.v37i11.26535.
- [22] X. V. Lin, R. Socher, C. Xiong, Bridging textual and tabular data for cross-domain text-to-SQL semantic parsing, in: *Findings of the Association for Computational Linguistics: EMNLP 2020*, 2020, pp. 4870–4888.
- [23] A. Safdarian, M. Mohammadi, E. Jahanbakhsh, M. Shahamat Naderi, H. Faili, SchemaGraphSQL: Efficient schema linking with pathfinding graph algorithms for text-to-SQL on large-scale databases, in: *Findings of the Association for Computational Linguistics: EACL 2026*, 2026, pp. 2585–2599. doi:10.18653/v1/2026.findings-eacl.134.
- [24] T. D. Hoang, T. T. Nguyen, T. T. Huynh, H. Yin, Q. V. H. Nguyen, Scaling Text2SQL via LLM-efficient schema filtering with functional dependency graph rerankers, *arXiv preprint arXiv:2512.16083* (2025).
- [25] D. McMillan, Structured context engineering for file-native agentic systems: Evaluating schema accuracy, format effectiveness, and multi-file navigation at scale, *arXiv preprint arXiv:2602.05447* (2026).
- [26] Y. Song, S. Miret, B. Liu, MatSci-NLP: Evaluating scientific

- language models on materials science language tasks using text-to-schema modeling, in: Proceedings of the 61st Annual Meeting of the ACL, 2023, pp. 3621–3639.
- [27] V. Mishra, S. Singh, M. Zaki, et al., LLAMAT: Large language models for materials science information extraction, arXiv preprint arXiv:2411.00177 (2024).
 - [28] G. Zhuang, A. B. Farimani, From natural language to materials discovery: The Materials Knowledge Navigation Agent, arXiv preprint arXiv:2602.11123 (2026).
 - [29] Y. Hu, V. Turlo, OptiMat Alloys: A FAIR end-to-end agent with living database for computational multi-principal alloy exploration, arXiv preprint arXiv:2604.21850 (2026).
 - [30] B. Debrah, [Materials Project MCP Server](https://www.pulsemcp.com/servers/benedictdebrah-materials-project), model Context Protocol integration for Materials Project database (2025).
URL <https://www.pulsemcp.com/servers/benedictdebrah-materials-project>
 - [31] EMMC-CSA Consortium, [Elementary multiperspective material ontology \(EMMO\)](https://github.com/emmo-repo/EMMO), version 1.0.0, CC BY 4.0 (2020).
URL <https://github.com/emmo-repo/EMMO>
 - [32] J. F. Sequeda, D. Allemang, B. Jacob, A benchmark to understand the role of knowledge graphs on large language model’s accuracy for question answering on enterprise SQL databases, in: Proceedings of the 7th Joint Workshop on Graph Data Management Experiences & Systems (GRADES) and Network Data Analytics (NDA), ACM, 2024. doi:10.1145/3661304.3661901.
 - [33] D. Allemang, J. F. Sequeda, Increasing the LLM accuracy for question answering: Ontologies to the rescue!, arXiv preprint arXiv:2405.11706 (2024).
 - [34] P. Villars, K. Cenzual, J. Daams, R. Gladyshevskii, Crystal structures of inorganic compounds, Landolt-Börnstein – Numerical Data and Functional Relationships in Science and Technology (2004).
 - [35] A. A. Hagberg, D. A. Schult, P. J. Swart, Exploring network structure, dynamics, and function using NetworkX, proceedings of the 7th Python in Science Conference (SciPy) (2008).
 - [36] F. K. Hwang, D. S. Richards, P. Winter, The Steiner Tree Problem, North-Holland, 1992.
 - [37] P. Lewis, E. Perez, A. Piktus, F. Petroni, V. Karpukhin, N. Goyal, H. Küttler, M. Lewis, W.-t. Yih, T. Rocktäschel, et al., Retrieval-augmented generation for knowledge-intensive NLP tasks, Advances in Neural Information Processing Systems 33 (2020) 9459–9474.
 - [38] T. B. Brown, B. Mann, N. Ryder, et al., Language models are few-shot learners, Advances in Neural Information Processing Systems 33 (2020) 1877–1901.
 - [39] G. Salton, C. Buckley, Term-weighting approaches in automatic text retrieval, Inf. Process. Manage. 24 (1988) 513–523. doi:10.1016/0306-4573(88)90021-0.
 - [40] T. Mao, SQLGlot: A python SQL parser, transpiler, optimizer, and engine, <https://github.com/tobymao/sqlglot> (2023).
 - [41] P. Jaccard, The distribution of the flora in the alpine zone, New Phytologist 11 (2) (1912) 37–50. doi:10.1111/j.1469-8137.1912.tb05611.x.
 - [42] L. Vegard, Die Konstitution der Mischkristalle und die Raumfüllung der Atome, Z. Phys. 5 (1921) 17–26.
 - [43] H. W. King, Quantitative size-factors for metallic solid solutions, J. Mater. Sci. 1 (1966) 79–90.
 - [44] S. Minamoto, T. Kadohira, K. Ito, M. Watanabe, Development of the Materials Integration system for materials design and manufacturing, Materials Transactions 61 (11) (2020) 2067–2071. doi:10.2320/matertrans.MT-MA2020002.
 - [45] S. Minamoto, T. Kadohira, J. Fujima, Y. Fujiwara, A. Endo, C. Suematsu, K. Daimaru, H. Izuno, J. Sakurai, M. Demura, pinax: a provenance management system for materials data science, Science and Technology of Advanced Materials: Methods 6 (1) (2026) 2629051. doi:10.1080/27660400.2026.2629051.